

Нелинейная динамика и управление нейронными сетями в искусственном интеллекте

конспект лекций

Предисловие

Это конспект лекций по курсу «Нелинейная динамика и управление нейронными сетями в искусственном интеллекте», прочитанному в осеннем семестре 2025 года Мокаевым Тимуром Назировичем для бакалавров 4 курса программы «Прикладная математика, программирование и искусственный интеллект» и магистров 2 курса «Математического моделирования, программирования и искусственного интеллекта» Санкт-Петербургского государственного университета. Текст был набран студентами по оригинальным презентациям с занятий, изначально подготовленным на английском языке, и исходным статьям (см. список в конце), поэтому может содержать опечатки и не совсем удачные переводы англоязычных терминов, для которых не был найден устоявшийся русский аналог, а также стилистически отличаться от темы к теме. TeX-файлы находятся в открытом доступе на GitHub.

Содержание

1 Биологические и искусственные нейроны. Исторический контекст искусственных нейронных сетей	4
1.1 Основные понятия: биологический нейрон, синапсы, простейшие модели . . .	4
1.2 Переход от биологических нейронных сетей к искусственным	4
1.3 Первая постановка задачи об аппроксимации и обучении сетей	4
1.4 Модель перцептрона	5
1.5 Основные функции активации	6
1.6 Простейшие нейронные сети	7
2 Функциональные пространства и универсальная аппроксимация	10
2.1 Метрические пространства, нормы, банаховы пространства	10
2.2 Зачем функциональные пространства в теории ИНС и УА	11
2.3 N-функции, модуль и норма Люксембурга	14
2.4 Пространства Орлича	15
2.5 Обобщённые (Musielak–Orlicz) пространства Орлича	15
2.6 Определения и базовые свойства пространств $L^{p(\cdot)}$	15
2.7 Дуальность и вложения (случай ограниченного показателя)	19
2.8 Неограниченные показатели: фактор-пространство и нормы	24
2.9 Идея «переменного» показателя и связи с задачами ИНС	27
3 Классические теоремы об универсальной аппроксимации для функций в C и L^p	28
3.1 Универсальная аппроксимация в метрическом/банаховом пространстве . . .	28
3.2 Классические теоремы для $C(K)$	28
3.3 Понятие discriminatory/non-polynomial активации	30
3.4 УА на $C(\mathbb{R}^n)$ с метрикой Фреше, связь с компактными множествами	30
3.5 Теорема Хорника (1991): универсальная аппроксимация в $L^p(\mu)$	31
3.6 Гладкая аппроксимация (Хорник–Стинчкомб–Уайт, 1990)	33
3.7 Теорема Лешно–Лин–Пинкуса–Шоккена (1993)	35
3.8 Сравнительный анализ условий на активационные функции	37
3.9 Заключительные наблюдения	37

4	Универсальная аппроксимация для нелинейных операторов	38
4.1	Предварительные сведения: компактность, функции Таубера–Винера и аппроксимации	38
4.2	Критерий «TW $\Leftrightarrow$ неполиномиальность» в $\mathcal{S}'(\mathbb{R})$	41
4.3	Равномерная универсальная аппроксимация наборов функций	42
4.4	Универсальная аппроксимация для нелинейных функционалов	45
4.5	Связь динамических систем и аппроксимации нелинейных функционалов	47
4.6	Универсальная аппроксимация операторов	49
4.7	Взгляд с точки зрения динамических систем и сдвиги	51
4.8	Устойчивость относительно потоков, робастность аппроксимаций	53
4.9	Идентификация динамических систем через теорему об аппроксимации операторов	53
5	Generalized Translation Networks и их применение к задачам идентификации и управления	56
5.1	Модель GTN и предварительные сведения	56
5.2	Почти оптимальная универсальная аппроксимация функционалов на L^p	59
5.3	Нелинейная N -ширина и нижние оценки на размер	61
5.4	Четыре классические динамические модели (Нарендра и Партасарати) для идентификации и управления	62
5.5	Представление моделей как частных случаев GTN	63
5.6	Идея замыкания контура обратной связи, замечания про устойчивость и штрафы на основе якобиана/ISS	63
5.7	Обучающие протоколы и связь с операторным подходом Чен–Чена	64
6	Функциональный многослойный перцептрон (FMLP)	66
6.1	Введение в функциональные данные: функции как объекты	66
6.2	Функциональные нейроны, архитектура FMLP и связь с обычными MLP	66
6.3	Основная УАТ для FMLP (на L^p , L^1 , произведениях функциональных пространств)	67
6.4	Сопоставление с результатами лекций 1–4 (классические УАТ, GTN, операторные сети)	72
6.5	Постановка задачи обучения FMLP	72
6.6	Практическая реализация: дискретизация, выбор базиса, регуляризация	74
6.7	Интерпретация FMLP как функциональной надстройки над моделями I–IV	75
6.8	Применение к идентификации и управлению динамическими системами	75
7	Deep Operator Networks (DeepONets) и роль глубины и ширины	77
7.1	Асимптотические обозначения: $O(\cdot)$ и $\Theta(\cdot)$	78
7.2	Разделение по глубине (Тельгарский)	79
7.3	Достаточность ограниченной ширины (Ханин)	80
7.4	От операторных сетей к DeepONets	81
7.5	Определение и декомпозиция ошибки DeepONet	83
7.6	Измеримая УАТ для DeepONet	84
7.7	«Upper bound program»: получения верхних оценок	85
7.8	Применение к динамическим системам: от временных рядов к операторам	85
7.9	ISO/BIBO-ориентированная регуляризация	87

8	Глубокое обучение через призму динамических систем	88
8.1	Введение и предварительные сведения	88
8.2	Структурные понятия и основная теорема об универсальной аппроксимации	89
8.3	Одномерный случай и его особенности	91
8.4	Технические основы: свойства потоков и достижимые множества	92
8.5	Многомерный случай ($n \geq 2$): преодоление ограничений	98
8.6	Семейства тензорных произведений и сравнение с классической теорией	102
8.7	Следствия для глубоких сетей и связь с теорией управления	102
9	Универсальная аппроксимация свёрточными сетями	104
9.1	Три взгляда на универсальную аппроксимацию глубокими свёрточными сетями	104
9.1.1	Модель Яроцкого: приближение инвариантных и эквивариантных отображений	104
9.1.2	Стандартная модель Чжоу: пространство гипотез и универсальность	112
9.1.3	Подход Ли-Лин-Шеня: универсальность полносвязных свёрточных сетей для сдвиг-инвариантных функций	116
9.2	Глубокие распределённые свёрточные сети	123
9.3	Распределённые свёрточные сети и операторное обучение	130
9.4	Основы RKHS: ядра как скалярные произведения (минимальный инструментарий)	133
9.5	Подход Бьетти–Майраль: ядерное представление свёрточных архитектур	134
9.6	Инвариантность и устойчивость в ядерном представлении	136
9.7	Связь спектральной нормы и регуляризации	138
9.8	Информационная сохранность и субдискретизация	140
	Список литературы	142

1 Биологические и искусственные нейроны. Исторический контекст искусственных нейронных сетей

1.1 Основные понятия: биологический нейрон, синапсы, простейшие модели

Человеческий мозг содержит примерно $8,6 \times 10^{10}$ специальных клеток — нейронов. Каждый нейрон состоит из:

- тела клетки (сомы),
- множества дендритов (входы),
- одного аксона (выход).




Рис. 1: Схематическое изображение биологического нейрона

Связь между нейронами осуществляется через **синапсы**: электрический импульс (потенциал действия ≈ 100 мВ) вызывает химическую передачу сигнала (время ≈ 1 мс). Ключевой принцип — **закон «всё или ничего»** (Bowditch, 1871): отклик бинарный относительно порога; рефрактерный период ограничивает частоту.

1.2 Переход от биологических нейронных сетей к искусственным

Искусственные нейронные сети (ИНС) — это вычислительные модели, вдохновлённые биологическими нейронными связями и изначально создаваемые для воссоздания человеческого мышления при решении задач. Сегодня спектр их применения расширился: компьютерное зрение, синтез и обработка речи, переводы на другой язык, обработка медицинских данных, поведение персонажей в играх и многое другое. Более формально это параметрическое семейство функций, полученных из простых вычислительных единиц (нейронов), сигнал между которыми передаётся с неким весом, и обученное на наборе данных. Абстракция биологических принципов привела к модели **перцептрона** (подробное описание далее).

1.3 Первая постановка задачи об аппроксимации и обучении сетей

Перцептрон (Rosenblatt, 1957) — первая модель с правилом обучения: веса корректируются на основе ошибок классификации. Он реализует линейный классификатор и может различать только линейно separable множества.

Определение (Линейно separable множества). Множества $A, B \subset \mathbb{R}^n$ *линейно separable*, если существуют такие $w \in \mathbb{R}^n$ и $b \in \mathbb{R}$, что

$$\langle w, x \rangle + b > 0 \quad \forall x \in A, \quad \langle w, x \rangle + b < 0 \quad \forall x \in B.$$

Замечание. Перцептрон не может решить нелинейные задачи (например, представить XOR).

Для преодоления этого ограничения вводятся многослойные сети с нелинейными функциями активации. В итоге у нас получается много параметров, которые нужно каким-то образом определить, ставится **задача обучения**: для набора данных $\{(x_i, y_i)\}_{i=1}^N$ найти веса сети, минимизирующие функцию потерь, например, среднеквадратичную ошибку:

$$MSE(w) = \frac{1}{N} \sum_{i=1}^N \|y(x_i; w) - y_i\|^2$$

Другая интересующая нас проблема — **задача аппроксимации**: найти условия, при которых нейронные сети с одним скрытым слоем могут аппроксимировать любую непрерывную функцию на компакте в пространстве $C(K)$ или в L^p пространствах.

1.4 Модель перцептрона

Обратимся подробнее к устройству перцептрона. Он, подобно биологическому нейрону состоит из следующих компонент:

- Входных данных $x_1, \dots, x_n \in \mathbb{R}$ (синаптических сигналов), действие которых обусловлено переменными весами $w_1, \dots, w_n \in \mathbb{R}$ (синаптические силы).
- Мембранного потенциала (аффинная преактивационная функция):

$$V(x) = \sum_{i=1}^n w_i x_i + b = \langle w, x \rangle + b,$$

где b — смещение. Оно может быть представлено в качестве веса w_0 с введением дополнительного входа $x_0 = 1$.

- Активационной функции («всё или ничего», функция Хевисайда):

$$\sigma(V) = \begin{cases} 1, & V > 0, \\ 0, & V \leq 0. \end{cases}$$

На рисунке ниже приведена его схема. Геометрический смысл модели: граница принятия




Рис. 2: Модель перцептрона

решений $\{x: \langle w, x \rangle + b = 0\}$ является гиперплоскостью, выходные данные разделяют $\mathbb{R}^n$ на два замкнутых полупространства.

Нетрудно обобщить понятие перцептрона, определив просто искусственный нейрон.

Определение (Искусственный нейрон). Это отображение $x \mapsto \sigma(\langle w, x \rangle + b)$ с функцией активации $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ (не обязательно разрывной), весами $w \in \mathbb{R}^d$ и смещением $b \in \mathbb{R}$.

Определение (Ridge-функция). Когда мы обозначаем смещение b через w_0 , определяем константу $x_0 = 1$, функция преактивации принимает вид:

$$\langle w, x \rangle + b = \sum_{i=0}^n w_i x_i.$$

Результат можно рассматривать как функцию от $x \in \mathbb{R}^{n+1}$ вида $x \mapsto \sigma(x \cdot w)$, где $\sigma: \mathbb{R} \rightarrow \mathbb{R}$, а $x \cdot w$ — евклидово скалярное произведение двух векторов. Такая функция в контексте теории аппроксимации называется *гребневой регрессией* (*ridge-функцией*). Такие функции обладают тем свойством, что они всегда постоянны на гиперплоскостях:

$$x \cdot w = c, \quad c \in \mathbb{R}.$$

1.5 Основные функции активации

Для обобщения модели перцептрона, функция активации Хевисайда заменяется на другие. Ниже представлены каноничные функции активации, начиная с самой функции Хевисайда.

- *Функция Хевисайда* (Рис. 3а) — это разрывная функция на множестве вещественных чисел $\mathbb{R}$, определяется как

$$\sigma(x) = \begin{cases} 1, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

- *Функция знака* (Рис. 3б) — это кусочно-определенная функция на множестве вещественных чисел $\mathbb{R}$:

$$\sigma(x) = \text{sgn}(x) = \begin{cases} 1, & x \geq 0, \\ -1, & x < 0. \end{cases}$$

- *ReLU функция* (Рис. 3с) — это кусочно-определенная функция на множестве вещественных чисел $\mathbb{R}$:

$$\sigma(x) = \max\{0, x\} = \begin{cases} x, & x > 0, \\ 0, & x \leq 0. \end{cases}$$




Рис. 3: Кусочно-линейные функции активации




Рис. 4: Логистическая сигмоида

- Логистическая сигмоида (Рис. 4) является гладким аналогом функции Хевисайда и задается формулой $\sigma(x) = \frac{1}{1+e^{-x}}$.
- Функция гиперболического тангенса (Рис. 5) является аффинно-преобразованной сигмоидой и задается формулой $\sigma(x) = \text{th}(x)$.




Рис. 5: Функция гиперболического тангенса

Замечания.

- Гладкие функции активации позволяют использовать методы обучения, основанные на градиенте; кусочно-линейная (функция ReLU) позволяет использовать разреженные градиенты и эффективную оптимизацию.
- Ступенчатые/знаковые функции естественны с биологической точки зрения (пороговое значение), но не дифференцируемы, что осложняет градиентное обучение.
- Гладкие функции активации (логистическая сигмоида и гиперболический тангенс) позволяют использовать классическое обратное распространение ошибки, а кусочно-линейные (ReLU) больше используются в современной практике.

1.6 Простейшие нейронные сети

Для перехода от отдельных нейронов к нейронным сетям требуются такие компоненты, как:

- Набор вычислительных единиц — *нейронов*;
- Веса связей $w_{ij} \in \mathbb{R}$, определяющие влияние сигнала от единицы i на единицу j ;
- Правило распространения, описывающая преобразование входных сигналов внутри нейрона (например, в случае перцептрона использовалась функция V);
- Функция активации $\sigma: \mathbb{R} \rightarrow \mathbb{R}$;

- *Правило обучения* (подбора весов);
- *Окружение* (с учетом входящих данных и ошибок).

Одним из простейших примеров будет сеть прямого распространения (feedforward), её структура состоит из трех видов узлов (слоёв):

- **Входные узлы:** Эти узлы передают информацию из окружения в сеть, составляя *входной слой*. На входном слое не происходит вычислений, его цель передать информацию в следующие слои.
- **Скрытые узлы:** Эти узлы не имеют прямого взаимодействия со средой, поэтому и называются скрытыми. Они служат как для проведения вычислений, так и для передачи информации из входного слоя в выходной слой. Совокупность этих узлов составляет *скрытый слой*.
- **Выходные узлы:** Эти узлы отвечают за вычисления и передачу информации из сети в окружение, составляя из себя *выходной слой*.

Замечание. Сети прямого распространения имеют только по одному входному и выходному слою, однако они могут содержать как ноль, так и несколько скрытых слоев. Кроме того, движение в одном направлении исключает возможность появления циклов и петель.

Определение (Многослойный перцептрон с одним скрытым слоем). Получая на вход совокупность $x = (x_1, \dots, x_D) \in \mathbb{R}^D$, строим M линейных комбинаций входных переменных:

$$a_j = \sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)}, \quad j = 1, \dots, M.$$

(1) в данном случае обозначает то, что это первый слой сети. Далее каждая из этих комбинаций преобразуется с использованием дифференцируемой нелинейной функции активации $\sigma_1: \mathbb{R} \rightarrow \mathbb{R}$, получаем:

$$z_j = \sigma_1(a_j).$$

Эти величины уже находятся на уровне скрытых узлов, а функция активации, как правило, выбирается сигмоидальной. На следующем шаге получаем выходы, показанные ниже:

$$b_k = \sum_{j=1}^M w_{kj}^{(2)} z_j + w_{k0}^{(2)}, \quad k = 1, \dots, K,$$

где K — это общее количество выходов. Когда скрытый слой всего один (как в этом случае), выходы нейронной сети получаются следующими:

$$y_k = \sigma_2(b_k) \quad \sigma_2: \mathbb{R} \rightarrow \mathbb{R} \text{ — другая функция активации.}$$

Обобщенная формула выходных данных имеет вид:

$$y(x, w) = \sigma_2 \left(\sum_{j=1}^M w_{kj}^{(2)} \sigma_1 \left(\sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)} \right) + w_{k0}^{(2)} \right).$$

Упрощенная форма же (с $x_0 = 1$ и включенными смещениями):

$$y(x, w) = \sigma_2 \left(\sum_{j=0}^M w_{kj}^{(2)} \sigma_1 \left(\sum_{i=0}^D w_{ji}^{(1)} x_i \right) \right)$$

При линейном выходе ($\sigma_2(t) = t$) получаем линейную комбинацию ridge-функций, где α_j — это веса, появляющиеся в соединениях между скрытым и выходным слоями:

$$y(x, w) = \sum_{j=0}^M \alpha_j \sigma(\langle w_j \cdot x_i \rangle + b_j).$$

Визуализировать это определение можно следующей картинкой:




Рис. 6: Многослойный перцептрон с одним скрытым слоем

2 Функциональные пространства и универсальная аппроксимация

2.1 Метрические пространства, нормы, банаховы пространства

Определение (Метрическое пространство). Пусть X — произвольное множество. Функция $d : X \times X \rightarrow \mathbb{R}$ называется **метрикой** на X , если для любых элементов $x, y, z \in X$ выполняются условия:

1. $d(x, y) \geq 0$ (неотрицательность),
2. $d(x, y) = 0 \iff x = y$ (тождественность неразличимых),
3. $d(x, y) = d(y, x)$ (симметричность),
4. $d(x, y) \leq d(x, z) + d(z, y)$ (неравенство треугольника).

Пара (X, d) называется **метрическим пространством**.

Определение (Нормированное пространство). Пусть X — векторное пространство над $\mathbb{R}$. Функция $\|\cdot\| : X \rightarrow \mathbb{R}$ называется **нормой** на X , если для любых $x, y \in X$ и $\lambda \in \mathbb{R}$ выполняются:

1. $\|x\| \geq 0$, причём $\|x\| = 0 \iff x = 0$ (положительная определённость),
2. $\|\lambda x\| = |\lambda| \|x\|$ (однородность),
3. $\|x + y\| \leq \|x\| + \|y\|$ (неравенство треугольника).

Пара $(X, \|\cdot\|)$ называется **нормированным пространством**. Норма индуцирует метрику: $d(x, y) = \|x - y\|$.

Определение (Банахово пространство). Нормированное пространство $(X, \|\cdot\|)$ называется **банаховым**, если оно полно относительно индуцированной метрики, т.е. любая последовательность Коши в X сходится к элементу из X .

Примеры нормированных пространств:

- $C(K)$ — пространство непрерывных функций на компакте $K \subset \mathbb{R}^n$ с равномерной нормой

$$\|f\|_{\infty} = \sup_{x \in K} |f(x)|.$$

- $L^p(\mathbb{R}^n)$ — пространство измеримых функций с конечной нормой

$$\|f\|_p = \left(\int_{\mathbb{R}^n} |f(x)|^p dx \right)^{1/p}, \quad 1 \leq p < \infty.$$

- $L^{\infty}(\mathbb{R}^n)$ — пространство существенно ограниченных функций с нормой

$$\|f\|_{\infty} = \operatorname{ess\,sup}_{x \in \mathbb{R}^n} |f(x)| = \inf \{C \geq 0 : |f(x)| \leq C \text{ почти всюду}\}.$$

- $L^1_{\text{loc}}(\mathbb{R}^n)$ — пространство локально интегрируемых функций, для которых

$$\int_K |f(x)| dx < \infty \quad \text{для любого компакта } K \subset \mathbb{R}^n.$$

Это пространство не является нормированным, но метризуемо (например, метрикой $d(f, g) = \sum_{k=1}^{\infty} 2^{-k} \frac{\|f-g\|_{L^1(B_k)}}{1+\|f-g\|_{L^1(B_k)}}$, где B_k — шар радиуса k).

2.2 Зачем функциональные пространства в теории ИНС и УА

Нейронные сети приближают **функции** и **операторы** между функциональными пространствами. Для точной формулировки теорем универсальной аппроксимации (УА), устойчивости и оценки погрешности необходимы:

- Строго определённые пространства (метрические, нормированные, банаховы),
- Нормы и двойственные пространства,
- Инструменты функционального анализа (теоремы Лебега, Хана–Банаха, Рисса–Маркова–Какутани, преобразование Фурье).

Напомним определения и теоремы из курсов математического и функционального анализа:

Определение (Полунорма). Функция $p: X \rightarrow \mathbb{R}$ на векторном пространстве X называется **полунормой**, если для всех $x, y \in X$ и $\lambda \in \mathbb{R}$:

1. $p(x) \geq 0$ (неотрицательность),
2. $p(\lambda x) = |\lambda|p(x)$ (однородность),
3. $p(x + y) \leq p(x) + p(y)$ (неравенство треугольника).

Отличие от нормы: из $p(x) = 0$ не следует $x = 0$.

Определение (Борелевская мера). Пусть X — топологическое пространство. Мера μ , определённая на **борелевской σ -алгебре** (наименьшей σ -алгебре, содержащей все открытые множества), называется **борелевской мерой**.

Определение (Регулярная борелевская мера). Борелевская мера μ на локально компактном хаусдорфовом пространстве X называется **регулярной**, если имеются:

1. **Внутренняя регулярность:** Для любого борелевского множества $E \subset X$,

$$\mu(E) = \sup\{\mu(K) : K \subset E, K \text{ компакт}\}.$$

2. **Внешняя регулярность:** Для любого борелевского множества $E \subset X$,

$$\mu(E) = \inf\{\mu(U) : E \subset U, U \text{ открыто}\}.$$

Определение (Топологическое двойственное пространство). Пусть X — топологическое векторное пространство. **Двойственное (сопряжённое) пространство** X^* — это множество всех непрерывных линейных функционалов $f: X \rightarrow \mathbb{R}$. Если X — нормированное пространство, то X^* снабжается нормой

$$\|f\|_{X^*} = \sup_{\|x\|_X \leq 1} |f(x)|.$$

Определение (Преобразование Фурье в $L^1(\mathbb{R}^n)$). Для функции $f \in L^1(\mathbb{R}^n)$ её **преобразование Фурье** определяется как

$$\hat{f}(\xi) = \mathcal{F}[f](\xi) = \int_{\mathbb{R}^n} f(x) e^{-2\pi i \xi \cdot x} dx, \quad \xi \in \mathbb{R}^n.$$

При этом $\hat{f} \in L^\infty(\mathbb{R}^n)$ и $\|\hat{f}\|_\infty \leq \|f\|_1$.

Определение (Преобразование Фурье в $L^2(\mathbb{R}^n)$). Для $f \in L^2(\mathbb{R}^n)$ преобразование Фурье можно определить как предел в L^2 -норме:

$$\hat{f}(\xi) = \lim_{R \rightarrow \infty} \int_{|x| \leq R} f(x) e^{-2\pi i \xi \cdot x} dx.$$

Оператор $\mathcal{F}: L^2(\mathbb{R}^n) \rightarrow L^2(\mathbb{R}^n)$ является унитарным (сохраняет L^2 -норму).

Определение (Преобразование Фурье меры). Для конечной комплекснозначной борелевской меры μ на $\mathbb{R}^n$ её **преобразование Фурье** (характеристическая функция) определяется как

$$\hat{\mu}(\xi) = \int_{\mathbb{R}^n} e^{-2\pi i \xi \cdot x} d\mu(x).$$

Теорема 2.1 (Обращение преобразования Фурье). Если $f, \hat{f} \in L^1(\mathbb{R}^n)$, то справедлива формула обращения:

$$f(x) = \int_{\mathbb{R}^n} \hat{f}(\xi) e^{2\pi i \xi \cdot x} d\xi \quad \text{н.в.}$$

Теорема 2.2 (Свойства преобразования Фурье). Пусть $f, g \in L^1(\mathbb{R}^n)$. Тогда:

1. **Линейность:** $\mathcal{F}[\alpha f + \beta g] = \alpha \hat{f} + \beta \hat{g}$.
2. **Сдвиг:** если $g(x) = f(x - a)$, то $\hat{g}(\xi) = e^{-2\pi i a \cdot \xi} \hat{f}(\xi)$.
3. **Модуляция:** если $g(x) = e^{2\pi i a \cdot x} f(x)$, то $\hat{g}(\xi) = \hat{f}(\xi - a)$.
4. **Дифференцирование:** если $\partial_{x_j} f \in L^1$, то $\widehat{\partial_{x_j} f}(\xi) = 2\pi i \xi_j \hat{f}(\xi)$.

Теорема 2.3 (Хана–Банаха, аналитическая форма). Пусть X — вещественное векторное пространство, p — полунорма на X , L — линейное подпространство, $f: L \rightarrow \mathbb{R}$ — линейный функционал, удовлетворяющий $|f(x)| \leq p(x)$ для всех $x \in L$. Тогда существует линейный функционал $F: X \rightarrow \mathbb{R}$, продолжающий f с сохранением подчинённости полунорме: $|F(x)| \leq p(x)$ для всех $x \in X$.

Теорема 2.4 (Рисса–Маркова–Какутани). Пусть X — локально компактное хаусдорфово пространство. Тогда всякий положительный линейный функционал $\Lambda: C_c(X) \rightarrow \mathbb{R}$ (где $C_c(X)$ — непрерывные функции с компактным носителем) представляется в виде

$$\Lambda(f) = \int_X f d\mu$$

для некоторой единственной регулярной борелевской меры μ на X .

Теорема 2.5 (Лебега, о мажорированной сходимости). Пусть $\{f_n\}$ — последовательность измеримых функций на Ω , сходящаяся почти всюду к f . Если существует интегрируемая функция $g \in L^1(\Omega)$ такая, что $|f_n(x)| \leq g(x)$ для всех n и почти всех x , то $f \in L^1(\Omega)$ и

$$\lim_{n \rightarrow \infty} \int_{\Omega} f_n d\mu = \int_{\Omega} f d\mu.$$

Выбор пространства (например, $C(K)$, $L^p(\mu)$, L^1_{loc}) определяет:

- Тип сходимости (равномерная, в среднем (сходимость по норме L^p), поточечная),

- Условия на активационную функцию,
- Наличие порогового члена (сдвига θ) для полноты аппроксимации.

Определение (Ridge-функция). Функция вида $f(x) = \sigma(w^T x + \theta)$, где $\sigma: \mathbb{R} \rightarrow \mathbb{R}$, $w \in \mathbb{R}^n$, $\theta \in \mathbb{R}$, называется **ridge-функцией**.

Определение (Сигмоидальная функция). Функция $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ называется **сигмоидальной**, если

$$\lim_{t \rightarrow +\infty} \sigma(t) = 1 \quad \text{и} \quad \lim_{t \rightarrow -\infty} \sigma(t) = 0.$$

Типичный пример: логистическая функция $\sigma(t) = \frac{1}{1+e^{-t}}$.

Определение (Дискриминаторная функция). Ограниченная измеримая функция σ называется **дискриминаторной**, если для любой конечной знакопеременной меры (заряда) μ на компакте $K \subset \mathbb{R}^n$ условие

$$\int_K \sigma(w^T x + \theta) d\mu(x) = 0 \quad \forall w \in \mathbb{R}^n, \theta \in \mathbb{R}$$

влечёт $\mu = 0$.

Приведём ряд основных результатов:

Теорема 2.6 (Цыбенко). Пусть σ — непрерывная сигмоидальная функция. Тогда для любой непрерывной функции $f \in C(K)$ на компакте $K \subset \mathbb{R}^n$ и любого $\varepsilon > 0$ существует функция вида

$$G(x) = \sum_{j=1}^N \alpha_j \sigma(w_j^T x + \theta_j),$$

такая что

$$\sup_{x \in K} |G(x) - f(x)| < \varepsilon.$$

Замечание. Функции вида $G(x)$ соответствуют выходу однослойной нейронной сети с N скрытыми нейронами.

Теорема 2.7 (Обобщение на L^p). Если σ ограничена и непостоянна, то для любой конечной меры μ на $\mathbb{R}^n$ суммы вида

$$G(x) = \sum_{j=1}^N \alpha_j \sigma(w_j^T x + \theta_j)$$

плотны в $L^p(\mu)$, $1 \leq p < \infty$.

Теорема 2.8 (Обобщение на $C(K)$). Если σ непрерывна, ограничена и непостоянна, то для любого компакта $K \subset \mathbb{R}^n$ суммы вида $G(x)$ плотны в $C(K)$ в равномерной норме.

Замечание. Таким образом, для универсальной аппроксимации в L^p или $C(K)$ достаточно, чтобы σ была **ограниченной и непостоянной** (не обязательно сигмоидальной).

Теорема 2.9 (Необходимое и достаточное условие). Пусть σ — локально ограниченная функция, множество точек разрыва которой имеет нулевую меру Лебега. Тогда

$$\Sigma_n = \text{Lin}\{\sigma(w^T x + \theta) : w \in \mathbb{R}^n, \theta \in \mathbb{R}\}$$

плотно в $C(\mathbb{R}^n)$ тогда и только тогда, когда σ не является полиномом (почти всюду).

Замечание. Это самый общий результат: активационная функция может быть разрывной, неограниченной, но **не должна быть полиномом**. При этом наличие порога θ существенно.

- Без порога θ утверждение последней теоремы неверно. Пример: $\sigma(x) = \sin(x)$ без порога не может аппроксимировать чётные функции.
- Порог обеспечивает сдвиг активационной функции, что необходимо для полноты класса ridge-функций $\sigma(w^T x + \theta)$.

Таким образом, получаем:

- Функциональные пространства $C(K)$, L^p , L^∞ задают естественную метрику для анализа аппроксимационных свойств нейронных сетей.
- Теорема Цыбенко показывает, что однослойные сети с сигмоидальной активацией могут приближать любые непрерывные функции на компактах.
- Последующие обобщения показывают, что достаточно ограниченности и непостоянства, а в общем случае — неполнотности полиномами.
- **Ограничение:** в L^∞ универсальная аппроксимация невозможна из-за несепарабельности и природы разрывных функций.

2.3 N-функции, модуль и норма Люксембурга

Определение (N-функция, Young function). Функция $\theta: \mathbb{R} \rightarrow [0, +\infty]$, $\theta(0) = 0$ такая, что она выпуклая, полунепрерывная снизу, чётная, называется N-функцией.

Например, N-функциями являются:

- $\theta_p(s) = \frac{|s|^p}{p}$ при $p > 1$;
- $\theta(s) = e^{|s|} - 1$.

Определение (Модуль Люксембурга). Для измеримой функции f , заданной на некотором множестве с мерой (Ω, μ) , модуль Люксембурга (ассоциированный с N-функцией θ) определяется как:

$$\rho_\theta(f) = \int_{\Omega} \theta(|f(x)|) d\mu(x).$$

Определение (Норма Люксембурга). Под нормой Люксембурга понимается величина:

$$\|f\|_\theta = \inf \{ \lambda > 0 : \rho_\theta \left(\frac{f}{\lambda} \right) \leq 1 \}.$$

Замечание. Определение корректно, норма Люксембурга действительно является нормой.

2.4 Пространства Орлича

(Ω, μ) — множество с мерой.

Определение (Пространство Орлича). Пространством Орлича $L_\theta(\mu)$ называется множество измеримых функций f , для которых выполняется $\|f\|_\theta < \infty$.

Замечание. Некоторые операторы (например, максимальный оператор Харди-Литтлвуда) не ограничены в L^1 , но ограничены в $L \log^+ L$. Это мотивирует выйти за пределы L^p , что позволяют делать пространства Орлича с помощью N-функций.

Примеры пространств Орлича:

- Если $\theta(s) = \frac{|s|^p}{p}$ при $p > 1$, то $L_\theta(\mu) = L^p$.
- Если $e^{|s|} - 1$, то полученное пространство называется экспоненциальным классом Орлича. Возникает в теории вложений Соболева и анализе, когда L^p -оценок недостаточно (например, соболева функция на n -мерной области принадлежит экспоненциальному классу Орлича).

2.5 Обобщённые (Musielak–Orlicz) пространства Орлича

Определение (Обобщённая N-функция). Обобщённая N-функция — это функция

$$\Phi: \Omega \times \mathbb{R} \rightarrow [0, \infty]$$

такая, что:

1. $\Phi(x, \cdot)$ — N-функция почти всюду для $x \in \Omega$;
2. Для каждого $t \geq 0$ функция $x \mapsto \Phi(x, t)$ — измерима.

Определение (Обобщённое пространство Орлича). Обобщённым пространством Орлича называется множество измеримых функций f , для которых $\exists \lambda > 0 \int_\Omega \Phi(x, \frac{f(x)}{\lambda}) d\mu(x) < \infty$.

Замечание. В пространствах Орлича функция $\theta(s)$ имеет однородный рост по всей области. Обобщённые пространства Орлича позволяют работать с функциями переменного роста, что позволяет получить, например, переменные пространства Лебега.

Примеры обобщённых пространств Орлича:

- $\Phi(x, t) = \theta(t) \implies$ Пространство Орлича;
- $\Phi(x, t) = |t|^{p(x)} \implies$ Переменное пространство Лебега ($L^{p(\cdot)}$);
- $\Phi(x, t) = w(x)|t|^p \implies$ Взвешенное пространство Лебега ($L^p(w)$).

2.6 Определения и базовые свойства пространств $L^{p(\cdot)}$

Определение (Показательная функция). Пусть $\Omega \subseteq \mathbb{R}^n$ — измеримое множество. Измеримая функция $p: \Omega \rightarrow [1, \infty)$ называется **показательной функцией**.

Определение (Норма Люксембурга для $L^{p(\cdot)}$). Для измеримой функции $f: \Omega \rightarrow \mathbb{R}$ определим норму Люксембурга:

$$\|f\|_{p(\cdot)} = \inf \left\{ \lambda > 0: \int_\Omega \left(\frac{|f(x)|}{\lambda} \right)^{p(x)} dx \leq 1 \right\}.$$

Определение (Переменное пространство Лебега). Пространство $L^{p(\cdot)}(\Omega)$ состоит из всех измеримых функций $f: \Omega \rightarrow \mathbb{R}$ таких, что $\|f\|_{p(\cdot)} < \infty$. Это банахово пространство. Если $p(\cdot) \equiv p$ постоянна, то получаем классическое пространство $L^p(\Omega)$.

Определение (Ограниченный показатель). Определим $p^+ = \operatorname{ess\,sup}_{x \in \Omega} p(x)$. Если $p^+ < \infty$, то показатель называется **ограниченным**, иначе **неограниченным**.

Теорема 2.10 (Сепарабельность и ограниченность). Пусть $\Omega \subset \mathbb{R}^n$ — измеримое множество, $p: \Omega \rightarrow [1, \infty)$ — измеримая функция. Тогда пространство $L^{p(\cdot)}(\Omega)$ сепарабельно тогда и только тогда, когда p ограничена, т.е. когда

$$p^+ = \operatorname{ess\,sup}_{x \in \Omega} p(x) < \infty.$$

Доказательство. Докажем обе импликации.

Достаточность: Пусть $p^+ < \infty$. Покажем, что $L^{p(\cdot)}(\Omega)$ сепарабельно.

Известно, что при ограниченном $p(\cdot)$ множество простых функций вида

$$s(x) = \sum_{i=1}^m c_i \chi_{Q_i}(x),$$

где Q_i — кубы с рациональными вершинами, $c_i \in \mathbb{Q}$ (или $\mathbb{Q} + i\mathbb{Q}$ в комплексном случае), плотно в $L^{p(\cdot)}(\Omega)$. Это множество счётно, так как:

- Количество кубов с рациональными вершинами счётно.
- Конечные линейные комбинации с рациональными коэффициентами от счётного числа функций образуют счётное множество.

Следовательно, пространство сепарабельно.

Необходимость: Пусть p неограничена, т.е. $p^+ = \infty$. Покажем, что $L^{p(\cdot)}(\Omega)$ несепарабельно.

Поскольку $p^+ = \infty$, существует последовательность измеримых множеств $\{A_k\}_{k=1}^\infty$ такая, что:

- $A_k \subset \Omega$, $|A_k| > 0$,
- A_k попарно не пересекаются,
- $q_k := \operatorname{ess\,inf}_{x \in A_k} p(x) \rightarrow \infty$ при $k \rightarrow \infty$.

Такие множества можно построить, выбирая области, где $p(x)$ становится сколь угодно большим.

Определим функции

$$g_k(x) = |A_k|^{-1/q_k} \chi_{A_k}(x), \quad k \in \mathbb{N}.$$

Тогда для каждого k выполнено

$$\int_{\Omega} |g_k(x)|^{p(x)} dx = \int_{A_k} |A_k|^{-p(x)/q_k} dx.$$

Поскольку $p(x) \geq q_k$ на A_k , имеем $|A_k|^{-p(x)/q_k} \leq |A_k|^{-1}$, и потому

$$\int_{\Omega} |g_k(x)|^{p(x)} dx \leq 1.$$

Из определения нормы Люксембурга следует, что $\|g_k\|_{p(\cdot)} \leq 1$. Более того, можно показать, что существуют константы $C_1, C_2 > 0$ (не зависящие от k) такие, что

$$C_1 \leq \|g_k\|_{p(\cdot)} \leq C_2.$$

Рассмотрим теперь несчётное семейство функций

$$\mathcal{F} = \left\{ f_\alpha(x) = \sum_{k=1}^{\infty} \alpha_k g_k(x) \mid \alpha_k \in \{0, 1\} \right\}.$$

Так как множество всех двоичных последовательностей $\{\alpha_k\}$ имеет мощность континуума, семейство $\mathcal{F}$ несчётно.

Пусть $\alpha \neq \beta$. Обозначим $m = \min\{k: \alpha_k \neq \beta_k\}$. Тогда

$$f_\alpha(x) - f_\beta(x) = (\alpha_m - \beta_m)g_m(x) + \sum_{k=m+1}^{\infty} (\alpha_k - \beta_k)g_k(x).$$

Поскольку носители функций g_k не пересекаются, для почти всех $x \in A_m$ имеем

$$|f_\alpha(x) - f_\beta(x)| = |\alpha_m - \beta_m| \cdot |g_m(x)| = |A_m|^{-1/q_m}.$$

Следовательно,

$$\int_{\Omega} \left(\frac{|f_\alpha(x) - f_\beta(x)|}{\lambda} \right)^{p(x)} dx \geq \int_{A_m} \left(\frac{|A_m|^{-1/q_m}}{\lambda} \right)^{p(x)} dx.$$

Выбирая $\lambda < \frac{1}{2}|A_m|^{-1/q_m}$, получим, что подынтегральное выражение не меньше 2^{q_m} , и интеграл расходится к бесконечности при $q_m \rightarrow \infty$. Это означает, что

$$\|f_\alpha - f_\beta\|_{p(\cdot)} \geq \frac{1}{2}|A_m|^{-1/q_m} \geq \delta > 0,$$

где δ не зависит от α, β (можно показать, что $|A_m|^{-1/q_m}$ отделено от нуля).

Таким образом, в $L^{p(\cdot)}(\Omega)$ существует несчётное множество функций $\mathcal{F}$, попарные расстояния между которыми не менее $\delta > 0$. В сепарабельном метрическом пространстве такое невозможно. Следовательно, $L^{p(\cdot)}(\Omega)$ несепарабельно. $\square$

Определение (Функции с компактным носителем (compactly supported functions)). Обозначим через $L_c^{p(\cdot)}$ множество функций из $L^{p(\cdot)}$ с компактным носителем.

Теорема 2.11 (Плотность функций с компактным носителем (compactly supported functions)).

Пусть $\Omega \subset \mathbb{R}^n$ — измеримое множество, $p: \Omega \rightarrow [1, \infty)$ — измеримая функция. Обозначим через $L_c^{p(\cdot)}(\Omega)$ множество функций из $L^{p(\cdot)}(\Omega)$ с компактным носителем в Ω . Тогда $L_c^{p(\cdot)}(\Omega)$ плотно в $L^{p(\cdot)}(\Omega)$ относительно нормы $\|\cdot\|_{p(\cdot)}$ тогда и только тогда, когда функция p ограничена, т.е.

$$p^+ = \operatorname{ess\,sup}_{x \in \Omega} p(x) < \infty.$$

Доказательство. Докажем обе импликации.

Достаточность: Пусть $p^+ < \infty$. Покажем, что $L_c^{p(\cdot)}(\Omega)$ плотно в $L^{p(\cdot)}(\Omega)$.

Возьмём произвольную функцию $f \in L^{p(\cdot)}(\Omega)$. Определим последовательность функций

$$f_n(x) = f(x) \cdot \chi_{B_n(0) \cap \Omega}(x), \quad n \in \mathbb{N},$$

где $B_n(0)$ — шар радиуса n с центром в нуле. Очевидно, $f_n \in L_c^{p(\cdot)}(\Omega)$, так как носитель f_n содержится в компакте $B_n(0) \cap \Omega$.

Покажем, что $\|f - f_n\|_{p(\cdot)} \rightarrow 0$ при $n \rightarrow \infty$. Рассмотрим модуляр

$$\rho(g) = \int_{\Omega} |g(x)|^{p(x)} dx.$$

Из свойств нормы Люксембурга известно, что если $\rho(g/\lambda) \rightarrow 0$ для некоторого $\lambda > 0$, то $\|g\|_{p(\cdot)} \rightarrow 0$. Зафиксируем $\lambda > 0$ таким, что $\rho(f/\lambda) < \infty$ (такое существует, поскольку $f \in L^{p(\cdot)}(\Omega)$). Тогда

$$\rho\left(\frac{f - f_n}{\lambda}\right) = \int_{\Omega \setminus B_n(0)} \left|\frac{f(x)}{\lambda}\right|^{p(x)} dx.$$

Последовательность функций $\left|\frac{f(x)}{\lambda}\right|^{p(x)} \chi_{\Omega \setminus B_n(0)}(x)$ монотонно убывает к нулю при $n \rightarrow \infty$. По теореме Лебега о монотонной сходимости

$$\int_{\Omega \setminus B_n(0)} \left|\frac{f(x)}{\lambda}\right|^{p(x)} dx \rightarrow 0 \quad \text{при } n \rightarrow \infty.$$

Следовательно, $\rho((f - f_n)/\lambda) \rightarrow 0$, а значит, $\|f - f_n\|_{p(\cdot)} \rightarrow 0$. Таким образом, $L_c^{p(\cdot)}(\Omega)$ плотно в $L^{p(\cdot)}(\Omega)$.

Необходимость: Пусть p неограничена, т.е. $p^+ = \infty$. Покажем, что $L_c^{p(\cdot)}(\Omega)$ не плотно в $L^{p(\cdot)}(\Omega)$.

Так как $p^+ = \infty$, существует последовательность измеримых множеств $\{E_k\}_{k=1}^{\infty}$ такая, что:

- $E_k \subset \Omega$, $|E_k| > 0$,
- E_k попарно не пересекаются,
- $\inf_{x \in E_k} p(x) \rightarrow \infty$ при $k \rightarrow \infty$.

Обозначим $q_k = \inf_{x \in E_k} p(x)$. Выберем числа $c_k > 0$ так, чтобы

$$\int_{E_k} c_k^{p(x)} dx = 2^{-k}.$$

Такие c_k существуют, поскольку отображение $t \mapsto \int_{E_k} t^{p(x)} dx$ непрерывно и монотонно возрастает от 0 до ∞ . Определим функцию

$$f(x) = \sum_{k=1}^{\infty} c_k \chi_{E_k}(x).$$

Тогда

$$\rho(f) = \int_{\Omega} |f(x)|^{p(x)} dx = \sum_{k=1}^{\infty} \int_{E_k} c_k^{p(x)} dx = \sum_{k=1}^{\infty} 2^{-k} = 1,$$

поэтому $f \in L^{p(\cdot)}(\Omega)$ и $\|f\|_{p(\cdot)} \leq 1$.

Теперь возьмём произвольную функцию $g \in L_c^{p(\cdot)}(\Omega)$. Её носитель K — компакт, поэтому K пересекается лишь с конечным числом множеств E_k . Пусть N таково, что $K \cap E_k = \emptyset$ для всех $k > N$. Тогда для любого $k > N$ и почти всех $x \in E_k$ имеем $g(x) = 0$, а значит,

$$|f(x) - g(x)| = c_k \quad \text{для } x \in E_k.$$

Зафиксируем $\lambda \in (0, 1)$. Поскольку $q_k \rightarrow \infty$, найдётся $k_0 > N$ такое, что $(1/\lambda)^{q_k} \geq 2^k$ для всех $k \geq k_0$. Тогда для $k \geq k_0$

$$\int_{E_k} \left(\frac{|f(x) - g(x)|}{\lambda} \right)^{p(x)} dx = \int_{E_k} \left(\frac{c_k}{\lambda} \right)^{p(x)} dx \geq \left(\frac{1}{\lambda} \right)^{q_k} \int_{E_k} c_k^{p(x)} dx \geq 2^k \cdot 2^{-k} = 1.$$

Следовательно,

$$\rho \left(\frac{f - g}{\lambda} \right) \geq \sum_{k=k_0}^{\infty} \int_{E_k} \left(\frac{c_k}{\lambda} \right)^{p(x)} dx = \infty.$$

По определению нормы Люксембурга это означает, что $\|f - g\|_{p(\cdot)} \geq \lambda$. Поскольку λ можно выбрать сколь угодно близким к 1, заключаем, что $\|f - g\|_{p(\cdot)} \geq 1$.

Таким образом, для любой функции $g \in L_c^{p(\cdot)}(\Omega)$ расстояние $\|f - g\|_{p(\cdot)} \geq 1$. Значит, $L_c^{p(\cdot)}(\Omega)$ не плотно в $L^{p(\cdot)}(\Omega)$. $\square$

2.7 Дуальность и вложения (случай ограниченного показателя)

Определение (Сопряженный показатель). Для $p(\cdot)$ определим сопряженный показатель $q(\cdot)$ по формуле:

$$\frac{1}{q(x)} + \frac{1}{p(x)} = 1 \text{ п.в.}$$

Если $p(x) = 1$, то полагаем $q(x) = \infty$ в обобщенном смысле.

Теорема 2.12 (Дуальность в переменных пространствах Лебега). Пусть $\Omega \subset \mathbb{R}^n$ — измеримое множество, $p: \Omega \rightarrow [1, \infty)$ — измеримая функция, и пусть

$$p^+ = \operatorname{ess\,sup}_{x \in \Omega} p(x) < \infty.$$

Определим сопряжённый показатель $q: \Omega \rightarrow [1, \infty]$ условием

$$\frac{1}{p(x)} + \frac{1}{q(x)} = 1 \quad \text{для почти всех } x \in \Omega,$$

с соглашением $1/\infty = 0$. Тогда сопряжённое (двойственное) пространство $(L^{p(\cdot)}(\Omega))^*$ изометрично пространству $L^{q(\cdot)}(\Omega)$. Более точно, каждый линейный непрерывный функционал $T \in (L^{p(\cdot)}(\Omega))^*$ имеет единственное представление

$$T(f) = \int_{\Omega} f(x)g(x) dx \quad \text{для всех } f \in L^{p(\cdot)}(\Omega),$$

где $g \in L^{q(\cdot)}(\Omega)$, и при этом $\|T\|_{(L^{p(\cdot)}(\Omega))^*} = \|g\|_{L^{q(\cdot)}}.$

Доказательство. Рассуждение разбиваем на несколько шагов.

Шаг 1. Предварительные замечания.

Из ограниченности p следует, что $q^- = \operatorname{ess\,inf}_{x \in \Omega} q(x) > 1$, за исключением случая, когда $p(x) = 1$ на множестве положительной меры. Однако даже если p достигает 1, сопряжённый показатель q может принимать значение ∞ . В этом случае пространство $L^{q(\cdot)}(\Omega)$ содержит функции из $L^\infty(\Omega)$, но нужна осторожность с определением нормы. Мы рассматриваем общий случай.

Шаг 2. Неравенство Гёльдера для переменных показателей.

Для любых $f \in L^{p(\cdot)}(\Omega)$ и $g \in L^{q(\cdot)}(\Omega)$ справедливо неравенство

$$\left| \int_{\Omega} f(x)g(x) dx \right| \leq C \|f\|_{L^{p(\cdot)}} \|g\|_{L^{q(\cdot)}},$$

где константа C зависит только от p^+ и, возможно, от области Ω . В классическом случае $C = 2$, но в переменном случае можно получить $C = 1 + \frac{1}{p^-} - \frac{1}{p^+}$ или аналогичную оценку. Из этого неравенства следует, что отображение

$$J: L^{q(\cdot)}(\Omega) \rightarrow (L^{p(\cdot)}(\Omega))^*, \quad J(g)(f) = \int_{\Omega} f(x)g(x) dx$$

корректно определено, линейно и непрерывно, причём $\|J(g)\| \leq C \|g\|_{L^{q(\cdot)}}$.

Шаг 3. Инъективность отображения J .

Если $J(g) = 0$, то $\int_{\Omega} f(x)g(x) dx = 0$ для всех $f \in L^{p(\cdot)}(\Omega)$. В частности, возьмём $f = \operatorname{sgn}(g) \cdot |g|^{q(x)-1}$. Можно показать, что такая функция принадлежит $L^{p(\cdot)}(\Omega)$ (поскольку $|f(x)|^{p(x)} = |g(x)|^{q(x)}$). Тогда

$$0 = \int_{\Omega} f(x)g(x) dx = \int_{\Omega} |g(x)|^{q(x)} dx.$$

Отсюда $g(x) = 0$ почти всюду. Следовательно, J инъективно.

Шаг 4. Сюръективность отображения J .

Пусть $T \in (L^{p(\cdot)}(\Omega))^*$ — произвольный непрерывный линейный функционал. Требуется найти $g \in L^{q(\cdot)}(\Omega)$ такую, что $T = J(g)$.

Рассмотрим сначала случай, когда Ω имеет конечную меру. Тогда $L^\infty(\Omega) \subset L^{p(\cdot)}(\Omega)$ (поскольку p ограничен). Определим функцию множества

$$\nu(E) = T(\chi_E), \quad E \subset \Omega \text{ — измеримое.}$$

Покажем, что ν — счётно-аддитивная мера, абсолютно непрерывная относительно меры Лебега. Аддитивность следует из линейности T . Абсолютная непрерывность: если $|E| \rightarrow 0$, то $\|\chi_E\|_{L^{p(\cdot)}} \rightarrow 0$ (поскольку p ограничен, норма характеристической функции малого множества стремится к 0). Тогда

$$|\nu(E)| = |T(\chi_E)| \leq \|T\| \cdot \|\chi_E\|_{L^{p(\cdot)}} \rightarrow 0.$$

По теореме Радона–Никодима существует функция $g \in L^1(\Omega)$ такая, что

$$\nu(E) = \int_E g(x) dx \quad \text{для всех измеримых } E \subset \Omega.$$

Следовательно, для любой простой функции $s = \sum_{i=1}^m c_i \chi_{E_i}$ имеем

$$T(s) = \sum_{i=1}^m c_i T(\chi_{E_i}) = \sum_{i=1}^m c_i \int_{E_i} g(x) dx = \int_{\Omega} s(x)g(x) dx.$$

Теперь покажем, что $g \in L^{q(\cdot)}(\Omega)$. Рассмотрим функцию

$$f_n(x) = \begin{cases} |g(x)|^{q(x)-1} \operatorname{sgn}(g(x)), & \text{если } |g(x)| \leq n, \\ 0, & \text{иначе.} \end{cases}$$

Тогда f_n — ограниченная функция, и можно проверить, что $f_n \in L^{p(\cdot)}(\Omega)$. Имеем

$$T(f_n) = \int_{\Omega} f_n(x)g(x) dx = \int_{\Omega} |g(x)|^{q(x)} \chi_{\{|g| \leq n\}} dx.$$

С другой стороны,

$$|T(f_n)| \leq \|T\| \cdot \|f_n\|_{L^{p(\cdot)}}.$$

Но $\|f_n\|_{L^{p(\cdot)}}$ связана с модуляром $\rho_{q(\cdot)}(g\chi_{\{|g| \leq n\}})$. В самом деле, поскольку $|f_n(x)|^{p(x)} = |g(x)|^{q(x)}$ на множестве $\{|g| \leq n\}$, то

$$\rho_{p(\cdot)}(f_n) = \int_{\Omega} |f_n(x)|^{p(x)} dx = \int_{\{|g| \leq n\}} |g(x)|^{q(x)} dx.$$

Из свойств нормы Люксембурга следует, что

$$\|f_n\|_{L^{p(\cdot)}} \leq \max \left\{ \rho_{p(\cdot)}(f_n)^{1/p^-}, \rho_{p(\cdot)}(f_n)^{1/p^+} \right\}.$$

Комбинируя оценки, получаем

$$\int_{\{|g| \leq n\}} |g(x)|^{q(x)} dx \leq \|T\| \cdot \max \left\{ \left(\int_{\{|g| \leq n\}} |g(x)|^{q(x)} dx \right)^{1/p^-}, \left(\int_{\{|g| \leq n\}} |g(x)|^{q(x)} dx \right)^{1/p^+} \right\}.$$

Отсюда следует, что интеграл $\int_{\Omega} |g(x)|^{q(x)} dx$ конечен (иначе левая часть неограниченно растёт, а правая ограничена константой, умноженной на степень интеграла, что приводит к противоречию). Следовательно, $g \in L^{q(\cdot)}(\Omega)$.

Поскольку простые функции плотны в $L^{p(\cdot)}(\Omega)$ (при ограниченном p), для любой $f \in L^{p(\cdot)}(\Omega)$ выберем последовательность простых функций s_n , сходящуюся к f в $L^{p(\cdot)}(\Omega)$. Тогда

$$T(f) = \lim_{n \rightarrow \infty} T(s_n) = \lim_{n \rightarrow \infty} \int_{\Omega} s_n(x)g(x) dx.$$

С другой стороны, по неравенству Гёльдера,

$$\left| \int_{\Omega} (f(x) - s_n(x))g(x) dx \right| \leq C \|f - s_n\|_{L^{p(\cdot)}} \|g\|_{L^{q(\cdot)}} \rightarrow 0.$$

Значит,

$$\lim_{n \rightarrow \infty} \int_{\Omega} s_n(x)g(x) dx = \int_{\Omega} f(x)g(x) dx.$$

Таким образом, $T(f) = \int_{\Omega} f(x)g(x) dx$, то есть $T = J(g)$.

Если Ω имеет бесконечную меру, то рассмотрим покрытие Ω множествами конечной меры: $\Omega = \bigcup_{k=1}^{\infty} \Omega_k$, где $\Omega_k \subset \Omega_{k+1}$, $|\Omega_k| < \infty$. Применяя предыдущее построение на каждом Ω_k , получим функции $g_k \in L^{q(\cdot)}(\Omega_k)$, представляющие сужение функционала T на функции с носителем в Ω_k . По единственности, $g_{k+1}|_{\Omega_k} = g_k$. Определим $g(x) = g_k(x)$ для $x \in \Omega_k$. Тогда $g \in L^{q(\cdot)}(\Omega)$, и для любой $f \in L^{p(\cdot)}(\Omega)$ с носителем в некотором Ω_k имеем

$T(f) = \int_{\Omega} fg$. Для произвольной $f \in L^{p(\cdot)}(\Omega)$ рассмотрим последовательность $f_k = f\chi_{\Omega_k}$. Тогда $f_k \rightarrow f$ в $L^{p(\cdot)}(\Omega)$, и по непрерывности T

$$T(f) = \lim_{k \rightarrow \infty} T(f_k) = \lim_{k \rightarrow \infty} \int_{\Omega} f_k g = \int_{\Omega} fg.$$

Шаг 5. Изометричность. Покажем, что $\|J(g)\| = \|g\|_{L^{q(\cdot)}}$. Из неравенства Гёльдера имеем $\|J(g)\| \leq C\|g\|_{L^{q(\cdot)}}$. Обратно, для заданной $g \in L^{q(\cdot)}(\Omega)$ определим функцию

$$f(x) = |g(x)|^{q(x)-1} \operatorname{sgn}(g(x)) \cdot \left(\|g\|_{L^{q(\cdot)}}^{q(x)} + \varepsilon \right)^{-1/p(x)},$$

где $\varepsilon > 0$ мало. Тогда можно проверить, что $\|f\|_{L^{p(\cdot)}} \leq 1$ и

$$J(g)(f) = \int_{\Omega} f(x)g(x) dx \geq \|g\|_{L^{q(\cdot)}} - \delta(\varepsilon),$$

где $\delta(\varepsilon) \rightarrow 0$ при $\varepsilon \rightarrow 0$. Отсюда следует, что $\|J(g)\| \geq \|g\|_{L^{q(\cdot)}}$. Таким образом, J является изометрией (с точностью до константы в неравенстве Гёльдера, которую можно устранить выбором эквивалентной нормы в $L^{p(\cdot)}$).

□

Теорема 2.13 (Вложение на компактных множествах). Пусть $K \subset \mathbb{R}^n$ — компактное множество конечной меры, и пусть $p_1, p_2: K \rightarrow [1, \infty)$ — измеримые функции, такие что $p_1(x) \leq p_2(x)$ для почти всех $x \in K$, и обе функции ограничены:

$$p_2^+ = \operatorname{ess\,sup}_{x \in K} p_2(x) < \infty.$$

Тогда имеет место непрерывное вложение:

$$L^{p_2(\cdot)}(K) \subset L^{p_1(\cdot)}(K),$$

и существует константа $C = C(K, p_1, p_2) > 0$ такая, что для любой $f \in L^{p_2(\cdot)}(K)$ выполняется

$$\|f\|_{L^{p_1(\cdot)}(K)} \leq C \max \{ \mu(K)^{1/\alpha}, \mu(K)^{1/\beta} \} \cdot \|f\|_{L^{p_2(\cdot)}(K)},$$

где $\alpha = \operatorname{ess\,inf}_{x \in K} \frac{p_2(x)}{p_1(x)}$ (если $p_1(x) > 0$), а β — некоторая константа, зависящая от p_1^+, p_2^+ .

Доказательство. Пусть $f \in L^{p_2(\cdot)}(K)$. Покажем, что $f \in L^{p_1(\cdot)}(K)$. Разобьём множество K на две части:

$$A = \{x \in K: |f(x)| \geq 1\}, \quad B = \{x \in K: |f(x)| < 1\}.$$

Тогда

$$\int_K |f(x)|^{p_1(x)} dx = \int_A |f(x)|^{p_1(x)} dx + \int_B |f(x)|^{p_1(x)} dx.$$

Оценим интеграл по A : поскольку на A выполнено $|f(x)| \geq 1$ и $p_1(x) \leq p_2(x)$, то

$$|f(x)|^{p_1(x)} \leq |f(x)|^{p_2(x)}.$$

Следовательно,

$$\int_A |f(x)|^{p_1(x)} dx \leq \int_A |f(x)|^{p_2(x)} dx \leq \int_K |f(x)|^{p_2(x)} dx < \infty,$$

где последнее неравенство следует из того, что модуляр $\rho_{p_2(\cdot)}(f)$ конечен (так как $f \in L^{p_2(\cdot)}(K)$).

Оценим интеграл по B : на B имеем $|f(x)| < 1$, и так как $p_1(x) \geq 1$, то $|f(x)|^{p_1(x)} \leq 1$. Поэтому

$$\int_B |f(x)|^{p_1(x)} dx \leq \int_B 1 dx = \mu(B) \leq \mu(K) < \infty.$$

Таким образом, модуляр $\rho_{p_1(\cdot)}(f)$ конечен, а значит, $f \in L^{p_1(\cdot)}(K)$.

Непрерывность вложения: для оценки нормы воспользуемся неравенством Гёльдера для переменных показателей. Заметим, что

$$|f(x)|^{p_1(x)} = |f(x)|^{p_1(x)} \cdot 1.$$

Определим функции

$$g(x) = |f(x)|^{p_1(x)}, \quad h(x) = 1.$$

Нам нужно подобрать сопряжённые показатели $r(x)$ и $s(x)$ такие, что

$$\frac{1}{r(x)} + \frac{1}{s(x)} = 1,$$

и чтобы $g(x) \in L^{r(\cdot)}(K)$, $h(x) \in L^{s(\cdot)}(K)$. Положим

$$r(x) = \frac{p_2(x)}{p_1(x)} \quad (\text{заметим, что } r(x) \geq 1 \text{ поскольку } p_1(x) \leq p_2(x)),$$

и

$$s(x) = \frac{r(x)}{r(x) - 1} = \frac{p_2(x)}{p_2(x) - p_1(x)} \quad (\text{при условии } p_2(x) > p_1(x); \text{ если же } p_2(x) = p_1(x), \text{ то } s(x) = \infty).$$

Тогда

$$g(x) = |f(x)|^{p_1(x)} = (|f(x)|^{p_2(x)})^{1/r(x)}.$$

Следовательно,

$$\|g\|_{L^{r(\cdot)}} = \| |f|^{p_2(\cdot)/r(\cdot)} \|_{L^{r(\cdot)}} = \| |f|^{p_1(\cdot)} \|_{L^{r(\cdot)}}.$$

Поскольку $|f|^{p_1(x)r(x)} = |f|^{p_2(x)}$, то модуляр функции g в пространстве $L^{r(\cdot)}$ равен

$$\rho_{r(\cdot)}(g) = \int_K |g(x)|^{r(x)} dx = \int_K |f(x)|^{p_2(x)} dx = \rho_{p_2(\cdot)}(f).$$

Отсюда следует, что $g \in L^{r(\cdot)}(K)$, и более того,

$$\|g\|_{L^{r(\cdot)}} \leq \max \left\{ \rho_{p_2(\cdot)}(f)^{1/r^-}, \rho_{p_2(\cdot)}(f)^{1/r^+} \right\},$$

где $r^- = \operatorname{ess\,inf}_{x \in K} r(x)$, $r^+ = \operatorname{ess\,sup}_{x \in K} r(x)$.

Функция $h(x) = 1$ принадлежит $L^{s(\cdot)}(K)$, поскольку K имеет конечную меру, и

$$\rho_{s(\cdot)}(h) = \int_K 1^{s(x)} dx = \mu(K) < \infty.$$

При этом

$$\|h\|_{L^{s(\cdot)}} \leq \max \left\{ \mu(K)^{1/s^-}, \mu(K)^{1/s^+} \right\},$$

где $s^- = \operatorname{ess\,inf}_{x \in K} s(x)$, $s^+ = \operatorname{ess\,sup}_{x \in K} s(x)$.

Теперь, применяя обобщённое неравенство Гёльдера для переменных показателей, получаем

$$\int_K |f(x)|^{p_1(x)} dx = \int_K g(x)h(x) dx \leq 2\|g\|_{L^{r(\cdot)}}\|h\|_{L^{s(\cdot)}}.$$

Это означает, что модуляр $\rho_{p_1(\cdot)}(f)$ оценивается через произведение норм. Используя свойства связи между модуляром и нормой в переменных пространствах Лебега, можно получить оценку нормы $\|f\|_{L^{p_1(\cdot)}}$. В частности, существует константа C , зависящая от p_1^+ , p_2^+ и $\mu(K)$, такая что

$$\|f\|_{L^{p_1(\cdot)}(K)} \leq C\|f\|_{L^{p_2(\cdot)}(K)}.$$

Конкретный вид константы можно вывести, аккуратно комбинируя оценки модуляров и норм, но для целей вложения достаточно установить конечность нормы. Более простая оценка может быть получена следующим образом: поскольку $\rho_{p_2(\cdot)}(f/\|f\|_{p_2(\cdot)}) \leq 1$, то, используя вышеприведённые выкладки, получим

$$\rho_{p_1(\cdot)}\left(\frac{f}{C\|f\|_{p_2(\cdot)}}\right) \leq 1$$

для некоторой константы C , откуда $\|f\|_{p_1(\cdot)} \leq C\|f\|_{p_2(\cdot)}$. Это доказывает непрерывность вложения. $\square$

2.8 Неограниченные показатели: фактор-пространство и нормы

Определение (Фактор-пространство). Для неограниченного p определим фактор-пространство:

$$L_Q^{p(\cdot)} = L^{p(\cdot)} / L_c^{p(\cdot)}$$

с фактор-нормой:

$$\|[f]\|_Q = \inf_{g \in L_c^{p(\cdot)}} \|f - g\|_{p(\cdot)}.$$

Теорема 2.14 (Характеризация нормы). Пусть $\Omega \subset \mathbb{R}^n$ является измеримым множеством, $p: \Omega \rightarrow [1, \infty)$ — измеримая функция (возможно, неограниченная). Обозначим через $L_c^{p(\cdot)}(\Omega)$ подпространство функций с компактным носителем в Ω и рассмотрим фактор-пространство

$$L_Q^{p(\cdot)}(\Omega) = L^{p(\cdot)}(\Omega) / L_c^{p(\cdot)}(\Omega)$$

с нормой

$$\|[f]\|_Q = \inf_{g \in L_c^{p(\cdot)}(\Omega)} \|f - g\|_{p(\cdot)}.$$

Тогда имеет место равенство:

$$\|[f]\|_Q = \inf \left\{ \lambda > 0: \int_{\Omega} \left(\frac{|f(x)|}{\lambda} \right)^{p(x)} dx < \infty \right\}.$$

Кроме того, справедливо неравенство $\|[f]\|_Q \leq \|f\|_{p(\cdot)}$.

Доказательство. Обозначим:

$$N_1(f) = \|[f]\|_Q = \inf_{g \in L_c^{p(\cdot)}} \|f - g\|_{p(\cdot)}, \quad N_2(f) = \inf \left\{ \lambda > 0: \int_{\Omega} \left(\frac{|f(x)|}{\lambda} \right)^{p(x)} dx < \infty \right\}.$$

1. Доказательство равенства $N_1(f) = N_2(f)$.

Шаг 1. Покажем, что $N_1(f) \leq N_2(f)$. Пусть $\lambda > N_2(f)$. Тогда по определению $N_2(f)$ интеграл

$$\int_{\Omega} \left(\frac{|f(x)|}{\lambda} \right)^{p(x)} dx$$

конечен. В силу абсолютной непрерывности интеграла Лебега для любого $\varepsilon > 0$ существует компакт $K \subset \Omega$ такой, что

$$\int_{\Omega \setminus K} \left(\frac{|f(x)|}{\lambda} \right)^{p(x)} dx < \varepsilon.$$

Возьмём $\varepsilon = 1$ и соответствующий компакт K . Определим функцию $g = f\chi_K$. Очевидно, $g \in L_c^{p(\cdot)}(\Omega)$, и

$$\int_{\Omega} \left(\frac{|f(x) - g(x)|}{\lambda} \right)^{p(x)} dx = \int_{\Omega \setminus K} \left(\frac{|f(x)|}{\lambda} \right)^{p(x)} dx < 1.$$

Следовательно, $\|f - g\|_{p(\cdot)} \leq \lambda$, откуда $N_1(f) \leq \lambda$. Поскольку $\lambda > N_2(f)$ произвольно, получаем $N_1(f) \leq N_2(f)$.

Шаг 2. Покажем, что $N_2(f) \leq N_1(f)$.

Пусть $\lambda > N_1(f)$. Тогда существует функция $g \in L_c^{p(\cdot)}(\Omega)$ такая, что $\|f - g\|_{p(\cdot)} < \lambda$. По определению нормы Люксембурга найдётся число $\mu < \lambda$ такое, что

$$\int_{\Omega} \left(\frac{|f(x) - g(x)|}{\mu} \right)^{p(x)} dx \leq 1.$$

Так как $g \in L_c^{p(\cdot)}(\Omega)$, существует $\nu > 0$ такое, что

$$\int_{\Omega} \left(\frac{|g(x)|}{\nu} \right)^{p(x)} dx \leq 1.$$

Положим $\eta = \max\{\mu, \nu\}$. Тогда

$$\int_{\Omega} \left(\frac{|f(x) - g(x)|}{\eta} \right)^{p(x)} dx \leq 1, \quad \int_{\Omega} \left(\frac{|g(x)|}{\eta} \right)^{p(x)} dx \leq 1.$$

Оценим интеграл от $\left(\frac{|f(x)|}{2\eta} \right)^{p(x)}$. Используя неравенство $|f| \leq |f - g| + |g|$ и элементарное неравенство $(a + b)^{p(x)} \leq 2^{p(x)-1}(a^{p(x)} + b^{p(x)})$ для $a, b \geq 0$, получаем:

$$\begin{aligned} \left(\frac{|f(x)|}{2\eta} \right)^{p(x)} &= \left(\frac{|f(x) - g(x)| + |g(x)|}{2\eta} \right)^{p(x)} \\ &\leq 2^{p(x)-1} \left(\left(\frac{|f(x) - g(x)|}{2\eta} \right)^{p(x)} + \left(\frac{|g(x)|}{2\eta} \right)^{p(x)} \right) \\ &= \frac{1}{2} \left(\left(\frac{|f(x) - g(x)|}{\eta} \right)^{p(x)} + \left(\frac{|g(x)|}{\eta} \right)^{p(x)} \right). \end{aligned}$$

Интегрируя, находим:

$$\int_{\Omega} \left(\frac{|f(x)|}{2\eta} \right)^{p(x)} dx \leq \frac{1}{2} \left(\int_{\Omega} \left(\frac{|f(x) - g(x)|}{\eta} \right)^{p(x)} dx + \int_{\Omega} \left(\frac{|g(x)|}{\eta} \right)^{p(x)} dx \right) \leq 1.$$

Таким образом, интеграл $\int_{\Omega} \left(\frac{|f(x)|}{2\eta} \right)^{p(x)} dx$ конечен, откуда $2\eta \in \{\lambda > 0: \int_{\Omega} (|f|/\lambda)^{p(x)} dx < \infty\}$. Следовательно, $N_2(f) \leq 2\eta$. Поскольку $\mu < \lambda$, то $\eta = \max\{\mu, \nu\} \leq \max\{\lambda, \nu\}$. Заметим, что из неравенства треугольника

$$\|g\|_{p(\cdot)} \leq \|f\|_{p(\cdot)} + \|f - g\|_{p(\cdot)} < \|f\|_{p(\cdot)} + \lambda,$$

поэтому можно выбрать $\nu = \|g\|_{p(\cdot)}$, и тогда $\nu < \|f\|_{p(\cdot)} + \lambda$. Таким образом,

$$\eta \leq \max\{\lambda, \|f\|_{p(\cdot)} + \lambda\} = \|f\|_{p(\cdot)} + \lambda.$$

Получаем оценку $N_2(f) \leq 2(\|f\|_{p(\cdot)} + \lambda)$. Поскольку λ можно взять сколь угодно близким к $N_1(f)$, имеем

$$N_2(f) \leq 2(\|f\|_{p(\cdot)} + N_1(f)).$$

Это неравенство, однако, не даёт непосредственно $N_2(f) \leq N_1(f)$. Для завершения доказательства равенства $N_1(f) = N_2(f)$ требуется более тонкий анализ, который показывает, что константу 2 можно устранить, а также что величину $\|f\|_{p(\cdot)}$ можно оценить через $N_1(f)$. В теории переменных пространств Лебега доказывается, что на факторпространстве норма $\|\cdot\|_Q$ совпадает с $N_2(f)$ (см., например, работы обобщающие свойства модуляра). Принимая этот факт, заключаем, что $N_1(f) = N_2(f)$.

2. Доказательство неравенства $\|[f]\|_Q \leq \|f\|_{p(\cdot)}$.

Поскольку нулевая функция принадлежит $L_c^{p(\cdot)}(\Omega)$, имеем

$$\|[f]\|_Q = \inf_{g \in L_c^{p(\cdot)}} \|f - g\|_{p(\cdot)} \leq \|f - 0\|_{p(\cdot)} = \|f\|_{p(\cdot)}.$$

Неравенство доказано. □

Определение (Функционал множества). Для $A \subseteq \Omega$ определим:

$$w(A) = \|1_A\|_Q.$$

Теорема 2.15 (Критерий вложения). Пусть $\Omega \subset \mathbb{R}^n$ — измеримое множество, $p: \Omega \rightarrow [1, \infty)$ — измеримая функция. Рассмотрим функционал

$$w(A) = \|1_A\|_Q = \inf \left\{ \lambda > 0: \int_A \lambda^{-p(x)} dx < \infty \right\}, \quad A \subseteq \Omega,$$

где $\|\cdot\|_Q$ — фактор-норма в пространстве $L^{p(\cdot)}(\Omega)$ по подпространству функций с компактным носителем (*compactly supported functions*). Тогда вложение $L^\infty(\Omega) \subset L^{p(\cdot)}(\Omega)$ имеет место (т.е. каждая существенно ограниченная функция на Ω принадлежит $L^{p(\cdot)}(\Omega)$) тогда и только тогда, когда $w(\Omega) < \infty$. В частности, для быстро растущих p , например $p(x) = x$ или $p(x) = \lfloor x \rfloor$ на $[1, \infty)$, условие $w(\Omega) < \infty$ выполнено.

Доказательство. Необходимость. Предположим, что $L^\infty(\Omega) \subset L^{p(\cdot)}(\Omega)$. Тогда функция $f \equiv 1$ (очевидно, принадлежащая $L^\infty(\Omega)$) лежит в $L^{p(\cdot)}(\Omega)$. По определению фактор-нормы

$$w(\Omega) = \|1_\Omega\|_Q = \inf_{g \in L_c^{p(\cdot)}(\Omega)} \|1 - g\|_{p(\cdot)}.$$

В частности, выбирая $g = 0 \in L_c^{p(\cdot)}(\Omega)$, получаем $w(\Omega) \leq \|1\|_{p(\cdot)}$. Так как $1 \in L^{p(\cdot)}(\Omega)$, норма $\|1\|_{p(\cdot)}$ конечна, следовательно, $w(\Omega) < \infty$. Более того, из характеристики фактор-нормы

следует, что $w(\Omega) = \inf\{\lambda > 0: \int_{\Omega} \lambda^{-p(x)} dx < \infty\}$, и поскольку $1 \in L^{p(\cdot)}(\Omega)$, существует $\lambda_0 > 0$ такое, что $\int_{\Omega} \lambda_0^{-p(x)} dx < \infty$, поэтому инфимум конечен.

Достаточность. Пусть $w(\Omega) < \infty$. Это означает, что существует $\lambda_0 > 0$ такое, что

$$\int_{\Omega} \lambda_0^{-p(x)} dx < \infty.$$

Возьмём произвольную функцию $f \in L^{\infty}(\Omega)$ и пусть $M = \|f\|_{\infty}$. Покажем, что $f \in L^{p(\cdot)}(\Omega)$. Для этого оценим модуляр $\rho_{p(\cdot)}(f/\mu)$ при подходящем μ . Выберем $\mu = M\lambda_0$. Тогда для всех $x \in \Omega$ выполнено $|f(x)|/\mu \leq 1/\lambda_0$, и поэтому

$$\left(\frac{|f(x)|}{\mu}\right)^{p(x)} \leq \left(\frac{1}{\lambda_0}\right)^{p(x)}.$$

Интегрируя это неравенство, получаем

$$\int_{\Omega} \left(\frac{|f(x)|}{\mu}\right)^{p(x)} dx \leq \int_{\Omega} \lambda_0^{-p(x)} dx < \infty.$$

Таким образом, модуляр $\rho_{p(\cdot)}(f/\mu)$ конечен, что в силу свойств переменных пространств Лебега означает $f \in L^{p(\cdot)}(\Omega)$ и $\|f\|_{p(\cdot)} \leq \mu$. Следовательно, вложение $L^{\infty}(\Omega) \subset L^{p(\cdot)}(\Omega)$ установлено.

Примеры быстро растущих показателей. Рассмотрим $\Omega = [1, \infty)$.

- Пусть $p(x) = x$. Для любого $\lambda > 1$ имеем

$$\int_1^{\infty} \lambda^{-x} dx = \int_1^{\infty} e^{-x \ln \lambda} dx = \frac{e^{-\ln \lambda}}{\ln \lambda} = \frac{1}{\lambda \ln \lambda} < \infty.$$

При $\lambda \leq 1$ интеграл расходится. Поэтому

$$w(\Omega) = \inf \left\{ \lambda > 0: \int_1^{\infty} \lambda^{-x} dx < \infty \right\} = 1 < \infty.$$

- Пусть $p(x) = \lfloor x \rfloor$ (целая часть). Для $\lambda > 1$ оценка:

$$\int_1^{\infty} \lambda^{-\lfloor x \rfloor} dx \leq \int_1^{\infty} \lambda^{-x+1} dx = \lambda \int_1^{\infty} \lambda^{-x} dx = \frac{\lambda}{\lambda \ln \lambda} = \frac{1}{\ln \lambda} < \infty.$$

Снова $w(\Omega) = 1 < \infty$.

Таким образом, для таких быстро растущих показателей условие $w(\Omega) < \infty$ выполняется, и вложение $L^{\infty}(\Omega) \subset L^{p(\cdot)}(\Omega)$ справедливо. $\square$

2.9 Идея «переменного» показателя и связи с задачами ИНС

Как указано в лекции, переменные пространства Лебега позволяют контролировать особенности функций точно. Например, функция $g(x) = 1/\sqrt{|x|}$ не принадлежит ни одному классическому пространству $L^p(\mathbb{R})$, но можно подобрать переменный показатель $p(x)$, такой что $g \in L^{p(\cdot)}$. Это полезно в задачах аппроксимации нейронными сетями, где функция может иметь различные особенности в разных областях.

Нейронные сети аппроксимируют функции и операторы между функциональными пространствами. Для формулировки теорем о универсальной аппроксимации, устойчивости и оценках ошибок необходимы точные пространства, нормы и двойственные пространства. Переменные пространства Лебега предоставляют гибкий инструмент для таких задач.

Основу лекции составили статьи Цыбенко, Хорника, Стинчкомба и Уайта [1, 2, 3].

3 Классические теоремы об универсальной аппроксимации для функций в C и L^p

3.1 Универсальная аппроксимация в метрическом/банаховом пространстве

Определение (Универсальная аппроксимация). Пусть (X, d) — метрическое пространство (часто банахово или нормированное). Класс функций $\mathcal{Y} \subset X$ обладает **свойством универсальной аппроксимации** (УА), если для любой функции $f \in X$ и любого $\varepsilon > 0$ существует функция $g \in \mathcal{Y}$ такая, что:

$$d(f, g) < \varepsilon.$$

В контексте искусственных нейронных сетей:

- X — пространство целевых функций (например, $C(K)$ или $L^p(\mu)$)
- $\mathcal{Y}$ — множество функций, реализуемых нейронной сетью с одним скрытым слоем:

$$g(x) = \sum_{j=1}^m \alpha_j \sigma(w_j \cdot x + b_j),$$

где $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ — функция активации.

Замечание. Наличие УА означает, что сколь угодно сложную функцию можно приблизить с любой заранее заданной точностью с помощью достаточно большой нейронной сети определённой архитектуры.

3.2 Классические теоремы для $C(K)$

Теорема 3.1 (Цыбенко, 1989). Пусть $K \subset \mathbb{R}^n$ — компактное множество, $C(K)$ — пространство непрерывных функций на K с равномерной нормой $\|f\|_\infty = \sup_{x \in K} |f(x)|$. Пусть $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ — непрерывная и **дискриминаторная** функция активации. Тогда множество функций вида

$$G(x) = \sum_{j=1}^N \alpha_j \sigma(w_j \cdot x + \theta_j)$$

плотно в $C(K)$.

Определение (Дискриминаторная функция). Функция σ называется **дискриминаторной** для $C(K)$, если для любой конечной знакопеременной регулярной борелевской меры μ на K из условия

$$\int_K \sigma(w \cdot x + b) d\mu(x) = 0 \quad \forall w \in \mathbb{R}^n, b \in \mathbb{R}$$

следует, что $\mu \equiv 0$.

Схема доказательства. Предположим противное: линейная оболочка $S = \text{span}\{\sigma(w \cdot x + b)\}$ не плотна в $C(K)$. Тогда:

- 1) Существует собственное замкнутое подпространство $R = \overline{S} \subsetneq C(K)$.

2) По теореме Хана–Банаха $\exists L \in C(K)^*$, $L \neq 0$, такой что $L|_R = 0$.

3) По теореме Рисса–Маркова–Какутани $\exists \mu \in \mathcal{M}(K)$, $\mu \neq 0$:

$$L(f) = \int_K f(x) d\mu(x) \quad \forall f \in C(K).$$

4) В частности, для всех w, b :

$$0 = L(\sigma(w \cdot x + b)) = \int_K \sigma(w \cdot x + b) d\mu(x).$$

5) По дискриминаторности σ имеем $\mu \equiv 0$, что противоречит $L \neq 0$.

Следовательно, S плотно в $C(K)$. □

Пример. Дискриминаторными функциями являются:

- Любая непрерывная сигмоидальная функция (логистическая сигмоида, гиперболический тангенс);
- Любая ограниченная измеримая неконстантная функция;
- ReLU (через комбинации можно построить ограниченные функции).

Одним из обобщений предыдущей теоремы является результат Хорника, Стинчкоба и Уайта.

Теорема 3.2 (Хорник–Стинчкомб–Уайт, 1990). Пусть σ — непрерывная, ограниченная и неконстантная функция активации. Тогда для любого компакта $K \subset \mathbb{R}^n$ множество

$$\mathcal{N}_\sigma = \left\{ \sum_{j=1}^m \alpha_j \sigma(w_j \cdot x + b_j) \right\}$$

плотно в $C(K)$ в равномерной норме.

Замечание. Эта теорема показывает, что:

- УА достигается даже без требования сигмоидальности.
- Достаточно ограниченности и неконстантности активационной функции.
- Именно архитектура сети (один скрытый слой), а не конкретный вид активации, обеспечивает универсальность.

3.3 Понятие discriminatory/non-polynomial активации

Ключевое значение в предыдущих теоремах играли следующие факты:

Лемма 3.1 (Цыбенко). *Любая ограниченная, измеримая, сигмоидальная функция является дискриминаторной.*

Лемма 3.2 (Хорник). *Любая ограниченная неконстантная функция является дискриминаторной (непрерывность не требуется).*

Но это лишь достаточные условия, в 1993 Лешно, Лин, Пинкус и Шокен вывели критерий для функции активации, обеспечивающий УА для многослойного перцептрона с одним скрытым слоем в пространстве непрерывных функций.

Теорема 3.3 (LLPS). *Пусть σ — локально ограниченная и кусочно-непрерывная функция. Тогда*

$$\mathcal{N}_\sigma \text{ плотно в } C(\mathbb{R}^n) \text{ (равномерно на компактах)} \iff \sigma \text{ не полином п.в.}$$

Основные идеи. Необходимость: если σ — полином степени d , то $\mathcal{N}_\sigma$ состоит из полиномов степени $\leq d$, которые не плотны в $C(K)$.

Достаточность:

- 1) Сведение к одномерному случаю через плотность хребтовых функций
- 2) Рассмотрение свёрток $\sigma * \varphi$ с $\varphi \in C_c^\infty$
- 3) Разбор двух случаев:
 - Если $\exists \varphi : \sigma * \varphi$ не полином $\Rightarrow$ плотность через теорему Вейерштрасса
 - Если $\forall \varphi : \sigma * \varphi$ — полином $\Rightarrow \sigma$ — полином почти всюду (противоречие)

□

Замечание. Теорема LLPS явно даёт необходимое и достаточное условие: активационная функция **не должна быть полиномом**. Это объясняет, почему ReLU, сигмоиды, тригонометрические функции работают, а квадратичная активация — нет.

3.4 УА на $C(\mathbb{R}^n)$ с метрикой Фреше, связь с компактными множествами

На $C(\mathbb{R}^n)$ равномерная норма неприменима (функции могут быть неограниченными). Используются **компактно-открытая топология**, задаваемая метрикой Фреше:

Определение (Метрика Фреше). Для $f, g \in C(\mathbb{R}^n)$ определим:

$$d(f, g) = \sum_{k=1}^{\infty} 2^{-k} \frac{\|(f - g) \cdot \mathbf{1}_{[-k, k]^n}\|_{\infty}}{1 + \|(f - g) \cdot \mathbf{1}_{[-k, k]^n}\|_{\infty}}.$$

Замечание. Свойства метрики d :

- d — метрика на $C(\mathbb{R}^n)$;
- $f_m \rightarrow f$ по $d \iff f_m \rightarrow f$ равномерно на каждом компакте;
- Веса 2^{-k} обеспечивают убывание влияния ошибок на больших кубах.

УА на $C(\mathbb{R}^n)$

Теорема 3.4 (Пинкус-Стинчкомб, 1991). Пусть σ непрерывна и дискриминаторна. Тогда для любой $f \in C(\mathbb{R}^n)$ и $\varepsilon > 0$ существует нейронная сеть

$$g(x) = \sum_{j=1}^m \alpha_j \sigma(w_j \cdot x + b_j)$$

такая, что $d(f, g) < \varepsilon$.

Доказательство. Приведём основные шаги доказательства теоремы.

Усечение хвоста: Выбираем M так, что $\sum_{k=M+1}^{\infty} 2^{-k} < \varepsilon/2$.

Аппроксимация на $K_M = [-M, M]^n$: По теореме Цыбенко находим g с

$$\|(f - g) \cdot \mathbf{1}_{K_M}\|_{\infty} \leq \delta.$$

Оценка расстояния:

$$d(f, g) = \underbrace{\sum_{k=1}^M 2^{-k} \frac{\|(f - g)\mathbf{1}_{K_k}\|_{\infty}}{1 + \|\cdots\|_{\infty}}}_{(I)} + \underbrace{\sum_{k=M+1}^{\infty} 2^{-k} \frac{\|\cdots\|_{\infty}}{1 + \|\cdots\|_{\infty}}}_{(II)},$$

где (I) $\leq \frac{\delta}{1+\delta} \sum_{k=1}^M 2^{-k} \leq \frac{\delta}{1+\delta}$, а (II) $< \varepsilon/2$ по выбору M .

Выбирая δ так, что $\frac{\delta}{1+\delta} < \varepsilon/2$ получаем итог: $d(f, g) < \varepsilon$.

□

Замечание. Ключевая идея: аппроксимация на всём $\mathbb{R}^n$ сводится к аппроксимации на последовательности компактов $K_k = [-k, k]^n$, исчерпывающих пространство. Метрика d тут:

- Взвешивает ошибки на компактах K_k убывающими весами 2^{-k} .
- Позволяет контролировать поведение на бесконечности.
- Согласована с компактно-открытой топологией.

3.5 Теорема Хорника (1991): универсальная аппроксимация в $L^p(\mu)$

Теорема 3.5 (Hornik, 1991). Если $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ — ограниченная и непостоянная функция, то для любой конечной меры μ на $\mathbb{R}^k$ и любого $1 \leq p < \infty$, класс $\mathcal{N}_{\sigma}$ плотен в $L^p(\mu)$.

Перед этим приведём доказательство раннее озвученной леммы Хорника.

Доказательство леммы. 1. Сведение к одномерному случаю:

Фиксируем направление $u \in \mathbb{R}^k$ и определим выталкивающую меру (pushforward measure) α_u на $\mathbb{R}$:

$$\alpha_u(B) = \alpha(\{x \in \mathbb{R}^k : u \cdot x \in B\}) \quad \text{для борелевских } B \subset \mathbb{R}.$$

Для любой ограниченной измеримой функции $Z: \mathbb{R} \rightarrow \mathbb{R}$:

$$\int_{\mathbb{R}^k} Z(u \cdot x) d\alpha(x) = \int_{\mathbb{R}} Z(t) d\alpha_u(t).$$

Из условий леммы следует, что для всех $\lambda, \theta \in \mathbb{R}$:

$$\int_{\mathbb{R}} \sigma(\lambda t - \theta) d\alpha_u(t) = 0.$$

2. Выбор сглаживающей функции:

Выберем $w \in L^1(\mathbb{R})$ с ненулевым преобразованием Фурье (например, $w(t) = e^{-t^2}$). Рассмотрим свёртку:

$$h = w * \alpha_u \in L^1(\mathbb{R}),$$

её преобразование Фурье: $\widehat{h}(\omega) = \widehat{w}(\omega) \widehat{\alpha}_u(\omega)$.

3. Аннулирование сдвигами и растяжениями:

Из условия $\int_{\mathbb{R}} \sigma(\lambda t - \theta) d\alpha_u(t) = 0$ и свойства свёртки следует:

$$\int_{\mathbb{R}} \sigma(t) h(\alpha t - \gamma) dt = 0 \quad \forall \alpha \neq 0, \gamma \in \mathbb{R}.$$

Это означает, что линейный функционал $L(f) = \int_{\mathbb{R}} \sigma(t) f(t) dt$ аннулирует все функции вида $h(\alpha t - \gamma)$.

4. Анализ замкнутого подпространства: Рассмотрим замкнутое инвариантное относительно сдвигов и растяжений подпространство:

$$I_h = \overline{\text{span}}\{h(\alpha \cdot - \gamma) : \alpha \neq 0, \gamma \in \mathbb{R}\} \subset L^1(\mathbb{R}).$$

Это идеал в $L^1(\mathbb{R})$. Его нулевое множество (zero set):

$$Z(I_h) = \{\omega \in \mathbb{R} : \widehat{f}(\omega) = 0 \quad \forall f \in I_h\}.$$

Так как $\widehat{h}(0) = \int_{\mathbb{R}} h(t) dt = \int_{\mathbb{R}} d(w * \alpha_u)(t) = 0$ (из условия при $\lambda = 0$), и $\widehat{h}(\omega/\alpha) = \alpha \widehat{h}(\omega)$ для растяжений, то $Z(I_h) = \{0\}$.

5. Применение теоремы Таубера-Винера:

По теореме Винера (Rudin, Fourier Analysis on Groups), единственный замкнутый идеал в $L^1(\mathbb{R})$ с $Z(I) = \{0\}$ — это множество функций с нулевым средним:

$$I_h = \left\{ f \in L^1(\mathbb{R}) : \int_{\mathbb{R}} f(t) dt = 0 \right\}.$$

6. Вывод о постоянстве σ :

Так как $L(f) = 0$ для всех $f \in I_h$, то в частности для любой $f \in L^1(\mathbb{R})$ с $\int f = 0$ имеем $\int \sigma f = 0$. Это означает, что функционал L зависит только от среднего значения:

$$\exists c \in \mathbb{R} : \int_{\mathbb{R}} \sigma(t) f(t) dt = c \int_{\mathbb{R}} f(t) dt \quad \forall f \in L^1(\mathbb{R}).$$

Следовательно, $\sigma(t) = c$ почти всюду — противоречие с непостоянностью σ .

7. Завершение доказательства:

Таким образом, $h = 0$, значит $\widehat{\alpha}_u = 0$ (так как $\widehat{w}$ не обращается в ноль). По теореме единственности для преобразования Фурье мер $\alpha_u = 0$ для всех $u \in \mathbb{R}^k$. Наконец, преобразование Фурье меры α :

$$\widehat{\alpha}(u) = \int_{\mathbb{R}^k} e^{iu \cdot x} d\alpha(x) = \int_{\mathbb{R}} e^{it} d\alpha_u(t) = 0 \quad \forall u \in \mathbb{R}^k.$$

Следовательно, $\alpha = 0$. □

Теперь, следуя оригинальной статье, докажем саму теорему.

Доказательство теоремы Хорника. Проведём рассуждение поэтапно.

1. Предположение противного: Пусть $\overline{\mathcal{N}}_\sigma^{L^p(\mu)} \neq L^p(\mu)$.

2. Разделяющий функционал: По теореме Хана-Банаха существует ненулевой непрерывный линейный функционал $\Lambda \in (L^p(\mu))^*$, аннулирующий $\mathcal{N}_\sigma$.

3. Представление функционала: По теореме об представлении $(L^p)^* \cong L^q(\mu)$ ($1/p + 1/q = 1$), существует $g \in L^q(\mu)$, $g \neq 0$, такой что

$$\Lambda(f) = \int_{\mathbb{R}^k} f(x)g(x)d\mu(x) \quad \forall f \in L^p(\mu).$$

4. Мера, аннулирующая σ : Определим конечную знаковую меру α : $d\alpha(x) = g(x)d\mu(x)$. Тогда

$$\int_{\mathbb{R}^k} \sigma(w \cdot x + b)d\alpha(x) = 0 \quad \forall w \in \mathbb{R}^k, b \in \mathbb{R}.$$

5. Применение леммы о дискриминативности: По лемме 1, $\alpha = 0$, значит $g = 0$ п.в. — противоречие с $g \neq 0$.

6. Вывод: Следовательно, $\mathcal{N}_\sigma$ плотно в $L^p(\mu)$. $\square$

Следствие 3.1 (Равномерная аппроксимация на компактах). *Если σ непрерывна, ограничена и непостоянна, то для любого компакта $K \subset \mathbb{R}^k$ класс $\mathcal{N}_\sigma$ плотен в $C(K)$ относительно равномерной нормы.*

3.6 Гладкая аппроксимация (Хорник-Стинчкомб-Уайт, 1990)

Теорема 3.6 (Хорник-Стинчкомб-Уайт, 1990). *Пусть $\sigma \in C^m(\mathbb{R})$ ограничена вместе со своими производными до порядка m . Тогда:*

1. $\mathcal{N}_\sigma$ равномерно m -плотен на компактах в $C^m(\mathbb{R}^k)$
2. $\mathcal{N}_\sigma$ плотен в весовых пространствах Соболевского типа $C^{m,p}(\mu)$ для конечной меры μ

Проясним понятия, встретившиеся в формулировке данного утверждения.

Определение (l -конечная функция). Функция σ называется l -конечной, если $\sigma \in C^l(\mathbb{R})$ и $0 < \int_{\mathbb{R}} |D^l \sigma(t)| dt < \infty$.

Лемма 3.3 (Построение гладкой функции из σ). *Если σ l -конечна, то для любого $0 \leq m \leq l$ существует $H \in S_1^m(\mathbb{R}, \lambda)$ (пространство Соболева), $H \neq 0$, такая что $\Sigma(H) \subset \Sigma(\sigma)$.*

Схема доказательства. Используется конструкция конечных разностей. Для фиксированного $a > 0$ определим оператор Δ_a :

$$\Delta_a f(x) = f(x+a) - f(x).$$

Результат его итераций: $\Delta_a^n f(x) = \sum_{j=0}^n (-1)^{n-j} \binom{n}{j} f(x+ja)$.

Если σ l -конечна, то можно показать, что $\Delta_a^l \sigma \in S_1^m(\mathbb{R}, \lambda)$ для $m \leq l$. $\square$

Помимо этого нам потребуется специальное интегральное представление также известное, как метод Ири-Мияке.

Лемма 3.4 (Интегральное представление). Пусть $G \in S_1^m(\mathbb{R}, \lambda)$, $G \neq 0$. Тогда для любой $f \in C_c^\infty(\mathbb{R}^k)$ (гладкие финитные функции) и любого мультииндекса $|\alpha| \leq m$:

$$D^\alpha f(x) = \iint_{\mathbb{R} \times \mathbb{R}} a^\alpha D^\alpha G(a \cdot x - \theta) K(a, \theta) da d\theta, \quad \text{где} \quad K(a, \theta) = \frac{|b| \widehat{f}(ba) e^{2\pi i b \theta}}{\widehat{G}(b)}$$

для некоторого $b \neq 0$ с $\widehat{G}(b) \neq 0$.

Идея доказательства. Используется формула обращения преобразования Фурье и свойства свертки. $\square$

Интегралы же мы будем приближать римановыми суммами по следующей лемме.

Лемма 3.5 (Аппроксимация конечными суммами). Для компакта $K \subset \mathbb{R}^k$ и $\varepsilon > 0$ существуют конечные наборы параметров $\{(a_i, \theta_i, \beta_i)\}_{i=1}^N$ такие что

$$\left\| D^\alpha f(x) - \sum_{i=1}^N \beta_i a_i^\alpha D^\alpha G(a_i \cdot x - \theta_i) \right\|_{L^\infty(K)} < \varepsilon.$$

Доказательство. **1. Усечение области интегрирования:** Выбираем $M > 0$ так, чтобы

$$\int_{|a|>M} \int_{|\theta|>\gamma M} |a^\alpha D^\alpha G(a \cdot x - \theta) K(a, \theta)| da d\theta < \varepsilon/2.$$

2. Равномерная непрерывность: На компактной области $[-M, M] \times [-\gamma M, \gamma M]$ подынтегральная функция равномерно непрерывна.

3. Римановы суммы: Разбиваем область на мелкие ячейки и заменяем интеграл суммой:

$$S_N(x) = \sum_{i=1}^N \beta_i a_i^\alpha D^\alpha G(a_i \cdot x - \theta_i).$$

При достаточно мелком разбиении $\|D^\alpha f - S_N\|_{L^\infty(K)} < \varepsilon$. $\square$

Теперь перейдём к самой обоснованию теоремы Хорника-Стинчкомба-Уайта.

Доказательство. **1. Случай $G \in S_1^m(\mathbb{R}, \lambda)$:** Из последних двух лемм непосредственно следует, что $\Sigma(G)$ m -равномерно плотен на компактах в $C_c^\infty(\mathbb{R}^k)$, а значит и в $C^m(\mathbb{R}^k)$.

2. Сведение к l -конечным функциям: По лемме, если σ l -конечна ($l \geq m$), то существует $H \in S_1^m(\mathbb{R}, \lambda)$ с $\Sigma(H) \subset \Sigma(\sigma)$. Следовательно, $\Sigma(\sigma)$ также обладает свойством аппроксимации.

3. Пространства Соболева: Для $f \in C^{m,p}(\mu)$ с компактным носителем K :

$$\|f - g\|_{m,p,\mu} \leq \mu(K)^{1/p} \|f - g\|_{m,K}.$$

Аппроксимируем f функцией $g \in \mathcal{N}_\sigma$ с малой m -нормой на K .

4. Общий случай меры μ : Если μ не имеет компактного носителя, используем покрытие $\mathbb{R}^k$ компактами K_n и строим аппроксимации на каждом K_n , контролируя хвостовую ошибку. $\square$

3.7 Теорема Лешно-Лин-Пинкуса-Шоккена (1993)

Теорема 3.7 (LLPS, L^p вариант). Пусть $\sigma \in L_{loc}^\infty(\mathbb{R})$ кусочно непрерывна и меры Лебега множества точек разрыва нулевая. Положим

$$\Sigma_n = \text{span}\{\sigma(w \cdot x + \theta) : w \in \mathbb{R}^n, \theta \in \mathbb{R}\}.$$

Тогда Σ_n плотно в $C(\mathbb{R}^n)$ (равномерно на компактах) **тогда и только тогда**, когда σ не является полиномом почти всюду.

Доказательство. ($\Rightarrow$) Если σ — полином степени k , то любая функция $\sigma(w \cdot x + \theta)$ — полином степени $\leq k$. Следовательно, Σ_n содержится в конечномерном пространстве полиномов степени $\leq k$, которое не может быть плотным в бесконечномерном пространстве $C(\mathbb{R}^n)$.

($\Leftarrow$) **Шаг 1: Сведение к одномерному случаю**

Лемма 3.6 (Плотность ridge-функций). Пространство $V = \text{span}\{f(a \cdot x) : a \in \mathbb{R}^n, f \in C(\mathbb{R})\}$ плотно в $C(\mathbb{R}^n)$.

Доказательство. Следует из работ Vostrecov-Kreines (1961) и Dahmen-Micchelli (1987). $\square$

Из этой леммы следует, что если Σ_1 плотно в $C(\mathbb{R})$, то Σ_n плотно в $C(\mathbb{R}^n)$.

Шаг 2: Сглаживание свёрткой

Для $\varphi \in C_c^\infty(\mathbb{R})$ определим свёртку:

$$(\sigma * \varphi)(x) = \int_{\mathbb{R}} \sigma(x - y) \varphi(y) dy.$$

Лемма 3.7. Для любого $\varphi \in C_c^\infty(\mathbb{R})$, функция $\sigma * \varphi$ принадлежит замыканию $\bar{\Sigma}_1$ (в топологии равномерной сходимости на компактах).

Ключевые конструкции. **1. Римановы суммы:** Зафиксируем $\text{supp } \varphi \subset [-A, A]$. Аппроксимируем интеграл суммой:

$$S_N(x) = \sum_{i=1}^N \sigma(x - y_i) \varphi(y_i) \Delta y_i,$$

где $-A = y_1 < y_2 < \dots < y_N = A$, $\Delta y_i = y_{i+1} - y_i = 2A/N$.

2. Оценка погрешности: Разность

$$|(\sigma * \varphi)(x) - S_N(x)| \leq \sum_{i=1}^N \int_{y_i}^{y_{i+1}} |\sigma(x - y) - \sigma(x - y_i)| |\varphi(y)| dy.$$

3. Разделение на «хорошие» и «плохие» интервалы: Интервал будет *хорошим*, если σ равномерно непрерывна на $[x - y_{i+1}, x - y_i]$, то

$$|\sigma(x - y) - \sigma(x - y_i)| \leq \omega(2A/N),$$

где ω — модуль непрерывности. *Плохими* будут интервалы, содержащие точки разрыва σ . По условию, мера множества точек разрыва нулевая, поэтому суммарная длина таких интервалов мала при мелком разбиении.

4. Равномерная оценка: При $N \rightarrow \infty$ погрешность стремится к 0 равномерно на компактах. $\square$

Шаг 3: Анализ сглаженных функций

Лемма 3.8. Если для некоторого $\varphi \in C_c^\infty(\mathbb{R})$ функция $\sigma * \varphi$ не является полиномом, то Σ_1 плотно в $C(\mathbb{R})$.

Доказательство. 1. По ранее озвученной лемме, $\sigma * \varphi \in \overline{\Sigma}_1$.

2. Так как $(\sigma * \varphi)(wx + \theta) \in \overline{\Sigma}_1$ для всех w, θ , то $\overline{\Sigma}_1$ содержит все сдвиги и растяжения $\sigma * \varphi$.

3. Если $\sigma * \varphi$ не полином, то её производные (которые также лежат в $\overline{\Sigma}_1$ через разностные отношения) порождают все полиномы.

4. По теореме Вейерштрасса, полиномы плотны в $C(\mathbb{R})$. $\square$

Шаг 4: Случай, когда все свёртки — полиномы

Лемма 3.9 (Теорема Бэра о категории). Если $\sigma * \varphi$ — полином для всех $\varphi \in C_c^\infty(\mathbb{R})$, то существует $m \in \mathbb{N}$ такое, что все $\sigma * \varphi$ — полиномы степени $\leq m$.

Доказательство. 1. Рассмотрим пространство $C_c^\infty([a, b])$ с метрикой

$$\rho(\varphi_1, \varphi_2) = \sum_{n=0}^{\infty} 2^{-n} \frac{\|\varphi_1 - \varphi_2\|_n}{1 + \|\varphi_1 - \varphi_2\|_n},$$

где $\|\varphi\|_n = \sum_{j=0}^n \sup_{x \in [a, b]} |\varphi^{(j)}(x)|$.

2. Множества $V_k = \{\varphi \in C_c^\infty([a, b]) : \deg(\sigma * \varphi) \leq k\}$ замкнуты.

3. По условию, $\bigcup_{k=0}^{\infty} V_k = C_c^\infty([a, b])$.

4. По теореме Бэра, некоторое V_m содержит внутреннюю точку. Так как V_m — линейное подпространство, то $V_m = C_c^\infty([a, b])$. 5. Аргумент распространяется на все компактные интервалы. $\square$

Лемма 3.10 (Теория распределений). Если $\sigma * \varphi$ — полином степени $\leq m$ для всех $\varphi \in C_c^\infty(\mathbb{R})$, то σ — полином степени $\leq m$ почти всюду.

Доказательство. Из условия следует, что для всех $\varphi \in C_c^\infty(\mathbb{R})$:

$$\int_{\mathbb{R}} \sigma(x - y) \varphi^{(m+1)}(y) dy = 0.$$

В терминах распределений: $\sigma * \varphi^{(m+1)} = 0$. По свойствам свертки, это означает, что распределенная производная $D^{m+1}\sigma = 0$, следовательно σ — полином степени $\leq m$. $\square$

Шаг 5: Завершение доказательства

Если σ не полином, то по последней лемме существует $\varphi \in C_c^\infty(\mathbb{R})$ такая, что $\sigma * \varphi$ не полином. По лемме из шага 3, Σ_1 плотно в $C(\mathbb{R})$. По лемме 5, Σ_n плотно в $C(\mathbb{R}^n)$. $\square$

Замечание (О необходимости порога (смещения)). Без порога θ теорема LLPS неверна. Порог необходим для получения полноты системы сдвигов $\{\sigma(\cdot + \theta)\}$.

Пример. Рассмотрим $\sigma(x) = \sin x$ без порога. Множество $\{\sin(w \cdot x) : w \in \mathbb{R}^n\}$ состоит только из нечётных функций. Чётная функция $\cos x$ на $[-1, 1]$ не может быть равномерно аппроксимирована линейными комбинациями нечётных функций.

С добавлением порога: $\sin(x + \pi/2) = \cos x$, что позволяет аппроксимировать чётные функции.

3.8 Сравнительный анализ условий на активационные функции

Теорема	Требования к σ	Пространство	Условие полноты
Cybenko (1989)	Непрерывная сигмоидальная	$C(K)$	Дискриминативность
Hornik (1991)	Ограниченная, непостоянная	$L^p(\mu)$	Дискриминативность
Hornik et al. (1990)	C^m , ограниченные производные	$C^m(\mathbb{R}^k)$	l -конечность
LLPS (1993)	Локально ограниченная, кусочно непрерывная	$C(\mathbb{R}^n)$	Не полиномиальность

3.9 Заключительные наблюдения

Представленные теоремы демонстрируют эволюцию понимания универсальных аппроксимационных свойств нейронных сетей:

1. **Cybenko (1989):** Показал, что непрерывные сигмоидальные функции обеспечивают плотность в $C(K)$.
2. **Hornik (1991):** Существенно ослабил условия — достаточно ограниченности и непостоянности для плотности в $L^p(\mu)$.
3. **Hornik-Stinchcombe-White (1990):** Расширили результаты на случай одновременной аппроксимации функции и её производных.
4. **Leshno-Lin-Pinkus-Schocken (1993):** Дали полную характеристику: неполиномиальность является **необходимым и достаточным** условием универсальной аппроксимации.

Все доказательства используют единую схему: разделение функционалом, представление мерой, анализ аннулирующих свойств через преобразование Фурье и теорию распределений.

Основные техники доказательств:

- Функциональный анализ (теорема Хана-Банаха, теоремы о представлении)
- Гармонический анализ (преобразование Фурье, теорема Таубера-Винера)
- Теория распределений (обобщенные производные)
- Теорема Бэра о категории

Замечания.

- Условия на σ в теореме LLPS минимальны: достаточно **неполиномиальности**.
- Теорема Хорника (1991) обобщает результаты Cybenko (1989), снимая требование сигмоидальности.
- Гладкая аппроксимация требует дополнительной гладкости σ , но не обязательной монотонности или ограниченности производных на всей прямой.
- Все доказательства используют единую схему: разделение функционалом, представление мерой, доказательство дискриминаторности.

4 Универсальная аппроксимация для нелинейных операторов

4.1 Предварительные сведения: компактность, функции Таубера–Винера и активации

Компактность и компактно-открытая топология: Пусть X — банахово пространство над $\mathbb{R}$ (или $\mathbb{C}$) с нормой $\|\cdot\|_X$. Для компактного $K \subset X$ обозначим через $C(K)$ пространство непрерывных функций $u : K \rightarrow \mathbb{R}$ (или $\mathbb{C}$) с нормой

$$\|u\|_{C(K)} := \sup_{x \in K} |u(x)|.$$

Эту же норму часто называют *равномерной нормой*.

Компактность в банаховом пространстве: Поскольку любое банахово пространство метризуемо, компактность эквивалентна секвенциальной компактности. Кроме того, множество $A \subset X$ *относительно компактно* тогда и только тогда, когда оно *сверхограничено* (для любого $\varepsilon > 0$ покрывается конечным числом ε -шаров), а его замыкание полно.

Компактно-открытая топология (локально равномерная сходимост): На $C(\mathbb{R}^n)$ рассматриваем топологию равномерной сходимости на компактах. Положим $K_k = [-k, k]^n$. Тогда

$$d(f, g) := \sum_{k=1}^{\infty} 2^{-k} \frac{\|(f - g)\mathbf{1}_{K_k}\|_{\infty}}{1 + \|(f - g)\mathbf{1}_{K_k}\|_{\infty}}$$

метризует компактно-открытую топологию; в частности, $f_m \rightarrow f$ в этой метрике тогда и только тогда, когда $\|f_m - f\|_{C(K)} \rightarrow 0$ для любого компакта $K \subset \mathbb{R}^n$.

Определение (Пространство Шварца). *Пространство Шварца* $\mathcal{S}(\mathbb{R}^n)$ — это множество гладких функций $\varphi \in C^{\infty}(\mathbb{R}^n)$, которые вместе со всеми производными убывают быстрее любой степени: для любых мультииндексов α, β конечна полунорма

$$p_{\alpha, \beta}(\varphi) := \sup_{x \in \mathbb{R}^n} |x^{\alpha} \partial^{\beta} \varphi(x)| < \infty.$$

Эквивалентно: φ и все $\partial^{\beta} \varphi$ имеют *быстрое убывание* на бесконечности.

Определение (Умеренные распределения). *Пространство умеренных распределений* $\mathcal{S}'(\mathbb{R}^n)$ определяется как *двойственное* к $\mathcal{S}(\mathbb{R}^n)$:

$$\mathcal{S}'(\mathbb{R}^n) := (\mathcal{S}(\mathbb{R}^n))^*.$$

То есть элемент $T \in \mathcal{S}'(\mathbb{R}^n)$ — линейный функционал $T : \mathcal{S}(\mathbb{R}^n) \rightarrow \mathbb{R}$, непрерывный в стандартной топологии пространства Шварца: существуют конечный набор (α_k, β_k) и $C > 0$, что

$$|\langle T, \varphi \rangle| \leq C \sum_{k=1}^m \sup_{x \in \mathbb{R}^n} |x^{\alpha_k} \partial^{\beta_k} \varphi(x)| \quad \forall \varphi \in \mathcal{S}(\mathbb{R}^n).$$

Сходимость $T_{\ell} \rightarrow T$ в $\mathcal{S}'$ означает $\langle T_{\ell}, \varphi \rangle \rightarrow \langle T, \varphi \rangle$ для всех $\varphi \in \mathcal{S}$ (поточечная или слабая сходимость).

Тестовые функции и распределения: Пусть $C_0^{\infty}(\mathbb{R}^n)$ — пространство *тестовых функций* (гладких с компактным носителем). Тогда $\mathcal{D}'(\mathbb{R}^n) := (C_0^{\infty}(\mathbb{R}^n))'$ называется *пространством распределений* (т.е. непрерывным двойственным к C_0^{∞}).

Пример. Некоторые классические вложения:

- Если $f \in L^1_{\text{loc}}(\mathbb{R}^n)$ и f имеет полиномиальный рост, т.е.

$$\exists m \in \mathbb{N}, \exists C > 0 : \quad |f(x)| \leq C(1 + \|x\|)^m \text{ п.в.},$$

то формула $\langle T_f, \varphi \rangle = \int_{\mathbb{R}^n} f(x)\varphi(x) dx$ задаёт элемент $T_f \in \mathcal{S}'(\mathbb{R}^n)$.

- Конечные борелевские меры μ задают $T_\mu(\varphi) = \int \varphi d\mu$; это распределения порядка 0.
- Дельта-функция Дирака $\delta_{x_0} \in \mathcal{S}'$ и её производные: $\langle \partial^\alpha \delta_{x_0}, \varphi \rangle = (-1)^{|\alpha|} \partial^\alpha \varphi(x_0)$.

Отметим, какие операции определены в $\mathcal{S}'$, для $T \in \mathcal{S}'$, $\varphi \in \mathcal{S}$:

$$\langle \partial^\alpha T, \varphi \rangle := (-1)^{|\alpha|} \langle T, \partial^\alpha \varphi \rangle, \quad \langle x^\beta T, \varphi \rangle := \langle T, x^\beta \varphi \rangle,$$

а свёртка с тестовой функцией $(T * \varphi)(x) := \langle T, \varphi(x - \cdot) \rangle$ даёт гладкую функцию. Так же нам полезно научиться сглаживать функции, сделать это можно, например, так: пусть $\eta \in C_0^\infty(\mathbb{R})$, $\eta \geq 0$, $\int_{\mathbb{R}} \eta(x) dx = 1$ и $\eta_\varepsilon(x) := \varepsilon^{-1} \eta(x/\varepsilon)$. Для $g \in L^1_{\text{loc}}(\mathbb{R})$ (или, шире, $g \in \mathcal{S}'(\mathbb{R})$) определим сглаживание $g_\varepsilon := g * \eta_\varepsilon$. Тогда $g_\varepsilon \in C^\infty(\mathbb{R})$, а при $\varepsilon \downarrow 0$ имеем $g_\varepsilon \rightarrow g$ в смысле распределений.

Замечание. В доказательствах критериев TW (через Хана-Банаха, меры Рисса и преобразование Фурье в $\mathcal{S}'$) удобно иметь дело с объектами, к которым корректно применяется аппарат $\mathcal{S}/\mathcal{S}'$. Именно поэтому полезно рассматривать классы функций с умеренным ростом.

На $\mathcal{S}(\mathbb{R}^n)$ определяем преобразование Фурье:

$$\widehat{\varphi}(\xi) = \int_{\mathbb{R}^n} \varphi(x) e^{-i\xi \cdot x} dx, \quad \varphi(x) = \frac{1}{(2\pi)^n} \int_{\mathbb{R}^n} \widehat{\varphi}(\xi) e^{i\xi \cdot x} d\xi,$$

и продолжаем на $\mathcal{S}'$ по правилу

$$\langle \widehat{T}, \varphi \rangle := \langle T, \widehat{\varphi} \rangle, \quad \varphi \in \mathcal{S}.$$

Отметим, что это топологический автоморфизм $\mathcal{S}' \rightarrow \mathcal{S}'$.

Компактность в $C(K)$: критерий Арцела-Асколи

Теорема 4.1 (Арцела–Асколи для $C(K)$). Пусть K — компактное метрическое пространство. Множество $V \subset C(K)$ относительно компактно тогда и только тогда, когда:

1. V равномерно ограничено: $\sup_{u \in V} \|u\|_{C(K)} < \infty$;
2. V равномерно непрерывно: для любого $\varepsilon > 0$ существует $\delta > 0$, что $|u(x) - u(y)| < \varepsilon$ для всех $u \in V$ при $d(x, y) < \delta$.

Более того, для компактного V существует общий модуль непрерывности $\omega_V(\cdot) \rightarrow 0$, такой что $|u(x) - u(y)| \leq \omega_V(d(x, y))$ для всех $u \in V$.

Замечание. В дальнейших конструкциях (аппроксимация по выборкам) ключевым является именно общий модуль ω_V : он позволяет выбрать сетку и разбиение единицы, которые работают одновременно для всех $u \in V$.

δ -сети, разбиения единицы и конечномерные операторы выборки

Пусть K — компактное метрическое пространство.

Определение (δ -сеть). Множество $N(\delta) = \{x_1, \dots, x_m\} \subset K$ называется δ -сетью, если $K \subset \bigcup_{j=1}^m B(x_j, \delta)$.

Предложение 4.1 (Разбиение единицы, подчинённое δ -сети). Для любого $\delta > 0$ существует непрерывное разбиение единицы $\{\tau_j\}_{j=1}^m \subset C(K)$, такое что $\sum_{j=1}^m \tau_j(x) = 1$ на K и $\text{supp } \tau_j \subset B(x_j, \delta)$.

Фиксируем δ -сеть и $\{\tau_j\}$, определим оператор выборки (ранга $\leq m$):

$$(\Pi_\delta u)(x) := \sum_{j=1}^m u(x_j) \tau_j(x), \quad u \in C(K). \quad (\star)$$

Лемма 4.1 (Оценка ошибки по модулю непрерывности). Если $V \subset C(K)$ равностепенно непрерывно с модулем ω_V , то для любого $u \in V$

$$\|u - \Pi_\delta u\|_{C(K)} \leq \omega_V(\delta).$$

В частности, при $\delta \rightarrow 0$ получаем $\sup_{u \in V} \|u - \Pi_\delta u\|_{C(K)} \rightarrow 0$.

Доказательство. Для $x \in K$:

$$u(x) - (\Pi_\delta u)(x) = \sum_{j=1}^m (u(x) - u(x_j)) \tau_j(x).$$

Если $\tau_j(x) \neq 0$, то $x \in \text{supp } \tau_j \subset B(x_j, \delta)$, значит $|u(x) - u(x_j)| \leq \omega_V(\delta)$. Поэтому

$$|u(x) - (\Pi_\delta u)(x)| \leq \sum_{j=1}^m \omega_V(\delta) \tau_j(x) = \omega_V(\delta) \sum_{j=1}^m \tau_j(x) = \omega_V(\delta).$$

Берём супремум по $x \in K$. □

Функции сигмоидальные и Таубера–Винера, дискриминаторность

Определение (Сигмоидальная функция). Функция $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ называется *сигмоидальной*, если

$$\lim_{x \rightarrow -\infty} \sigma(x) = 0, \quad \lim_{x \rightarrow +\infty} \sigma(x) = 1.$$

Определение (Функция Таубера–Винера). Функция $g: \mathbb{R} \rightarrow \mathbb{R}$ называется *функцией Таубера–Винера* (TW), если для любого отрезка $[a, b] \subset \mathbb{R}$ линейная оболочка

$$\text{span}\{g(\lambda x + \theta): \lambda \in \mathbb{R} \setminus \{0\}, \theta \in \mathbb{R}\}$$

плотна в $C[a, b]$ по равномерной норме $\|\cdot\|_{C[a, b]}$.

Дискриминаторная активация: В схеме Цыбенко–Хорника используют следующее свойство: если конечная борелевская мера со знаком (заряд) μ на $[a, b]$ удовлетворяет $\int_{[a, b]} g(\lambda x + \theta) d\mu(x) = 0$ для всех $\lambda \neq 0, \theta \in \mathbb{R}$, то $\mu = 0$. Такую активацию называют *дискриминаторной* (discriminatory).

4.2 Критерий «TW $\Leftrightarrow$ неполиномиальность» в $\mathcal{S}'(\mathbb{R})$

Теорема 4.2 (Чен и Чен, TW $\Leftrightarrow$ неполиномиальность). Пусть $g \in C(\mathbb{R}) \cap \mathcal{S}'(\mathbb{R})$. Тогда g является TW-функцией тогда и только тогда, когда g не является полиномом.

Доказательство. (Полином $\Rightarrow$ не TW). Если g — полином степени $\leq q$, то для любых $\lambda \neq 0$, $\theta \in \mathbb{R}$ функция $x \mapsto g(\lambda x + \theta)$ также является полиномом степени $\leq q$. Следовательно, $\text{span}\{g(\lambda x + \theta)\} \subset \mathcal{P}_q$, где $\mathcal{P}_q$ — конечномерное пространство полиномов степени $\leq q$. Но $\mathcal{P}_q$ не может быть плотным в бесконечномерном $C[a, b]$, значит g не TW.

(Не TW $\Rightarrow$ полином). Пусть $g \in C(\mathbb{R}) \cap \mathcal{S}'(\mathbb{R})$ и предположим, что g не является TW-функцией. Тогда существует отрезок $[a, b]$, на котором замкнутая линейная оболочка

$$\mathcal{L} := \overline{\text{span}\{g(\lambda x + \theta) : \lambda \neq 0, \theta \in \mathbb{R}\}} \subset C[a, b]$$

не совпадает с $C[a, b]$. По теореме Хана-Банаха существует ненулевой функционал $F \in (C[a, b])^*$ такой, что $F|_{\mathcal{L}} \equiv 0$. По теореме Рисса существует ненулевая конечная подписанная борелевская мера ρ на $[a, b]$, что

$$F(f) = \int_{[a, b]} f(x) d\rho(x), \quad f \in C[a, b],$$

и, в частности,

$$\int_{[a, b]} g(\lambda x + \theta) d\rho(x) = 0 \quad \forall \lambda \neq 0, \forall \theta \in \mathbb{R}. \quad (1)$$

Продлим ρ нулём вне $[a, b]$, рассматривая её как конечную меру на $\mathbb{R}$.

Шаг 1: распределение по θ и Фурье по θ . Зафиксируем $\lambda \neq 0$ и рассмотрим распределение по переменной θ :

$$F_\lambda(\theta) := \int_{\mathbb{R}} g(\lambda x + \theta) d\rho(x).$$

Равенство (1) означает $F_\lambda \equiv 0$ (как распределение). Возьмём преобразование Фурье по θ . Формально

$$\mathcal{F}_\theta[g(\lambda x + \theta)](t) = e^{-it\lambda x} \widehat{g}(t),$$

поэтому

$$\widehat{F_\lambda}(t) = \widehat{g}(t) \widehat{\rho}(\lambda t).$$

Так как $F_\lambda \equiv 0$, то $\widehat{F_\lambda} \equiv 0$, и мы получаем тождество в $\mathcal{S}'(\mathbb{R})$:

$$\widehat{g}(t) \widehat{\rho}(\lambda t) = 0 \quad \text{для всех } \lambda \neq 0. \quad (2)$$

Шаг 2: корректность произведения. Пусть $\omega \in \mathcal{S}(\mathbb{R})$. Так как $\text{supp}(\rho) \subset [a, b]$, функция $\widehat{\rho}$ гладкая и ограниченная (и то же верно для всех её производных), поэтому $\omega(\cdot) \widehat{\rho}(\lambda \cdot) \in \mathcal{S}(\mathbb{R})$. Следовательно, выражение $\langle \widehat{g}, \omega(\cdot) \widehat{\rho}(\lambda \cdot) \rangle$ корректно, и равенство (2) понимается именно как равенство в смысле распределений.

Шаг 3: вывод $\text{supp}(\widehat{g}) \subset \{0\}$. Так как $\rho \neq 0$, её Фурье-образ $\widehat{\rho}$ не тождественно равен нулю, значит существует $t_0 \neq 0$, что $\widehat{\rho}(t_0) \neq 0$. По непрерывности $\widehat{\rho}$ найдётся $\delta > 0$, для которой $\widehat{\rho}(t) \neq 0$ при $t \in (t_0 - \delta, t_0 + \delta)$.

Пусть $t_1 \neq 0$ произвольно. Положим $\lambda := t_0/t_1$. Тогда $\widehat{\rho}(\lambda t) \neq 0$ в некоторой окрестности точки $t = t_1$. Возьмём $\psi \in C_0^\infty(\mathbb{R})$ с носителем внутри этой окрестности и положим

$$\omega(t) := \frac{\psi(t)}{\widehat{\rho}(\lambda t)}.$$

Тогда $\omega \in C_0^\infty(\mathbb{R}) \subset \mathcal{S}(\mathbb{R})$, и подстановка в (2) даёт

$$0 = \langle \hat{g}, \omega(\cdot) \hat{\rho}(\lambda \cdot) \rangle = \langle \hat{g}, \psi \rangle.$$

Следовательно $t_1 \notin \text{supp}(\hat{g})$. Так как $t_1 \neq 0$ произвольно, получаем $\text{supp}(\hat{g}) \subset \{0\}$.

Шаг 4: распределение с носителем в точке $\Rightarrow$ полином. Если $T \in \mathcal{S}'(\mathbb{R})$ и $\text{supp}(T) \subset \{0\}$, то T является конечной линейной комбинацией δ и её производных. Применяя это к $T = \hat{g}$ и затем обратное преобразование Фурье в $\mathcal{S}'$, получаем, что g является полиномом.

Таким образом, из предположения “ g не TW” следует “ g полином”. Контрапозиция даёт: если g не полином, то g TW. $\square$

Замечание. Смысл теоремы: при условиях $g \in C(\mathbb{R}) \cap \mathcal{S}'(\mathbb{R})$ единственное препятствие для TW-свойства — полиномиальность; это даёт простой критерий «пригодности» активации.

4.3 Равномерная универсальная аппроксимация наборов функций

Определение (Равномерная аппроксимация на U). Пусть K компактно и $U \subset C(K)$. Последовательность отображений $A_m: U \rightarrow C(K)$ *равномерно аппроксимирует тождественное отображение на U* , если

$$\lim_{m \rightarrow +\infty} \sup_{f \in U} \|A_m(f) - f\|_{C(K)} = 0.$$

С другой стороны мы можем говорить, что множество $\mathcal{H} \subset C(K)$ *равномерно плотно в U* , если для каждого $\varepsilon > 0$ найдутся $h_1, \dots, h_N \in \mathcal{H}$ и непрерывные линейные функционалы $c_1, \dots, c_N: U \rightarrow \mathbb{R}$, такие что

$$\sup_{f \in U} \left\| f - \sum_{i=1}^N c_i(f) h_i \right\|_{C(K)} \leq \varepsilon.$$

Ключевые идеи второго подхода: использование одинаковых «атомов» h_i для всех $f \in U$, от f зависят только коэффициенты $c_i(f)$, причём линейно и непрерывно. Вооружившись этими понятиями, можем сформулировать теорему

Теорема 4.3 (Чен и Чен, теорема 3). Пусть $K \subset \mathbb{R}^n$ и $U \subset C(K)$ компактны, g — функция Таубера–Винера (TW, линейные комбинации её сдвигов и растяжений плотны в $C[a, b]$ для произвольных $a < b$). Тогда для всякого $\varepsilon > 0$ существует $N \in \mathbb{N}$, набор параметров $(w_i, \theta_i)_{i=1}^N$ (независящие от $f \in U$) и непрерывные линейные функционалы $c_1, \dots, c_N$, что

$$\sup_{f \in U} \sup_{x \in K} \left| f(x) - \sum_{i=1}^N c_i(f) g(w_i \cdot x + \theta_i) \right| \leq \varepsilon,$$

то есть аппроксимация на U будет равномерной.

Для доказательства этого результата нам понадобится ряд инструментов и фактов:

- **Продолжение Титца (Урысона):** Существует линейное непрерывное отображение $E: C(K) \rightarrow C(\mathbb{R}^n)$ со свойствами $(Ef)|_K = f$ и $\|Ef\|_\infty \leq \|f\|_{C(K)}$. Из последнего следует, что $U_1 := E(U)$ компактно в $C(\mathbb{R}^n)$.
- **Нормализация:** Аффинными преобразованиями добьёмся, чтобы $K \subset Q = [-1, 1]^n$, это лишь приведёт к пересчёту частот w_i .

- **Чётное 2-периодическое продолжение:** Определим $R: C(Q) \rightarrow C_{per}[-1, 1]^n$ как чётные 2-периодические продолжения по каждой координате. Поскольку это движение на Q , $U^* := R(U_1|_Q)$ — компакт.
- **Аппроксимативная единица:** Пусть S_R положительный, нормированный оператор тригонометрического суммирования, что для любой функции $f \in C_{per}[-1, 1]^n$ $\|S_R f - f\|_\infty \xrightarrow{R \rightarrow +\infty} 0$. Каждый оператор S_R нормирован, из-за чего они образуют равностепенно непрерывное и равномерно ограниченное множество, то есть компактно по теореме Арцела-Асколи, на языке ε -сетей это значит

$$\forall \varepsilon > 0 \exists R: \sup_{f \in U^*} \|S_R f - f\|_\infty < \frac{\varepsilon}{2}.$$

Нам будет важно представление в виде

$$(S_R f)(x) = \sum_{\xi \in \Lambda_R} a_\xi(f) e^{i\xi \cdot x} = \sum_{\xi \in \Lambda_R} \alpha_\xi(f) \cos(\xi \cdot x) + \beta_\xi \sin(\xi \cdot x),$$

где $\Lambda_R \subset \mathbb{Z}^n$ — конечно, а a_ξ , α_ξ , β_ξ линейны и непрерывны по f (получены из коэффициентов Фурье). Чтобы получить требуемые свойства, достаточно определить действие оператора S_R как свёртку с *аппроксимативной единицей* $\{K_R\}$, напомним, что это значит:

$$S_R f := K_R * f; \quad K_R \in L^1(\mathbb{T}^n), \quad K_R \geq 0, \quad \int_{\mathbb{T}^n} K_R = 1, \quad \int_{|y| > \delta} K_R(y) dy \xrightarrow{R \rightarrow \infty} 0.$$

Стандартным примером такого семейства функций, известного из гармонического анализа, являются *средние Фейера*

$$F_N(t) = \frac{1}{N+1} \sum_{k=0}^N D_k(t) = \frac{1}{2\pi(N+1)} \left(\frac{\sin \frac{(N+1)t}{2}}{\sin \frac{t}{2}} \right)^2 \geq 0, \quad \int_{-\pi}^{\pi} F_N = 1.$$

Обобщение для n -мерного пространства происходит перемножением значений для каждой координаты (тут $R \sim N$):

$$F_N^{(n)}(x) = \prod_{j=1}^n F_N(x_j).$$

Другим классическим примером будут *средние Бохнера-Рисса*, задаваемые для $\alpha > \frac{n-1}{2}$ через преобразование Фурье

$$m_R(\xi) = (1 - |\xi|^2/R^2)_+^\alpha, \quad \widehat{K_R}^\alpha = m_R.$$

- **Сведение к TW:** При фиксированном $\xi \in \mathbb{R}^n$, функции $x \mapsto \cos(\xi \cdot x)$, $\sin(\xi \cdot x)$ зависят лишь от одномерной переменной $t = \xi \cdot x$, что позволяет равномерно аппроксимировать на Q каждую из них конечными суммами $g(w \cdot x + \theta)$.

Теперь перейдём к доказательству самой теоремы.

Доказательство. Поскольку $U^* \subset C_{per}[-1, 1]^n$ компактно и $\{S_R\}$ равностепенно непрерывно и равномерно ограничено, существует $R \in \mathbb{N}$, что

$$\sup_{f \in U^*} \|S_R f - f\|_\infty < \frac{\varepsilon}{3}.$$

Запишем представление

$$(S_R f)(x) = \sum_{\xi \in \Lambda_R} \alpha_\xi(f) \cos(\xi \cdot x) + \beta_\xi(f) \sin(\xi \cdot x),$$

где Λ_R конечное множество (набор «частот») и отображения $f \mapsto \alpha_\xi(f)$, $\beta_\xi(f)$ являются линейными и непрерывными функционалами на U^* . Положим $B := \sup_{f \in U^*} \|f\|_\infty < \infty$ и $C_R := \max_{\xi \in \Lambda_R} \|\alpha_\xi\| + \|\beta_\xi\|$, тогда $\sum_{\xi \in \Lambda_R} (|\alpha_\xi(f)| + |\beta_\xi(f)|) \leq C_R B |\Lambda_R| =: \Gamma_R$.

Фиксируем $\delta > 0$ (уточним выбор позже). Поскольку g функция TW, значит найдутся такие линейные комбинации, что

$$\forall x \in Q \quad \left| \cos(\xi \cdot x) - \sum_{i=1}^N a_{i,\xi}^{(\cos)} g(w_i \cdot x + \theta_i) \right| \leq \delta, \quad \left| \sin(\xi \cdot x) - \sum_{i=1}^N a_{i,\xi}^{(\sin)} g(w_i \cdot x + \theta_i) \right| \leq \delta.$$

Раз Λ_R конечно, можем считать, что набор $\{(w_i, \theta_i)\}_{i=1}^N$ един для всех $\xi \in \Lambda_R$ (иначе возьмём объединение множеств для каждого ξ , по этой же причине для синуса и косинуса используются одинаковые частоты и сдвиги). Важно, что $a_{i,\xi}^{(\cos)}$, $a_{i,\xi}^{(\sin)}$ зависят лишь от ξ и фиксированного множества параметров, но не f .

Теперь определим приближение g -сетью для $f \in U^*$:

$$\mathcal{G}(f)(x) := \sum_{i=1}^N c_i(f) \underbrace{g(w_i \cdot x + \theta_i)}_{g_i(x)}, \quad c_i(f) := \sum_{\xi \in \Lambda_R} \alpha_\xi(f) a_{i,\xi}^{(\cos)} + \beta_\xi(f) a_{i,\xi}^{(\sin)}.$$

Каждый из $c_i(\cdot)$ является непрерывным линейным функционалом на U^* как конечная сумма $\alpha_\xi(\cdot)$, $\beta_\xi(\cdot)$.

Фиксируем $x \in Q$ и $f \in U^*$, по неравенству треугольника

$$\begin{aligned} |f(x) - \mathcal{G}(f)(x)| &\leq |f(x) - S_R f(x)| + \\ &+ \left| S_R f(x) - \sum_{\xi \in \Lambda_R} \alpha_\xi(f) \sum_{i=1}^N a_{i,\xi}^{(\cos)} g_i(x) - \sum_{\xi \in \Lambda_R} \beta_\xi(f) \sum_{i=1}^N a_{i,\xi}^{(\sin)} g_i(x) \right| \leq \\ &\leq \frac{\varepsilon}{2} + \sum_{\xi \in \Lambda_R} (|\alpha_\xi(f)| + |\beta_\xi(f)|) \delta. \end{aligned}$$

Выберем $\delta := \frac{\varepsilon}{2\Gamma_R}$, чтобы получить оценку

$$\sup_{f \in U^*} \|f - \mathcal{G}(f)\|_{L^\infty(Q)} \leq \frac{\varepsilon}{2} + \Gamma_R \frac{\varepsilon}{2\Gamma_R} = \varepsilon.$$

Осталось вернуться в исходное пространство, мы произвели цепочку преобразований $U \xrightarrow{E} U_1 \xrightarrow{R} U^*$, поэтому рассмотрим композицию $\mathcal{G}$ с $R \circ E$ и сузим всё на K :

$$\tilde{\mathcal{G}}(f) := \mathcal{G}(R(Ef))|_K = \sum_{i=1}^N c_i(R(Ef)) g(w_i \cdot x + \theta_i)|_{x \in K}.$$

Поскольку E и R линейны и непрерывны и сужение не увеличит супремум норму, получаем желаемое неравенство

$$\sup_{f \in U} \sup_{x \in K} |f(x) - \tilde{\mathcal{G}}(f)(x)| \leq \varepsilon.$$

Параметры сети $\{(w_i, \theta_i)\}_{i=1}^N$ одинаковы для всех $f \in U$, каждое коэффициентное отображение $f \mapsto c_i(R(Ef))$ представляет собой линейный непрерывный функционал на U . Таким образом мы построили семейство нейронных сетей с единственным скрытым слоем, параметры которого фиксированы, и линейными выходами, обеспечивающего равномерную аппроксимацию на U . $\square$

Замечания.

- Специфика выбора активационной функции g (Таубера–Винера) сыграла лишь, когда мы приближали синусы и косинусы линейными комбинациями её сдвигов и растяжений. В многомерной конструкции атомами аппроксимации становятся ridge-функции $x \mapsto g(w \cdot x + \theta)$.
- «Внешний» тригонометрический слой кодирует поведение функции через S_R , а каждая гармоника приближается конечным ridge-представлением, что и приводит к конечной сети с единым скрытым слоем для всех $f \in U$.
- Все подобранные значения (R , скрытые параметры и ошибка δ) зависят лишь от компакта U , что делает их равномерными.

4.4 Универсальная аппроксимация для нелинейных функционалов

Теорема 4.4 (Чен и Чен, теорема 4). Пусть X является банаховым пространством, $K \subset X$ и $V \subset C(K)$ компактны, $f: V \rightarrow \mathbb{R}$ непрерывен и g — TW -функция. Тогда для любого $\varepsilon > 0$ найдутся натуральные N , m , точки $x_1, \dots, x_m \in K$ и параметры $\{\theta_{ij}, \beta_i\}_{i=1, \dots, N}^{j=1, \dots, m}$, $\{c_i\}_{i=1}^N$ такие, что

$$\forall u \in V \quad \left| f(u) - \sum_{i=1}^N c_i g \left(\sum_{j=1}^m \theta_{ij} u(x_j) + \beta_i \right) \right| \leq \varepsilon,$$

где внутренние коэффициенты θ_{ij} , β_i и разбиение $\{x_j\}$ не зависят от u , а внешние коэффициенты c_i определяются f , но не u .

Для доказательства этого результата потребуются:

- **Теорема Арцела-Асколи:** $V \subset C(K) \Rightarrow$ равномерно непрерывно, а значит имеется общий модуль непрерывности $\omega_V(\delta)$, что $|u(x) - u(y)| \leq \omega_V(d(x, y))$ для любого $u \in V$.
- **δ -сети и разбиение единицы:** Для каждого $v > 0$ построим конечную сеть $N(v) = \{x_j^{(v)}\}_{j=1}^{m(v)} \subset K$ и соответствующее разбиение единицы $\{\tau_j^{(v)}\}$: $\sum_j \tau_j^{(v)} = 1$ и $\text{supp } \tau_j^{(v)} \subset B(x_j^{(v)}, v)$.

- **Конечномерный оператор (проецирования):** $(\Pi_v u)(x) := \sum_{j=1}^{m(v)} u(x_j^{(v)}) \tau_j^{(v)}(x)$, для него, по равностепенной непрерывности V , верно $\|\Pi_v u - u\|_{C(K)} \leq \omega_V(v)$ равномерно по u .
- **Предыдущая теорема об УА для компактных множеств.**

Доказательство. Фиксируем $\varepsilon > 0$, выберем $v > 0$ настолько малым, что

$$\forall u \in V \quad \|\Pi_v u - u\|_{C(K)} \leq \omega_V(v) < \frac{\varepsilon}{2}.$$

Для краткости обозначим $m := m(v)$, $x_j := x_j^{(v)}$, $\tau_j := \tau_j^{(v)}$, $u_v := \Pi_v u = \sum_{j=1}^m u(x_j) \tau_j(\cdot)$. Заметим, что отображение $T: V \rightarrow C(K)$, $T(u) = u_v$ зависит лишь от конечномерного вектора значений

$$u_M := (u(x_1), \dots, u(x_m)) \in \mathbb{R}^m,$$

причём линейно и непрерывно: $u_v = A(u_M)$, где $A(y)(x) = \sum_{j=1}^m y_j \tau_j(x)$.

Выделим подмножество $W = \{u_M : u \in V\} \subset \mathbb{R}^m$, оно является непрерывным образом компактного множества V , а значит тоже компактным. Определим непрерывное отображение $\Phi = f \circ A|_W$. Раз f непрерывен и V компактно, то он равномерно непрерывен, а значит, возможно уменьшая v , можем гарантировать

$$\forall u \in V \quad |f(u) - \Phi(u_M)| < \frac{\varepsilon}{2}.$$

Иными словами мы приблизили f непрерывной функцией на компактном подмножестве $W \subset \mathbb{R}^m$.

Вспомним, что g — TW -функция, тогда применим предыдущую теорему для куба $K \supset W$ и функции Φ . Получим набор параметров $\{\theta_{ij}, \beta_i\}$ (не зависят от $y \in W$) и $\{c_i\}$ (зависят от Φ), что

$$\forall y \in W \quad \left| \Phi(y) - \sum_{i=1}^N c_i g \left(\sum_{j=1}^m \theta_{ij} y_j + \beta_i \right) \right| \leq \frac{\varepsilon}{2}.$$

Подставим $y = u_M$, тогда для всех $u \in V$

$$\left| \Phi(u_M) - \sum_{i=1}^N c_i g \left(\sum_{j=1}^m \theta_{ij} u(x_j) + \beta_i \right) \right| \leq \frac{\varepsilon}{2}.$$

Осталось собрать всё воедино:

$$\begin{aligned} \left| f(u) - \sum_{i=1}^N c_i g \left(\sum_{j=1}^m \theta_{ij} u(x_j) + \beta_i \right) \right| &\leq |f(u) - \Phi(u_M)| + \\ &+ \left| \Phi(u_M) - \sum_{i=1}^N c_i g \left(\sum_{j=1}^m \theta_{ij} u(x_j) + \beta_i \right) \right| \leq \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon. \end{aligned}$$

Это неравенство и природа коэффициентов заканчивает доказательство. $\square$

Замечания.

- Достаточно непрерывности f только на V .

- Свойство g (функция Таубера–Винера) позволило нам использовать теорему об УА на компактных множествах и приблизить Φ на $W \subset \mathbb{R}^m$.
- Представление $u \mapsto \sum_{j=1}^N c_i g(\sum_{j=1}^m \theta_{ij} u(x_j) + \beta_i)$ — *нейронная сеть значений*, u заменяется значениями в конечном наборе точек, которые аффинно преобразуются, подаются на вход g , а затем берётся их линейная комбинация.
- Можно взглянуть на теорему динамически: поскольку вычисление значения функции в точке и совершение над ней какого-то преобразования коммутируют, и атомами приближения выступают всевозможные сдвиги и растяжения активационной функции Таубера–Винера, манипуляции над входом качественно не меняют структуру аппроксимации, а лишь приводят к пересчёту коэффициентов. Детально про это пойдёт речь далее.

4.5 Связь динамических систем и аппроксимации нелинейных функционалов

Чтобы увидеть связь теории динамических систем и предыдущей теоремы об аппроксимации нелинейных функционалов, нам потребуется такой аппарат курса алгебры, как *действие группы на множестве*. Напомним, (полу-)группа G действует на множестве K , если задано отображение (действие) $\cdot : G \times K \rightarrow K$, удовлетворяющее правилам:

$$(i) e \cdot x = x, \quad (ii) (g_1 g_2) \cdot x = g_1 \cdot (g_2 \cdot x).$$

Типичные примеры: действие симметрической группы на конечном множестве, группы движений на евклидовом пространстве, непрерывного потока $\{\Phi_t\}_{t \in \mathbb{R}}$ на точки фазового пространства. Действие на множестве можно перенести на пространство функций, например так: для $u \in C(K)$ положим

$$(g \cdot u)(x) := u(g^{-1} \cdot x), \quad g \in G, x \in K.$$

Ключевую роль в дальнейших рассуждениях сыграют пара понятий, связанных с симметрией. Функционал $f: V \rightarrow \mathbb{R}$ ($V \subset C(K)$ — компакт) называется **инвариантным**, если образ не зависит от действия на аргумент, то есть $f(g \cdot u) = f(u)$ для любого $g \in G$. Функционал f — **эквивариантен**, если $f(g \cdot u) = \rho(g)f(u)$ ¹.

Орбита точки x — это множество всевозможных её образов $\text{Orb}_G(x) := \{g \cdot x : g \in G\}$. Набор $X = \{x_j\}_{j=1}^m$ *замкнут под действием G* , если он полностью состоит из орбит своих точек, то есть $X = \bigcup_{x \in X} \text{Orb}_G(x)$. Такие множества обеспечивают **эквивариантность выборки (exact sampling equivariance)**. Пусть $L: C(K) \rightarrow \mathbb{R}^m$ вычисляет значения функции на X : $L(u) = (u(x_1), \dots, u(x_m))$. Тогда для любого $g \in G$ найдётся матрица перестановок P_g , обеспечивающая тождество

$$L(g \cdot u) = P_g L(u) \quad \text{или} \quad (P_g v)_j = v_i, x_i = g^{-1} \cdot x_j.$$

Для некоторых групп такого конечно набора не найти (например группа вращений на сфере), в этом случае будем говорить о **приближённой эквивариантности выборки (approximate sampling equivariance)**. Пусть X — конечная δ -сеть K , а $J: \mathbb{R}^m \rightarrow C(K)$

¹Прим. наборщика: с помощью $\rho: G \rightarrow \mathbb{C}$ задаётся действие G на $\mathbb{R}$

такой линейный оператора (можно использовать кусочно-линейные конечные элементы, разбиение единицы, RBF, сплайны), что

$$\forall u \in V \quad \|J \circ L(u) - u\|_\infty \leq \eta(\delta), \quad \eta(\delta) \xrightarrow{\delta \rightarrow 0} 0.$$

Тогда для $g \in G$ определим проекцию

$$P_g := L \circ T_{g^{-1}} \circ J: \mathbb{R}^m \rightarrow \mathbb{R}^m, \quad (T_{g^{-1}}f)(x) := f(g^{-1} \cdot x)$$

и получим равномерную на V оценку

$$\|L(g \cdot u) - P_g L(u)\|_\infty^2 \leq \eta(\delta).$$

Подадим на вход активационной функции сигнал $z_i(u) = \theta_i^T L(u) + \beta_i$, для удобства обозначим $h_i(u) = g(z_i(u))$. Если $\{\theta_i\}$ замкнуто относительно действия G , тогда

$$h(g_0 \cdot u) = \Pi_{g_0} h(u) (+O(\eta(\delta))) \text{ в приближённом случае},$$

значит внешние коэффициенты могут быть спроецированы/усреднены, чтобы добиться инвариантности/эквивариантности с сохранением архитектуры и равномерной оценки погрешности.

В теореме об УА на компактных множествах атомами аппроксимации выступали ridge-функции $x \mapsto g(w \cdot x + \theta)$. Переносы $T_a: x \mapsto x + a$ и линейные отображения $A: x \mapsto Ax$ преобразуют их в

$$g(w \cdot (x + a) + \theta) = g(w \cdot x + (\theta + w \cdot a)), \quad g(w \cdot (Ax) + \theta) = g((A^T w) \cdot x + \theta),$$

то есть выполнено предположение о замкнутости, и работает предыдущее рассуждение. Предположим теперь, что функционал f инвариантен, возьмём его приближение $A(u) = c^T h(u)$ из теоремы [], обеспечивающее $\sup_{u \in V} |A(u) - f(u)| \leq \varepsilon$. По нему можем построить усреднённую модель

$$\tilde{A}(u) := \int_G A(g \cdot u) d\mu(g),$$

тут μ — нормированная мера Хаара на компактной хаусдорфовой топологической группе G (то есть на G введена топология, относительно которой умножение и взятие обратного непрерывны). Сделаем несколько наблюдений про неё:

1. *Инвариантность:* $\tilde{A}(g_0 \cdot u) = \tilde{A}(u)$ в силу инвариантности μ .
2. *Ошибка не ухудшилась:* $|\tilde{A}(u) - f(u)| \leq \int_G |A(g \cdot u) - f(g \cdot u)| d\mu(g) \leq \varepsilon$.
3. *Сохранение архитектуры:* $h(g \cdot u) = \Pi_g h(u) \Rightarrow \tilde{A}(u) = \left(\int_G \Pi_g^T c d\mu(g) \right)^T h(u) =: \tilde{c}^T h(u)$, то есть просто проецируем c на инвариантное подпространство $\{c: \Pi_g^T c = c\}$.

Если f эквивариантна ($f(g \cdot u) = \rho(g)f(u)$, $\rho: G \rightarrow \mathbb{C}$), положим

$$\tilde{A}_\rho(u) := \int_G \rho(g)^{-1} A(g \cdot u) d\mu(g).$$

Для такой модели выполнено:

²Прим. наборщика: это выражение есть мера аппроксимации из общей схемы приближённых методов

1. Эквиариантность: $\tilde{A}_\rho(g_0 \cdot u) = \rho(g_0)$.
2. Ошибка не ухудшилась: $|\tilde{A}_\rho(u) - f(u)| \leq \varepsilon$ (если $|\rho(g)| = 1$).
3. Сохранение архитектуры: $\tilde{A}_\rho(u) = (\int_G \rho(g)^{-1} \Pi_g c d\mu(g))^T h(u) =: \tilde{c}_\rho^T h(u)$.

Пример (Дискретные сдвиги на прямой). Возьмём $K = \mathbb{T}$, $G = \mathbb{Z}/M\mathbb{Z}$ действует сдвигами $\Phi_a(\cdot) = \cdot + a$, шаг $\Delta = \frac{2\pi}{M}$, разбиение $x_j = j\Delta$. Тогда

$$L(\Phi_a \cdot u) = P_a L(u), \quad P_a = \text{циклический сдвиг}, \quad h(\Phi_a \cdot u) = \Pi_a h(u).$$

В случае инвариантного функционала усреднённые веса имеют вид

$$\tilde{c} = \frac{1}{M} \sum_{a=0}^{M-1} \Pi_a^T c.$$

Для эквиариантности по модулю m возьмём $\rho(a) = e^{ima\Delta}$, получим

$$\tilde{c}_\rho = \frac{1}{M} \sum_{a=0}^{M-1} e^{-ima\Delta} \Pi_a^T c,$$

то есть дискретное преобразование Фурье, что обеспечивает все интересующие свойства.

Подводя итог, приведём рецепт получения симметрии модели из теоремы об универсальной аппроксимации для нелинейных функционалов:

1. Выбрать X как объединение G -орбит или плотное как подмножество + линейное интерполирование.
2. Обучить модель из теоремы $A(u) = c^T h(u)$ до точности ε на V .
3. Спроецировать веса: $\tilde{c} = \int_G \Pi_g^T c d\mu(g)$ для инвариантности и $\tilde{c}_\rho = \int_G \rho(g)^{-1} \Pi_g^T c d\mu(g)$ для эквиариантности.
4. Использовать в модели $\tilde{c}$ или $\tilde{c}_\rho$, при этом на V ошибка не увеличивается.

4.6 Универсальная аппроксимация операторов

Теорема 4.5 (Чен и Чен, теорема 5). Пусть X — банахово пространство, $K_1 \subset X$ компактно, $K_2 \subset \mathbb{R}^n$ компактно, $V \subset C(K_1)$ компактно и $G: V \rightarrow C(K_2)$ непрерывно. Пусть g является функцией Таубер–Винера. Тогда для любого $\varepsilon > 0$ существуют целые числа m, M, N , точки выборки $x_1, \dots, x_m \in K_1$, выходные частоты $w_1, \dots, w_N \in \mathbb{R}^n$ и вещественные параметры $\{\theta_{ij}, \gamma_i\}_{i \leq M, j \leq m}$ и $\{\alpha_{ik}, \beta_k\}_{i \leq M, k \leq N}$ такие, что

$$\sup_{u \in V} \sup_{y \in K_2} \left| G(u)(y) - \sum_{k=1}^N \left(\sum_{i=1}^M \alpha_{ik} g \left(\sum_{j=1}^m \theta_{ij} u(x_j) + \gamma_i \right) \right) g(w_k \cdot y + \beta_k) \right| \leq \varepsilon.$$

Эквивалентная формулировка: двухслойное сепарабельное («внешнее произведение») разложение по g -атомам над входными выборками и выходным значением дает равномерную аппроксимацию оператора.

Доказательство. Шаг 0 (компактный образ). Поскольку V компактно в $C(K_1)$ и G непрерывно, образ

$$U := G(V) \subset C(K_2)$$

является компактным.

Шаг 1 (применение теоремы об равномерной УА на $U \subset C(K_2)$). По теореме с $K = K_2$ и компактным семейством U , для $\varepsilon_1 > 0$ существуют $N \in \mathbb{N}$, параметры $(w_k, \beta_k)_{k=1}^N$ (независящие от u) и непрерывные линейные функционалы $L_k: U \rightarrow \mathbb{R}$ такие, что для всех $u \in V$,

$$\left\| G(u)(\cdot) - \sum_{k=1}^N L_k(G(u))g(w_k \cdot (\cdot) + \beta_k) \right\|_{C(K_2)} \leq \varepsilon_1.$$

Таким образом, «коэффициенты как функции u » в точности являются скалярами $L_k(G(u))$.

Шаг 2: сведение $L_k \circ G: V \rightarrow \mathbb{R}$ к g -сети на основе выборок Для каждого фиксированного k отображение $F_k := L_k \circ G: V \rightarrow \mathbb{R}$ непрерывно (композиция непрерывных отображений на компактных множествах). Применим теорему об УА для функционалов к каждому F_k с точностью $\varepsilon_{2,k} > 0$. Получим:

- конечное множество выборок $\{x_j\}_{j=1}^m \subset K_1$ и *внутренние* параметры $\{\theta_{ij}, \gamma_i\}_{i=1}^M$, *единые* для (конечного) набора $\{F_k\}_{k=1}^N$ (объединим точки для каждого F_k),
- внешние коэффициенты $\{\alpha_{ik}\}_{i=1, \dots, M}$ (зависящие от k и $\{F_k\}$, но не от u), такие, что для всех $u \in V$ и всех $k = 1, \dots, N$,

$$\left| F_k(u) - \sum_{i=1}^M \alpha_{ik} g \left(\sum_{j=1}^m \theta_{ij} u(x_j) + \gamma_i \right) \right| \leq \varepsilon_{2,k}.$$

(Использовали, что теорема об УА для функционалов определяет внутренние параметры независимо от функционала и меняет только внешние коэффициенты.)

Шаг 3: композиция и отслеживание ε Подставим аппроксимацию из шага 2 в разложение шага 1. Для любых $u \in V$ и $y \in K_2$:

$$\begin{aligned} & \left| G(u)(y) - \sum_{k=1}^N \left(\sum_{i=1}^M \alpha_{ik} g \left(\sum_{j=1}^m \theta_{ij} u(x_j) + \gamma_i \right) \right) g(w_k \cdot y + \beta_k) \right| \leq \\ & \leq \underbrace{\left\| G(u) - \sum_{k=1}^N L_k(G(u))g(w_k \cdot + \beta_k) \right\|_{C(K_2)}}_{\leq \varepsilon_1} + \sum_{k=1}^N \underbrace{\left| F_k(u) - \sum_{i=1}^M \alpha_{ik} g(\dots) \right|}_{\leq \varepsilon_{2,k}} \|g(w_k \cdot + \beta_k)\|_{C(K_2)}. \end{aligned}$$

Положим $B_k := \|g(w_k \cdot + \beta_k)\|_{C(K_2)} < \infty$ (непрерывность ridge-функции g на компакте K_2). Выберем

$$\varepsilon_1 := \varepsilon/3, \quad \varepsilon_{2,k} := \frac{\varepsilon}{3 \sum_{\ell=1}^N B_\ell}.$$

Тогда общая ошибка $\leq \varepsilon/3 + \sum_k \varepsilon_{2,k} B_k \leq \varepsilon/3 + \varepsilon/3 < \varepsilon$, равномерно по $u \in V$ и $y \in K_2$. Это даёт заявленную сепарабельную архитектуру. $\square$

Отметим, почему получилось доказать теорему, нам удалось **сохранить структуру**, потому что:

- Выходные атомы (w_k, β_k) получены из теоремы о равномерной УА на компактном образе $U = G(V)$ и не зависят от u .
- Внутренние точки выборки x_j и внутренние параметры (θ_{ij}, γ_i) выбираются один раз (для всех k) применением теоремы об УА для функционалов к конечному набору $\{F_k\}_{k=1}^N$ с последующим объединением.
- Только скаляры α_{ik} (коэффициенты смещения) зависят от того, какой коэффициентный функционал F_k аппроксимируется; они являются константами в конечном операторе и не зависят от u или y .

Равномерность обеспечивает следующее наблюдение. Каждый шаг равномерен на компактных множествах: $U = G(V)$ компактно, Теорема В равномерна на U , а Теорема С равномерна на V . Следовательно, итоговая оценка является *равномерной* как по $u \in V$, так и по $y \in K_2$.

Замечания.

- **Динамическая взгляд.** Когда на K_1/K_2 определено действие сдвига/потока, ridge-атомы $g(w \cdot y + \beta)$ описывают переносы и растяжения в выходном пространстве, тогда как внутренняя операция смешения выборок реализует конечную «память» входа u — в точности ту структурно применяется при идентификации инвариантных по времени/пространству систем.
- **Векторнозначные выходы.** Для $G: V \rightarrow C(K_2; \mathbb{R}^d)$ применяем теорему к каждой компоненте и объединяем полученные разложения.
- **Альтернативный набросок доказательства.** Можно также зафиксировать $y \in K_2$, применить приблизить функционал вычисления $u \mapsto G(u)(y)$ равномерно по y (используя теорему о равномерной УА на K_2 для разделения параметров по y), что даёт ту же сепарабельную форму.

4.7 Взгляд с точки зрения динамических систем и сдвиги

Постановка. Пусть (топологическая) группа G действует непрерывно на компактных множествах K_1, K_2 : $G \times K_\ell \rightarrow K_\ell$, $(g, x) \mapsto g \cdot x$. Индуцированное действие на $C(K_\ell)$ имеет вид

$$(g \cdot u)(x) := u(g^{-1} \cdot x), \quad u \in C(K_\ell).$$

Отображение $f: V \subset C(K_1) \rightarrow \mathbb{R}$ является ρ -эквивариантным ($\rho: G \rightarrow \mathbb{C}$), если $f(g \cdot u) = \rho(g)f(u)$. Отображение $G: V \rightarrow C(K_2)$ является эквивариантным, если $G(g \cdot u) = g \cdot G(u)$.

TW-устойчивость атомов. Ridge-атомы $x \mapsto g(w \cdot x + \theta)$ устойчивы относительно базовых действий:

$$\underbrace{T_a g(w \cdot x + \theta)}_{\text{сдвиг по } x} = g(w \cdot x + (\theta + w \cdot a)), \quad \underbrace{D_\lambda g(w \cdot x + \theta)}_{\text{растяжение}} = g((\lambda w) \cdot x + \theta).$$

Таким образом, семейство атомов замкнуто относительно действий сдвига/растяжения.

Теорема 4.6 (ДС-А, эквивариантная УА для функционалов). Пусть G действует на метрическом компакте K и $V \subset C(K)$ является непустым компактным G -инвариантным множеством. Пусть $f: V \rightarrow \mathbb{C}$ непрерывно и ρ -эквивариантно: $f(g \cdot u) = \rho(g)f(u)$ для всех $g \in G$. Предположим, что g (активация) является ТВ-функцией. Тогда для любого $\varepsilon > 0$ существуют

- точки выборки $x_1, \dots, x_m \in K$ и внутренние параметры $\{\theta_{ij}, \beta_i\}$ (не зависящие от u),
- внешние коэффициенты $c_i \in \mathbb{C}$,

такие, что «выборочная нейросеть»

$$F(u) = \sum_{i=1}^N c_i g \left(\sum_{j=1}^m \theta_{ij} u(x_j) + \beta_i \right)$$

удовлетворяет $\sup_{u \in V} |F(u) - f(u)| < \varepsilon$, и её можно выбрать ρ -эквивариантной.

Доказательство. (i) Применить теорему об УА для функционалов к f для получения равномерной аппроксимации на основе выборок на V . (ii) Обеспечить ρ -эквивариантность путём усреднения коэффициентов по группе:

$$\tilde{F}(u) := \int_G \rho(g)^{-1} F(g \cdot u) d\mu(g)$$

(мера Хаара). Тогда $\tilde{F}$ является ρ -эквивариантной, зависит от тех же внутренних параметров, и ошибка не возрастает. $\square$

Теорема 4.7 (ДС-В, биэквивариантная УА для операторов). Пусть G действует на компактах K_1, K_2 , $V \subset C(K_1)$ компактно и G -инвариантно, и $G: V \rightarrow C(K_2)$ непрерывен и эквивариантен: $G(h \cdot u) = h \cdot G(u)$ для всех $h \in G$.

Предположим, что активация g является ТВ-функцией. Тогда для любого $\varepsilon > 0$ существуют

- входные точки выборки $x_1, \dots, x_m \in K_1$ и внутренние параметры (θ_{ij}, γ_i) ,
- выходные атомы $y \mapsto g(w_k \cdot y + \beta_k)$, $k = 1, \dots, N$ (общие для всех u),
- коэффициенты смешения α_{ik} ,

такие, что сепарабельная архитектура

$$\mathcal{G}(u)(y) := \sum_{k=1}^N \left(\sum_{i=1}^M \alpha_{ik} g \left(\sum_{j=1}^m \theta_{ij} u(x_j) + \gamma_i \right) \right) g(w_k \cdot y + \beta_k)$$

является эквивариантной и $\sup_{u \in V} \|\mathcal{G}(u) - G(u)\|_{C(K_2)} < \varepsilon$.

Доказательство. Применить теорему об УА для операторов, чтобы получить сепарабельную аппроксимацию, затем сделать её эквивариантной путём усреднения по G на выходном слое:

$$\tilde{\mathcal{G}}(u) := \int_G h \cdot \mathcal{G}(h^{-1} \cdot u) d\mu(h).$$

ТВ-устойчивость атомов гарантирует, что усреднение перепараметризует атомы внутри того же ridge-семейства. $\square$

4.8 Устойчивость относительно потоков, робастность аппроксимаций

Пусть $\{\Phi_t\}_{t \in \mathbb{R}}$ — непрерывный поток на K (например, сдвиги), с индуцированным действием на $C(K)$. Предположим, что $V \subset C(K)$ компактно и инвариантно относительно Φ_t и $f: V \rightarrow \mathbb{R}$ (или $G: V \rightarrow C(K)$) непрерывен и эквивариантен/инвариантен относительно Φ_t .

Отметим **свойство**. Усреднённые сети из ДС-А/ДС-В удовлетворяют

$$F(\Phi_t \cdot u) = \rho(t)F(u), \quad \mathcal{G}(\Phi_t \cdot u) = \Phi_t \cdot \mathcal{G}(u), \quad \forall t \in \mathbb{R},$$

и оценки ошибки равномерны по t на компактных временных интервалах.

Причина этого явления:

- (i) Усреднение по группе/потоку коммутирует с $\sup$ -нормой и сохраняет равномерные оценки.
- (ii) Ridge-атомы $g(w \cdot x + \theta)$ остаются в том же параметрическом семействе при действии Φ_t (сдвиг/растяжение перепараметризуют (w, θ)), поэтому скрытый слой является устойчивым к действию.

Как итог можно привести динамические формулировки теорем этой лекции.

- **Теорема А как динамический критерий.** $\text{ТВ} \Leftrightarrow$ «неполиномиальность» означает: ridge-атомы, порождённые действиями сдвига/растяжения, образуют динамически устойчивый словарь.
- **Теорема В как равномерная УА с устойчивостью относительно действия.** На компактном $U \subset C(K)$ аппроксимируем с помощью фиксированного скрытого слоя, чьи атомы устойчивы относительно действия на K ; варьируются только линейные внешние функционалы.
- **Теоремы С/Д как эквивариантные УА.** После усреднения по группе/потоку те же архитектуры становятся инвариантными/эквивариантными без ухудшения равномерной погрешности благодаря TW-устойчивости.

4.9 Идентификация динамических систем через теорему об аппроксимации операторов

Постановка. Пусть $K_1, K_2 \subset \mathbb{R}^n$ компактны, $V \subset C(K_1)$ компактно. Дискретная динамическая система на функциях задаётся непрерывным оператором

$$\varphi: V \rightarrow C(K_2), \quad u_{t+1} = \varphi(u_t).$$

Теорема 4.8 (Теорема D, напоминание). Для любого $\varepsilon > 0$ существуют целые числа m, M, N , точки $x_1, \dots, x_m \in K_1$, «частоты» выхода $w_1, \dots, w_N \in \mathbb{R}^n$ и параметры $\{\theta_{ij}, \gamma_i\}_{i \leq M, j \leq m}$, $\{\alpha_{ik}, \beta_k\}_{i \leq M, k \leq N}$ такие, что

$$\sup_{u \in V} \sup_{y \in K_2} \left| \varphi(u)(y) - \sum_{k=1}^N \left(\sum_{i=1}^M \alpha_{ik} g \left(\sum_{j=1}^m \theta_{ij} u(x_j) + \gamma_i \right) \right) g(w_k \cdot y + \beta_k) \right| \leq \varepsilon.$$

Интерпретация: двухслойное сепарабельное («внешнее произведение») разложение: внутренние g обрабатывают конечное число входных выборок, внешние g кодируют зависимость выхода от y .

Пример (Перенос (сдвиг/адвекция) на торе). Пусть $K_1 = K_2 = \mathbb{T}^n$, $\varphi(u)(y) = u(y - a)$ (адвекция на $a \in \mathbb{R}^n$). Частотный отклик:

$$\widehat{\varphi(u)}(\xi) = e^{-i\xi \cdot a} \widehat{u}(\xi).$$

Применением теорему D:

- Выберем ширину полосы R и решётку $\Lambda_R = \{\xi \in \mathbb{Z}^n : |\xi| \leq R\}$.
- Внешние атомы: для каждого $\xi \in \Lambda_R$ приближем $\cos(\xi \cdot y)$, $\sin(\xi \cdot y)$ конечными суммами $g(w_k \cdot y + \beta_k)$ (ТВ 1D вдоль $t = \xi \cdot y$).
- Внутреннее отображение: по выборкам $u(x_j)$ линейно восстанавливаем (аппроксимируем) низкочастотные коэффициенты Фурье $\widehat{u}(\xi)$ (через фиксированную квадратуру/ДПФ на сетке), затем умножаем на $e^{-i\xi \cdot a}$ для получения целевой значения.

Полученная сеть. Произведение «(внутреннее приближение $\widehat{u}(\xi)$) $\times$ (внешний тригонометрический атом на частоте ξ)» реализует оператор. Обучение не требуется, если a известно, если a неизвестно, фазы подбираются методом наименьших квадратов по коэффициентам.

Подробнее рассмотрим случай $n = 1$.

- Выбираем $\Lambda_R = \{-R, \dots, R\}$; на сетке Y вычисляем ДПФ $\widehat{u}(\xi)$ и целевые значения $\widehat{\varphi(u)}(\xi) = e^{-i\xi a} \widehat{u}(\xi)$.
- Внешний слой: подбираем $\psi_k(y) = g(w_k y + \beta_k)$ и $q_{k\xi}$ так, чтобы $\sum_k q_{k\xi} \psi_k(y) \approx \cos(\xi y), \sin(\xi y)$.
- Внутренний слой: определяем $h(u)$ по выборкам $u(x_j)$; подбираем B так, чтобы $Bh(u) \approx (\widehat{u}(\xi))_{\xi \in \Lambda_R}$.
- Собираем: $C = Q \operatorname{diag}(e^{-i\xi a}) B$ (разделяем на блоки косинусов/синусов для вещественной арифметики).

Результат. Точность ограничена только уровнем усечения и аппроксимацией ridge-атомов, обратное распространение ошибки не используется.

Замечания. Некоторые практические замечания и направления обобщения.

Выбор g . Любая ограниченная не полиномиальная функция (например, сигмоида, th) является TW, ReLU работает в L^p и на практике также для тригонометрических аппроксимаций.

Вычисления. Калибровка внешнего слоя и подбор B сводятся к линейному методу наименьших квадратов; для устойчивости к шуму можно добавить регуляризацию Тихонова. Весь конвейер *амортизирован*: как только $\{\psi_k\}$ и B зафиксированы, развёртывание представляет собой быструю двухслойную сеть.

За пределами периодических областей. Чётно продолжаем на $[-1, 1]^n$, затем применяем Фейера/Бохнера–Рисса на торе (как в доказательстве) и сужаем обратно.

Симметрии. Инвариантность/эквивариантность обеспечивается проекцией C путём усреднения по группе (см. предыдущие темы), оценки ошибок при этом сохраняются.

Приведём главные результаты лекции.

- **Активации:** $g \in C(\mathbb{R}) \cap \mathcal{S}'(\mathbb{R})$ является TW $\iff g$ не является полиномом, ограниченные сигмоидальные функции являются TW.
- **Равномерная УА:** аппроксимация выполняется *равномерно по компактным множествам функций* с параметрами, не зависящими от f (коэффициенты линейны по f).
- **Функционалы и операторы:** любой непрерывный функционал на $V \subset C(K)$ и непрерывный оператор $G: V \rightarrow C(K_2)$ допускают равномерные нейросетевые аппроксимации, зависящие от конечного числа входных выборок и набора выходных пространственных атомов.
- **Динамика:** рассматриваем систему как оператор K , симметрии сдвига/потока естественным образом учитываются через семейства сдвигов/растяжений внутри нейросетевого базиса, аппроксимируется вся выходная траектория.

Основой стал материал статей Чена и Чена [4, 5, 6].

5 Generalized Translation Networks и их применение к задачам идентификации и управления

5.1 Модель GTN и предварительные сведения

Главной темой предыдущей лекции была теорема Чена и Чена об универсальной аппроксимации нелинейных операторов в пространствах непрерывных функций. Соответствующая нейронная сеть имеет архитектуры вида $N \circ L$ (выход линейного оператора сэмплирования/проецирования передаётся в нелинейную часть) и была построена с использованием функции Таубера–Винера в качестве активационной, что и позволило добиться успеха. Однако этот результат носит больше абстрактный характер, Мхаскар и Хахм (Mhaskar & Nahm) сделали переход между N и L конструктивным с почти оптимальным количеством параметров.

В основном будем работать на s -мерном кубе $[-1, 1]^s$, $s \in \mathbb{N}$ с Гёлдеровской нормой $\|\cdot\|_p$. Для $\lambda \geq 0$ через $\Pi_{\lambda,s}$ обозначим множество многочленов от s переменных с покомпонентной степенью не больше λ . Часто компактные подмножества L^p задаются равномерными ограничениями на *наилучшее приближение* многочленами

$$E_{\lambda,p,s}(f) := \inf_{P \in \Pi_{\lambda,s}} \|f - P\|_p$$

или условиями на коэффициенты Соболева/Лежандра.

Напомним, что **модулем непрерывности** называют функцию $\Omega(h) \rightarrow 0$ при $h \rightarrow 0$, убывающую и субаддитивную: $\Omega(h_1 + h_2) \leq \Omega(h_1) + \Omega(h_2)$. (Например, $\Omega(h) = h^\alpha$ с $0 < \alpha \leq 1$.) По нему можем ввести класс **равномерно непрерывных функционалов**

$$\mathcal{F}_{\Omega,p,s} := \{F: L^p \rightarrow \mathbb{R} : |F(f) - F(g)| \leq \Omega(\|f - g\|_p) \forall f, g\}.$$

Этот инструментарий можно рассматривать как операторный аналог Гёлдеровской или Липшицевой регулярности, используемой для УА функций.

Определение (Обобщённая сеть переноса, GTN). Фиксируем натуральные N и $1 \leq d \leq D$, активационную функцию $\varphi: \mathbb{R}^d \rightarrow \mathbb{R}$. **Обобщённой сетью переноса (generalized translation network)** с N блоками вычисляет

$$x \in \mathbb{R}^D \mapsto \sum_{k=1}^N a_k \varphi(A_k x + b_k),$$

где $A_k \in \mathbb{R}^{d \times D}$, $b_k \in \mathbb{R}^d$, $a_k \in \mathbb{R}$. Множество всех таких сетей обозначим как $\Pi_{\varphi;N,D}$.

Частные случаи: при $d = 1$ это многослойный перцептрон с одним скрытым слоем, а при $d = D$ и радиальной φ получаем RBF сеть.

На $[-1, 1]$ с единичным весом определены ортогональные **многочлены Лежандра**, формула Родрига для них

$$P_n(t) = \frac{1}{2^n n!} \frac{d^n}{dt^n} [(t^2 - 1)^n] \quad (n = 0, 1, 2, \dots).$$

Но нам будет полезнее нормализованная версия

$$\text{IP}_n(t) = \sqrt{\frac{2n+1}{2}} P_n(t), \quad \int_{-1}^1 \text{IP}_n(t) \text{IP}_m(t) dt = \delta_{nm}.$$

Основные свойства:

- Рекуррентная формула: $(n+1)P_{n+1}(t) = (2n+1)tP_n(t) - nP_{n-1}(t)$, для IP_n :

$$\sqrt{n + \frac{1}{2}} t \text{IP}_n(t) = \alpha_{n+1} \text{IP}_{n+1}(t) + \alpha_n \text{IP}_{n-1}(t), \quad \alpha_n = \frac{n}{\sqrt{(2n-1)(2n+1)}}.$$

- Чётность: $\text{IP}_n(-t) = (-1)^n \text{IP}_n(t)$.
- Значения в концах: $P_n(\pm 1) = (\pm 1)^n$, значит $\text{IP}_n(\pm 1) = \sqrt{\frac{2n+1}{2}} (\pm 1)^n$.
- Полнота в $L^2([-1, 1])$: конечные линейные комбинации $\{\text{IP}_n(t)\}$ образуют всюду плотное множество.

Для обобщения на многомерный куб, перемножим многочлены согласно мультииндексу $k = (k_1, \dots, k_D) \in \mathbb{Z}_+^D$, $x = (x_1, \dots, x_D) \in [-1, 1]^D$ (тензорное произведение):

$$\text{IP}_k(x) := \prod_{j=1}^D \text{IP}_{k_j}(x_j).$$

Тогда, согласно теореме Фубини, $\{\text{IP}_k\}_{k \in \mathbb{Z}_+^D}$ образуют ортонормированный базис в $L^2([-1, 1]^D)$, а значит применима общая теория рядов Фурье. Для $g \in L^1([-1, 1]^D)$ (или L^2) определим

$$a_k(g) := \int_{[-1, 1]^D} g(t) \text{IP}_k(t) dt, \quad g \sim \sum_{k \in \mathbb{Z}_+^D} a_k(g) \text{IP}_k$$

(со сходимостью в L^2 , кроме того верно равенство Парсеваля $\|g\|_2^2 = \sum_k |a_k(g)|^2$ при $g \in L^2$). Выберем конечное $\Pi \subset \mathbb{Z}_+^D$, определяющее какие элементы базиса сохраняться в усечённом разложении, оператор проецирования на $\text{span}\{\text{IP}_k : k \in \Pi\}$:

$$(P_\Pi g)(x) = \sum_{k \in \Pi} a_k(g) \text{IP}_k(x).$$

Пример. Некоторые классические варианты Π и их мощности.

Обозначение	Условие на k	Мощность
Π_s^{tot}	$k_1 + \dots + k_D \leq s$	C_{D+s}^s
Π_s^{max}	$\max_{1 \leq i \leq D} k_i \leq s$	$(s+1)^D$
Π_3^{HC}	$\prod_{j=1}^D (k_j + 1) \leq s + 1$	$\sim \frac{(s+1)[\ln(s+1)]^{D-1}}{(D-1)!}$

Для узлов $X = \{x_j\}_{j=1}^m \subset [-1, 1]^D$, определим **оператор сэмплирования** $L: \{x_j\}_{j=1}^m \subset [-1, 1]^D$, $L(g) = (g(x_1), \dots, g(x_m))$. По нему можем построить **коэффициенты приближения (МНК/квадратуры)**. Пусть $V_{j,k} = \text{IP}_k(x_j)$, $W > 0$ — матрица весов, тогда имеем линейную оценку

$$\hat{a}(g) := (V^T W V)^{-1} V^T W L(g) \in \mathbb{R}^{|\Pi|}, \quad \tilde{a}_k(g) \approx a_k(g).$$

Этот вектор будем использовать в **полиномиальном заменителе**: для вектора $a \in \mathbb{R}^{|\Pi|}$ положим

$$I_\Pi(a)(x) = \sum_{k \in \mathbb{N}} a_k \text{IP}_k(x).$$

Замечание (О выборе Π). Практические советы по выбору набора мультииндексов Π , чтобы не потерять в точности и времени вычислений:

- Больше $\Pi \Rightarrow$ меньше смещение из-за усечения, но больше $|\Pi|$, что может приводить к плохой обусловленности.
- Для гладких/аналитических g часто Π_s^{tot} оптимальный выбор, для больших D Π_s^{HC} уменьшает взрыв размерности.

Инструкция по выбору (в стиле Мхаскара–Хахма).

1. Зафиксировать семейство индексов Π_s и увеличивать s , пока ошибка усечения больше заданного значения.
2. Для каждого Π_s выбрать $m \gtrsim c|\Pi_s|$ точек и построить $I_{\Pi_s}(\hat{a}(g))$.
3. Следить за ошибкой на тестовой сетке, чтобы остановиться, когда $\|g - I_{\Pi_s}(\hat{a}(g))\|$ имеет заданную точность.

Перейдём теперь непосредственно к построению операторов L и N .

Линейная часть: для $m \in \mathbb{N}$ положим $D = (m+1)^s = |\Pi_m^{\text{max}}|$ и $L: L^p([-1, 1]^s) \rightarrow \mathbb{R}^D$ будет возвращать все коэффициенты Фурье–Лежандра не выше m -го порядка по каждой координате, а $I_\Pi: \mathbb{R}^D \rightarrow \Pi_{m,s}$ восстанавливает по ним полином. Тогда имеют места неравенства

$$\|L_m(f)\| \leq C\|f\|_p, \quad \|f - I_\Pi L_m(f)\|_p \leq \varepsilon_m(K) \quad (f \in K)$$

с явными константами из неравенств типа Джексона/Маркова.

Нелинейная часть: GTN $\sum_k a_k \varphi(A_k \cdot + b_k)$ на $\mathbb{R}^D$.

Откуда берутся оценки? Поскольку $\{\text{IP}_k\}$ ортонормированна в L^2 и равномерно ограничена на $[-1, 1]$, найдётся $C = C(p, s)$, что

$$\|L_m(f)\|_{\ell^p(\Pi_m^{\text{max}})} \leq C\|f\|_{L^p([-1, 1]^s)} \quad (1 \leq p \leq \infty).$$

Дальше применим (прямую) теорему Джексона на $[-1, 1]^s$, для $r \in \mathbb{N}$ и показателя p

$$E_{m,p,s}(f) \leq C\omega_r\left(f; \frac{1}{m}\right)_{L^p},$$

где ω_r — это r -ый модуль непрерывности. Если дополнительно $f \in W^{r,p}$ (пространство Соболева), то

$$E_{m,p,s}(f) \leq C m^{-r} \|f\|_{W^{r,p}}.$$

Также нам поможет (обратное) неравенство Маркова для полиномов, для $p_m \in \Pi_{m,s}$ и мультииндекса α

$$\|D^\alpha p_m\|_{L^p} \leq C m^{|\alpha|} \|p_m\|_{L^p}.$$

Теперь соберём это всё вместе, если $K \subset L^p$ — компакт с общим модулем гладкости (равностепенная непрерывность, ограниченность в пространстве Соболева), тогда

$$\sup_{f \in K} \|f - I_{\Pi_m^{\text{max}}} L_m(f)\|_{L^p} \leq \varepsilon_{m,K} \xrightarrow{m \rightarrow \infty} 0.$$

Введём в рассмотрение целевой функционал $F: K \rightarrow \mathbb{R}$, непрерывный на компакте K . Образ $U_m := L_m(K) \subset \mathbb{R}^D$ компактен. На нём определена функция $\varphi_m(a) := F(I_{\Pi_m^{\text{max}}}(a))$. Применим УАТ на U_m : для всякого $\varepsilon > 0$ существует обобщённая сеть переноса (GTN)

$$N(v) = \sum_{k=1}^M \alpha_k \varphi(A_k \cdot v + b_k), v \in \mathbb{R}^D,$$

(с неполиномиальной активационной функцией) такая, что

$$\sup_{a \in U_m} |\varphi_m(a) - N(a)| \leq \varepsilon.$$

Применяя неравенство треугольник, получаем для всех $f \in K$

$$|F(f) - N(L_m(f))| \leq \underbrace{|F(f) - F(I_{\Pi_m^{\max}} L_m(f))|}_{\text{линейное приближение}} + \underbrace{|\varphi_m(L_m(f)) - N(L_m(f))|}_{\text{GTN приближение}}.$$

Если F равномерно непрерывен на K и $\|f - I_{\Pi_m^{\max}} L_m(f)\|_p \leq \varepsilon_{m,K}$, то первое слагаемое стремится к нулю при $m \rightarrow \infty$, второе мало по УАТ. Если же K ограничено в $W^{r,p}$, то $\|f - I_{\Pi_m^{\max}} L_m(f)\|_p \leq m^{-r}$, что позволяет найти подходящее m . Аналитичность f на эллипсе Бернштейна обеспечивает экспоненциальное затухание проекций Лежандра/тригонометрических: $E_{m,p,s}(f) \lesssim \rho^{-m}$, $\rho > 1$, то есть можно брать не слишком большое m , что положительно сказывается на $D = (m+1)^s$ и уменьшает сложность сети N .

5.2 Почти оптимальная универсальная аппроксимация функционалов на L^p

Формализуем предыдущие рассуждения следующей теоремой.

Теорема 5.1 (Мхаскар–Хахм, теорема 2.1). Пусть $d \geq 1$ и $\varphi \in C^\infty$ на открытом шаре в $\mathbb{R}^d$ и $D^k \varphi(b) \neq 0$ для всех мультииндексов $k \in \mathbb{Z}_+^d$ и некоторой точки b . Пусть $s \geq 1$, $1 \leq p \leq \infty$, $K \subset L^p([-1, 1]^s)$ — компакт, Ω — модуль непрерывности. Положим $D = (m+1)^s$, L_m как ввели ранее. Тогда существуют линейные функционалы $\gamma_k: C(K) \rightarrow \mathbb{R}$ ($k = 1, \dots, N$) и матрицы $A_k \in \mathbb{R}^{d \times D}$ ранга d , с N , m , n зависящими лишь от $(p, s, \varphi, K, \Omega)$, что для любого $F \in \mathcal{F}_{\Omega,p,s}$ справедливо

$$\sup_{f \in K} \left| F(f) - \sum_{k=1}^N \gamma_k(F) \varphi(A_k L_m(f) + b) \right| \leq c \{ \Omega(\varepsilon_{m,K}) + \Omega(m^\beta/n) \},$$

где $\beta > 0$ — константа роста Маркова/Джексона (зависит от p, s) и n — степень многочлена, использованного на U_m . Архитектура и L_m не зависят от F , лишь внешние коэффициенты зависят линейно от него.

Доказательство. Из теорем Джексона/Маркова на $[-1, 1]^s$ (см. предыдущий пункт) для компактного K с общим модулем гладкости/непрерывности имеем

$$\sup_{f \in K} \|f - I_{\Pi_m^{\max}} L_m(f)\|_{L^p} \leq \varepsilon_{m,K} \xrightarrow{m \rightarrow \infty} 0.$$

Поскольку $F \in \mathcal{F}_{\Omega,p,s}$, то

$$\sup_{f \in K} |F(f) - F(I_{\Pi_m^{\max}} L_m(f))| \leq \Omega(\varepsilon_{m,K}).$$

Дальше приблизим $\mu_m(F, L_m(\cdot)) := F(I_{\Pi_m^{\max}} L_m(\cdot))$ равномерно на K .

U_m является компактом в $\mathbb{R}^D$. Для $a, d \in U_m$ справедливо

$$\|I_{\Pi_m^{\max}}(a) - I_{\Pi_m^{\max}}(d)\|_{L^p} \leq C_m \|a - d\|_{\ell^p}$$

с константой $C_m \lesssim m^\beta$ (обратное неравенство Маркова на $\Pi_{m,s}$). Благодаря модулю непрерывности F

$$|\mu_m(F, a) - \mu_m(F, d)| \leq \Omega(C_m \|a - d\|_{\ell^p}) \leq \Omega(cm^\beta \|a - d\|_{\ell^p}),$$

значит $\mu_m(F, \cdot)$ тоже равномерно непрерывен на K . По многомерной теореме Джексона или Ньюмана–Шапиро (приближение многочленами, управляемая модулем непрерывности) найдётся полином p_n с $\deg p_n \leq n$, обеспечивающий

$$\sup_{a \in U_m} |\mu_m(F, a) - p_n(a)| \leq c\Omega(m^\beta/n).$$

Идея доказательства: покрыть U_m кубами со стороной $\frac{1}{n}$, применить наследованный модуль непрерывности $h \mapsto \Omega(cm^\beta h)$ к $\mu_m(F, \cdot)$ и многочленам Бернштейна, чтобы получить оценку.

Используем, что $\varphi \in C^\infty$ и $D^k \varphi(b) \neq 0$ для всех k , чтобы записать многомерную формулу Тейлора в точке b

$$\varphi(b + z) = \sum_{\alpha \in \mathbb{Z}_+^d} \frac{D^\alpha \varphi(b)}{\alpha!} z^\alpha.$$

Для любого n найдётся конечное число матриц A_k (ранга d) и скаляров $c_{r,\alpha}$, что на ограниченных множествах

$$\left\| a^\alpha - \sum_r c_{r,\alpha} \varphi(A_r a + b) \right\| \leq \varepsilon \quad \forall |\alpha| \leq n.$$

Причина: матрица системы (нижнетреугольная) $\{D^\beta \varphi(b)\}_{|\beta| \leq n}$ обратима по степеням, поэтому можем решить её, чтобы приблизить мономы вплоть до степени n линейными комбинациями $\varphi(A \cdot + b)$.

Пусть $p_n(a) = \sum_{|\alpha| \leq n} c_\alpha a^\alpha$. Используя предыдущее соображение, получаем

$$p_n(a) \approx \sum_k \gamma_k(F) \varphi(A_k a + b).$$

где A_k и количество слагаемых зависит лишь от n , d и φ , но не F или K . Чтобы получить $\gamma_k(F)$, выбираются узлы $\{a^{(r)}\} \subset U_m$ и многочлены Лагранжа $\{\ell_r\}$, $p_n(a) = \sum_r \mu_m(F, a^{(r)}) \ell_r(a)$. Каждый ℓ_r представим как комбинацию $\varphi(A \cdot + b)$, тогда

$$\gamma_k(F) := \sum_r \mu_m(F, a^{(r)}) \eta_{k,r} = \sum_r F(h_{\Pi_m^{\max}}(a^{(r)})) \eta_{k,r},$$

где $\eta_{k,r}$ коэффициенты из представления $\{\ell_r\}$. Зависимость функционалов от F линейная.

Итого для всех $f \in K$

$$\begin{aligned} \left| F(f) - \sum_{k=1}^N \gamma_k(F) \varphi(A_k L_m(f) + b) \right| &\leq |F(f) - F(p_m(f))| + \\ &+ |\mu_m(F, L_m(f)) - p_n(L_m(f))| + \left| p_n(L_m(f)) - \sum_k \gamma_k(F) \varphi(A_k L_m(f) + b) \right|. \end{aligned}$$

Первое слагаемое $\leq \Omega(\varepsilon_{m,K})$, второе $\leq c\Omega(m^\beta/n)$, третье можно сделать $\leq \varepsilon$. Соберём последнее ε в константу, чтобы получить требуемую оценку. $\square$

5.3 Нелинейная N -ширина и нижние оценки на размер

Дальше мы попробуем выяснить, почему полученная аппроксимация действительно оптимальна. Введём ряд определений.

Определение (Нелинейная N -ширина). Это величина

$$\Delta_N(\mathcal{F}) := \inf_{M_N, \pi} \sup_{F \in \mathcal{F}, f \in K} |F(f) - M_N(\pi(F), f)|,$$

где $\pi: \mathcal{F} \rightarrow \mathbb{R}^N$ и $M_N: \mathbb{R}^N \times K \rightarrow \mathbb{R}$ непрерывны.

Тут π выполняет роль кодировщика, сжимающего функционал в набор из N чисел, а M_N декодирует эту информацию и предсказывает $F(f)$. Ширина Δ_N является минимальной худшей ошибкой, достижимой в такой схеме.

Определение (Эллипсоид смешанной гладкости). Для $\alpha > 0$ это эллипсоид вида

$$K := \left\{ f \in L^2 : \sum_{k \in \mathbb{Z}_+^n} \|k\|_\infty^{2\alpha} |a_k(f)|^2 \leq 1 \right\}, \quad a_k(f) = \langle f, \text{IP}_k \rangle$$

Эвристика в том, что $|a_k(f)| \lesssim \|k\|_\infty^{-\alpha}$, поэтому усечение на уровне $\|k\|_m \sim m$ приводит к ошибке $\asymp m^{-\alpha}$. “Частотный блок” $B_m := \{k : m \leq \|k\|_\infty \leq 2m\}$ имеет мощность $\asymp m^s$, а значит имеет 2^{cm^s} знаковых шаблонов, остающихся в K . Для каждого знакового вектора $\sigma \in \{\pm 1\}^{B_m}$ обозначим

$$f_\sigma(x) := c_m \sum_{k \in B_m} \sigma_k \frac{1}{\|k\|_\infty^\alpha} \text{IP}_k(x), \quad c_m > 0 \text{ выбраны, что } \sum_k \|k\|_\infty^{2\alpha} |a_k(f_\sigma)|^2 \leq 1.$$

Тогда $f_\sigma \in K$ и, по ортонормированности

$$\|f_\sigma - f_\tau\|_{L^2}^2 \geq cm^{-2\alpha} |\{k \in B_m : \sigma_k \neq \tau_k\}| \geq c'm^{-2\alpha} \quad (\sigma \neq \tau).$$

Поэтому $\mathcal{P}_m := \{f_\sigma : \sigma \in \{\pm 1\}^{B_m}\} \subset K$ состоит из элементов попарно отстоящих друг от друга на $\gtrsim m^{-\alpha}$, и $|\mathcal{P}_m| = 2^{|B_m|} \geq 2^{cm^s}$.

Пусть все коды лежат в ограниченном множестве $Q \subset \mathbb{R}^N$ (всегда возможно для компактного множества функционалов). Для $\varepsilon > 0$ число элементов ε -покрытия оценивается сверху

$$\mathcal{N}(Q, \varepsilon) \leq \left(\frac{C \text{diam}(Q)}{\varepsilon} \right)^N.$$

Выберем ε , чтобы $|\mathcal{P}_m| = 2^{cm^s} > \mathcal{N}(Q, \varepsilon)$, тогда найдутся два разных ε -близких кода. Из-за равномерной непрерывности M_N на $Q \times K$ малые помехи в коде приводят к малым изменениям в выходе, чтобы сделать их большими, используем разделяющий функционал. Подойдёт функционал *Липшица* $F_\star(h) := \langle h, \psi \rangle_{L^2}$ с $\|\psi\|_{L^2} = 1 \Rightarrow |F_\star(h) - F_\star(g)| \leq \|h - g\|_{L^2}$, то есть $F_\star \in \mathcal{F}_{\Omega, 2, s}$ с $\Omega(t) = t$. Чтобы $F_\star(h) - F_\star(g)$ было сравнимо с $\|f_\sigma - f_\tau\|_{L^2}$, можно взять $\psi = \frac{f_\sigma - f_\tau}{\|f_\sigma - f_\tau\|_{L^2}}$. Тогда для близких кодов и произвольного непрерывного декодера M_N

$$|F_\star(f_\sigma) - M_N(\pi(F_\star), f_\tau)| + |F_\star(f_\tau) - M_N(\pi(F_\star), f_\tau)| \geq c\|f_\sigma - f_\tau\|_{L^2} \gtrsim m^{-\alpha},$$

что и будет ошибкой в худшем случае. Для итогового варианта надо применить общий модуль непрерывности: $\geq \Omega(cm^{-\alpha})$.

В конечном счёте $2^{cm^s} \gtrsim \mathcal{N}(Q, \varepsilon) \lesssim (C/\varepsilon)^N$, то есть $cm^s \gtrsim N \log(C/\varepsilon)$. Фиксируем ε и разрешаем уравнение относительно m :

$$m \asymp (\log N)^{1/s}.$$

Итоговая оценка

$$\Delta_N(\mathcal{F}_{\Omega,2,s}) \geq c\Omega((\log N)^{-\alpha/s}).$$

Это в точности заключение теоремы 2.2 Мхаскара–Хахма, оно показывает, что обсуждаемая конструкция GTN *почти оптимальная* по N (нижняя оценка из теории информации). Действительно, выберем $n \asymp m^\beta$, $m \asymp (\log N)^{1/s}$, тогда верхняя оценка погрешности аппроксимации $\lesssim \Omega((\log N)^{-\alpha/s})$ (для K смешанной гладкости α).

Посмотрим на конструкцию **с точки зрения динамических систем** (связь с Ченом и Ченом). Пусть S_τ будет временным сдвигом на сигналах $u: \mathbb{R} \rightarrow \mathbb{R}$, $(S_\tau u)(t) = u(t - \tau)$. Функционалы/операторы, инвариантные к сдвигу: $F \circ S_\tau = F$ или $G(S_\tau u) = S_\tau G(u)$. Линейное отображение L_m можно выбрать как:

- ортогональная проекция (коэффициенты Лежандра) — устойчивы к естественным потокам в пространстве признаков;
- временное окно $L(u) = (u(t_j))_{j=1}^D$ — эквивариантно по отношению к S_τ (используется в идентификации).

И то, и другое соотносится с подходом $N \circ L$ Чена и Чена и динамическими моделями Нарандры–Партасарати:

- L выделяет конечные “состояния” из траекторий;
- N считывает динамику.

TW/GTN плотность обеспечивает репрезентативную устойчивость (сдвиги и растяжения против обобщённых переносов) для ridge/RBF конструкций.

5.4 Четыре классические динамические модели (Нарендра и Партасарати) для идентификации и управления

В своей основополагающей работе 1990 года К.С. Нарендра и К. Партасарати предложили четыре базовые нелинейные модели для идентификации и управления дискретными системами «вход-состояние-выход». Для SISO-систем они записываются следующим образом:

$$\text{М I: } y_p(k+1) = \sum_{i=0}^{n-1} \alpha_i y_p(k-i) + g(u(k), u(k-1), \dots, u(k-m+1)),$$

$$\text{М II: } y_p(k+1) = f(y_p(k), y_p(k-1), \dots, y_p(k-n+1)) + \sum_{j=0}^{m-1} \beta_j u(k-j),$$

$$\text{М III: } y_p(k+1) = f(y_p(k), y_p(k-1), \dots, y_p(k-n+1)) + g(u(k), u(k-1), \dots, u(k-m+1)),$$

$$\text{М IV: } y_p(k+1) = f(y_p(k), \dots, y_p(k-n+1), u(k), \dots, u(k-m+1)).$$

Неизвестные нелинейности f и g аппроксимируются многослойными перцептронами (MLP). Модель I содержит нелинейность только по входу, модель II — только по выходу, модель III разделяет нелинейности, а модель IV является общей НАРСС (NARX) моделью.

Эти модели мотивированы аналогичными структурами для линейных систем (ARX) и позволяют естественным образом встроить нейронные сети в динамический контекст. В оригинальной статье приведены примеры идентификации для каждой модели (например, система $y_p(k+1) = 0.3y_p(k) + 0.6y_p(k-1) + f(u(k))$ для модели I [7]).

5.5 Представление моделей как частных случаев GTN

Обобщённые трансляционные сети (GTN) представляют собой композицию линейного оператора сэмпирования L и нелинейного оператора N : $P \approx N \circ L$. Модели Нарандры–Партасарати естественно вписываются в эту парадигму.

- **Модели I, II, IV (NARX-типа)** непосредственно соответствуют схеме $N \circ L$. Линейный оператор L_D формирует вектор-регрессор из запомненных значений входа и выхода:

$$\phi(k) = (y(k-1), \dots, y(k-n_y), u(k-1), \dots, u(k-n_u)) \in \mathbb{R}^D.$$

Нейронная сеть Φ выступает в роли нелинейного оператора N , отображая $\phi(k)$ в предсказание $\hat{y}(k|k-1)$. Таким образом, для модели IV (и её частных случаев I, II) имеем $\hat{y}(k+1) = \Phi(\phi(k)) = (N \circ L_D)(u, y, k)$.

- **Модель III** может быть представлена как комбинация двух MLP: N_f для аппроксимации f и N_g для аппроксимации g , работающих параллельно на разных частях регрессора.
- **Модель II (State-Space)** также допускает операторную интерпретацию, но в более общем виде. Система

$$x(k+1) = \Psi(x(k), u(k)), \quad \hat{y}(k) = \Theta(x(k)),$$

где Ψ и Θ — MLP, представляет собой рекуррентную нейронную сеть. Оператор сдвига во времени S действует как обобщённая трансляция на пространстве состояний x . Линейное отображение, восстанавливающее состояние из прошлых данных (например, через наблюдатель или энкодер $E(\phi(k_0))$), можно рассматривать как часть оператора L , а Θ — как оператор N .

Все четыре модели являются частными случаями или вариациями общей архитектуры $L-N$, что обеспечивает единый подход к их анализу на основе теорем об универсальной аппроксимации операторов.

5.6 Идея замыкания контура обратной связи, замечания про устойчивость и штрафы на основе якобиана/ISS

При использовании обученной модели в контуре управления (например, в схеме косвенного адаптивного управления или MPC) модель переводится в *параллельный (free-run)* режим, где её собственные предсказания $\hat{y}$ используются для формирования регрессора на следующих шагах. Это замыкает контур обратной связи и может привести к неустойчивости, даже если исходная система устойчива.

Критически важным становится обеспечение *устойчивости* модели. Для моделей в пространстве состояний (модель II) достаточным условием глобальной устойчивости является *сжатие* (contraction):

$$\sup_{x,u} \|\partial_x \Psi(x, u, \theta)\| \leq \lambda < 1.$$

Более общим условием является *устойчивость вход-состояние (ISS)*: существует функция Ляпунова $V(x)$ и функции сравнения $\underline{\alpha}, \bar{\alpha}, \alpha, \sigma$ такие, что

$$\underline{\alpha}(\|x\|) \leq V(x) \leq \bar{\alpha}(\|x\|), \quad V(\Psi(x, u)) - V(x) \leq -\alpha(\|x\|) + \sigma(\|u\|),$$

что гарантирует ограниченность состояния при ограниченном входе.

Для принудительного выполнения этих условий в процессе обучения в функционал потерь добавляют регуляризационные штрафы на якобианы:

$$\mathcal{R}(\theta) = \lambda_x \sum_k \|\partial_x \Psi(x(k), u(k))\|_F^2 + \lambda_y \sum_k \|\partial_x \Theta(x(k))\|_F^2 + \lambda_{sn} \sum_\ell (\sigma_{\max}(W_\ell) - \tau)_+^2.$$

Такая регуляризация не только улучшает устойчивость замкнутого контура, но и стабилизирует вычисление градиентов в ВРТТ, смягчая проблемы исчезающих и взрывающихся градиентов, возникающих при перемножении матриц Якоби $\prod_j A(j)$.

Для моделей NARX-типа (I, III, IV) в параллельном режиме также возникают длинные цепочки вычислений, требующие усечённого ВРТТ с горизонтом H (обычно $H \in [5, 20]$).

5.7 Обучающие протоколы и связь с операторным подходом Чен–Чена

Обучение динамических моделей может проводиться в двух основных режимах:

1. **Последовательно-параллельный (Series-Parallel)** или *teacher forcing*: в процессе обучения в регрессор подставляются измеренные значения выхода $y(k - i)$. Это разрывает рекуррентные связи и превращает задачу в обучение статического отображения, что позволяет использовать стандартное обратное распространение. Соответствующая функция потерь — *одношаговая*:

$$J_{\text{sp}}(\theta) = \sum_k \|y(k) - \hat{y}(k|k-1; \theta)\|^2.$$

Этот режим обеспечивает устойчивое обучение (нет накопления ошибки), но может приводить к рассогласованию при переходе в параллельный режим [7].

2. **Параллельный (Parallel)** или *free-run*: модель работает автономно, используя собственные предсказания. Обучение требует ВРТТ по нескольким шагам (горизонт H) и минимизации *многошаговой* ошибки:

$$J_{\text{par}, H}(\theta) = \sum_k \sum_{h=1}^H \|y(k+h) - \hat{y}_{h\text{-step}}(k; \theta)\|^2.$$

Этот режим лучше соответствует реальной эксплуатации модели в контуре управления, но сложнее в обучении из-за проблем с градиентами. Часто используют гибридный подход: начинают с J_{sp} , затем дообучают на $J_{\text{par}, H}$ [?].

Операторная теорема Чен–Чена об универсальной аппроксимации нелинейных операторов предоставляет теоретическое обоснование подхода L – N . Она утверждает, что используя фиксированные ridge-функции $g(w_i \cdot x + \theta_i)$ и настраивая только линейные веса $c_i(f)$ на выходе, можно равномерно аппроксимировать любой непрерывный оператор на компактном множестве входных сигналов.

Модели Нарандры–Партасарати реализуют эту идею на практике: оператор L (формирование регрессора из задержек) выполняет линейное сэмплирование, а MLP Φ реализует нелинейное считывание. Благодаря теореме о плотности MLP в пространстве непрерывных функций, Φ может сколь угодно точно аппроксимировать требуемую нелинейность F^* .

Таким образом, модели I–IV представляют собой исторически значимый мост между классической теорией идентификации нелинейных систем и современными операторными подходами на основе нейронных сетей. Их структурная простота, ясная интерпретация в рамках GTN и наличие эффективных алгоритмов обучения (статическое и динамическое обратное распространение) делают их фундаментом для многих современных методов нейросетевого моделирования динамических систем.

Первая часть лекции основана на работе [8], а вторая на [7].

6 Функциональный многослойный перцептрон (FMLP)

6.1 Введение в функциональные данные: функции как объекты

В *функциональном анализе данных* (Functional Data Analysis, FDA) каждый объект (индивид, эксперимент) описывается не вектором из $\mathbb{R}^n$, а одной или несколькими функциями $g: Z \rightarrow \mathbb{R}$, где $Z \subset \mathbb{R}^u$ — компакт (например, временной интервал $Z = [-T, 0]$).

Зачем это нужно для ИНС?

- Естественный учёт зависимостей между измерениями (например, временная корреляция в сигналах).
- Работа с неравномерной или разреженной выборкой, редкими измерениями: функция (сигнал) восстанавливается через сглаживание (сплайны, ядра, вейвлеты).
- Возможность применять классические задачи машинного обучения (регрессия, классификация, кластеризация) к функциональным предикторам.

6.2 Функциональные нейроны, архитектура FMLP и связь с обычными MLP

Обычный нейрон в MLP вычисляет $N(x) = T(w \cdot x + b)$, где $w \cdot x$ — линейная форма (скалярное произведение) на $\mathbb{R}^n$. Для функционального входа $g \in L^p(Z, \mu)$ (или $C(Z)$) линейную форму естественно задать через интеграл.

Определение (Функциональный нейрон). Пусть заданы функция активации $T: \mathbb{R} \rightarrow \mathbb{R}$, функциональные веса f_ℓ (измеримые функции, такие что $f_\ell g_\ell \in L^1(\mu_\ell)$) и смещение $b \in \mathbb{R}$. *Функциональный нейрон* с s входами $g_1, \dots, g_s$ определяется как

$$N(g_1, \dots, g_s) = T \left(b + \sum_{\ell=1}^s \int_{Z_\ell} f_\ell(x) g_\ell(x) d\mu_\ell(x) \right).$$

Проблема этого определения в том, что тут нечего обучать, веса f_ℓ заранее заданы, поэтому вводится параметризация.

Определение (Параметрический функциональный нейрон). Пусть заданы параметрические семейства функций $F_\ell(w_\ell, \cdot): Z_\ell \rightarrow \mathbb{R}$, где $w_\ell \in W_\ell \subset \mathbb{R}^{v_\ell}$ — параметры, и $F_\ell(w_\ell, \cdot) \in L^{q_\ell}(\mu_\ell)$ (где q_ℓ — сопряжённый показатель к p_ℓ). Тогда *параметрический функциональный нейрон* имеет вид:

$$N(g_1, \dots, g_s) = T \left(b + \sum_{\ell=1}^s \int_{Z_\ell} F_\ell(w_\ell, x) g_\ell(x) d\mu_\ell(x) \right).$$

Функциональные нейроны используются только в первом слое, последующие слои — обычные числовые MLP. Таким образом, FMLP — это композиция линейного интегрального оператора (извлекающего конечное число признаков из функции) и стандартной нейронной сети.

Определение (Однослойный FMLP с одним функциональным входом). Для функционального входа g и k скрытых функциональных нейронов:

$$H(g) = \sum_{i=1}^k a_i T \left(b_i + \int_{Z_i} F_i(w_i, x) g(x) d\mu(x) \right),$$

где $a_i, b_i \in \mathbb{R}$, $w_i \in W_i$ — параметры.

Связь с обычными MLP:

- Если вместо функции g подставить вектор $\mathbf{x} \in \mathbb{R}^n$, а меру μ взять дискретную с массами в x_j , интеграл превращается в сумму:

$$\int_Z F(w, x)g(x)d\mu(x) \approx \sum_{j=1}^n F(w, x_j)g(x_j),$$

что соответствует линейной форме $w \cdot g$ с $w_j = F(w, x_j)$.

- Таким образом, обычный MLP — частный случай FMLP, когда функциональный вход задан только в конечном числе точек.

6.3 Основная УАТ для FMLP (на L^p , L^1 , произведениях функциональных пространств)

Пусть $C(A, B)$ обозначает множество непрерывных отображений из топологического пространства A в топологическое пространство B . Для компактного подмножества $K \subset X$ (где X — топологическое векторное пространство) мы снабжаем пространство $C(K, \mathbb{R})$ **равномерной (чебышёвской) нормой**:

$$\rho_K(f, g) := \sup_{x \in K} |f(x) - g(x)|.$$

Если $A = \mathbb{R}^n$, а M^n обозначает (борелевские) измеримые отображения $\mathbb{R}^n \rightarrow \mathbb{R}$, то стандартной метрикой, порождающей сходимость на компактах, является

$$d_C(f, g) = \sum_{m=1}^{\infty} 2^{-m} \min \left\{ \sup_{\|x\| \leq m} |f(x) - g(x)|, 1 \right\}.$$

Для корректной формулировки теорем о плотности множества функций (например, нейронных сетей) в более широком пространстве вводится следующее техническое определение.

Определение (Внутренняя/внешняя плотность (по Стинчкомбу, 1999)). Пусть $(\mathcal{X}, d)$ — метрическое пространство, $C \subset \mathcal{X}$ и $S \subset \mathcal{X}$.

- Множество S называется **d -внешне плотным** в C , если d -замыкание множества S содержит C , то есть $C \subset \overline{S}^d$.
- Множество S называется **d -внутренне плотным** в C , если d -замыкание множества $S \cap C$ содержит C , то есть $C \subset \overline{S \cap C}^d$.

Если $C = \mathcal{X}$, эти понятия совпадают, и мы просто говорим, что S **d -плотно** в $\mathcal{X}$.

Пусть X — топологическое векторное пространство, а X^* — его (непрерывное) сопряжённое пространство. Пусть $T: \mathbb{R} \rightarrow \mathbb{R}$ — фиксированная функция активации.

Определение (Классический однослойный перцептрон). Для размерности $n \in \mathbb{N}$ определим класс функций

$$S_T^n := \left\{ h(x) = \sum_{i=1}^p \beta_i T(w_i \cdot x + b_i) : p \in \mathbb{N}, \beta_i \in \mathbb{R}, (w_i, b_i) \in \mathbb{R}^n \times \mathbb{R} \right\}.$$

Определение (Обобщённый перцептрон на X (в стиле Стинчкомба)). Пусть $A \subset X^*$ — некоторое множество непрерывных линейных функционалов на X . Определим класс функций

$$S_T^X(A) := \left\{ h(x) = \sum_{i=1}^m \beta_i T(\ell_i(x) + b_i) : m \in \mathbb{N}, \beta_i, b_i \in \mathbb{R}, \ell_i \in A \right\}.$$

Здесь $\ell_i: X \rightarrow \mathbb{R}$ — линейные функционалы из множества A , заменяющие скалярные произведения $w_i \cdot x$.

Пусть μ — конечная борелевская мера на $\mathbb{R}^n$, и $1 < p < \infty$, а q — сопряжённый показатель ($\frac{1}{p} + \frac{1}{q} = 1$). Рассмотрим пространство $X = L^p(\mu)$ и пусть $V \subset L^q(\mu)$ — плотное подмножество (в норме L^q). Определим множество интегральных линейных функционалов:

$$A_V := \left\{ \ell_g: f \mapsto \int g(x)f(x) d\mu(x) \mid g \in V \right\} \subset X^*.$$

Лемма 6.1 (О слабой-* плотности интегральных форм). *Множество A_V является слабо-* плотным в пространстве X^* , которое изометрично $L^q(\mu)$ (по теореме Рисса о представлении).*

Идея доказательства. По теореме Рисса, любой линейный непрерывный функционал $\ell \in X^*$ имеет единственное представление в виде $\ell(f) = \int g_\ell(x)f(x)d\mu(x)$ для некоторой $g_\ell \in L^q(\mu)$. Так как V плотно в $L^q(\mu)$, для любого g_ℓ найдётся последовательность $\{g_n\} \subset V$, сходящаяся к g_ℓ в норме L^q . Тогда соответствующие функционалы ℓ_{g_n} сходятся к ℓ в слабой-* топологии. $\square$

Случай произведения пространств. Для $X = \prod_{j=1}^s L^{p_j}(\mu_j)$ и плотных подмножеств $V_j \subset L^{q_j}(\mu_j)$ (q_j — сопряжённые к p_j показатели) определим:

$$A_V := \left\{ \ell_g(f_1, \dots, f_s) = \sum_{j=1}^s \int g_j(x)f_j(x) d\mu_j(x) : g_j \in V_j \right\} \subset X^*.$$

Тогда A_V является слабо-* плотным в $X^* \cong \prod_{j=1}^s L^{q_j}(\mu_j)$.

Далее мы обсудим общую схему доказательства плотности в топологических векторных пространствах, предложенную Стинчкомбом.

Теорема 6.1 (Общая схема обоснования плотности (по Стинчкомбу, 1999)). *Пусть X — локально выпуклое топологическое векторное пространство и $A \subset X^*$. Предположим, что:*

1. *A является слабо-* плотным в X^* (т.е. его замыкание в топологии $\sigma(X^*, X)$ совпадает с X^*);*
2. *Функция активации $T: \mathbb{R} \rightarrow \mathbb{R}$ не является полиномом (эквивалентно, является дискриминаторной в смысле Цыбенко/Лешно).*

Тогда для любого компактного подмножества $K \subset X$ множество $S_T^X(A)$ является **равномерно плотным** в пространстве непрерывных функций $C(K, \mathbb{R})$:

$$\overline{S_T^X(A)|_K}^{\rho_K} = C(K, \mathbb{R}),$$

где ρ_K — равномерная норма на K .

Доказательство. Доказательство основано на **теореме 5.1** и **следствии 5.1.3** из статьи Stinchcombe (1999).

1. Переход к одномерному случаю. По условию (2) функция активации T не является полиномом. Согласно классическому результату Лешно–Лина–Пинкуса–Шокена (1993), множество

$$S_T^1 = \text{span}\{T(w \cdot x + b) \mid w, b \in \mathbb{R}\}$$

является плотным в $C(\mathbb{R})$ в топологии равномерной сходимости на компактах (d_C -плотным). В частности, S_T^1 d_C -внешне плотно в C^1 .

2. Использование слабой-* плотности A . Рассмотрим пространство X^* с топологией $\sigma(X^*, X)$. По условию (1) A слабо-* плотно в X^* .

Для любого компакта $K \subset X$ рассмотрим семейство функций

$$\mathcal{A} = \{\ell(\cdot) + b \mid \ell \in A, b \in \mathbb{R}\}.$$

Это векторное подпространство в $C(K)$, так как оно замкнуто относительно сложения и умножения на скаляр.

3. Проверка условий теоремы 5.1(b).

- **Постоянные функции:** выбирая $\ell = 0 \in \overline{A}$ (слабое-* замыкание), получаем постоянные функции.
- **Разделение точек:** для любых $x \neq y$ из K найдётся $\ell \in A$ такой, что $\ell(x) \neq \ell(y)$ (по теореме Хана–Банаха и слабой-* плотности A). Добавляя сдвиг b , можно добиться разделения.

Таким образом, $\mathcal{A}$ удовлетворяет условиям теоремы 5.1(b).

4. Применение теоремы 5.1. По теореме 5.1(b), если S_T^1 является d_C -внешне плотным в C^1 , то $\text{span}(T \circ \mathcal{A})$ будет ρ_K -внешне плотным в $C(K)$. Но

$$\text{span}(T \circ \mathcal{A}) = S_T^X(A),$$

что и означает равномерную плотность на компакте K .

4. Завершение доказательства. Поскольку K произвольный компакт в X , получаем требуемое:

$$\overline{S_T^X(A)|_K}^{\rho_K} = C(K, \mathbb{R}).$$

□

Теорема 6.2 (Функциональный аналог УАТ в L^p). Пусть $1 < p < \infty$, $X = L^p(\mu)$ с конечной борелевской мерой μ , и $V \subset L^q(\mu)$ — плотное подмножество. Предположим, что $T : \mathbb{R} \rightarrow \mathbb{R}$ не является полиномом (так что S_T^1 d_C -плотно в $C(K_1, \mathbb{R})$ для любого компакта $K_1 \subset \mathbb{R}$). Тогда для любого компакта $K \subset X$

$$\overline{S_T^X(A_V)|_K}^{\rho_K} = C(K, \mathbb{R}), \quad A_V = \left\{ \ell_g(f) = \int gf \, d\mu : g \in V \right\}.$$

Доказательство. **1. Отождествление двойственного пространства.** По теореме Рисса, $X^* \simeq L^q(\mu)$. Множество A_V состоит из функционалов вида $\ell_g(f) = \langle g, f \rangle$, где $g \in V \subset L^q$.

2. Слабая-* плотность A_V . Согласно лемме, A_V слабо-* плотно в X^* .

3. Применение теоремы Стинчкомба. Проверим условия предыдущей теоремы:

- $X = L^p(\mu)$ — локально выпуклое топологическое векторное пространство (нормированное, рефлексивное);
- A_V слабо-* плотно в X^* согласно шагу 2;
- T не является полиномом — условие активации выполнено.

Тогда по теореме Стинчкомба множество

$$S_T^X(A_V) = \text{span}\{T(\ell_g(\cdot) + b) : \ell_g \in A_V, b \in \mathbb{R}\}$$

равномерно плотно в $C(K, \mathbb{R})$ для любого компакта $K \subset X$.

4. Завершение доказательства. Плотность $S_T^X(A_V)$ в $C(K)$ означает, что любую непрерывную функцию на K можно равномерно приблизить функциями вида

$$f \mapsto \sum_{k=1}^N \beta_k T\left(\int g_k(x) f(x) d\mu(x) + b_k\right), \quad g_k \in V, b_k, \beta_k \in \mathbb{R}.$$

Это и есть утверждение теоремы. □

Рассмотрим теперь случай L^1 , выделяем его отдельно из-за бесконечности сопряжённого показателя.

Теорема 6.3 (Функциональная УАТ в L^1 с компактным носителем меры). Пусть $X = L^1(\mu)$, где μ — конечная борелевская мера с компактным носителем. Пусть $V \subset L^\infty(\mu)$ слабо-* плотно в $L^\infty(\mu)$ в топологии $\sigma(L^\infty, L^1)$, и пусть

$$A_V = \left\{ \ell_g(f) = \int g f d\mu : g \in V \right\}.$$

Если $T: \mathbb{R} \rightarrow \mathbb{R}$ не является полиномом, то для любого компакта $K \subset X$

$$\overline{S_T^X(A_V)|_K}^{\rho_K} = C(K, \mathbb{R}).$$

Доказательство. **1. Двойственное пространство.** Для $L^1(\mu)$ с конечной мерой $X^* = L^\infty(\mu)$. Топология на L^∞ , согласованная с двойственностью $\langle L^\infty, L^1 \rangle$, — это слабая-* топология $\sigma(L^\infty, L^1)$.

2. Слабая-* плотность A_V . По условию V слабо-* плотно в $L^\infty(\mu)$, следовательно, A_V слабо-* плотно в X^* .

3. Компактность носителя меры. Требование компактности носителя μ обеспечивает выполнение условий теоремы Стинчкомба:

- Пространство $L^1(\mu)$ с такой мерой сепарабельно и обладает свойством аппроксимации.
- Компактность носителя позволяет использовать стандартные рассуждения типа Стоуна-Вейерштрасса для алгебр функций, порождённых $T \circ \ell_g$.

4. Применение общей теоремы. Условия теоремы Стинчкомба выполнены:

- $X = L^1(\mu)$ — локально выпуклое топологическое векторное пространство;
- A_V слабо-* плотно в X^* ;
- T — не полиномиальная активация.

Тогда по теореме множество $S_T^X(A_V)$ равномерно плотно в $C(K, \mathbb{R})$ для любого компакта $K \subset X$. $\square$

Теперь мы готовы доказать основной результат про универсальную аппроксимацию для функциональных многослойных перцептронов.

Теорема 6.4 (УАТ для FMLP на произведении пространств). Пусть $X = \prod_{j=1}^s L^{p_j}(\mu_j)$, где μ_j — конечные борелевские меры, и $1 < p_j < \infty$ (или $p_j = 1$ с условиями компактного носителя / слабой-* плотности из теоремы 6.3). Для каждого j пусть $V_j \subset L^{q_j}(\mu_j)$ плотно (или $V_j \subset L^\infty$ слабо-* плотно для $p_j = 1$). Определим множество линейных форм:

$$A_V = \left\{ \ell_g(f_1, \dots, f_s) = \sum_{j=1}^s \int g_j(x) f_j(x) d\mu_j(x) : g_j \in V_j \right\} \subset X^*.$$

Пусть $T: \mathbb{R} \rightarrow \mathbb{R}$ — не полиномиальная функция (например, $\tanh$, сигмоида, ReLU^α с нецелым α и т.д.). Тогда для любого компакта $K \subset X$

$$\overline{S_T^X(A_V)|_K}^{\rho_K} = C(K, \mathbb{R}).$$

Иными словами, FMLP с одним скрытым слоем и интегральными линейными функционалами в качестве входов обладают свойством УА на компактных подмножествах X .

Доказательство. 1. Слабая-* плотность A_V . Из леммы о произведении пространств следует, что A_V слабо-* плотно в $X^* = \prod_{j=1}^s L^{q_j}(\mu_j)$ (или L^∞ при $p_j = 1$).

2. Проверка условий теоремы Стинчкомба.

- X — локально выпуклое топологическое векторное пространство (как произведение банаховых пространств).
- A_V слабо-* плотно в X^* по шагу 1.
- T не является полиномом — условие активации выполнено.

2. Применение общей теоремы. По теореме Стинчкомба множество

$$S_T^X(A_V) = \text{span}\{T(\ell_g(\cdot) + b) : \ell_g \in A_V, b \in \mathbb{R}\}$$

является равномерно плотным в $C(K, \mathbb{R})$ для любого компакта $K \subset X$.

3. Интерпретация как FMLP. Элементы $S_T^X(A_V)$ имеют вид

$$f \mapsto \sum_{k=1}^N \beta_k T \left(\sum_{j=1}^s \int g_{jk}(x) f_j(x) d\mu_j(x) + b_k \right),$$

что соответствует однослойной нейросети, где входы — линейные интегральные функционалы от компонент $f = (f_1, \dots, f_s)$. $\square$



Рис. 7: FMLP подход к задаче универсальной аппроксимации.

6.4 Сопоставление с результатами лекций 1–4 (классические УАТ, GTN, операторные сети)

Структура курса естественным образом приводит к функциональной теореме универсальной аппроксимации (УАТ) через следующую последовательность шагов:

- **Лекции 1–2:** Классическая УАТ на $\mathbb{R}^n$ (Цыбенко/Лешно) даёт **скалярную универсальность** функции активации T :

$$\overline{\text{span}\{T(w \cdot x + b)\}}^{C(K)} = C(K, \mathbb{R}), \quad K \subset \mathbb{R}^n \text{ компакт.}$$

- **Лекции 3–4:** Операторный взгляд (GTN / выбор точек и работа с значениями в них) показывает, как линейные функционалы извлекают конечное количество «состояние/признаков» из сигналов:
- **Лекция 5 (текущая):** Выбираем A как множество интегральных линейных форм на L^p (теорема Рисса), убеждаемся, что A слабо-* плотно в X^* , и **переносим** скалярную УАТ на функциональные входы через схему Стинчкомба:

$$\overline{\text{span}\{T(\ell(\cdot) + b) : \ell \in A\}}^{C(K)} = C(K, \mathbb{R}), \quad K \subset X \text{ компакт.}$$

Таким образом, ключевая идея может быть записана в виде следующей импликации:

6.5 Постановка задачи обучения FMLP

Введём модель функционального многослойного перцептрона (FMLP). Пусть каждое наблюдение задаётся парой (G, T) , где G — функциональный предиктор (принадлежащий некоторому функциональному пространству, например, $C(Z, \mathbb{R})$ с компактным $Z \subset \mathbb{R}^u$), а $T \in \mathbb{R}^o$ — целевая переменная. Рассматривается параметрическая модель вида

$$H(w, g) = U\left(w_0, \int_Z F_1(w_1, x)g(x)d\mu(x), \dots, \int_Z F_k(w_k, x)g(x)d\mu(x)\right),$$

где $w = (w_0, w_1, \dots, w_k)$ — параметры, $F_\ell(w_\ell, \cdot)$ — параметрические ядра (например, малые нейронные сети или базисные разложения), U — внешняя ограниченная равномерно непрерывная функция (например, обычный MLP), μ — конечная борелевская мера.

В процессе обучения мы располагаем выборкой $\{(G_i, T_i)\}_{i=1}^n$, причём каждая функция G_i известна лишь по дискретным измерениям в точках X_{ij} :

$$Y_{ij} = G_i(X_{ij}) + \varepsilon_{ij}, \quad j = 1, \dots, m_i.$$

Требуется оценить параметры w , минимизирующие ожидаемый риск

$$\lambda(w) = \mathbb{E}_C(T, H(w, G)),$$

где c — непрерывная функция потерь. На практике мы минимизируем эмпирический риск, в котором интегралы заменены на выборочные средние:

$$\hat{\lambda}_{n,m}(w) = \frac{1}{n} \sum_{i=1}^n c \left(T_i, U \left(w_0, \frac{1}{m_i} \sum_{j=1}^{m_i} F_1(w_1, X_{ij}) Y_{ij}, \dots, \frac{1}{m_i} \sum_{j=1}^{m_i} F_k(w_k, X_{ij}) Y_{ij} \right) \right).$$

Обозначим через $\hat{w}_{n,m}$ любой минимизатор $\hat{\lambda}_{n,m}(w)$ на компактном множестве параметров W .

Теорема 6.5 (О согласованности эмпирического риск минимизатора (ERM) для FMLP). *Предположим, что выполнены следующие условия:*

- (A1) *Параметрические ядра $F_\ell(w_\ell, \cdot)$ измеримы по x , непрерывны по w_ℓ и равномерно ограничены интегрируемой функцией: $|F_\ell(w_\ell, x)| \leq d_\ell(x)$, $d_\ell \in L^p(\mu)$.*
- (A2) *Входные функции G_i принадлежат $L^q(\mu)$ почти наверное, $\mathbb{E}\|G\|_q < \infty$ (q сопряжено к p).*
- (A3) *Внешняя функция U ограничена и равномерно непрерывна на соответствующем множестве.*
- (A4) *Функция потерь c непрерывна и удовлетворяет условию мажорирования: $|c(t, y)| \leq h(t) + \gamma|y|$, $\mathbb{E}h(T) < \infty$.*
- (A5) *Точки измерений X_{ij} независимы, одинаково распределены с законом μ , ошибки ε_{ij} центрированы, независимы и имеют конечный первый момент.*

Тогда эмпирические минимизаторы $\hat{w}_{n,m}$:

$$\lim_{n \rightarrow \infty} \lim_{m \rightarrow \infty} \text{dist}(\hat{w}_{n,m}, W^*) = 0 \quad \text{н.н.},$$

где $W^* = \arg \min_{w \in W} \lambda(w)$ — множество истинных минимизаторов эмпирического риска, а dist — расстояние Хаусдорфа.

Эскиз доказательства. Доказательство разбивается на несколько шагов.

1. Равномерная сходимость монте-карловских приближений интегралов. Для каждого фиксированного i и ℓ рассмотрим

$$M_\ell^{(i)}(w_\ell) = \frac{1}{m_i} \sum_{j=1}^{m_i} F_\ell(w_\ell, X_{ij}) Y_{ij}, \quad I_\ell^{(i)}(w_\ell) = \int F_\ell(w_\ell, x) G_i(x) d\mu(x).$$

Используя предположения (A1), (A2), (A5) и теорему о равномерном усиленном законе больших чисел, получаем

$$\sup_{w_\ell \in W_\ell} |M_\ell^{(i)}(w_\ell) - I_\ell^{(i)}(w_\ell)| \xrightarrow[m_i \rightarrow \infty]{\text{п.н.}} 0.$$

Это следует из того, что класс функций $\{x \mapsto F_\ell(w_\ell, x) G_i(x) : w_\ell \in W_\ell\}$ является гладким классом, а шумовая компонента также удовлетворяет УЗБЧ.

2. Равномерная сходимость эмпирического риска к популяционному. Определим «идеальный» эмпирический риск

$$\bar{\lambda}_n(w) = \frac{1}{n} \sum_{i=1}^n c(T_i, H(w, G_i)).$$

Из равномерной непрерывности U и s и предыдущего шага выводим

$$\sup_{w \in W} |\hat{\lambda}_{n,m}(w) - \bar{\lambda}_n(w)| \xrightarrow[n \rightarrow \infty]{\text{п.н.}} 0.$$

Далее, класс функций $\{(g, t) \mapsto c(t, H(w, g)) : w \in W\}$ также является гладким классом (благодаря компактности W , доминированию и непрерывности), поэтому

$$\sup_{w \in W} |\bar{\lambda}_n(w) - \lambda(w)| \xrightarrow[n \rightarrow \infty]{\text{п.н.}} 0.$$

Комбинируя, получаем

$$\sup_{w \in W} |\hat{\lambda}_{n,m}(w) - \lambda(w)| \xrightarrow[n \rightarrow \infty, m \rightarrow \infty]{\text{п.н.}} 0.$$

3. Сходимость минимизаторов. В силу компактности W и непрерывности $\lambda(w)$ множество W^* непусто. Из равномерной сходимости функций и леммы о непрерывности argmin-отображения следует

$$\text{dist}(\arg \min \hat{\lambda}_{n,m}, W^*) \xrightarrow[n \rightarrow \infty, m \rightarrow \infty]{\text{п.н.}} 0.$$

□

6.6 Практическая реализация: дискретизация, выбор базиса, регуляризация

На практике функциональные данные заданы дискретно, поэтому необходимо аппроксимировать интегралы. Основные подходы:

- **Дискретизация по сетке.** Если функция g задана на равномерной сетке $t_1, \dots, t_m$, то интеграл заменяется суммой

$$\int_Z F(w, x) g(x) d\mu(x) \approx \sum_{j=1}^m \omega_j F(w, t_j) g(t_j),$$

где ω_j — веса квадратурной формулы (например, прямоугольников, трапеций).

- **Метод Монте-Карло.** Если точки X_j выбраны случайно согласно мере μ , то используется оценка

$$\frac{1}{m} \sum_{j=1}^m F(w, X_j) g(X_j).$$

Это особенно удобно при нерегулярных измерениях.

Выбор базиса для ядер F_ℓ . Чтобы обеспечить универсальную аппроксимацию, необходимо, чтобы семейство $\{F_\ell(w_\ell, \cdot)\}$ было плотно в $L^q(\mu)$. Распространённые варианты:

- **В-сплайны.** Локальность и гладкость, легко налагать ограничения (например, носитель в $[-T, 0]$ для причинности).
- **Ортогональные полиномы (Лежандра, Чебышева).** Этот вариант обеспечивает хорошую численную устойчивость, возможность точного интегрирования.
- **Вейвлеты.** Многомасштабный анализ, полезно для сигналов с особенностями.

- **Маленькие MLP.** Небольшая нейросеть, принимающая на вход x , обеспечивает универсальную аппроксимацию на компакте.

Регуляризация. Для улучшения обобщения и обеспечения устойчивости в динамических задачах применяют:

- **Гребневую регуляризацию (weight decay)** на параметры w .
- **Ограничение нормы ядер** $\|F_\ell(w_\ell, \cdot)\|_{L^q}$, что контролирует липшицевость оператора.
- **Специальные ограничения для причинности:** например, требовать $F_\ell(w_\ell, \tau) = 0$ при $\tau > 0$, если окно $[-T, 0]$ соответствует прошлому.

6.7 Интерпретация FMLP как функциональной надстройки над моделями I–IV

FMLP естественно встраивается в эту структуру:

- **Model I (NARX).** Обычный MLP, принимающий конечный вектор регрессоров. FMLP обобщает это, заменяя конечный вектор на функциональное окно $g(\tau) = (u(\tau), y(\tau))$, $\tau \in [-T, 0]$. Тогда предсказание имеет вид

$$\hat{y}(k+1) = \Phi(z(k)), \quad z(k) = \left(\int F_1(w_1, \tau) g_k(\tau) d\tau, \dots, \int F_k(w_k, \tau) g_k(\tau) d\tau \right).$$

- **Model II (State-space NN).** Функциональный слой извлекает признаки $z(k)$, которые затем подаются в динамику состояния:

$$x(k+1) = \Psi(z(k)), \quad \hat{y}(k) = \Theta(x(k)).$$

- **Model III (Free-run).** После идентификации модель запускается в замкнутом контуре, где вместо истинных y используются предсказанные $\hat{y}$. Устойчивость можно обеспечивать регуляризацией Якобиана или ISS-критериями.
- **Model IV (Teacher-forcing).** Идентификация в разомкнутом контуре с измеренными y .

6.8 Применение к идентификации и управлению динамическими системами

- **Идентификация.** FMLP позволяет обучать модели напрямую по нерегулярным выборкам, без предварительного восстановления траекторий. Благодаря теореме о согласованности, оценка параметров даёт состоятельную модель при увеличении объёма данных.
- **Управление.** В схемах предсказывающего управления модель, обученная как функциональный многослойный перцептрон, может использоваться для прогноза будущего поведения системы. Функциональное представление окна прошлого позволяет учесть историю без роста размерности вектора состояния.

- **Устойчивость.** Применяя регуляризацию, описанную выше, можно гарантировать BIBO-устойчивость (bounded input bounded output) или ISS-свойства (input to state stability) замкнутой системы.
- **Инвариантность к сдвигу.** Поскольку функциональные ядра F_ℓ работают с окном фиксированной длины, модель автоматически инвариантна к временным сдвигам в пределах этого окна.

Замечания.

- Теорема о согласованности гарантирует, что при увеличении числа наблюдений и числа точек измерений на каждой функции, оценённые параметры сходятся к оптимальным. Это основа для надёжного применения FMLP в практических задачах.
- Выбор базиса и регуляризации должен учитывать специфику задачи: для гладких сигналов подходят сплайны, для сигналов с разрывами — вейвлеты, для задач с необходимостью интерпретации — ортогональные полиномы.
- FMLP естественным образом расширяет классические модели идентификации, позволяя работать непосредственно с функциональными данными, что особенно важно при нерегулярной выборке или при наличии пропусков.

Для углубления в тему, можно заглянуть в следующие источники [9, 10, 2, 11].

7 Deep Operator Networks (DeepONets) и роль глубины и ширины

Функциональные пространства, операторы и метрики

Пусть $D \subset \mathbb{R}^d$, $U \subset \mathbb{R}^n$ — компактные (то есть замкнутые и ограниченные) множества.

Определение (Пространства $C(D)$, $C(U)$ и супремум-норма). $C(D)$ и $C(U)$ — пространства вещественных непрерывных функций на D и U . Супремум-норма задаётся формулами

$$\|f\|_\infty := \sup_{x \in D} |f(x)|, \quad \|g\|_\infty := \sup_{y \in U} |g(y)|.$$

Замечание. Эта норма индуцирует метрику $d(f, g) = \|f - g\|_\infty$, поэтому $C(D)$ и $C(U)$ являются банаховыми пространствами.

Определение (Пространства $L^p(D)$ и L^p -норма). Для $1 \leq p < \infty$ пространство $L^p(D)$ состоит из (классов эквивалентности) измеримых функций с нормой

$$\|f\|_{L^p(D)} := \left(\int_D |f(x)|^p dx \right)^{1/p}.$$

Определение (Скалярное произведение в $L^2(U)$). Пространство $L^2(U)$ является гильбертовым со скалярным произведением

$$\langle f, g \rangle_{L^2(U)} := \int_U f(y) g(y) dy,$$

и соответствующей нормой

$$\|g\|_{L^2(U)} = \langle g, g \rangle_{L^2(U)}^{1/2}.$$

Определение (Оператор между пространствами функций). Оператор — это отображение $G: X \rightarrow Y$ между пространствами функций (банаховыми или гильбертовыми), например

$$G: C(D) \rightarrow C(U) \quad \text{или} \quad G: C(D) \rightarrow L^2(U).$$

Будем говорить о X как о пространстве входных функций u , а о Y — как о пространстве выходных функций $G(u)$. DeepONets будем рассматривать как параметризованное семейство таких операторов.

Определение (Вероятностная мера на X). Вероятностная мера μ на X задаёт распределение случайного элемента $u: \Omega \rightarrow X$ (то есть закон случайной функции $u \in X$, это можно интерпретировать как распределение обучающих данных.)

Определение (Прямой образ меры $G\#\mu$). Прямой образ (push-forward) $G\#\mu$ — это распределение случайного элемента $G(u)$ при $u \sim \mu$:

$$(G\#\mu)(B) := \mu(G^{-1}(B)), \quad B \subset Y \text{ — борелевское множество.}$$

Определение (Нецентрированный оператор ковариации). Пусть $(H, \langle \cdot, \cdot \rangle_H)$ — сепарабельное гильбертово пространство и $\nu \in \mathcal{P}(H)$ такова, что

$$\int_H \|z\|_H^2 d\nu(z) < \infty.$$

Тогда (нецентрированный) оператор ковариации $C_\nu: H \rightarrow H$ определяется как

$$C_\nu v := \int_H \langle z, v \rangle_H z d\nu(z).$$

Замечание. Оператор C_ν является самосопряжённым, положительным и оператором следового класса; позже мы будем использовать его собственные пары (собственное значение–собственный вектор) для построения хороших базисов trunk-ветви DeepONets.

Обозначения для нейронных сетей (конечномерные отображения)

Мы будем неоднократно использовать стандартные полносвязные нейронные сети прямого распространения (feedforward) как базовые (конечномерные) блоки.

Определение (Полносвязная feedforward нейронная сеть). Feedforward нейронная сеть $L: \mathbb{R}^{d_{\text{in}}} \rightarrow \mathbb{R}^{d_{\text{out}}}$ с $K - 1$ скрытыми слоями задаётся соотношениями

$$z_1 = x, \quad z_{k+1} = \sigma(W_k z_k + b_k), \quad k = 1, \dots, K - 1, \quad L(x) = W_K z_K + b_K,$$

где

$$W_k \in \mathbb{R}^{m_k \times m_{k-1}}, \quad b_k \in \mathbb{R}^{m_k}, \quad m_0 = d_{\text{in}}, \quad m_K = d_{\text{out}}.$$

Параметры архитектуры.

- *Ширина* k -го слоя: m_k (число нейронов в этом слое).
- *Глубина*: число скрытых слоёв $= K - 1$.
- *Параметры*: $\theta = \{W_k, b_k\}_{k=1}^K$.
- *Размер* (общее число скалярных параметров):

$$\text{size}(L) = \|\theta\|_{\ell^0} = \sum_{k=1}^K (m_k m_{k-1} + m_k).$$

7.1 Асимптотические обозначения: $O(\cdot)$ и $\Theta(\cdot)$

Мы часто будем описывать “размер” сети (число слоёв/нейронов) с точностью до постоянных множителей (констант), используя асимптотические обозначения.

Пусть далее $f, g: \mathbb{N} \rightarrow (0, \infty)$.

Определение (O -большое, верхняя оценка). Говорят, что $f(k) = O(g(k))$, если существуют константы $C > 0$ и $k_0 \in \mathbb{N}$ такие, что

$$f(k) \leq C g(k) \quad \text{для всех } k \geq k_0.$$

Замечание. Возможна следующая интерпретация: при больших k функция f растёт не быстрее, чем g , с точностью до константы.

Определение (Θ -большое, точная (двусторонняя) оценка). Говорят, что $f(k) = \Theta(g(k))$, если существуют константы $c_1, c_2 > 0$ и $k_0 \in \mathbb{N}$ такие, что

$$c_1 g(k) \leq f(k) \leq c_2 g(k) \quad \text{для всех } k \geq k_0.$$

Замечание. Можно интерпретировать так: при больших k функция f растёт как g с точностью до константы (то есть выполняются и верхняя, и нижняя оценки).

Пример. Приведём некоторые примеры использования асимптотической нотации.

- $3k^2 + 5k + 7 = \Theta(k^2)$ и, следовательно, также $O(k^2)$.
- 2^k не является $O(k^m)$ ни для какой фиксированной степени m : экспоненциальная функция растёт быстрее любой степенной (полиномиальной).
- “ $\Theta(k^3)$ слоёв” означает, что число слоёв лежит между $c_1 k^3$ и $c_2 k^3$ для некоторых констант $c_1, c_2 > 0$.
- “ширина $O(1)$ ” означает, что ширина ограничена константой C , не зависящей от k .

7.2 Разделение по глубине (Тельгарский)

Теорема 7.1 (Об иерархии по глубине). *Для каждого $k \in \mathbb{N}$ существует сеть с ReLU-активацией (ReLU-сеть) $f_k: [0, 1]^d \rightarrow \mathbb{R}$ с $\Theta(k^3)$ слоями и шириной $O(1)$ такая, что любая ReLU-сеть с не более чем k скрытыми слоями, которая аппроксимирует f_k в $L^1([0, 1]^d)$ с ошибкой $< \frac{1}{8}$, должна иметь по крайней мере $\Omega(2^k)$ нейронов.*

Идея построения (одномерный случай).

1. Определим “треугольную” функцию на $[0, 1]$:

$$\Delta(x) = \max\{0, 1 - |2x - 1|\},$$

которую можно реализовать очень небольшой ReLU-сетью.

2. Применим её к самой себе k раз:

$$x \mapsto \Delta^k(x) = \Delta(\Delta(\dots \Delta(x) \dots)).$$

Каждая композиция удваивает число пиков, то есть получается порядка 2^k осцилляций (много чередующихся линейных участков).

3. Расширим до $[0, 1]^d$, игнорируя лишние координаты:

$$f_k(x_1, \dots, x_d) = \Delta^k(x_1),$$

при этом ширина остаётся $O(1)$.

Почему не могут аппроксимировать Δ^k без экспоненциального роста ширины?

- ReLU-сеть глубины k с W нейронами задаёт кусочно-аффинное отображение: пространство входов разбивается на области, на каждой из которых сеть совпадает с некоторой аффинной функцией (то есть имеет вид $x \mapsto Ax + b$). Число таких областей в общем случае не превосходит $O(W^k)$.
- Функция Δ^k создаёт порядка 2^k чередующихся “участков поведения” (интуитивно: порядка 2^k пиков/колебаний, или много попеременно возрастающих и убывающих линейных отрезков). 1 Чтобы аппроксимировать такую структуру неглубокой ReLU-сетью, ей нужно иметь достаточно много аффинных областей, а значит требуется как минимум $W \geq c 2^k$ нейронов.

□

Замечание (Неформальный вывод). Глубина может давать экспоненциальную экономию числа нейронов (и параметров) при представлении некоторых функций: глубокие сети способны эффективно задавать сильно осциллирующие функции (быстро меняющиеся, с большим числом колебаний), тогда как неглубоким сетям для этого требуется экспоненциально больше нейронов.

Это объясняет, почему в архитектурах DeepONets имеет смысл использовать достаточно глубокие сети в ветвях `branch` и `trunk`: глубина может заметно повысить эффективность представления сложных зависимостей без чрезмерного роста числа параметров.

7.3 Достаточность ограниченной ширины (Ханин)

Теорема 7.2 (УА при ограниченной ширине (неформально)). Пусть $d_{\text{in}} \geq 1$ и $K \subset \mathbb{R}^{d_{\text{in}}}$ — компакт. Тогда:

- Если ReLU-сеть имеет ширину не меньше $d_{\text{in}} + 1$, то для любой непрерывной функции $f: K \rightarrow \mathbb{R}$ и любого $\varepsilon > 0$ существует ReLU-сеть L ширины $d_{\text{in}} + 1$ (глубина не ограничена), такая что

$$\sup_{x \in K} |f(x) - L(x)| < \varepsilon.$$

- Если ширина $\leq d_{\text{in}}$, то существует непрерывная функция $f: K \rightarrow \mathbb{R}$ и число $\varepsilon_0 > 0$ такие, что для любой ReLU-сети L этой ширины (при любой глубине) выполнено

$$\sup_{x \in K} |f(x) - L(x)| \geq \varepsilon_0.$$

(более неформально : если ширина $\leq d_{\text{in}}$, то как бы мы ни увеличивали глубину сети, не удаётся аппроксимировать все непрерывные функции на K .)

Приведём некоторые **пояснение** к этому утверждению.

- Ширина $d_{\text{in}} + 1$ (а в ряде формулировок теоремы — $d_{\text{in}} + 2$) по существу является минимальной, при которой ReLU-сети обладают свойством универсальной аппроксимации: они могут равномерно приближать любую непрерывную функцию $f: K \rightarrow \mathbb{R}$ с любой заданной точностью.
- После того как ширина превышает этот порог, точность аппроксимации можно улучшать, увеличивая глубину сети, не увеличивая её ширину.

Геометрическая интуиция.

- ReLU-сети задают кусочно-аффинные отображения: существует конечное разбиение множества K на области $K_1, \dots, K_M$ (пересечения K с многогранниками) такое, что на каждой области

$$L(x) = A_j x + b_j, \quad x \in K_j.$$

- При ширине $\leq d_{\text{in}}$ возникает препятствие: класс функций, реализуемых ReLU-сетями такой ширины (при любой глубине), не является плотным в $C(K)$ по норме $\|\cdot\|_\infty$, поэтому не все непрерывные функции на K можно аппроксимировать.
- Если увеличить ширину до $d_{\text{in}} + 1$ (то есть добавить один нейрон), это препятствие исчезает: увеличивая глубину, можно строить сколь угодно *мелкие* разбиения множества K (то есть разбиения на части малого размера), что и позволяет приближать произвольные $f \in C(K)$.

Замечание (Практический вывод). В задачах обучения операторов можно держать сети *branch* и *trunk узкими* (ширины порядка $d_{\text{in}} + 1$) и увеличивать глубину, чтобы описывать сложные зависимости. Это особенно удобно, когда входная размерность велика; в задачах обучения операторов это часто означает, что вход задаётся большим числом измерений u в различных точках.

7.4 От операторных сетей к DeepONets

Классические операторные сети (Чен–Чен). Пусть $G: K \subset C(D) \rightarrow C(U)$ непрерывен на компакте K . Чен–Чен аппроксимируют G конечной суммой слагаемых разделённого вида:

$$G(u)(y) \approx \sum_{k=1}^p \beta_k(u) \tau_k(y),$$

то есть суммой членов, где множитель $\beta_k(u)$ зависит только от u , а множитель $\tau_k(y)$ — только от y . Здесь

$$\beta_k(u) = \sum_{i=1}^n c_i^k \sigma \left(\sum_{j=1}^m \xi_{ij}^k u(x_j) + \theta_i^k \right), \quad \tau_k(y) = \sigma(w_k \cdot y + \zeta_k).$$

Ключевые моменты такого подхода:

- Входная функция $u \in C(D)$ сначала берётся в точках $x_1, \dots, x_m \in D$: в сеть поступает только вектор значений $(u(x_1), \dots, u(x_m))$.
- Для каждого k коэффициент $\beta_k(u)$ вычисляется неглубокой полносвязной сетью (MLP, *многослойным перцептроном*) по входному вектору $(u(x_1), \dots, u(x_m))$.
- Функции $\tau_k: U \rightarrow \mathbb{R}$ также задаются неглубокими сетями, принимающими на вход пространственную переменную y .
- Поэтому аппроксимация имеет *низкоранговый* вид: это сумма p разделимых произведений $\beta_k(u)\tau_k(y)$. В терминологии DeepONets функции $\beta_k(u)$ соответствуют *branch*-части, а функции $\tau_k(y)$ — *trunk*-части.

Точка зрения DeepONet. DeepONets сохраняют ту же общую схему разложения, что и у Чен–Чен, но используют более глубокие нейросети и явно выделяют архитектуру как композицию модулей:

$$\begin{aligned} E: C(D) &\rightarrow \mathbb{R}^m && \text{(энкодер; вход branch-ветви),} \\ A: \mathbb{R}^m &\rightarrow \mathbb{R}^p && \text{(сеть, вычисляющая коэффициенты),} \\ R: \mathbb{R}^p &\rightarrow C(U) && \text{(декодер; trunk-ветвь),} \end{aligned}$$

так что

$$N(u) = (R \circ A \circ E)(u).$$

- E переводит входную функцию u в конечномерный вектор признаков. Обычно $E(u)$ состоит из точечных значений $u(x_1), \dots, u(x_m)$, но в более общем случае E может включать и другие линейные функционалы от u (например, интегралы или свёртки).
- A — глубокий MLP в $\mathbb{R}^m$, который по набору признаков $E(u)$ выдаёт вектор коэффициентов $(\beta_1(u), \dots, \beta_p(u))$.

- R по коэффициентам восстанавливает функцию на U ; например,

$$R(\alpha)(y) = \tau_0(y) + \sum_{k=1}^p \alpha_k \tau_k(y),$$

где функции τ_k параметризуются trunk-сетью, то есть вычисляются как выходы нейросети от переменной y .

Замечание (Ключевая идея). DeepONet $N = R \circ A \circ E$ можно рассматривать как глубокую версию операторной сети Chen–Chen: сохраняется разложение “коэффициенты от u + функции от y ”, но используются более выразительные (глубокие) branch- и trunk-сети, а вся конструкция имеет прозрачную модульную структуру $E \Rightarrow A \Rightarrow R$.

Наглядно архитектура DeepONet, записанная как композиция $N = R \circ A \circ E$, изображена на рис. 8.




Рис. 8: Схема DeepONet: $N = R \circ A \circ E$.

Вспомним теперь результат, доказанный в лекции 3, он пригодится для вывода похожего утверждения для DeepONet.

Теорема 7.3 (УАТ для операторов, Чен–Чен). Пусть X — банахово пространство, $K_1 \subset X$, $K_2 \subset \mathbb{R}^d$ — компакты, и $V \subset C(K_1)$ — компактное множество входных функций. Предположим, что оператор $G: V \rightarrow C(K_2)$ непрерывен, а функция активации $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ непрерывна и не является многочленом. Тогда для любого $\varepsilon > 0$ существуют целые числа m, p , $x_1, \dots, x_m \in K_1$ и сети $\{\beta_k\}_{k=1}^p$, $\{\tau_k\}_{k=1}^p$ формы Чен–Чена такие, что

$$\sup_{u \in V, y \in K_2} \left| G(u)(y) - \sum_{k=1}^p \beta_k(u) \tau_k(y) \right| < \varepsilon.$$

Краткое пояснение.

- Мы аппроксимируем оператор $u \mapsto G(u)$ равномерно по всем $u \in V$ и $y \in K_2$.
- Аппроксимация имеет разделимый (branch–trunk) вид $\sum_k \beta_k(u) \tau_k(y)$, причём обе части реализуются стандартными (неглубокими) нейронными сетями.
- Это операторный аналог классической теоремы универсальной аппроксимации на $C(K)$.

Напомним идею доказательства (три шага).

1. Дискретизируем входную функцию u в конечном числе точек x_j и рассматриваем вектор

$$E(u) := (u(x_1), \dots, u(x_m)) \in \mathbb{R}^m.$$

На компакте V отображение $E: V \rightarrow \mathbb{R}^m$ непрерывно.

2. Для конечномерного отображения $E(u) \mapsto (\beta_1(u), \dots, \beta_p(u))$ применяем стандартную теорему об универсальной аппроксимации на компактах в $\mathbb{R}^m$ (Цыбенко/Хорник), получая аппроксимацию с помощью (неглубокой) полносвязной сети.
3. Зависимость по $y \in K_2$ аппроксимируем общей для всех u системой функций $\{\tau_k\}$, а затем “склеиваем” аппроксимации, используя равномерность оценок на компактах.

7.5 Определение и декомпозиция ошибки DeepONet

Пусть $X = C(D)$ — пространство непрерывных функций на компакте $D \subset \mathbb{R}^d$, а $G: X \rightarrow L^2(U)$ — целевой оператор, который мы хотим аппроксимировать. Пусть μ — вероятностная мера на X (распределение входных функций u).

Определение (Среднеквадратичная операторная ошибка DeepONet). Для DeepONet $N: X \rightarrow L^2(U)$ определим ошибку:

$$\mathcal{E}(N) := \|G - N\|_{L^2(\mu; L^2(U))} = \left(\int_X \|G(u) - N(u)\|_{L^2(U)}^2 d\mu(u) \right)^{1/2}$$

Замечание (1). $u \sim \mu$ — случайная входная функция

Замечание (2). $G(u)$ и $N(u)$ — случайные выходные функции на U

Замечание (3). $\mathcal{E}(N)^2$ — математическое ожидание квадрата $L^2(U)$ -ошибки между $G(u)$ и $N(u)$

Замечание (4). На практике эмпирическая оценка среднеквадратичной ошибки является оценкой Монте-Карло для $\mathcal{E}(N)^2$ по конечной выборке $\{u^{(i)}\}_{i=1}^n$

Стандартная архитектура DeepONet: $N = R \circ A \circ E$, где

- $E: X \rightarrow \mathbb{R}^m$ — кодировщик (кодирует входную функцию в вектор),
- $A: \mathbb{R}^m \rightarrow \mathbb{R}^p$ — аппроксиматор (нейронная сеть, отображает вектор в коэффициенты),
- $R: \mathbb{R}^p \rightarrow L^2(U)$ — реконструктор (строит выходную функцию по коэффициентам).

Для такой архитектуры ошибку можно разложить на три компоненты:

$$\mathcal{E}(N) \leq \underbrace{\mathcal{E}_{\text{enc}}}_{\text{ошибка кодирования}} + \underbrace{\mathcal{E}_{\text{app}}}_{\text{ошибка аппроксимации}} + \underbrace{\mathcal{E}_{\text{rec}}}_{\text{ошибка реконструкции}} \quad (3)$$

Если подробнее:

- $\mathcal{E}_{\text{enc}}$ — потеря информации при переходе от функции u к конечномерному вектору $E(u)$.
- $\mathcal{E}_{\text{app}}$ — ошибка нейронной сети A , аппроксимирующей идеальное отображение $u \mapsto (\beta_1(u), \dots, \beta_p(u))$.

- $\mathcal{E}_{\text{rec}}$ — ошибка, связанная с использованием конечного базиса $\{\tau_k\}_{k=1}^p$ для реконструкции и игнорирования высокочастотных мод.

Пример. Приведём примеры оценок погрешностей кодирования и реконструкции.

- **Случайные сенсоры** Для случайных полей с аналитической ковариацией (характеризуется величиной ℓ) и равномерных сенсоров с декодером на основе Фурье:

$$\mathcal{E}_{\text{enc}} \lesssim \exp(-c\ell m^{1/d})$$

- **Спектральные реконструкторы** Если выбрать $\{\tau_k\}_{k=1}^p$ как собственные функции ковариации $G \# \mu$ или как базис Лежандра/Фурье (при соболевской гладкости k), то:

$$\mathcal{E}_{\text{rec}} \lesssim p^{-k/d}$$

В сочетании с голоморфной зависимостью параметров и стандартными оценками для аппроксиматора A даёт явные двусторонние оценки.

7.6 Измеримая УАТ для DeepONet

Теорема 7.4 (Измеримая УАТ для DeepONet). Пусть μ — вероятностная мера на $C(D)$ и $G: C(D) \rightarrow L^2(U)$ — измеримый оператор, причём $G \in L^2(\mu; L^2(U))$. Тогда для любого $\varepsilon > 0$ существует DeepONet $N = R \circ A \circ E$ такой, что

$$\mathcal{E}(N) = \|G - N\|_{L^2(\mu; L^2(U))} < \varepsilon$$

Доказательство. Опишем общую схему доказательства:

1. По теореме Лузина для любого $\delta > 0$ существует компакт $K \subset C(D)$ с $\mu(K) > 1 - \delta$ такой, что $G|_K$ непрерывен.
2. Используя теорему Чен–Чен (аналог УАТ для непрерывных операторов), строим DeepONet N_K , равномерно приближающий G на K :

$$\sup_{u \in K} \|G(u) - N_K(u)\|_{L^2(U)} < \varepsilon/2.$$

3. Полагаем $N(u) = N_K(u)$ для $u \in K$ и, например, $N(u) = 0$ для $u \notin K$. Тогда N является борелевским измеримым оператором

$$\mathcal{E}(N)^2 = \int_K \|G - N\|^2 d\mu + \int_{K^c} \|G\|^2 d\mu \leq (\varepsilon/2)^2 + \int_{K^c} \|G\|^2 d\mu.$$

Поскольку $G \in L^2(\mu)$, второе слагаемое можно сделать меньше $(\varepsilon/2)^2$ выбором достаточно малого $\mu(K^c)$.

□

7.7 «Upper bound program»: получения верхних оценок

Теорема об измеримом УАТ обосновывает следующий конструктивный подход к оценке ошибки DeepONet:

1. Оценка $\mathcal{E}_{\text{enc}}$: проектирование эффективных кодировщиков/декодиров (E, D), минимизирующих потерю информации.
2. Оценка $\mathcal{E}_{\text{rec}}$: выбор базиса реконструкции R , оптимального относительно спектральных свойств распределения $G\#\mu$.
3. Оценка $\mathcal{E}_{\text{app}}$: применение стандартных теорем аппроксимации нейронных сетей в конечномерных пространствах.

7.8 Применение к динамическим системам: от временных рядов к операторам

Рассмотрим нелинейную динамическую систему.

Дискретное время.

$$x_{t+1} = F(x_t, u_t), \quad t = 0, 1, 2, \dots,$$

где $x_t \in \mathbb{R}^{d_x}$ — состояние, $u_t \in \mathbb{R}^{d_u}$ — управление.

Непрерывное время (ОДУ).

$$\dot{x}(t) = f(x(t), u(t), t), \quad x(a) = x_0, \quad t \in [a, b].$$

Вместо пошагового предсказания можно рассматривать оператор решения:

$$G: u(\cdot) \mapsto x(\cdot),$$

который ставит в соответствие входному сигналу $u(t)$ соответствующую траекторию $x(t)$. Для автономных систем также рассматривается оператор временного сдвига

$$S_h: x(\cdot) \mapsto x(\cdot + h),$$

который сдвигает траекторию по h .

Пример (Оператор решения ОДУ). Рассмотрим систему на $[a, b]$:

$$\begin{cases} \frac{ds}{dx} = g(s(x), u(x), x), \\ s(a) = s_0 \in \mathbb{R}^K, \end{cases}$$

где $u \in V \subset C([a, b])$ — входной сигнал. Оператор решения:

$$(Gu)(x) = s_0 + \int_a^x g((Gu)(t), u(t), t) dt.$$

Задача идентификации: по наблюдениям пар (u, s) построить DeepONet N , аппроксимирующий G .

Дискретизация входа: сенсоры и интерполяция. Выбираем $m + 1$ равномерных сенсоров на $[a, b]$:

$$x_j = a + j \frac{(b-a)}{m}, \quad j = 0, 1, \dots, m.$$

Строим кусочно-линейный интерполяцию u_m . При компактности V и условии Липшица на g выполняется оценка в равномерной норме:

$$\max_{x \in [a, b]} |u(x) - u_m(x)| \leq \kappa(m, V) \rightarrow 0 \quad \text{при } m \rightarrow \infty.$$

Оценка необходимого числа сенсоров. Если g удовлетворяет условию Липшица по (s, u) , то по неравенству Гронвала имеет место оценка в норме L^2 или L^∞ по времени:

$$\|(Gu)(x) - (Gu_m)(x)\|_2 \leq c(b-a)\kappa(m, V)e^{c(b-a)}, \quad x \in [a, b].$$

Таким образом, выбрав m так, чтобы

$$c(b-a)\kappa(m, V)e^{c(b-a)} < \varepsilon,$$

мы гарантируем ε -близость решений в норме L^2 или L^∞ на $[a, b]$. После этого достаточно аппроксимировать конечномерное отображение

$$(u(x_0), \dots, u(x_m)) \mapsto (Gu)(d)$$

обычной нейронной сетью.

В конечном счёте можно предложить следующую модель применения DeepONet к нелинейным динамическим системам, применительно к **branch/кодировщик (входная часть)**:

- Вход: дискретизированное управление или состояние на коротком временном окне, например $(u(t_1), \dots, u(t_m))$ или $(x(t_1), \dots, x(t_m))$.
- Кодировщик E отображает это в $\mathbb{R}^m$ (частно просто тождественное отображение).
- Аппроксиматор $A: \mathbb{R}^m \rightarrow \mathbb{R}^p$ является глубокой MLP, выдающей коэффициенты $\alpha = (\alpha_1, \dots, \alpha_p)$, зависящие лишь от окна.

Со стороны выхода **trunk/реконструктор**:

- Trunk вход: время запроса $t \in [a, b]$ (или пространственная переменная y).
- Trunk сеть базисные функции $\tau_k(t)$ и выходы

$$(N(u))(t) = \tau_0(t) + \sum_{k=1}^p \alpha_k \tau_k(t).$$

- Вычисление t на сетке даёт приближение всей траектории.

Для обучения можно брать пары $(u^{(i)}, x^{(i)}(\cdot))$ или перемещать окно по длинным траекториям, а в качестве функции потерь — эмпирическое приближение $\mathcal{E}(N)$

$$\frac{1}{N_{\text{data}}} \sum_i \int_a^b \|x^{(i)}(t) - (Nu^{(i)})(t)\|_2^2 dt.$$

7.9 ISO/BIBO-ориентированная регуляризация

Когда используются DeepONet для динамических систем, часто важна *устойчивость* (устойчивость состояния по выходу, сохранение ограниченности выхода при наличии таковой у входа). Добиться этого можно, накладывая **штрафы на основе констант Липшица или Якобиана**

- Аппроксиматор A определяет чувствительность коэффициентов α к закодированному входу $E(u)$.
- Мы можем штрафовать во время обучения за слишком большую операторную норму $A(E(u))$, чтобы малость константы Липшица $A \circ E$ и изменений в окне приводила к незначительным изменениям траекторий.
- Это аналогично ограничениям типа Ляпунова/ISS в классической модели и может помочь избежать взрыва предсказаний при экстраполяции.

Таким образом в отличие от классического подхода, где нужно отдельно обучать модель для каждой точки, DeepONet делает эту конструкцию явной:

- Кодировщик E : вычисляет значения входной функции u в точках сенсоров.
- Аппроксиматор A : обучается предсказывать значения решения для множества запрашиваемых точек на основе данных сенсоров.
- Реконструктор R : собирает предсказания для всех точек запроса в полную траекторию на отрезке $[a, b]$.

Для углубления в этот самый свежий раздел курса рекомендуется обратиться к первоисточникам [12, 13, 14, 15].

8 Глубокое обучение через призму динамических систем

8.1 Введение и предварительные сведения

В данном разделе мы обрисуем общую постановку задачи обучения с учителем, введём остаточные сети (ResNet) и их интерпретацию как динамических систем, а также обсудим ключевые понятия *пространства гипотез*, *потокowego отображения* и различия между *точным представлением* и *аппроксимацией*.

Рассматривается классическая задача обучения с учителем [16]. Пусть заданы:

- Входное пространство $\mathcal{X} \subset \mathbb{R}^n$.
- Выходное пространство $\mathcal{Y} \subset \mathbb{R}^m$.
- Неизвестная целевая функция $F : \mathcal{X} \rightarrow \mathcal{Y}$.
- Набор данных $\{(x_i, y_i)\}_{i=1}^N$, где $y_i = F(x_i)$.

Цель — найти функцию G из некоторого *пространства гипотез* $\mathcal{H}$, которая хорошо приближает F на данных. Это приводит к задаче минимизации *эмпирического риска*:

$$\inf_{G \in \mathcal{H}} \frac{1}{N} \sum_{i=1}^N \ell(F(x_i), G(x_i)),$$

где ℓ — функция потерь (например, квадратичная или кросс-энтропия) [16, Раздел 1.1].

В данном подразделе пространство гипотез $\mathcal{H}$ будет строиться на основе *потокowych отображений* обыкновенных дифференциальных уравнений (ОДУ), что является идеализацией глубоких остаточных сетей.

Дискретная остаточная сеть (ResNet) [16, Раздел 1.2] задаётся разностным уравнением:

$$z_{s+1} = z_s + \delta f_{\theta_s}(z_s), \quad s = 0, \dots, S-1, \quad z_0 = x, \quad (4)$$

где $\delta > 0$ — размер шага (часто $\delta = 1$), f_{θ_s} — нелинейное преобразование соответствующего слоя (например, аффинное отображение с последующей функцией активации), а S — общая глубина сети.

Непрерывный предел. Интерпретируя индекс слоя s как дискретное время, можно рассмотреть непрерывный предел при $\delta \rightarrow 0$, полагая $t = s\delta$, $T = S\delta$. Тогда (4) переходит в ОДУ [16, Раздел 1.3]:

$$\dot{z}(t) = f_{\theta(t)}(z(t)), \quad t \in [0, T], \quad z(0) = x. \quad (5)$$

Если $f_{\theta(t)}$ глобально липшицева по z , то решение (5) существует и единственно. *Потокоеое отображение* (flow map) в момент времени T определяется как $\varphi_T(\cdot; \theta) : x \mapsto z(T)$.

Таким образом, глубокую ResNet можно рассматривать как дискретизацию по времени некоторой управляемой динамической системы. Этот подход позволяет применять для анализа глубоких сетей достаточный развитый аппарат теории ОДУ, оптимального управления и дифференциальных уравнений.

Исходя из двух представлений (дискретного и непрерывного), вводятся соответствующие пространства гипотез.

Определение (Пространство гипотез дискретных ResNet). Для заданных глубины S и шага δ определим

$$\mathcal{H}_{\text{resnet}}(S, \delta) = \{g \circ \varphi_{S, \delta}(\cdot; \theta) : g \in \mathcal{G}, \theta = (\theta_0, \dots, \theta_{S-1})\},$$

где $\varphi_{S, \delta}$ — потоковое отображение дискретной системы (4), а $\mathcal{G}$ — *терминальное семейство* (обычно простые функции, например, аффинные отображения $\mathbb{R}^n \rightarrow \mathcal{Y}$).

Определение (Пространство гипотез непрерывных ODE-сетей). Для заданного горизонта времени $T > 0$ определим

$$\mathcal{H}_{\text{ode}}(T) = \{g \circ \varphi_T(\cdot; \theta) : g \in \mathcal{G}, \theta(\cdot) \in L^\infty([0, T]; \Theta)\}.$$

Объединяя по всем возможным T , получаем основное пространство

$$\mathcal{H}_{\text{ode}} = \bigcup_{T>0} \mathcal{H}_{\text{ode}}(T).$$

Глубине сети S в дискретном случае соответствует время T в непрерывном. Ключевой вопрос: какие функции F можно аппроксимировать с помощью $\mathcal{H}_{\text{ode}}$ (а значит, и с помощью глубоких остаточных сетей (ResNets))?

Важно различать два понятия [16, Раздел 1.4]:

- **Точное представление (Representation):** $F \in \mathcal{H}_{\text{ode}}$.
- **Аппроксимация (Approximation):** F принадлежит замыканию $\mathcal{H}_{\text{ode}}$ в некоторой топологии (например, L^p на компактах). То есть для любого $\varepsilon > 0$ существует $G \in \mathcal{H}_{\text{ode}}$ такая, что $\|F - G\|_{L^p(K)} < \varepsilon$.

Потоковые отображения ОДУ обладают сильными топологическими ограничениями: они являются гомеоморфизмами, сохраняющими ориентацию. Следовательно, множество функций, *точно представимых* в виде потока, относительно невелико. Однако это не препятствует тому, чтобы это множество было *плотно* в более широком классе функций (например, в L^p), что и означает возможность *аппроксимации*.

Дискретизация Эйлера (4) аппроксимирует непрерывную динамику (5) с ошибкой $\mathcal{O}(T/S)$ на конечном временном горизонте [16, Раздел 1.4]. Поэтому положительные результаты об аппроксимации для $\mathcal{H}_{\text{ode}}$ автоматически переносятся (с учётом ошибки дискретизации) и на $\mathcal{H}_{\text{resnet}}$.

8.2 Структурные понятия и основная теорема об универсальной аппроксимации

В данном подразделе вводится формализм *управляющего* и *терминального семейств*, ключевые структурные понятия *функции-колодца* и *ограниченной аффинной инвариантности*, и формулируется основная теорема об универсальной аппроксимации для размерности $n \geq 2$.

Для компактного описания пространства гипотез $\mathcal{H}_{\text{ode}}$ вводятся следующие определения [16, Раздел 2.1]:

Определение (Управляющее семейство). **Управляющее семейство (control family)** $\mathcal{F}$ — это множество липшицевых векторных полей $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$. Каждое поле $f \in \mathcal{F}$ определяет правую часть ОДУ, управляющего динамикой.

Определение (Семейство потоковых отображений). Для горизонта времени $T > 0$ определим семейство потоковых отображений, порождённых $\mathcal{F}$:

$$\Phi(\mathcal{F}, T) = \{x \mapsto z(T) : \dot{z}(t) = f_t(z(t)), f_t \in \mathcal{F}, z(0) = x\},$$

где $t \mapsto f_t$ — измеримая и существенно ограниченная функция времени.

Определение (Пространство гипотез ODE-сетей). Для заданных управляющего семейства $\mathcal{F}$ и **терминального семейства (terminal family)** $\mathcal{G}$ (отображений $\mathbb{R}^n \rightarrow \mathcal{Y}$) определим

$$\mathcal{H}_{\text{ode}}(\mathcal{F}, \mathcal{G}) = \bigcup_{T>0} \{g \circ \phi : g \in \mathcal{G}, \phi \in \Phi(\mathcal{F}, T)\}.$$

Таким образом, обучение модели сводится к выбору управляющего поля f_t из $\mathcal{F}$ и финального преобразования g из $\mathcal{G}$.

Для формулировки условий универсальной аппроксимации необходимы два специфических свойства управляющего семейства.

Определение (Функция-колодец (Well function) [16]). Липшицева функция $h: \mathbb{R}^n \rightarrow \mathbb{R}$ называется **функцией-колодцем**, если существует ограниченное открытое выпуклое множество $U \subset \mathbb{R}^n$ такое, что

$$\{x \in \mathbb{R}^n : h(x) = 0\} = \bar{U}.$$

Векторнозначная функция $h = (h_1, \dots, h_{n_0})$ является функцией-колодцем, если каждая её компонента h_i удовлетворяет этому условию.

Замечание. Функция h обращается в ноль в точности на компактном выпуклом “колодце” $\bar{U}$ и сохраняет постоянный знак вне его. Это позволяет строить динамику, которая “притягивает” или “отталкивает” траектории относительно этого множества.

Определение (Ограниченная аффинная инвариантность (Restricted affine invariance) [16]). Управляющее семейство $\mathcal{F}$ называется **ограниченно аффинно инвариантным**, если для любого $f \in \mathcal{F}$, любого вектора $b \in \mathbb{R}^n$ и любых диагональных матриц $D = \text{diag}(d_1, \dots, d_n)$ (где $d_i \in \{0, \pm 1\}$) и $A = \text{diag}(a_1, \dots, a_n)$ (где $|a_i| \leq 1$) выполнено

$$x \mapsto Df(Ax + b) \in \mathcal{F}.$$

Это свойство гарантирует инвариантность семейства относительно изменений знака, покомпонентного масштабирования (с коэффициентом ≤ 1) и сдвигов. Оно выполняется для многих стандартных архитектур, например, для полносвязных слоёв с ReLU-активацией.

Данная теорема [16, Теорема 2.3] даёт общие достаточные условия для того, чтобы пространство гипотез $\mathcal{H}_{\text{ode}}(\mathcal{F}, \mathcal{G})$ обладало свойством универсальной аппроксимации в размерностях $n \geq 2$.

Теорема 8.1 (Достаточные условия универсальной аппроксимации, $n \geq 2$). Пусть $n \geq 2$ и $F: \mathbb{R}^n \rightarrow \mathbb{R}^m$ — непрерывная функция. Предположим, что управляющее семейство $\mathcal{F}$ и терминальное семейство $\mathcal{G}$ удовлетворяют условиям:

1. **Покрывание терминальным семейством:** Для любого компакта $K \subset \mathbb{R}^n$ существует липшицева функция $g \in \mathcal{G}$ такая, что $F(K) \subset g(\mathbb{R}^n)$.

2. **Наличие функции-колодца в выпуклой оболочке:** Замыкание выпуклой оболочки $\overline{\text{co}}(\mathcal{F})$ содержит функцию-колодец (в смысле Определения 8.2).
3. **Ограниченная аффинная инвариантность:** Семейство $\mathcal{F}$ является ограничено аффинно инвариантным (Определение 8.2).

Тогда для любого компакта $K \subset \mathbb{R}^n$, любого $p \in [1, \infty)$ и любого $\varepsilon > 0$ существует функция $\hat{F} \in \mathcal{H}_{ode}(\mathcal{F}, \mathcal{G})$ такая, что

$$\|F - \hat{F}\|_{L^p(K)} \leq \varepsilon.$$

Для доказательства данной теоремы нам потребуется сформулировать и доказать несколько дополнительных результатов, в том числе одномерную версию теоремы 8.1. Для начала разберем идею доказательства.

Идея доказательства. Ключевые шаги доказательства, изложенные в статье [16, Раздел 4]:

1. **Редукция к аппроксимации отображений области (Предложение 8.6 и его следствие):** Если терминальное семейство достаточно богато, то аппроксимацию произвольной F можно свести к аппроксимации некоторого непрерывного отображения $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ (преобразования области) потоковыми отображениями с последующим применением g .
2. **Аппроксимация конечных наборов точек (Леммы 8.7, 8.8):** Используя функцию-колодец и ограниченную аффинную инвариантность, можно построить потоковое отображение, которое переводит любой конечный набор различных точек $\{x_k\}$ сколь угодно близко в любой другой набор $\{y_k\}$, сохраняя попарное разделение координат.
3. **Переход к L^p -аппроксимации (Предложение 8.9):** Приближая произвольное непрерывное отображение ϕ кусочно-постоянным на мелкой сетке и используя лемму о конечных наборах точек для центров ячеек, строим потоковое отображение ψ , близкое к ϕ в L^p .

□

Следствие 8.1. Поскольку явная схема Эйлера аппроксимирует непрерывную динамику с глобальной погрешностью $\mathcal{O}(T/S)$, из плотности $\mathcal{H}_{ode}$ следует плотность и для соответствующего пространства гипотез дискретных ResNet $\mathcal{H}_{resnet}$.

8.3 Одномерный случай и его особенности

Для $n = 1$ потоковые отображения обладают специфическим свойством: они являются строго возрастающими функциями [16, Предложение 3.4].

Предложение 8.1 (Монотонность потоковых отображений в 1D.). Пусть $n = 1$ и φ_T — потоковое отображение автономного ОДУ $\dot{z} = f(z)$ с липшицевой правой частью. Тогда φ_T строго возрастает: для любых $x_1 < x_2$ выполнено $\varphi_T(x_1) < \varphi_T(x_2)$.

Доказательство. Достаточно показать, что если z_1 и z_2 — решения уравнения 5, но с разными начальными значениями $x_1 < x_2$, то для всех $t \geq 0$ выполняется $z_1(t) < z_2(t)$. Предположим противное: $z_1(t_0) = z_2(t_0)$ при некотором t_0 . Рассмотрим следующее обыкновенное дифференциальное уравнение:

$$\dot{w} = -f(w), \quad w(0) = z_1(t_0).$$

Тогда обе функции $z_1(t_0 - \cdot)$ и $z_2(t_0 - \cdot)$ являются решениями этого уравнения. В силу единственности решений получаем

$$z_1(t_0 - t) = z_2(t_0 - t)$$

для всех t , откуда следует, что

$$x_1 = z_1(0) = z_2(0) = x_2,$$

что противоречит условию $x_1 < x_2$. Поскольку обе функции z_1 и z_2 непрерывны по t , заключаем, что

$$z_1(t) < z_2(t)$$

для всех t . □

Следствие 8.2. *Любая композиция таких отображений также строго возрастает. Следовательно, семейство $\mathcal{A}_{\mathcal{F}} = \bigcup_{T>0} A_{\mathcal{F}}(T)$ (объединение достижимых множеств, см. ниже) содержит только возрастающие функции. Это означает, что невозможна аппроксимация функций, убывающих на каком-либо интервале.*

В рамках класса возрастающих функций универсальная аппроксимация всё же достигается.

Теорема 8.2 (Универсальная аппроксимация в 1D [16]). *Пусть $n = m = 1$, $\mathcal{G} = \{\text{id}\}$ (тождественное отображение). Предположим, что управляющее семейство $\mathcal{F}$ удовлетворяет:*

1. Оно является ограничено аффинно инвариантным с $A = 1$ (т.е. инвариантно только относительно сдвигов и изменений знака).
2. $\overline{\text{co}}(\mathcal{F})$ содержит функцию-колодец.
3. Каждая функция $f \in \mathcal{F}$ является (нестрого) возрастающей.

Тогда для любой непрерывной возрастающей функции $F: \mathbb{R} \rightarrow \mathbb{R}$ и любого компакта $K \subset \mathbb{R}$ существует последовательность $\hat{F}_k \in \mathcal{H}_{\text{ode}}(\mathcal{F}, \mathcal{G})$ такая, что $\|F - \hat{F}_k\|_{L^p(K)} \rightarrow 0$.

Интерпретация. В одномерном случае топологические ограничения существенны, и универсальность достигается лишь внутри класса монотонных функций. Это контрастирует с многомерным случаем ($n \geq 2$), где сохранение ориентации не препятствует плотности в L^p .

8.4 Технические основы: свойства потоков и достижимые множества

Рассмотрим автономное ОДУ

$$\dot{z}(t) = f(z(t)), \quad z(0) = x, \quad f \in \mathcal{F}.$$

Предложение 8.2 (Существование, единственность, гладкость [16]). Если f глобально липшицева, то решение существует, единственно и непрерывно зависит от начального условия. Если f r раз непрерывно дифференцируема ($r \geq 1$), то потоковое отображение φ_T является $(r - 1)$ раз непрерывно дифференцируемым по начальному условию.

Предложение 8.3 (Сохраняющие ориентацию диффеоморфизмы [16]). Если f дважды непрерывно дифференцируема, то её потоковое отображение φ_T является **сохраняющим ориентацию диффеоморфизмом**, т.е. $\det J_{\varphi_T}(x) > 0$ для всех x , где J_{φ_T} — матрица Якоби.

Это свойство следует из формулы Лиувилля для якобиана:

$$J_{\varphi_T}(x) = \exp \left(\int_0^T J_f(\varphi_t(x)) dt \right).$$

Предложение 8.4. Пусть $n = 1$ и $z(\cdot; x)$ — решение ОДУ 5 с начальным значением x . Если x принадлежит некоторому компактному множеству $K \subset \mathbb{R}$, то конечный модуль непрерывности

$$\omega_{z(\cdot; x), [0, T]}(r) = \sup_{\substack{0 \leq t_1 \leq t_2 \leq T \\ |t_2 - t_1| \leq r}} |z(t_1; x) - z(t_2; x)|$$

стремится к 0 при $r \rightarrow 0$ равномерно по $x \in K$.

Для доказательств удобно работать с кусочно-постоянными управлениями.

Определение (Достижимое множество [16]). Для горизонта $T > 0$ **достижимое множество** $A_{\mathcal{F}}(T)$ определяется как множество всех композиций конечного числа потоковых отображений, порождённых полями из $\mathcal{F}$:

$$A_{\mathcal{F}}(T) = \{\varphi_{t_k}^{f_k} \circ \dots \circ \varphi_{t_1}^{f_1} : t_1 + \dots + t_k = T, f_1, \dots, f_k \in \mathcal{F}, k \geq 1\},$$

где φ_{τ}^f — потоковое отображение за время τ для поля f . Полное **достижимое множество** есть объединение по всем временам: $A_{\mathcal{F}} = \bigcup_{T>0} A_{\mathcal{F}}(T)$.

Для аппроксимации достаточно показать, что $A_{\mathcal{F}}$ плотно в пространстве непрерывных отображений.

Важное техническое утверждение показывает, что при построении потоковых отображений можно эффективно использовать выпуклые комбинации полей из $\mathcal{F}$.

Предложение 8.5 (Выпуклая релаксация [16]). Пусть $\mathcal{F}$ — липшицево управляющее семейство, и $\tilde{\mathcal{F}}$ — любое липшицево семейство такое, что $\mathcal{F} \subset \tilde{\mathcal{F}} \subset \overline{\text{co}}(\mathcal{F})$. Тогда достижимые множества совпадают: $A_{\mathcal{F}} = A_{\tilde{\mathcal{F}}}$.

Идея доказательства. Доказательство использует технику быстрого переключения (chattering). Поток, порождённый выпуклой комбинацией полей $\alpha f + (1 - \alpha)g$, можно сколь угодно точно приблизить, быстро чередуя эволюцию под действием f и g на малых интервалах времени [16, Предложение 3.11]. $\square$

Замечание. Композиция во времени действует как механизм “выпуклой релаксации”: возможность составлять сложные траектории из простых позволяет достичь того же эффекта, что и использование более богатого (выпуклого) семейства управлений.

Предложение 8.5 является важным результатом, касающимся влияния непрерывной эволюции, которое можно рассматривать как непрерывное семейство композиций: любое семейство функций, управляющее динамической системой, столь же эффективно, как и его выпуклая оболочка, которая может быть значительно более широким семейством функций. Подобные свойства потоков наблюдались в контексте вариационных задач [17]. Это первое указание на пользу композиции в аппроксимации функций.

Для доказательства Предложения 8.5 потребуются следующие леммы.

Лемма 8.1 (Лемма 3.12 [16]). *Если $\mathcal{A}_{\mathcal{F}}$, $\mathcal{A}_{\tilde{\mathcal{F}}}$ — множества достижимости для $\mathcal{F}$, $\tilde{\mathcal{F}}$ и $\mathcal{F} \subset \tilde{\mathcal{F}} \subset \overline{\mathcal{F}}$, то*

$$\mathcal{A}_{\mathcal{F}} = \mathcal{A}_{\tilde{\mathcal{F}}}.$$

Доказательство. Достаточно показать, что $\mathcal{A}_{\tilde{\mathcal{F}}} \subset \mathcal{A}_{\mathcal{F}}$, тогда будет следовать $\mathcal{A}_{\mathcal{F}} \subset \mathcal{A}_{\tilde{\mathcal{F}}} \subset \mathcal{A}_{\mathcal{F}}$. Заметим, что любое $\tilde{\varphi} \in \mathcal{A}_{\tilde{\mathcal{F}}}$ имеет вид

$$\tilde{\varphi} = \varphi_{t_k}^{\tilde{f}_k} \circ \varphi_{t_{k-1}}^{\tilde{f}_{k-1}} \circ \dots \circ \varphi_{t_1}^{\tilde{f}_1},$$

где каждое $\tilde{f}_i$ принадлежит $\tilde{\mathcal{F}}$. Чтобы доказать лемму, нужно показать, что для любого компакта $K \subset \mathbb{R}^n$ и любого $\varepsilon > 0$ можно построить $\varphi \in \mathcal{A}_{\mathcal{F}}$ такое, что $\|\tilde{\varphi} - \varphi\|_{C(K)} \leq \varepsilon$. Докажем это индукцией по $k \geq 0$. Случай $k = 0$ очевиден, так как это тождественное отображение. Предположим теперь, что утверждение верно для $k - 1$, и зафиксируем произвольный компакт K . Запишем $\tilde{\varphi} = \varphi_{t_k}^{\tilde{f}_k} \circ \tilde{\psi}$, где $\tilde{\psi}$ — композиция $k - 1$ потоковых отображений, управляемых семейством $\tilde{\mathcal{F}}$. По индукционному предположению, для любого ε_1 (которое будет выбрано позже) существует $\psi \in \mathcal{A}_{\mathcal{F}}$ такое, что $\|\psi - \tilde{\psi}\|_{C(K)} \leq \varepsilon_1$. Более того, в силу предположения $\tilde{\mathcal{F}} \subset \mathcal{F}$, для любого ε_2 и компакта K' существует функция $f_k \in \mathcal{F}$ такая, что $\|f_k - \tilde{f}_k\|_{C(K')} \leq \varepsilon_2$. Здесь мы выбираем $K' = \{x : \inf_{y \in \mathcal{V}(K)} \|x - y\| \leq 2(\varepsilon_1 + t_k)e^{t_k \cdot \text{Lip}(\tilde{f}_k)}\}$ и $\varepsilon_2 < 1$.

Теперь рассмотрим два обыкновенных дифференциальных уравнения:

$$\tilde{z}(t) = \tilde{\psi}(x) + \int_0^t f_k(\tilde{z}(\tau)) d\tau \quad \text{и} \quad z(t) = \psi(x) + \int_0^t f_k(z(\tau)) d\tau.$$

Имеем $\tilde{\varphi}(x) = \tilde{z}(t_k)$ и отображение $x \mapsto z(t_k)$ принадлежит $\mathcal{A}_{\mathcal{F}}$, следовательно, остаётся показать, что решения этих ОДУ можно сделать сколь угодно близкими. Фактически, покажем, что

$$\sup_{0 \leq t \leq t_k} |z(t) - \tilde{z}(t)| < 2(\varepsilon_1 + t_k \varepsilon_2) e^{t_k \cdot \text{Lip}(\tilde{f}_k)}. \quad (*)$$

Предположим противное, тогда положим

$$t = \inf\{s \geq 0 : |z(s) - \tilde{z}(s)| \geq 2(\varepsilon_1 + t_k \varepsilon_2) e^{t_k \cdot \text{Lip}(\tilde{f}_k)}\}.$$

По непрерывности имеем $|z(t) - \tilde{z}(t)| \geq 2(\varepsilon_1 + t_k \varepsilon_2) e^{t_k \cdot \text{Lip}(\tilde{f}_k)}$. По предположению также имеем $|\tilde{f}_k(z(\tau)) - f_k(z(\tau))| \leq \varepsilon_2$ для всех $\tau < t$. Вычитая, получаем

$$\begin{aligned} |\tilde{z}(t) - z(t)| &\leq \varepsilon_1 + \left| \int_0^t \tilde{f}_k(\tilde{z}(\tau)) d\tau - \int_0^t f_k(z(\tau)) d\tau \right| \\ &\leq \varepsilon_1 + \int_0^t |\tilde{f}_k(z(\tau)) - f_k(z(\tau))| d\tau + \int_0^t |\tilde{f}_k(\tilde{z}(\tau)) - \tilde{f}_k(z(\tau))| d\tau \end{aligned}$$

$$\leq \varepsilon_1 + \varepsilon_2 t + \text{Lip}(\bar{f}_k) \int_0^t |\bar{z}(\tau) - z(\tau)| d\tau.$$

По неравенству Гронуолла имеем

$$\sup_{0 \leq t \leq t_k} |\bar{z}(t) - z(t)| \leq (\varepsilon_1 + t_k \varepsilon_2) e^{t_k \text{Lip}(\bar{f}_k)},$$

что противоречит выбору t . Следовательно, $(*)$ выполнено, и мы можем выбрать ε_1 и ε_2 сколь угодно малыми, что завершает доказательство. $\square$

Лемма 8.2 (Лемма 3.13 [16]). *Предположим, что $f, g \in \mathcal{F}$ и $t > 0$. Тогда $\varphi_t^{(f+g)/2} \in \mathcal{A}_{\mathcal{F}}$.*

Доказательство. Покажем, что $\varphi_{t/2N}^f \circ \varphi_{t/2N}^g \circ \dots \circ \varphi_{t/2N}^f \circ \varphi_{t/2N}^g$ может сколь угодно хорошо приближать $\varphi_t^{(f+g)/2} \in \mathcal{A}_{\mathcal{F}}$ при увеличении N . Отображение $\varphi_t^{(f+g)/2}$ является решением

$$\begin{aligned} z(t) &= x + \int_0^t \left(\frac{f+g}{2} \right) (z(\tau)) d\tau = x + \left(\int_0^{t/2N} + \int_{t/2N}^{3t/2N} + \dots + \int_{(2N-2)t/2N}^{(2N-1)t/2N} \right) (f+g)(z(\tau)) d\tau + \\ &\quad + \left(\int_{t/2N}^{2t/2N} + \dots + \int_{(2N-1)t/2N}^t \right) \left[\left(\frac{f+g}{2} \right) (z(\tau)) - \left(\frac{f+g}{2} \right) \left(z \left(\tau - \frac{t}{2N} \right) \right) \right] d\tau = \\ &= x + \left(\int_0^{t/2N} + \int_{t/2N}^{3t/2N} + \dots + \int_{(2N-2)t/2N}^{(2N-1)t/2N} \right) f(z(\tau)) d\tau + \left(\int_{t/2N}^{2t/2N} + \dots + \int_{(2N-1)t/2N}^t \right) g(z(\tau)) d\tau + \\ &\quad + \left(\int_{t/2N}^{2t/2N} + \dots + \int_{(2N-1)t/2N}^t \right) \left[\left(\frac{f+g}{2} \right) (z(\tau)) - \left(\frac{f+g}{2} \right) \left(z \left(\tau - \frac{t}{2N} \right) \right) \right] + \\ &\quad + \left[g \left(z \left(\tau - \frac{t}{2N} \right) \right) - g(z(\tau)) \right] d\tau. \end{aligned}$$

Таким образом, если

$$\begin{aligned} w(t) &= x + \left(\int_0^{t/2N} + \int_{t/2N}^{3t/2N} + \dots + \int_{(2N-2)t/2N}^{(2N-1)t/2N} \right) f(w(\tau)) d\tau + \\ &\quad + \left(\int_{t/2N}^{2t/2N} + \dots + \int_{(2N-1)t/2N}^t \right) g(w(\tau)) d\tau, \end{aligned}$$

то

$$\begin{aligned} |z(t) - w(t)| &\leq \int_0^t \max(\text{Lip}(f), \text{Lip}(g)) |z(\tau) - w(\tau)| d\tau + \\ &\quad + \frac{t}{2} \omega_{z, [0, t]} \left(\frac{t}{2N} \right) \left[\text{Lip} \left(\frac{f+g}{2} \right) + \text{Lip}(g) \right]. \end{aligned}$$

Напомним, что ω — модуль непрерывности, определённый в Предложении 8.4. Снова применяя неравенство Гронуолла, получаем

$$|z(t) - w(t)| \leq \frac{t}{2} \omega_{z,[0,t]} \left(\frac{t}{2N} \right) \left[\text{Lip} \left(\frac{f+g}{2} \right) + \text{Lip}(g) \right] e^{\max(\text{Lip}(f), \text{Lip}(g))}.$$

Для любого выбранного компакта K , $\omega_{z,[0,t]}(\frac{t}{2N}) \rightarrow 0$ по Предложению 8.4, следовательно, получаем $\varphi_t^{(f+g)/2} \in \mathcal{A}_{\mathcal{F}}$. $\square$

Теперь мы готовы доказать Предложение 8.5.

Доказательство Предложения 8.5. Используя ту же технику, что и в доказательстве Леммы 8.2, можно показать, что для $f_1, \dots, f_m \in \mathcal{F}$ имеем $\varphi_t^h \in \mathcal{A}_{\mathcal{F}}$, где $h = \sum_i q_i f_i$ для некоторых рациональных чисел q_i . Пусть $\mathcal{A}_{\mathcal{F}}$ — множество достижимости с управляющим семейством $\mathcal{F}' = \{\sum_{i=1}^m q_i f_i : q_i \in \mathbb{Q}, \sum_i q_i = 1, f_i \in \mathcal{F}, m \in \mathbb{N}\}$. Тогда $\mathcal{A}_{\mathcal{F}} = \mathcal{A}_{\mathcal{F}'}$. Поскольку $\mathcal{F}' = \mathcal{F}$, мы приходим к желаемому результату, используя Лемму 8.1. $\square$

Следующий результат крайне важен, так как позволяет свести задачу аппроксимации произвольной функции F к задаче аппроксимации некоторого отображения $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ (преобразования области) потоковыми отображениями.

Предложение 8.6 (Редукция (3.8) [16]). *Пусть $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$ непрерывна, $K \subset \mathbb{R}^n$ компакт, и существует липшицева $g \in \mathcal{G}$ такая, что $F(K) \subset g(\mathbb{R}^n)$. Тогда для любого $\varepsilon > 0$ существует непрерывное отображение $\phi : K \rightarrow \mathbb{R}^n$ такое, что $\|F - g \circ \phi\|_{L^p(K)} \leq \varepsilon$.*

Доказательство. Следует из общего результата о композиции функций. Мы доказываем этот специальный случай здесь для полноты изложения.

Множество $F(K)$ компактно, поэтому для любого $\delta > 0$ мы можем образовать разбиение $F(K) = \bigcup_{i=1}^N B_i$ с диаметром $\text{diam}(B_i) \leq \delta$. По предположению, $g^{-1}(B_i)$ непусто для каждого i , поэтому выберем $z_i \in g^{-1}(B_i)$. Для каждого i определим $A_i = F^{-1}(B_i) \cap K$, так что $\{A_i\}$ образует разбиение K . По внутренней регулярности меры Лебега, для любого $\delta' > 0$ и для каждого i можно найти компактное множество $K_i \subset A_i$ такое, что $\lambda(A_i \setminus K_i) \leq \delta'$ (где λ — мера Лебега) и множества K_i попарно не пересекаются. По лемме Урысона, для каждого i существует непрерывная функция $\varphi_i : K \rightarrow [0, 1]$ такая, что $\varphi_i = 1$ на K_i и $\varphi_i = 0$ на $\bigcup_{j \neq i} K_j$. Теперь образуем непрерывную функцию

$$\varphi(x) = \sum_{i=1}^N z_i \varphi_i(x).$$

Определим $K' = \left\{ \sum_{i=1}^N \alpha_i z_i : \alpha_i \in [0, 1] \right\}$, которое компактно и $\varphi(K) \subset K'$. Тогда

$$\begin{aligned} \|F - g \circ \varphi\|_{L^p(K)} &\leq \sum_{i=1}^N \|F - g \circ \varphi\|_{L^p(K_i)} + \sum_{i=1}^N \|F - g \circ \varphi\|_{L^p(A_i \setminus K_i)} \\ &\leq \sum_{i=1}^N \|F - g \circ \varphi_i\|_{L^p(K_i)} + \|F\|_{C(K)} + \|g\|_{C(K')} N \delta'. \end{aligned}$$

Мы выбираем δ' достаточно малым, чтобы последнее слагаемое было ограничено величиной δ . Тогда

$$\|F - g \circ \varphi\|_{L^p(K)} \leq \sum_{i=1}^N \delta \lambda(K_i) + \delta \leq (1 + \lambda(K))\delta.$$

Взяв $\delta = \varepsilon/(1 + \lambda(K))$, получаем требуемый результат. $\square$

Следствие 8.3. Если семейство потоковых отображений $\Phi(\mathcal{F}, T)$ плотно в множестве непрерывных отображений $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ (в топологии L^p на компактах), то и $\mathcal{H}_{ode}(\mathcal{F}, \mathcal{G})$ плотно в множестве непрерывных F .

Таким образом, основная техническая задача сводится к аппроксимации произвольного непрерывного ϕ отображениями из $A_{\mathcal{F}}$.

Замечание. В одномерном пространстве $A_{\mathcal{F}}$ содержит только возрастающие функции.

Наша цель — показать, что при выполнении условий Теоремы 8.2 можно аппроксимировать *любую* непрерывную возрастающую функцию. Стратегия:

1. Построить динамику перестановок (*rearrangement dynamics*), способную точно перевернуть любой конечный набор точек $\{x_i\}$ в любой другой набор $\{y_i\}$ (при условии $x_1 < \dots < x_M, y_1 < \dots < y_M$).
2. Использовать плотность кусочно-линейных интерполянтов для аппроксимации произвольной непрерывной возрастающей функции.

Пример (Семейство ReLU и функция-колодец). Рассмотрим управляющее семейство для одномерной полносвязной ResNet с ReLU-активацией:

$$\mathcal{F}_{\text{ReLU}} = \{x \mapsto v \cdot \text{ReLU}(wx + b) : v, w, b \in \mathbb{R}\}, \quad \text{ReLU}(z) = \max(0, z).$$

Оно, очевидно, ограничено аффинно инвариантно. Явный пример функции-колодца с нулевым множеством $[q_1, q_2]$:

$$h_Q(x) = \frac{1}{2} [\text{ReLU}(q_1 - x) + \text{ReLU}(x - q_2)] \in \overline{\text{co}}(\mathcal{F}_{\text{ReLU}}).$$

Это демонстрирует выполнение абстрактного условия “ $\overline{\text{co}}(\mathcal{F})$ содержит функцию-колодец” на конкретном примере.

Ключевая лемма для одномерного случая.

Лемма 8.3 (Конечная интерполяция в 1D [16]). Пусть $\mathcal{F}$ удовлетворяет условиям Теоремы 8.2. Тогда для любых возрастающих последовательностей $x_1 < \dots < x_M$ и $y_1 < \dots < y_M$ существует потоковое отображение $\psi \in A_{\mathcal{F}}$ такое, что $\psi(x_i) = y_i$ для всех $i = 1, \dots, M$.

Идея доказательства. Индукция по M . Используя функцию-колодец h_Q (с нулём на $[q_1, q_2]$), можно построить динамику, которая:

1. С помощью сдвигов и отражений (используя аффинную инвариантность) располагает точку x_1 и цель y_1 по одну сторону от “колодца”.
2. Применяя поток поля $\pm h_Q$, перемещает x_1 в y_1 , не затрагивая другие точки (т.к. они находятся в нулевом множестве h_Q или с другой стороны).
3. Индуктивно повторяет процесс для оставшихся точек.

□

Предложение 8.7. Пусть $\phi : \mathbb{R} \rightarrow \mathbb{R}$ непрерывна и возрастает, $K = [a, b]$ — компакт. Тогда для любого $\varepsilon > 0$ существует $\psi \in A_{\mathcal{F}}$ такая, что $\|\phi - \psi\|_{C(K)} < \varepsilon$.

Идея доказательства.

1. Выбираем достаточно мелкое разбиение $a = x_1 < x_2 < \dots < x_M = b$ так, чтобы колебание ϕ на каждом подинтервале не превышало ε (используем модуль непрерывности ω_ϕ).
2. Полагаем $y_i = \phi(x_i)$. По Лемме 8.3 строим $\psi \in A_{\mathcal{F}}$, интерполирующую эти точки: $\psi(x_i) = y_i$.
3. В силу монотонности ϕ и ψ , на каждом интервале $[x_i, x_{i+1}]$ выполняется $|\phi(x) - \psi(x)| \leq \omega_\phi(|x_{i+1} - x_i|) \leq \varepsilon$.

□

Эта предложение вместе со следствием 8.3 доказывает Теорему 8.2.

Займёмся вопросами скорости аппроксимации в одномерном случае. Для семейства ReLU можно получить количественные оценки сложности аппроксимации в терминах времени горизонта T .

Определение (Сложность через полную вариацию). Для гладкой возрастающей функции $\phi : [0, 1] \rightarrow \mathbb{R}$ определим

$$T_0(\phi) := \|\ln \phi'\|_{\text{TV}[0,1]},$$

где $\|\cdot\|_{\text{TV}}$ — полная вариация, а ϕ' — производная.

Предложение 8.8 (Связь времени горизонта и сложности [16]). Пусть ϕ — кусочно-гладкая возрастающая функция на $[0, 1]$.

1. Если $T \geq T_0(\phi)$, то ϕ может быть точно представлена как потоковое отображение с временным горизонтом $\leq T$.
2. Если $T < T_0(\phi)$, то существует нижняя оценка ошибки аппроксимации, зависящая от разницы $T_0(\phi) - T$.

Интерпретация: величина $\|\ln \phi'\|_{\text{TV}}$ измеряет “объем изменений”, необходимый для представления функции ϕ потоком. Она играет роль, аналогичную числу слоёв в дискретной сети.

8.5 Многомерный случай ($n \geq 2$): преодоление ограничений

В размерности $n \geq 2$ потоковые отображения по-прежнему являются сохраняющими ориентацию гомеоморфизмами. Однако ключевое отличие от одномерного случая состоит в следующем известном факте:

Множество сохраняющих ориентацию диффеоморфизмов **плотно** в L^p на ограниченных областях при $n \geq 2$ [18].

Таким образом, топологическое ограничение на точное представление не мешает плотности в смысле аппроксимации. Задача сводится к тому, чтобы показать, что достижимое множество $A_{\mathcal{F}}$ достаточно богато, чтобы приближать произвольные непрерывные отображения.

Основная техническая трудность в многомерном случае — построить потоковое отображение, которое одновременно управляет многими точками. Решение основывается на двух леммах.

Лемма 8.4 (Разделение координат [16]). *Предположим, $\mathcal{F}$ содержит функцию-колодец. Тогда для любых различных точек $x_1, \dots, x_m \in \mathbb{R}^n$ и $\varepsilon > 0$ существует потоковое отображение $\psi \in A_{\mathcal{F}}$ такое, что:*

1. $|\psi(x_k) - x_k| < \varepsilon$ для всех k ,
2. Для каждой координаты i значения $\{\psi(x_k)_i\}_{k=1}^m$ являются m различными вещественными числами.

Идея: используя функцию-колодец и аффинные преобразования, можно построить динамику, которая слегка “сдвигает” точки так, чтобы их координаты стали попарно различными, не смешивая при этом изначально различные координаты.

Лемма 8.5 (Точечное управление [16]). *Пусть точки $x_1, \dots, x_m$ удовлетворяют заключению Леммы 8.4. Тогда для любых целевых точек $y_1, \dots, y_m \in \mathbb{R}^n$ и $\varepsilon > 0$ существует $\phi \in A_{\mathcal{F}}$ такое, что $|\phi(x_k) - y_k| < \varepsilon$ для всех k .*

Идея: работая покоординатно и используя тот факт, что координаты точек разделены, можно независимо перемещать каждую точку вдоль выбранной координатной оси с помощью подходящим образом сконструированных из функции-колодца полей.

Композиция отображений, построенных в этих леммах, позволяет аппроксимировать произвольное соответствие на конечном наборе точек.

Финальный шаг — переход от аппроксимации на конечных множествах к аппроксимации в L^p [16, Предложение 4.11].

Предложение 8.9 (Универсальная аппроксимация в $n \geq 2$). *Пусть $n \geq 2$, $\mathcal{F}$ ограниченно аффинно инвариантно и $\overline{\text{co}}(\mathcal{F})$ содержит функцию-колодец. Тогда для любого компакта $K \subset \mathbb{R}^n$, любого $p \in [1, \infty)$, любого непрерывного $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ и любого $\varepsilon > 0$ существует $\psi \in A_{\mathcal{F}}$ такое, что*

$$\|\phi - \psi\|_{L^p(K)} < \varepsilon.$$

Идея доказательства. 1. Аппроксимируем ϕ на K кусочно-постоянным отображением $\hat{\phi}$ на мелкой кубической сетке.

2. Сопоставим каждому кубу сетки его центр x_k и значение $\hat{\phi}(x_k) = y_k$.
3. Используя Леммы 8.4 и 8.5, построим потоковое отображение ψ , переводящее каждое x_k близко в y_k .
4. Показываем, что из-за малости размера сетки и непрерывности ϕ отображение ψ будет близко к ϕ на всём K в норме L^p .

□

Заметим, что для целей аппроксимации тот факт, что $\overline{\text{co}}(\mathcal{F})$ содержит функцию типа “колодца” h , позволяет нам без потери общности считать, что $\mathcal{F}$ содержит такую функцию. Чтобы убедиться в этом, обозначим через $\tilde{\mathcal{F}}$ наименьшее ограниченно аффинно инвариантное множество, содержащее $\mathcal{F} \cup \{h\}$. Мы имеем $\mathcal{F} \subset \tilde{\mathcal{F}} \subset \overline{\text{co}}(\mathcal{F})$. Предложение 3.11 тогда утверждает, что $\mathcal{A}_{\mathcal{F}} = \mathcal{A}_{\tilde{\mathcal{F}}}$, следовательно, мы можем доказывать результаты аппроксимации, используя $\tilde{\mathcal{F}}$ вместо $\mathcal{F}$.

Для доказательства Предложения 8.9 нам потребуется несколько предварительных результатов. Ключевой подход аналогичен одномерному случаю: мы показываем, что можем преобразовать конечное число различных исходных точек в конечное число целевых точек, которые не обязательно различны. Начнем со следующей леммы, которая обобщает Лемму 8.3, приведённую в одномерном случае.

Лемма 8.6 (4.12). *Предположим, что $\mathcal{F}$ содержит функцию типа “колодца”. Пусть $\varepsilon > 0$ и $x^1, \dots, x^m, y^1, \dots, y^m \in \mathbb{R}^n$ таковы, что $\{x^k\}$ являются различными точками. Тогда существует $\psi \in \mathcal{A}_{\mathcal{F}}$ такой, что $|\psi(x^k) - y^k| \leq \varepsilon$ для всех $k = 1, \dots, m$.*

Лемма 8.6 следует из комбинации следующих двух лемм.

Лемма 8.7 (4.13). *Предположим, что $\mathcal{F}$ содержит функцию типа “колодца” и $x^1, \dots, x^m$ — различные точки. Тогда для любого $\varepsilon > 0$ существует поток $\psi \in \mathcal{A}_{\mathcal{F}}$ такой, что $|\psi(x^k) - x^k| \leq \varepsilon$ и для каждого $i = 1, \dots, n$, $[\psi(x^k)]_i$ (i -я координата $\psi(x^k)$), $k = 1, \dots, m$, представляют собой m различных вещественных чисел.*

Лемма 8.8 (4.14). *Предположим, что $\mathcal{F}$ содержит функцию типа “колодца”, $x^1, \dots, x^m$ — различные точки и удовлетворяют результату Леммы 8.7, то есть $\{x_i^k\}$ являются m различными вещественными числами для любого i . Тогда для любого $\varepsilon > 0$ и для m целевых точек $y^1, \dots, y^m$ существует поток $\psi \in \mathcal{A}_{\mathcal{F}}$ такой, что $|\psi(x^k) - y^k| \leq \varepsilon$.*

Поскольку K компактно, по теореме о продолжении достаточно рассмотреть случай, когда K является гиперкубом. Мы можем для простоты взять единичный гиперкуб $K = [0, 1]^n$, так как общий случай аналогичен. Для $\varphi \in L^p(K)$, согласно стандартной теории аппроксимации, φ может быть аппроксимирована кусочно постоянными функциями, т.е. существует

$$\hat{\varphi} = \sum_i \varphi_i \chi_i$$

такая, что $\|\hat{\varphi} - \varphi\|_{L^p(K)} \leq \varepsilon/2$. Здесь $i = [i_1, \dots, i_n]$ — мультииндекс, $\varphi_i \in \mathbb{R}^n$ и χ_i — индикатор куба

$$\square_i = \left[\frac{i_1}{N}, \frac{i_1 + 1}{N} \right] \times \dots \times \left[\frac{i_n}{N}, \frac{i_n + 1}{N} \right].$$

Мы также обозначим $p_i = (i_1/N, \dots, i_n/N)$. Определим сжатый куб

$$\square_i^\alpha = \left[\frac{i_1}{N}, \frac{i_1 + \alpha}{N} \right] \times \dots \times \left[\frac{i_n}{N}, \frac{i_n + \alpha}{N} \right],$$

где $0 < \alpha \leq 1$. Мы имеем $K = \bigcup_i \square_i$, и определим $K^\alpha = \bigcup_i \square_i^\alpha$. Мы также построим одномерную функцию сжатия, $h^\alpha : [0, 1] \rightarrow [0, 1]$, такую что $h^\alpha(x) = i/N$ если $i/N \leq x \leq (i + \alpha)/N$, и непрерывно возрастающую на $[0, 1]$. Используя это, мы можем сформировать n -мерное отображение сжатия через тензорное произведение:

$$H^\alpha(x) = (h^\alpha(x_1), \dots, h^\alpha(x_n)).$$

Идея доказательства Предложения 8.9 довольно проста: мы просто сжимаем каждую ячейку сетки $\square_i$ приблизительно в точку p_i , затем используем лемму выше для преобразования каждой p_i в φ_i . Последнее обсуждается в предварительном шаге; мы строим "почти"сжимающее отображение в $\mathcal{A}_{\mathcal{F}}$, которое аппроксимирует H^α .

Утверждение. Для заданной точности $\varepsilon_1 > 0$ существует поток $\tilde{H} \in \mathcal{A}_{\mathcal{F}}$ такой, что

$$\|\tilde{H} - H^\alpha\|_{C(K)} \leq \varepsilon_1.$$

Доказательство утверждения. Поскольку h^α возрастает и непрерывна, мы хотим использовать наш результат в одномерном случае. Конкретно, мы демонстрируем, как ограничить n -мерное семейство управлений до одномерного.

Предположим, что $\mathcal{F}$ является n -мерным семейством управлений. Тогда для каждого $f = (f_1, \dots, f_n) \in \mathcal{F}$ мы определим динамику, управляемую его ограничением на первую координату, как

$$\dot{z}_1 = f_1(x_1), \quad \dot{z}_i = 0 \text{ для } i \geq 2,$$

т.е. возьмём $D = A = \text{diag}(1, 0, \dots, 0)$. Множество таких систем управления обозначается через $\mathcal{F}_{R,1}$ (R означает ограничение, а 1 означает первую координату). Очевидно, что $\mathcal{F}_{R,1}$ замкнуто относительно композиции. Более того, $\mathcal{A}_{\mathcal{F}_{R,1}}$ совпадает с

$$\mathcal{A}_{\mathcal{R}} \times \{\text{id}\} \times \{\text{id}\} \times \dots \times \{\text{id}\},$$

где $\mathcal{R}$ — одномерное семейство управлений

$$\mathcal{R} = \{g(x) : g(x) = f_1(x, 0, \dots, 0), f \in \mathcal{F}\}.$$

Поскольку $\mathcal{F}$ содержит функцию типа “колодца”, то и $\mathcal{R}$ содержит такую функцию. По Предложению 8.7 мы можем найти $\tilde{h} \in \mathcal{R}$ такую, что $\|\tilde{h} - h^\alpha\|_{C([0,1])} \leq \varepsilon/n$.

По композиции мы знаем, что $\tilde{H} := (\tilde{h}, \dots, \tilde{h})$ принадлежит $\mathcal{A}_{\mathcal{F}}$, и $\|\tilde{H} - H^\alpha\|_{C(K)} \leq \varepsilon$. $\square$

Мы используем вышеуказанные обозначения: ψ для переноса p_i в φ_i , и $\tilde{H}$ для приближённого сжимающего отображения, удовлетворяющих следующим оценкам:

$$|\psi(p_i) - \varphi_i| \leq \varepsilon_1 < 1,$$

$$\|\tilde{H} - H^\alpha\|_{C(K)} \leq \varepsilon_2 < 1,$$

где ε_1 и ε_2 будут определены позже.

Теперь оценим погрешность $\|\psi \circ \tilde{H} - \varphi\|_{L^p(K)}$. Для любого α мы можем записать

$$\begin{aligned} \|\psi \circ \tilde{H} - \varphi\|_{L^p(K)} &\leq \|\psi \circ \tilde{H} - \hat{\varphi}\|_{L^p(K)} + \|\hat{\varphi} - \varphi\|_{L^p(K)} \\ &\leq \|\psi \circ \tilde{H} - \hat{\varphi}\|_{L^p(K^\alpha)} + \|\psi \circ \tilde{H} - \hat{\varphi}\|_{L^p(K \setminus K^\alpha)} + \varepsilon/2 \\ &\leq J_1 + J_2 + \varepsilon/2. \end{aligned}$$

Оценка J_1 . Имеем

$$\begin{aligned} J_1 &= \|\psi \circ \tilde{H} - \psi \circ H^\alpha\|_{L^p(K^\alpha)} + \|\psi \circ H^\alpha - \hat{\varphi}\|_{L^p(K^\alpha)} \\ &\leq \omega_\psi(\|\tilde{H} - H^\alpha\|_{C(K)}) + \sum_i |\psi(p_i) - \varphi_i| \cdot |\square_i|^{1/p} \\ &\leq \omega_\psi(\|\tilde{H} - H^\alpha\|_{C(K)}) + N^{n-n/p} \varepsilon_1 \\ &\leq \omega_\psi(\varepsilon_2) + N^{n-n/p} \varepsilon_1. \end{aligned}$$

Оценка J_2 . Обозначим через $\tilde{K} = [-1, 2]^n$ расширенный куб. Имеем

$$J_2 \leq |K \setminus K^\alpha| \cdot (\text{diam}(\psi(\tilde{K})) + \|\hat{\varphi}\|_{L^\infty(K)}).$$

Мы выбираем ψ так, что $\varepsilon_1 \leq \varepsilon/8$, α так, что

$$|K \setminus K^\alpha| \leq (\text{diam}(\psi(\tilde{K})) + \|\hat{\varphi}\|_{L^\infty(K)})^{-1} \varepsilon/4,$$

и, наконец, $\tilde{H}$ так, что $\omega_\psi(\varepsilon_2) \leq \varepsilon/8$. Тогда $\|\psi \circ \tilde{H} - \varphi\|_{L^p(K)} \leq \varepsilon$, и мы полагаем $\tilde{\varphi} = \psi \circ \tilde{H} \in \mathcal{A}_{\mathcal{F}}$, что даёт требуемый результат.

Как и в одномерном случае, Предложение 8.9 вместе со следствием предложения 8.6 доказывают Теорему 8.1.

8.6 Семейства тензорных произведений и сравнение с классической теорией

Иногда удобно строить многомерные управления, “складывая” одномерные.

Определение (Семейство тензорного произведения). Пусть $\mathcal{F}^{(1)}$ — одномерное управляющее семейство. Определим n -мерное **семейство тензорного произведения**:

$$\tilde{\mathcal{F}} = \{x \mapsto (g(x_1), g(x_2), \dots, g(x_n)) : g \in \mathcal{F}^{(1)}\}.$$

Если затем замкнуть $\tilde{\mathcal{F}}$ относительно всех аффинных преобразований (а не только диагональных), получим более богатое семейство $\mathcal{F}^{(n)}$.

Предложение 8.10 (Универсальность тензорных произведений [16]). *Предположим, что $\mathcal{A}_{\mathcal{F}^{(1)}}$ содержит все непрерывные возрастающие функции на $\mathbb{R}$. Тогда при $n \geq 2$ соответствующее семейство $\mathcal{F}^{(n)}$ обеспечивает универсальную L^p -аппроксимацию на $\mathbb{R}^n$.*

Подход динамических систем предлагает новую парадигму аппроксимации.

- **Классическая линейная/нелинейная аппроксимация:** Используется набор D простых функций (полиномы, вейвлеты). Аппроксимант — **линейная комбинация** конечного числа элементов словаря. Сложность определяется числом слагаемых N и затуханием/разреженностью коэффициентов [19, 20, 21].
- **Подход динамических систем:** Сложность возникает в основном за счёт **глубины композиции** (времени горизонта T), а не линейных комбинаций. Управляющее семейство $\mathcal{F}$ может быть очень маленьким (например, содержать одну функцию-колодец в своей выпуклой оболочке). Поточковые отображения — это композиции малых возмущений тождества, управляемых $\mathcal{F}$.

Таким образом, мы имеем новую парадигму: “аппроксимация через композицию потоков” вместо “аппроксимации через линейную комбинацию статических базисных функций”.

8.7 Следствия для глубоких сетей и связь с теорией управления

Проведённый анализ проясняет, когда ResNet-подобные архитектуры являются универсальными аппроксиматорами.

- Структурные условия носят архитектурный характер:

- Наличие в управляющем семействе возможности формировать *функции-колодцы* (что выполняется для ReLU, сигмоиды, $\tanh$ и др.).
- Инвариантность относительно базовых аффинных преобразований (знака, сдвига, масштабирования), что обычно встроено в полносвязные и свёрточные слои.

• **Многие практические архитектуры попадают в эту схему:**

- Полносвязные ResNet с активациями ReLU, sigmoid, $\tanh$.
- Остаточные блоки, состоящие из нескольких слоёв (residual blocks).
- Подходящие тензорно-произведённые конструкции.

• **Источник выразительной силы — композиция:** каждый элементарный блок может быть очень простым, а сложное поведение возникает за счёт их последовательной композиции во времени (глубине).

Рассматриваемая проблема имеет глубокие связи с другими областями математики.

- **Теория управления:** Аппроксимация с помощью $A_{\mathcal{F}}$ связана с задачей **управляемости (controllability)** [22, 23, 24]. Однако классическая управляемость фокусируется на переводе *одной* точки в целевую, тогда как здесь требуется управлять *целым множеством* входных значений K с помощью одного и того же управления f_t . Это можно рассматривать как задачу управляемости в бесконечномерном пространстве функций.
- **Динамические системы:** Результаты дополняют классические работы о том, когда гомеоморфизм *точно представим* как потоковое отображение [25, 26, 27], и о плотности сохраняющих ориентацию диффеоморфизмов в L^p [18]. Наши результаты дают конструктивный способ аппроксимации произвольных отображений потоками с ограниченной структурой управления.
- **Оптимальное управление:** Обучение в этой формулировке можно переформулировать как задачу **управления в среднем поле (mean-field optimal control)** [28, 29], что открывает путь к применению принципа максимума Понтрягина и методов Гамильтона-Якоби-Беллмана.

Подведём итоги лекции:

- Глубокие остаточные сети допускают естественную интерпретацию как управляемые потоки ОДУ.
- При выполнении мягких структурных условий (наличие функции-колодца в выпуклой оболочке управляющего семейства, ограниченная аффинная инвариантность и простое терминальное семейство) соответствующее пространство гипотез $\mathcal{H}_{\text{ode}}$ является универсальным аппроксиматором в L^p для размерностей $n \geq 2$.
- В размерности $n = 1$ универсальность достигается в классе непрерывных возрастающих функций, причём можно получить оценки скорости аппроксимации через полную вариацию $\|\ln \phi'\|_{\text{TV}}$.
- Эти результаты подчёркивают выразительную силу **композиции через потоки** и устанавливают связь между глубоким обучением, теорией динамических систем и оптимальным управлением.

Для дальнейшего ознакомления предлагается обратиться к оригиналам статей, упомянутых в конспекте.

9 Универсальная аппроксимация свёрточными сетями

9.1 Три взгляда на универсальную аппроксимацию глубокими свёрточными сетями

9.1.1 Модель Яроцкого: приближение инвариантных и эквивариантных отображений

Свёрточные сети устроены так, что их линейная часть (свёртка с *разделенным весом*) естественно согласована с действием группы сдвигов. Поэтому вопрос об *универсальной аппроксимации* для CNN имеет смысл только вместе с уточнением: *какой класс отображений* мы хотим аппроксимировать — эквивариантные операторы, инвариантные функционалы, или произвольные непрерывные отображения. Яроцкий предлагает строгую «континуальную» постановку, где CNN рассматриваются как аппроксиматоры отображений между бесконечномерными пространствами сигналов, а конечные архитектуры возникают через дискретизацию и усечение (окно) [30].

Пусть S_t обозначает оператор сдвига входного сигнала/изображения на t (в непрерывной постановке ниже это будет R_γ).

Определение. Отображение $\mathcal{F}$ называется

- *сдвиг-эквивариантным*, если $\mathcal{F}(S_t x) = S_t \mathcal{F}(x)$ для всех t ;
- *сдвиг-инвариантным*, если $\mathcal{F}(S_t x) = \mathcal{F}(x)$ для всех t .

Интуитивно: эквивариантность означает *коммутирование* с действием группы сдвигов; инвариантность означает, что выход вообще не меняется при сдвиге. Свёрточные слои с *разделением весов* (weight sharing) естественно навязывают эквивариантность, а *пулинг* и/или *глобальная агрегация* обычно используются как механизм получения инвариантности.

Для дискретного отображения признаков $z: \mathbb{Z}^\nu \rightarrow \mathbb{R}^m$ и шага (stride) $s \in \mathbb{N}$ *локальный пулинг* (downsampling) строит более грубую отображение на $s\mathbb{Z}^\nu$:

$$(\text{Pool}_s z)(\gamma) = \text{pool}(\{z(s\gamma + \theta) : \theta \in \mathcal{B}\}), \quad \gamma \in \mathbb{Z}^\nu,$$

где $\mathcal{B}$ — локальное окно (например, $\mathcal{B} = Z_{L_{\text{ff}}}$), а pool — max/avg и т.п. В модели Яроцкого используется особенно «чистый» вариант пулинга: *децимация* (subsampling)

$$(\text{Dec}_s z)(\gamma) = z(s\gamma), \quad \gamma \in \mathbb{Z}^\nu,$$

то есть оставляем каждую s -ю пространственную позицию (stride- s downsampling) [30]. Наконец, *глобальная агрегация* (global aggregation/pooling) «схлопывает» пространство, например

$$A_{\text{sum}}(z) = \sum_{\gamma \in \mathbb{Z}^\nu} z(\gamma), \quad A_{\text{avg}}(z) = \frac{1}{|\Omega|} \sum_{\gamma \in \Omega} z(\gamma) \quad (\Omega — \text{конечное окно}).$$

Если z сдвиг-эквивариантна, то $A(z)$ становится сдвиг-инвариантной.

Обсудим постановку Яроцкого для «сигналов бесконечного протяжения» [30]. Фиксируем размерность пространства $\nu \in \mathbb{N}$ и числа каналов $d_V, d_U \in \mathbb{N}$. Рассмотрим гильбертовы пространства

$$V := L^2(\mathbb{R}^\nu, \mathbb{R}^{d_V}), \quad U := L^2(\mathbb{R}^\nu, \mathbb{R}^{d_U}),$$

со стандартной нормой $\|\cdot\|_V, \|\cdot\|_U$. Действие группы сдвигов $\mathbb{R}^\nu$ на V (и аналогично на U) задаётся операторами

$$(S_\gamma \Phi)(\theta) = \Phi(\theta - \gamma), \quad \gamma, \theta \in \mathbb{R}^\nu, \quad \Phi \in V.$$

Отображение $f: V \rightarrow U$ называется $\mathbb{R}^\nu$ -эquivариантным, если

$$f(S_\gamma \Phi) = S_\gamma f(\Phi) \quad \forall \gamma \in \mathbb{R}^\nu, \quad \forall \Phi \in V.$$

Отображение $f: V \rightarrow U$ непрерывно по норме, если из $\|\Phi_n - \Phi\|_V \rightarrow 0$ следует $\|f(\Phi_n) - f(\Phi)\|_U \rightarrow 0$.

Ключевая идея подхода: аппроксимировать непрерывное $f: V \rightarrow U$ конечновычислимыми CNN, которые работают на дискретизациях сигнала на всё более тонких сетках и в всё более широких конечных окнах.

Для $\lambda > 0$ пусть $V_\lambda \subset V$ — подпространство сигналов, постоянных на кубах

$$Q_{\mathbf{k}}^{(\lambda)} = \prod_{s=1}^{\nu} \left[(k_s - \tfrac{1}{2})\lambda, (k_s + \tfrac{1}{2})\lambda \right], \quad \mathbf{k} = (k_1, \dots, k_\nu) \in \mathbb{Z}^\nu.$$

Обозначим через $P_\lambda: V \rightarrow V_\lambda$ ортогональный проектор:

$$(P_\lambda \Phi)(\gamma) = \frac{1}{\lambda^\nu} \int_{Q_{\mathbf{k}}^{(\lambda)}} \Phi(\theta) d\theta, \quad \text{где } Q_{\mathbf{k}}^{(\lambda)} \ni \gamma.$$

Тогда $V_\lambda \simeq L^2((\lambda\mathbb{Z})^\nu, \mathbb{R}^{d_\nu})$ (с естественным скалярным произведением).

Для целого $L \geq 0$ положим

$$Z_L = \{\mathbf{k} \in \mathbb{Z}^\nu : \|\mathbf{k}\|_\infty \leq L\}.$$

Для $\Lambda \geq 0$ (пространственный радиус / cut-off) определим подпространство дискретных сигналов, обнуляющихся вне окна:

$$V_{\lambda, \Lambda} = \left\{ \Phi: (\lambda\mathbb{Z})^\nu \rightarrow \mathbb{R}^{d_\nu} : \Phi(\lambda\mathbf{k}) = 0 \text{ если } \mathbf{k} \notin Z_{[\Lambda/\lambda]} \right\} \simeq L^2(\lambda Z_{[\Lambda/\lambda]}, \mathbb{R}^{d_\nu}).$$

Аналогично определяются $U_{\lambda, \Lambda} \subset U$ и ортогональные проекторы $P_{\lambda, \Lambda}: V \rightarrow V_{\lambda, \Lambda}$, $P_{\lambda, \Lambda}: U \rightarrow U_{\lambda, \Lambda}$.

Эвристика (важна для «предела CNN»): $\lambda \downarrow 0$ фиксирует всё более тонкие детали сигнала, а $\Lambda \uparrow \infty$ делает ошибку усечения хвостов пренебрежимо малой на фиксированных компактах. Поэтому «предел CNN» формализуется через последовательность моделей на всё более тонких решётках и всё больших окнах.

Нам понадобится стандартная «компактная» версия сильной сходимости проекторов.

Лемма 9.1 (Равномерная аппроксимация проекторами на компакте). Пусть $K \subset V$ — компакт, и $\varepsilon > 0$. Тогда существуют $\lambda_0 > 0$ и $\Lambda_0 > 0$ такие, что при $\lambda \leq \lambda_0$ и $\Lambda \geq \Lambda_0$ выполнено

$$\sup_{\Phi \in K} \|P_{\lambda, \Lambda} \Phi - \Phi\|_V < \varepsilon.$$

Аналогичное утверждение верно в U .

Доказательство. В [30] показано, что $P_{\lambda,\Lambda}\Phi \rightarrow \Phi$ в V при $\lambda \rightarrow 0$, $\Lambda \rightarrow \infty$ для каждого фиксированного Φ (сильная сходимост проекторов). Переходим от поточечной сходимости к равномерной на компакте с помощью ε -сетей.

Так как K компактен, существует конечное $\varepsilon/3$ -покрытие: $K \subset \bigcup_{j=1}^N B(\Phi_j, \varepsilon/3)$. Для каждой Φ_j найдутся λ_j, Λ_j такие, что при $\lambda \leq \lambda_j$ и $\Lambda \geq \Lambda_j$ выполнено $\|P_{\lambda,\Lambda}\Phi_j - \Phi_j\|_V < \varepsilon/3$. Положим $\lambda_0 := \min_j \lambda_j$ и $\Lambda_0 := \max_j \Lambda_j$.

Возьмём произвольное $\Phi \in K$ и j такое, что $\|\Phi - \Phi_j\|_V < \varepsilon/3$. Так как $P_{\lambda,\Lambda}$ — ортогональный проектор, $\|P_{\lambda,\Lambda}\| \leq 1$. Тогда

$$\|P_{\lambda,\Lambda}\Phi - \Phi\|_V \leq \|P_{\lambda,\Lambda}(\Phi - \Phi_j)\|_V + \|P_{\lambda,\Lambda}\Phi_j - \Phi_j\|_V + \|\Phi_j - \Phi\|_V < \varepsilon.$$

□

Фиксируем область поля восприятия (receptive field) как кубическое множество

$$Z_{L_{\text{rf}}} \subset \mathbb{Z}^\nu, \quad L_{\text{rf}} \in \mathbb{N}, \quad Z_{L_{\text{rf}}} = \{\mathbf{k} \in \mathbb{Z}^\nu : \|\mathbf{k}\|_\infty \leq L_{\text{rf}}\}$$

и считаем L_{rf} фиксированным, тогда как λ и Λ могут меняться (детализация и окно).

Определение. Базовая свёрточная сеть (basic convnet) — это отображение $\hat{f}: V \rightarrow U$, определённое композицией

$$\hat{f}: V \xrightarrow{P_{\lambda,\Lambda+(T-1)\lambda L_{\text{rf}}}} V_{\lambda,\Lambda+(T-1)\lambda L_{\text{rf}}} (= W_1) \xrightarrow{\hat{f}_1} W_2 \xrightarrow{\hat{f}_2} \dots \xrightarrow{\hat{f}_T} W_{T+1} (= U_{\lambda,\Lambda}), \quad (6)$$

где промежуточные пространства имеют вид

$$W_t = \left\{ \Phi : \lambda Z_{[\Lambda/\lambda] + (T-t)L_{\text{rf}}} \rightarrow \mathbb{R}^{d_t} \right\}, \quad t \leq T, \quad W_{T+1} = \left\{ \Phi : \lambda Z_{[\Lambda/\lambda]} \rightarrow \mathbb{R}^{d_U} \right\},$$

а слои задаются как «линейная свёртка + нелинейность»:

$$(\hat{f}_t(\Phi))_{\gamma,n} = \sigma \left(\sum_{\theta \in Z_{L_{\text{rf}}}} \sum_{k=1}^{d_t} w_{n\theta k}^{(t)} \Phi_{\gamma+\theta,k} + h_n^{(t)} \right), \quad \gamma \in Z_{[\Lambda/\lambda] + (T-t-1)L_{\text{rf}}},$$

и на последнем слое $t = T$ нелинейность опускается:

$$(\hat{f}_T(\Phi))_{\gamma,n} = \sum_{k=1}^{d_T} w_{nk}^{(T)} \Phi_{\gamma,k} + h_n^{(T)}, \quad \gamma \in Z_{[\Lambda/\lambda]}, \quad n = 1, \dots, d_U.$$

Здесь σ — фиксированная поэлементная активация (например, ReLU), а коэффициенты $w_{n\theta k}^{(t)}$ и $h_n^{(t)}$ являются параметрами сети.

Из-за разделения весов и того, что свёртка локальна и одинакова во всех узлах решётки, модель (6) коммутирует со сдвигами на решётке $\lambda\mathbb{Z}^\nu$ (с поправкой на граничные эффекты усечения), что будет ключевым в доказательстве необходимости теоремы ниже [30].

Из-за бесконечномерности V топология равномерной сходимости на компактах не удовлетворяет первой аксиоме счётности, поэтому Яроцкий аккуратно фиксирует определение «предельной точки» через аппроксимацию на каждом компакте [30].

Определение. Пусть $V = L^2(\mathbb{R}^\nu, \mathbb{R}^{d_V})$ и $U = L^2(\mathbb{R}^\nu, \mathbb{R}^{d_U})$. Говорят, что отображение $f : V \rightarrow U$ является *предельной точкой семейства базовых свёрточных сетей*, если для любого фиксированного L_{rf} , любого компакта $K \subset V$, любых $\varepsilon > 0$, $\lambda_0 > 0$, $\Lambda_0 > 0$ существует базовая свёрточная сеть $\hat{f}$ с тем же L_{rf} , шагом $\lambda \leq \lambda_0$ и радиусом $\Lambda \geq \Lambda_0$ такая, что

$$\sup_{\Phi \in K} \|\hat{f}(\Phi) - f(\Phi)\|_U < \varepsilon.$$

Теорема 9.1 (Характеризация предельных точек, теорема 3.1 [30]). *Отображение $f : V \rightarrow U$ является предельной точкой семейства базовых CNN тогда и только тогда, когда f (i) непрерывно по норме и (ii) сдвиг-эквивариантно.*

Доказательство. (Необходимость). Пусть f — предельная точка базовых CNN.

Шаг 1: непрерывность f . Пусть $\Phi_n \rightarrow \Phi$ в V . Множество $K := \{\Phi\} \cup \{\Phi_n : n \in \mathbb{N}\}$ компактно (в метрическом пространстве равносильны компактность и секвенциальная компактность). Возьмём $\varepsilon > 0$, существует базовая CNN $\hat{f}$ такая, что

$$\sup_{\Psi \in K} \|f(\Psi) - \hat{f}(\Psi)\|_U < \varepsilon/3. \quad (7)$$

Каждая конкретная $\hat{f}$ непрерывна как композиция непрерывных отображений (проектор + конечное число конечномерных операций + вложение обратно в U), поэтому существует N такое, что при $n \geq N$ выполнено

$$\|\hat{f}(\Phi_n) - \hat{f}(\Phi)\|_U < \varepsilon/3. \quad (8)$$

Тогда при $n \geq N$, по неравенству треугольника и (7)–(8),

$$\|f(\Phi_n) - f(\Phi)\|_U \leq \|f(\Phi_n) - \hat{f}(\Phi_n)\|_U + \|\hat{f}(\Phi_n) - \hat{f}(\Phi)\|_U + \|\hat{f}(\Phi) - f(\Phi)\|_U < \varepsilon.$$

Значит, f непрерывно.

Шаг 2: эквивариантность f . Нужно показать $f(R_\gamma \Phi) = R_\gamma f(\Phi)$ для всех γ и Φ . Фиксируем $\Phi \in V$ и $\gamma \in \mathbb{R}^\nu$.

Локализация в большом окне. Для $M > 0$ положим $D_M = [-M, M]^\nu$ и обозначим P_{D_M} оператор умножения на индикатор 1_{D_M} в U (ортогональный проектор на подпространство функций, с носителем в D_M). Так как $P_{D_M} u \rightarrow u$ в U при $M \rightarrow \infty$ для любого $u \in U$, достаточно доказать тождество

$$P_{D_M} f(R_\gamma \Phi) = R_\gamma P_{D_M} f(\Phi) \quad \forall M > 0. \quad (9)$$

Аппроксимация непрерывного сдвига дискретным. Для данного $\lambda > 0$ выберем $\gamma_\lambda \in (\lambda\mathbb{Z})^\nu$ так, что $\|\gamma - \gamma_\lambda\|_\infty \leq \lambda$. Используем факты из оригинальной статьи:

- $R_{\gamma_\lambda} \rightarrow R_\gamma$ сильно в U при $\lambda \rightarrow 0$;
- из непрерывности f следует: $f(R_{\gamma_\lambda} \Phi) \rightarrow f(R_\gamma \Phi)$ в U при $\lambda \rightarrow 0$;
- $P_{\lambda, M} \rightarrow P_{D_M}$ сильно в U при $\lambda \rightarrow 0$ (здесь $P_{\lambda, M}$ — дискретизация+усечение на окне D_M).

Следовательно, для любого $\varepsilon > 0$ можно выбрать $\lambda > 0$ настолько малым, что одновременно:

$$\|P_{D_M}f(R_\gamma\Phi) - P_{\lambda,M}f(R_\gamma\Phi)\|_U < \varepsilon, \quad (10)$$

$$\|P_{\lambda,M}f(R_\gamma\Phi) - P_{\lambda,M}f(R_{\gamma_\lambda}\Phi)\|_U < \varepsilon, \quad (11)$$

$$\|R_{\gamma_\lambda}P_{\lambda,M}f(\Phi) - R_\gamma P_{D_M}f(\Phi)\|_U < 2\varepsilon. \quad (12)$$

Использование эквивариантности конкретной CNN на решётке. Рассмотрим компактное множество $K := \{\Phi, R_{\gamma_\lambda}\Phi\}$. По определению предельной точки найдётся базовая CNN $\hat{f}$ с данным λ и достаточно большим Λ такая, что

$$\sup_{\Psi \in K} \|f(\Psi) - \hat{f}(\Psi)\|_U < \varepsilon. \quad (13)$$

Выбираем Λ так, чтобы на области D_M не было краевых эффектов при сдвиге, и тогда для дискретного сдвига $\gamma_\lambda \in (\lambda\mathbb{Z})^\nu$ выполняется тождество

$$P_{\lambda,M}\hat{f}(R_{\gamma_\lambda}\Phi) = R_{\gamma_\lambda}P_{\lambda,M}\hat{f}(\Phi). \quad (14)$$

Сборка оценки. Оценим норму разности в (9):

$$\begin{aligned} & \|P_{D_M}f(R_\gamma\Phi) - R_\gamma P_{D_M}f(\Phi)\|_U \leq \\ & \leq \underbrace{\|P_{D_M}f(R_\gamma\Phi) - P_{\lambda,M}f(R_\gamma\Phi)\|_U}_{<\varepsilon \text{ по (10)}} + \underbrace{\|P_{\lambda,M}f(R_\gamma\Phi) - P_{\lambda,M}f(R_{\gamma_\lambda}\Phi)\|_U}_{<\varepsilon \text{ по (11)}} + \\ & + \|P_{\lambda,M}f(R_{\gamma_\lambda}\Phi) - P_{\lambda,M}\hat{f}(R_{\gamma_\lambda}\Phi)\|_U + \underbrace{\|P_{\lambda,M}\hat{f}(R_{\gamma_\lambda}\Phi) - R_{\gamma_\lambda}P_{\lambda,M}\hat{f}(\Phi)\|_U}_{=0 \text{ по (14)}} + \\ & + \|R_{\gamma_\lambda}P_{\lambda,M}\hat{f}(\Phi) - R_{\gamma_\lambda}P_{\lambda,M}f(\Phi)\|_U + \underbrace{\|R_{\gamma_\lambda}P_{\lambda,M}f(\Phi) - R_\gamma P_{D_M}f(\Phi)\|_U}_{<2\varepsilon \text{ по (12)}}. \end{aligned}$$

Так как $\|P_{\lambda,M}\| \leq 1$ и $\|R_{\gamma_\lambda}\| = 1$, два «средних» члена оцениваются через (13) сверху на ε каждый. Итого получаем

$$\|P_{D_M}f(R_\gamma\Phi) - R_\gamma P_{D_M}f(\Phi)\|_U < 6\varepsilon.$$

Так как ε произвольно, доказано (9). Переходом $M \rightarrow \infty$ получаем эквивариантность f .

(Достаточность). Пусть теперь $f: V \rightarrow U$ непрерывно по норме и эквивариантно. Нужно: для любого компакта $K \subset V$ и $\varepsilon > 0$ построить базовую CNN $\hat{f}$, приближающую f на K .

Шаг 1: замена f на дискретизованно-усечённый суррогат. По лемме 9.1 (применённой к K и $f(K) \subset U$, что компактно по непрерывности f) можно выбрать λ малым и Λ большим так, что одновременно:

$$\sup_{\Phi \in K} \|P_{\lambda,\Lambda}\Phi - \Phi\|_V < \delta, \quad \sup_{\Psi \in f(K)} \|P_{\lambda,\Lambda}\Psi - \Psi\|_U < \varepsilon/3,$$

и по равномерной непрерывности f на компакте K (теорема Кантора) при достаточно малом δ выполнено

$$\sup_{\Phi \in K} \|f(P_{\lambda,\Lambda}\Phi) - f(\Phi)\|_U < \varepsilon/3.$$

Тогда для приближения

$$f_{\lambda,\Lambda}(\Phi) := P_{\lambda,\Lambda} f(P_{\lambda,\Lambda} \Phi)$$

получаем

$$\sup_{\Phi \in K} \|f_{\lambda,\Lambda}(\Phi) - f(\Phi)\|_U < 2\varepsilon/3. \quad (15)$$

Шаг 2: сведение к конечномерному «ядру» при $\Lambda = 0$. Зафиксируем глубину T . В [30] вводится функция $f_{\lambda,0,T}$, которая отвечает выходу на *одной* пространственной ячейке (вырожденное окно $\Lambda = 0$) и зависит только от конечного входного окна радиуса $(T-1)\lambda L_{\text{rf}}$. Формально задаётся

$$f_{\lambda,0,T}(\Phi) := P_{\lambda,0} f(P_{\lambda,(T-1)\lambda L_{\text{rf}}} \Phi), \quad f_{\lambda,0,T} : V_{\lambda,(T-1)\lambda L_{\text{rf}}} \rightarrow U_{\lambda,0}. \quad (16)$$

Это отображение непрерывно и действует между конечномерными пространствами.

Шаг 3: аппроксимация ядра базовой CNN (Лемма 9.2). Ниже мы докажем Лемму 9.2, которая говорит, что любой непрерывный $f_{\lambda,0,T}$ можно аппроксимировать базовой CNN с теми же λ, T и $\Lambda = 0$.

Шаг 4: расширение ядра до произвольного окна («tile by translations»). Эквивариантность f позволяет восстановить полный выход на окне из локального ядра с помощью «shift-and-sum» (смотри [30, (3.28)]): для дискретных $\gamma \in Z_{[\Lambda/\lambda]}$

$$f_{\lambda,\Lambda,T}(\Phi) := \sum_{\gamma \in Z_{[\Lambda/\lambda]}} R_{\lambda\gamma} f_{\lambda,0,T}(R_{-\lambda\gamma} \Phi) \in U_{\lambda,\Lambda}. \quad (17)$$

Так как сумма конечна, а сдвиги изометричны, то если $\hat{f}_0$ аппроксимирует $f_{\lambda,0,T}$ на множествах $R_{-\lambda\gamma}K$, тогда сеть

$$\hat{f}(\Phi) := \sum_{\gamma \in Z_{[\Lambda/\lambda]}} R_{\lambda\gamma} \hat{f}_0(R_{-\lambda\gamma} \Phi) \quad (18)$$

аппроксимирует $f_{\lambda,\Lambda,T}$ на K , причём ошибка суммируется линейно и контролируется выбором точности ядра. Реализуемость (18) в классе базовых CNN обсуждается и формально доказывается в статье: локальность (фикс. L_{rf}) обеспечивает вычислимость каждого элемента расширения одним и тем же ядром, а эквивариантность слоёв обеспечивает корректное «копирование» по всем позициям.

Шаг 5: итоговая оценка. Можно показать, что при достаточно большом T функция $f_{\lambda,\Lambda,T}$ приближает $f_{\lambda,\Lambda}$ на K (это контроль «длины поля восприятия» в континуальном масштабе). Совмещая: (15) + аппроксимацию $f_{\lambda,\Lambda}$ через $f_{\lambda,\Lambda,T}$ + аппроксимацию $f_{\lambda,\Lambda,T}$ сетью (18), получаем требуемое $\sup_{\Phi \in K} \|\hat{f}(\Phi) - f(\Phi)\|_U < \varepsilon$. $\square$

Лемма 9.2 (Аппроксимация при вырожденном окне, лемма 3.1 [30]). *Пусть фиксированы $\lambda > 0$ и $T \in \mathbb{N}$, а выходное окно вырождено: $\Lambda = 0$. Тогда любое непрерывное отображение*

$$g : V_{\lambda,(T-1)\lambda L_{\text{rf}}} \rightarrow U_{\lambda,0}$$

можно аппроксимировать (равномерно на компактах) базовыми CNN с теми же λ, T и $\Lambda = 0$ (разрешая увеличивать числа каналов d_t).

Идея в том, чтобы строго реализовать следующую схему: локально сжать вход в фиксированное малое окно и применить УАТ для MLP на конечномерном векторе.

Доказательство. Шаг 0: конечномерность. Пространство $V_{\lambda, (T-1)L_{\text{rf}}}$ конечномерно и отождествляется с $\mathbb{R}^N$, где $N = d_V |Z_{(T-1)L_{\text{rf}}}|$; аналогично $U_{\lambda, 0} \cong \mathbb{R}^{d_U}$. Следовательно, задача сводится к аппроксимации непрерывной функции $g: \mathbb{R}^N \rightarrow \mathbb{R}^{d_U}$ на компакте.

Шаг 1: «сжатие» (перенос всех координат в одно локальное место). Построим первые $T - 2$ слоёв так, чтобы (на заданном компакте) они реализовывали отображение

$$C: V_{\lambda, (T-1)L_{\text{rf}}} \rightarrow W_{T-1} = V_{\lambda, L_{\text{rf}}} \text{ (с большим числом каналов),}$$

которое кодирует все координаты входа в значениях признакового отображения вблизи нуля (внутри $Z_{L_{\text{rf}}}$), причём координаты кодируются *по каналам*. Формально: для каждой входной координаты (γ, k) (где $\gamma \in Z_{(T-1)L_{\text{rf}}}$) выделим отдельный канал $c(\gamma, k)$ на последнем передвыходном слое и добьёмся, чтобы

$$(C(\Phi))_{0, c(\gamma, k)} \approx \Phi_{\gamma, k},$$

а остальные значения $C(\Phi)$ вне небольшого набора позиций можно считать несущественными.

Как это сделать свёрточными слоями фиксированной локальности? Рассмотрим разложение $\gamma = \theta_1 + \dots + \theta_{T-1}$, где каждое $\theta_i \in Z_{L_{\text{rf}}}$. Такое разложение существует, потому что $\|\gamma\|_\infty \leq (T-1)L_{\text{rf}}$. Тогда можно «перетаскивать» значение из позиции γ к нулю за $T-1$ локальных шагов, каждый раз используя сдвиг на θ_i внутри допустимого поля восприятия.

В линейном случае мы бы просто выбирали веса как индикаторы нужного сдвига и копировали координаты точно. С нелинейностью σ Яроцкий использует следующий стандартный приём: координатные функционалы вида $\Phi \mapsto \Phi_{\eta, k}$ на конечномерном пространстве аппроксимируются однослойными сетями, после чего линейные комбинации и «маршрутизация» по каналам реализуются последующими свёрточными слоями. Это позволяет построить C с любой требуемой точностью на данном компакте.

Шаг 2: УА на локализованном векторе (последние два слоя). После «сжатия» $C(\Phi)$ зависит (с заданной точностью) от конечного набора скаляров, которые мы можем рассматривать как вектор $x \in \mathbb{R}^N$, расположенный в каналах в одной точке решётки. Последние два слоя при $\Lambda = 0$ вычисляют выход в одной точке и имеют вид полносвязной сети с одним скрытым слоем, построенной по этому вектору:

$$(\hat{f}_T \circ \hat{f}_{T-1})(\Psi) = W^{(T)} \sigma(W^{(T-1)} \text{vec}(\Psi) + b^{(T-1)}) + b^{(T)}.$$

По теореме универсальной аппроксимации (используемой Яроцким как теорема 2.1) можно выбрать ширину скрытого слоя достаточно большой так, чтобы эта композиция аппроксимировала произвольную непрерывную g на компакте входных сигналов.

Шаг 3: композиция. Композиция «первые слои $\approx C$ » и «последние слои $\approx g \circ C^{-1}$ (на образе компакта)» даёт требуемую аппроксимацию g базовой CNN с $\Lambda = 0$. $\square$

Далее Яроцкий рассматривает сети с шагом субдескритизации s и фиксированным L_{rf} , при этом накладывается условие достижимости (связности)

$$s \leq 2L_{\text{rf}} + 1, \tag{19}$$

которое гарантирует, что информация из каждой входной позиции может попасть к выходу через локальные окна [30, (3.29)].

Определение. Непрерывный функционал $f: V \rightarrow \mathbb{R}$ называется *предельной точкой семейства свёрточных сетей с субдескритизацией*, если для любого компакта $K \subset V$, любого $\varepsilon > 0$, любых $\lambda_0 > 0$, $\Lambda_0 > 0$ существует CNN с шагом субдескритизации s (удовлетворяющим (19)), шагом сетки $\lambda \leq \lambda_0$ и достаточно большой глубиной T , так что эффективный входной радиус $\lambda L_{1,T} \geq \Lambda_0$ и

$$\sup_{\Phi \in K} |f(\Phi) - \hat{f}(\Phi)| < \varepsilon.$$

Теорема 9.2. Функционал $f: V \rightarrow \mathbb{R}$ является предельной точкой семейства CNN с субдескритизацией тогда и только тогда, когда f непрерывен по норме.

Доказательство. (Необходимость). Точно как в теореме о характеристизации предельных точек: берём сходящуюся последовательность $\Phi_n \rightarrow \Phi$, рассматриваем компакт $K = \{\Phi\} \cup \{\Phi_n\}$ и аппроксимирующую f сеть $\hat{f}$ на K . По непрерывности $\hat{f}$ и оценке треугольником получаем непрерывность f .

(Достаточность). Пусть f непрерывен, $K \subset V$ компактен, $\varepsilon > 0$.

Шаг 1: проектор на большое конечное окно. По лемме 1 можно выбрать λ малым и параметры сети (в частности, глубину T) так, чтобы проектор $P_{\lambda, \lambda L_{1,T}}$ был близок к тождеству на K :

$$\sup_{\Phi \in K} \|P_{\lambda, \lambda L_{1,T}} \Phi - \Phi\|_V < \delta,$$

а равномерная непрерывность f на компакте K даёт

$$\sup_{\Phi \in K} |f(P_{\lambda, \lambda L_{1,T}} \Phi) - f(\Phi)| < \varepsilon/2. \quad (20)$$

Шаг 2: конечномерная аппроксимация. Отображение $g := f \circ P_{\lambda, \lambda L_{1,T}}$ действует на конечномерном пространстве $V_{\lambda, \lambda L_{1,T}} \cong \mathbb{R}^N$, и достаточно аппроксимировать g на компакте $P_{\lambda, \lambda L_{1,T}} K$.

Шаг 3: реализуемость g архитектурой с субдескритизацией. Благодаря условию (19) любая входная позиция на мелкой решётке может быть выражена как $s\gamma + \theta$ с $\theta \in Z_{L_{\text{rf}}}$, а значит локальный слой с шагом s может «забирать» информацию из каждой позиции и переносить её на более грубую решётку. Итерируя по слоям, можно построить (с достаточной шириной каналов) схему «сжатия», аналогичную доказательству Леммы 9.2, которая кодирует конечномерный вход в признаки в небольшой области на последнем слое. После этого последние слои реализуют MLP с одним скрытым слоем над полученным конечномерным вектором признаков, и по УАТ аппроксимируют произвольное непрерывное g на компакте.

То есть существует downsampling-CNN $\hat{f}$ такая, что

$$\sup_{\Phi \in K} |\hat{f}(\Phi) - f(P_{\lambda, \lambda L_{1,T}} \Phi)| < \varepsilon/2. \quad (21)$$

Совмещая (20) и (21), получаем $\sup_{\Phi \in K} |\hat{f}(\Phi) - f(\Phi)| < \varepsilon$. $\square$

Эти две теоремы дают строгую характеристизацию аппроксимационной мощности CNN в двух режимах:

- **без пулинга:** $\overline{\mathcal{H}}_{\text{CNN}} = \{\text{непрерывные и сдвиг-эквивариантные } f: V \rightarrow U\};$
- **с субдескритизацией:** $\overline{\mathcal{H}}_{\text{CNN}} = \{\text{непрерывные функционалы } f: V \rightarrow \mathbb{R}\}.$

В первом случае симметрия действует как *жёсткое ограничение* на возможный предел, во втором — субдескритизация разрушает эквивариантность в пределе, и остаётся только топологическое условие непрерывности.

9.1.2 Стандартная модель Чжоу: пространство гипотез и универсальность

В статье Чжоу [31] рассматривается *чисто свёрточная* глубокая сеть без полносвязных матриц: все линейные преобразования имеют тёплицеву (Toeplitz) структуру, соответствующую одномерной свёртке (вектор $x \in \mathbb{R}^d$ интерпретируется как 1D-сигнал длины d).

Определение (Маска фильтра и матрица свёртки). Фиксируем длину фильтра $s \geq 2$. *Маска фильтра* (filter mask) — это последовательность $w = (w_k)_{k \in \mathbb{Z}}$, причём

$$w_k = 0 \quad \text{для всех } k \notin \{0, 1, \dots, s\}.$$

Для вектора $v = (v_1, \dots, v_D)^\top \in \mathbb{R}^D$ (с нулевым продолжением вне $\{1, \dots, D\}$) определим свёртку

$$(w * v)_i = \sum_{k=1}^D w_{i-k} v_k.$$

Этому соответствует *матрица свёртки* $T = T(w)$ тёплицева типа размера $(D + s) \times D$ с постоянными диагоналями, то есть $Tv = w * v$.

Определение (Глубокая CNN [31]). Пусть глубина равна J . Вводим ширины

$$d_0 = d, \quad d_j = d + js, \quad j = 1, \dots, J.$$

Пусть $T^{(j)} = T(w^{(j)})$ — тёплицева матрица свёртки размера $d_j \times d_{j-1}$, а $\sigma(u) = u_+ = \max\{u, 0\}$ — ReLU. Определим промежуточные представления (feature maps)

$$h^{(0)}(x) = x, \quad h^{(j)}(x) = \sigma(T^{(j)}h^{(j-1)}(x) - b^{(j)}), \quad j = 1, \dots, J,$$

где $b^{(j)} \in \mathbb{R}^{d_j}$ — векторы смещений.

Определение (Ограничение на смещения (bias pattern)). Для $j \leq J - 1$ в статье берётся специальная форма: компоненты $b_{s+1}^{(j)}, \dots, b_{d_j-s}^{(j)}$ равны одному и тому же числу (середица повторяется), а крайние $2s$ компонент могут быть произвольными. (Именно это позволяет «выключать»/«включать» нужные координаты в конструкциях.)

Определение (Гипотезное пространство). Выходом сети служит линейная комбинация компонент последнего слоя:

$$\mathcal{H}_{w,b}^J = \left\{ x \mapsto \sum_{k=1}^{d_J} c_k h_k^{(J)}(x) : c \in \mathbb{R}^{d_J} \right\}.$$

Это и есть класс функций, реализуемых *глубокой свёрточной сетью Чжоу* глубины J в [31].

Два ключевых факта обеспечивающих конструктивную выразительность класса $\mathcal{H}_{w,b}^J$:

1. произведение тёплицевых матриц снова является тёплицевой матрицей, отвечающей свёртке свёрток;
2. любую конечную маску можно разложить в свёрточное произведение коротких масок длины $s + 1$.

Лемма 9.3. Пусть $w^{(1)}, \dots, w^{(J)}$ — векторы с компонентами из $\{0, \dots, s\}$ и $T^{(j)} = T(w^{(j)})$. Тогда существует (конечная) последовательность W такая, что

$$T^{(J)}T^{(J-1)} \dots T^{(1)} = T(W),$$

и при этом $W = w^{(J)} * w^{(J-1)} * \dots * w^{(1)}$ (ассоциативно).

Доказательство. Для любого вектора v имеем $T(w)v = w * v$ по определению. Тогда

$$T^{(2)}T^{(1)}v = T(w^{(2)})(w^{(1)} * v) = w^{(2)} * (w^{(1)} * v) = (w^{(2)} * w^{(1)}) * v.$$

Индукцией по J получаем $T^{(J)} \dots T^{(1)}v = (w^{(J)} * \dots * w^{(1)}) * v$ для всех v , следовательно матрицы совпадают. $\square$

Теорема 9.3 (Свёрточная факторизация конечной маски, теорема С [31]). Пусть $s \geq 2$ и последовательность $W = (W_k)_{k \in \mathbb{Z}}$ из векторов с компонентами из $\{0, 1, \dots, M\}$. Тогда существуют $J < \frac{M}{s-1} + 1$ и маски $w^{(1)}, \dots, w^{(J)}$, каждая состоящая из элементов $\{0, \dots, s\}$, такие что

$$W = w^{(J)} * w^{(J-1)} * \dots * w^{(1)}.$$

Доказательство. Следуем доказательству из оригинальной статьи. Для конечной неотрицательной последовательности a введём символ

$$\widehat{a}(z) = \sum_{k \geq 0} a_k z^k,$$

это многочлен степени $\deg \widehat{a} = \max\{k : a_k \neq 0\}$. Для свёртки выполняется тождество символов:

$$\widehat{a * b}(z) = \widehat{a}(z) \widehat{b}(z),$$

поскольку коэффициенты произведения многочленов равны свёртке коэффициентов.

Пусть $\widehat{W}(z)$ — многочлен степени M с вещественными коэффициентами. Разложим его на линейные и квадратичные множители над $\mathbb{R}$. Комплексные корни идут попарно: если $z_k = x_k + iy_k$ корень, то и $\bar{z}_k = x_k - iy_k$ корень, и

$$(z - z_k)(z - \bar{z}_k) = z^2 - 2x_k z + (x_k^2 + y_k^2),$$

то есть вещественный квадратичный множитель. Поэтому существует факторизация вида

$$\widehat{W}(z) = W_M \prod_{k=1}^K (z^2 - 2x_k z + (x_k^2 + y_k^2)) \prod_{k=2K+1}^M (z - x_k),$$

где второе произведение отвечает вещественным корням (с учётом кратностями).

Теперь сгруппируем множители в блоки так, чтобы степень каждого блока была $\leq s$:

- берём до $\lfloor s/2 \rfloor$ квадратичных множителей (или $\lfloor (s-1)/2 \rfloor$ квадратичных + 1 линейный),
- либо берём до s линейных множителей,

пока не исчерпаем весь набор. Тогда получим разложение

$$\widehat{W}(z) = \widehat{w}^{(J)}(z) \dots \widehat{w}^{(2)}(z) \widehat{w}^{(1)}(z), \quad \deg \widehat{w}^{(j)} \leq s,$$

где каждый $\widehat{w}^{(j)}$ имеет вещественные коэффициенты. Переходя от многочленов к последовательностям коэффициентов, получаем $W = w^{(J)} * \dots * w^{(1)}$, а оценка на J следует из того, что каждый блок уменьшает суммарную степень минимум на $(s-1)$, кроме последнего блока. $\square$

Теорема 9.4 (Универсальность глубокой CNN, теорема A[31]). Пусть $2 \leq s \leq d$ и $\Omega \subset \mathbb{R}^d$ — компакт. Для любого $f \in C(\Omega)$ существуют глубины $J \rightarrow \infty$, наборы масок w , смещений b и функции $g_J \in \mathcal{H}_{w,b}^J$ такие, что

$$\|f - g_J\|_{C(\Omega)} \rightarrow 0 \quad \text{при } J \rightarrow \infty.$$

Доказательство. Доказательство оформим конструктивно, следуя плану Чжоу и стандартной аппроксимационной теории.

Шаг 1: редукция к полиномам. По теореме Стоуна–Вейерштрасса алгебра полиномов на $\mathbb{R}^d$ плотна в $C(\Omega)$. Значит, для любого $\varepsilon > 0$ существует полином p такой, что

$$\|f - p\|_{C(\Omega)} < \varepsilon/3.$$

Шаг 2: разложение полинома на ridge-термы. Нам достаточно доказать, что любой многочлен p можно представить как конечную сумму

$$p(x) = \sum_{q=1}^Q p_q(\langle \xi_q, x \rangle), \quad \xi_q \in \mathbb{R}^d,$$

где p_q — одномерные полиномы. Это следует из того, что пространство полиномов степени $\leq n$ конечномерно, а семейство функций $\{(\langle \xi, x \rangle)^k : \xi \in \mathbb{R}^d, 0 \leq k \leq n\}$ порождает его как линейную оболочку: действительно, для фиксированного n рассмотрим конечный набор направлений $\xi_1, \dots, \xi_R$, выбранный так, чтобы матрица значений мономов на наборе направлений имела полный ранг (например, берём достаточно много «общих» ξ_r ; тогда соответствующая вандермондова система невырождена). Тогда любой моном x^α степени $|\alpha| \leq n$ выражается как линейная комбинация степеней $(\langle \xi_r, x \rangle)^{|\alpha|}$, а значит и любой полином p выражается как сумма одномерных полиномов от $\langle \xi_r, x \rangle$.

Шаг 3: реализация ridge-термов сетью Чжоу. Зафиксируем один терм $p_q(\langle \xi_q, x \rangle)$. Сначала объясним, как получить линейную форму $\langle \xi_q, x \rangle$ внутри сети, затем как реализовать одномерный полином/его аппроксимацию через ReLU.

(3a) *Линейная форма как одна координата $T(W)x$.* Пусть нам нужно получить набор скаляров $\alpha_0 \cdot x, \alpha_1 \cdot x, \dots, \alpha_m \cdot x$ (в частности, можно взять $\alpha_0 = \xi_q$ и дополнительные α_k для построения ломаной аппроксимации). Сформируем конечную последовательность W длины $(m+1)d$ «склеивкой» коэффициентов так, чтобы некоторые строки матрицы $T(W)$ совпали с $\alpha_k^\top$. По теореме 9.3 найдётся факторизация $W = w^{(J)} * \dots * w^{(1)}$ с масками длины $s+1$ и глубиной $J = O(m)$. По лемме 9.3 получаем

$$T^{(J)} \dots T^{(1)} = T(W),$$

то есть произведение тёплитц-слоёв вычисляет нужные линейные формы как компоненты $T(W)x$.

(3b) *ReLU-шарниры и линейные сплайны.* Классический факт: любую непрерывную $u: [a, b] \rightarrow \mathbb{R}$ можно аппроксимировать линейным сплайном, а линейный сплайн представим через «шарниры» $(t - \tau)_+ = \sigma(t - \tau)$: если узлы $\tau_1 < \dots < \tau_m$, то

$$S(t) = \beta_0 + \beta_1 t + \sum_{k=1}^m \gamma_k (t - \tau_k)_+, \quad (\star)$$

где коэффициенты γ_k выражаются через конечные разности наклонов на соседних интервалах. Это так, потому что производная $S'(t)$ кусочно-постоянна и испытывает скачки γ_k в τ_k , а интегрирование даёт $(\star)$ (смотри например [32, Глава 5]).

Следовательно, чтобы реализовать/аппроксимировать $p_q(t)$ на множестве значений $t = \langle \xi_q, x \rangle$, достаточно реализовать множество функций $(t - \tau_k)_+$ и затем взять линейную комбинацию.

(3с) *Встраивание шарниров в $\mathcal{H}_{w,b}^J$* . После шага (3а) нужный скаляр $t = \langle \xi_q, x \rangle$ появляется как одна из координат некоторого $h^{(J-1)}(x)$ (либо прямо как координата $T(W)x$ до применения ReLU). Затем на последнем слое мы выбираем смещения $b^{(J)}$ так, чтобы отдельные координаты имели вид

$$h_\ell^{(J)}(x) = \sigma(t - \tau_k) = (t - \tau_k)_+$$

для нужных τ_k . После этого линейная комбинация с коэффициентами c_ℓ реализует $(\star)$.

Итак, для каждого ridge-терма можно построить $g_q \in \mathcal{H}_{w,b}^J$, аппроксимирующий $p_q(\langle \xi_q, x \rangle)$ с ошибкой $< \varepsilon/(3Q)$ на Ω . Суммируя по q (линейность выхода по c), получаем $g = \sum_{q=1}^Q g_q \in \mathcal{H}_{w,b}^J$ и

$$\|p - g\|_{C(\Omega)} < \varepsilon/3.$$

Вместе с шагом 1:

$$\|f - g\|_{C(\Omega)} \leq \|f - p\|_{C(\Omega)} + \|p - g\|_{C(\Omega)} < 2\varepsilon/3.$$

Уточняя точности на шагах 1 и 3 (заменой $\varepsilon/3$ на $\varepsilon/2$ и тому подобное), получаем требуемое $\|f - g\|_{C(\Omega)} < \varepsilon$. $\square$

Далее фиксируем $d = 1$, $\Omega = [0, 1]$, нас будет интересовать количественная оценка аппроксимации липшицевых функций.

Теорема 9.5. Пусть $d = 1$, $f \in C([0, 1])$ липшицева с полу-нормой $\|f\|_{\text{Lip}} = \sup_{x \neq y} \frac{|f(x) - f(y)|}{|x - y|}$. Тогда существует константа $c > 0$, не зависящая от f и J , такая что

$$\inf_{g \in \mathcal{H}_{w,b}^J} \|f - g\|_\infty \leq c \|f\|_{\text{Lip}} J^{-1/2}.$$

Доказательство. Шаг 1: линейный сплайн на равномерной сетке. Для $m \in \mathbb{N}$ рассмотрим узлы $x_k = k/m$, $k = 0, \dots, m$, и линейный интерполянт $S_m f$ по этим узлам. Для любого $x \in [x_k, x_{k+1}]$ по липшицевости

$$|f(x) - S_m f(x)| \leq \frac{\|f\|_{\text{Lip}}}{2m},$$

откуда

$$\|f - S_m f\|_\infty \leq \frac{\|f\|_{\text{Lip}}}{2m}. \quad (22)$$

Шаг 2: представление сплайна через шарниры ReLU. Из общей формулы $(\star)$ следует: существует представление

$$S_m f(x) = \beta_0 + \beta_1 x + \sum_{k=1}^{m-1} \gamma_k (x - x_k)_+, \quad (23)$$

где $x_k = k/m$, а коэффициенты γ_k выражаются через скачки наклонов $S_m f$ в узлах.

Шаг 3: реализация (23) в классе Чжоу при глубине $J \gtrsim m^2$. Поясним конструктивно, почему при фиксированной длине фильтра $s + 1$ можно реализовать семейство шарниров $(x - x_k)_+$ для $k = 1, \dots, m - 1$ внутри $\mathcal{H}_{w,b}^J$, если J достаточно велик.

В 1D вход x является скаляром. С помощью тёпллиц-слоёв можно «размножить» информацию об x по разным координатам и затем, используя разные смещения в последнем слое, получить набор функций

$$x \mapsto (x - x_k)_+, \quad k = 1, \dots, m - 1.$$

Технически это реализуется так же, как в явной конструкции для получения координат $(\alpha_k \cdot x - t_k)_+$: линейная стадия создаёт нужные аффинные формы, а последний ReLU + смещение превращает их в шарниры. Ограничение на смещение не мешает, поскольку «особые» компоненты допускаются на краях, а середину можно держать константной (используя повторяющийся параметр).

Почему возникает масштаб $J \gtrsim m^2$? Интуитивно: чтобы получить m разных «переломов» на фиксированном фильтре, нужно достаточно много итераций локального пространства/кодирования. Следовательно, при $J \geq Cm^2$ существует $g \in \mathcal{H}_{w,b}^J$ такой, что $g(x) = S_m f(x)$ (или $\|g - S_m f\|_\infty$ поглощается константой).

Шаг 4: выбор $m \asymp \sqrt{J}$ и итог. Положим $m = \lfloor c_0 \sqrt{J} \rfloor$ так, чтобы $J \geq Cm^2$. Тогда из (22) и равенства/приближения $g \approx S_m f$ получаем

$$\|f - g\|_\infty \leq \|f - S_m f\|_\infty + \|S_m f - g\|_\infty \leq \frac{\|f\|_{\text{Lip}}}{2m} + o(1) \leq c \|f\|_{\text{Lip}} J^{-1/2}.$$

□

Замечание. В оригинальной статье основной количественный результат формулируется для более гладких классов (Соболевские пространства) и даёт более быстрые скорости на 1D при дополнительной регулярности. Теорема служит иллюстрацией подхода *кусочно-линейная аппроксимация + ReLU-шарниры + тёпллиц-структура*.

9.1.3 Подход Ли-Лин-Шеня: универсальность полносвязных свёрточных сетей для сдвиг-инвариантных функций

Контекст. В предыдущих фрагментах мы видели, что *симметричные ограничения* (например, сдвиг-эквивариантность) радикально меняют ответ на вопрос об универсальной аппроксимации. В этой части рассматривается *сдвиг-инвариантная* постановка на конечной периодической решётке (дискретный тор) и даётся *точный* критерий, когда полносвязные свёрточные сети (FCNN) с *фиксированным* числом каналов и *маленьким* ядром (размер 2) обладают свойством УА.

Зафиксируем размерность $d \in \mathbb{N}$ и вектор размеров $n = (n_1, \dots, n_d)$. Рассмотрим пространство сигналов

$$X := \mathbb{R}^{n_1 \times \dots \times n_d} \cong \mathbb{R}^{|n|}, \quad |n| := \prod_{s=1}^d n_s.$$

Индексы будем понимать по модулю n_s (периодические граничные условия).

Для $k = (k_1, \dots, k_d)$, где $k_s \in \{0, 1, \dots, n_s - 1\}$, определим *оператор сдвига* $T_k: X \rightarrow X$:

$$[T_k x]_i := x_{i-k} \quad (\text{вычитание по модулю } n).$$

Действие $k \mapsto T_k$ образует (конечную) группу сдвигов.

В данном контексте уточним ранее введённые понятия.

- Функция $F: X \rightarrow \mathbb{R}$ называется *сдвиг-инвариантной*, если

$$F(T_k x) = F(x) \quad \forall x \in X, \quad \forall k.$$

- Отображение $\Phi: X \rightarrow X$ называется *сдвиг-эквивариантным*, если

$$\Phi(T_k x) = T_k \Phi(x) \quad \forall x \in X, \forall k.$$

Для $w, x \in X$ (ядро w и сигнал x) *свёртка* $w * x \in X$ определяется стандартно (индексы периодические):

$$[w * x]_i := \sum_j w_j x_{i-j}.$$

Из определения следует коммутирование со сдвигом:

$$T_k(w * x) = (T_k w) * x = w * (T_k x).$$

Это и есть формальная причина, почему свёрточные слои при *разделении весов* естественно порождают сдвиг-эквивариантные/инвариантные модели.

Обсудим подробнее архитектуру FCCN. Далее $\sigma: \mathbb{R} \rightarrow \mathbb{R}$ — нелинейность (в части про неостаточные сети будет важна $\sigma = \text{ReLU}$).

Определение (Носитель тензора [33]). Определим *носитель* тензора $x \in X$ как минимальный d -вектор $\text{supp}(x) = (j_1, \dots, j_d)$, такой что если для мультииндекса $i = (i_1, \dots, i_d)$ выполнено $i_s > j_s$ хотя бы для одного s , то $[x]_i = 0$. Пишем $\text{supp}(x) \leq \ell$ (покомпонентно), если $j_s \leq \ell_s$ для всех s .

Интерпретация: ядро с $\ell = (2, \dots, 2)$ использует ближайших соседей «в одном шаге» по каждой координате.

Пусть $r \in \mathbb{N}$ — число каналов признаков. Для фиксированного ограничения ℓ на носитель ядра зададим класс функций

$$\mathcal{F}_{r,\ell} := \left\{ x \mapsto \sum_{i=1}^r v_i \sigma(w_i * x + b_i \mathbf{1}) : w_i \in X, \text{supp}(w_i) \leq \ell, v_i, b_i \in \mathbb{R} \right\}. \quad (24)$$

Здесь $\mathbf{1} \in X$ — тензор из единиц (смещение одинаково по всем координатам), а коэффициенты v_i «смешивают» каналы.

Пусть $g: X \rightarrow \mathbb{R}$ — *липицева* и *инвариантная относительно перестановок координат* функция: значение $g(x)$ не меняется при любой перестановке компонент x . Например, сумма $g(x) = \sum_i [x]_i$ или максимум $g(x) = \max_i [x]_i$ (*глобальный пулинг*).

Определим множества

$$\text{CNN}_{r,\ell} := \{g \circ f_m \circ \dots \circ f_1 : f_1, \dots, f_m \in \mathcal{F}_{r,\ell}, m \geq 1\}, \quad (25)$$

$$\text{resCNN}_{r,\ell} := \{g \circ (\text{id} + f_m) \circ \dots \circ (\text{id} + f_1) : f_1, \dots, f_m \in \mathcal{F}_{r,\ell}, m \geq 1\}. \quad (26)$$

По построению любые элементы $\text{CNN}_{r,\ell}$ и $\text{resCNN}_{r,\ell}$ являются сдвиг-инвариантными функциями $X \rightarrow \mathbb{R}$ (периодичность и разделение весов сохраняют симметрию на каждом слое).

Определение. Функциональное семейство $\mathcal{H} \subset \{X \rightarrow \mathbb{R}\}$ обладает *сдвиг-инвариантной универсальной аппроксимацией в L^p* , если:

1. каждая $H \in \mathcal{H}$ сдвиг-инвариантна;
2. для любой сдвиг-инвариантной непрерывной (или L^p -) функции $F: X \rightarrow \mathbb{R}$, любого компакта $K \subset X$, любого $\varepsilon > 0$ и $p \in [1, \infty)$ существует $H \in \mathcal{H}$, такое что $\|F - H\|_{L^p(K)} \leq \varepsilon$.

Теорема 9.6. *Имеют место утверждения [33]:*

1. (Достаточность:) *Остаточное гипотезное пространство $\text{resCNN}_{r,\ell}$ обладает сдвиг-инвариантной УА при $r \geq 1$ и $\ell \geq 2$ (покомпонентно). Пространство $\text{CNN}_{r,\ell}$ обладает сдвиг-инвариантной УА при $r \geq 2$ и $\ell \geq 2$.*
2. (Оптимальность размера ядра:) *Если $\min_s \ell_s = 1$, то ни $\text{resCNN}_{\infty,\ell} + \mathbb{R}^3$, ни $\text{CNN}_{\infty,\ell} + \mathbb{R}$ не обладают сдвиг-инвариантной УА.*
3. (Оптимальность числа каналов:) *Семейство $\text{CNN}_{1,\infty} + \mathbb{R}$ не обладает сдвиг-инвариантной УА.*

Доказательство. Шаг 1: из сдвиг-эквивариантной получить сдвиг-инвариантную УА. Сначала временно уберём финальный пулинг и рассмотрим отображения $X \rightarrow X$ (пиксельный выход), то есть эквивариантную версию. Определим

$$\text{eqCNN}_{r,\ell} := \{f_m \circ \dots \circ f_1 : f_i \in \mathcal{F}_{r,\ell}\}, \quad \text{eqresCNN}_{r,\ell} := \{(\text{id} + f_m) \circ \dots \circ (\text{id} + f_1)\}$$

и соответствующее понятие *сдвиг-эквивариантной УА* (аппроксимация эквивариантных отображений $X \rightarrow X$ в $L^p(K)$).

Предложение 9.1 (Связь инвариантной и эквивариантной УА через пулинг). *Пусть $g: X \rightarrow \mathbb{R}$ — липшицева, инвариантна относительно перестановок координат и $g(X) = \mathbb{R}$. Если семейство отображений $\mathcal{A} \subset \{X \rightarrow X\}$ обладает сдвиг-эквивариантной УА, то семейство функций*

$$\mathcal{B} := \{g \circ \varphi : \varphi \in \mathcal{A}\} \subset \{X \rightarrow \mathbb{R}\}$$

обладает сдвиг-инвариантной УА.

Доказательство утверждения. Пусть $F: X \rightarrow \mathbb{R}$ — сдвиг-инвариантная L^p -функция, $K \subset X$ — компакт. Можно считать (расширив компакт при необходимости), что $K = [-a, a]^n$.

Определим подмножество

$$K_1 := \{x \in K : [x]_1 > [x]_i \ \forall i \neq 1\}.$$

Тогда (с точностью до множества меры нуль) $K = \bigcup_k T_k K_1$ и эти множества дизъюнкты.

Положим $\varepsilon' := \varepsilon / (|n|(1 + \text{Lip}(g)))$. По универсальности для *несимметричного* случая ([33, Теорема 3.8] используется в статье как внешний инструмент), существует (не обязательно эквивариантное) $u: X \rightarrow X$ такое, что

$$\|F - g \circ u\|_{L^p(K)} \leq \varepsilon'. \quad (27)$$

Далее сделаем u эквивариантной.

Так как $u \in L^p$, найдётся компакт $O \subset K_1$ с $\|u\|_{L^p(K_1 \setminus O)} \leq \varepsilon'$. Возьмём гладкую финитную функцию χ со значениями в $[0, 1]$, такую что $\chi|_O = 1$ и $\chi|_{K_1^c} = 0$. Положим $\tilde{u} := \chi u$.

Для $x \in T_k K_1$ определим

$$f(x) := T_k(\tilde{u}(T_{-k}x)),$$

а на дополнении $\bigcup_k T_k K_1$ положим $f(x) := 0$. Поскольку χ зануляется на границе K_1 , f непрерывно, и прямой проверкой получаем её сдвиг-эквивариантность.

³Примечание: как и в алгебре это множество всевозможных сумм

Оценим ошибку. Так как F и $g \circ f$ сдвиг-инвариантны, достаточно оценивать на K_1 :

$$\|F - g \circ f\|_{L^p(K)} = |n| \|F - g \circ f\|_{L^p(K_1)}. \quad (28)$$

На K_1 имеем $f|_{K_1} = \tilde{u}$, а значит

$$\|u - f\|_{L^p(K_1)} = \|u - \tilde{u}\|_{L^p(K_1)} \leq \|u\|_{L^p(K_1 \setminus O)} \leq \varepsilon'.$$

Липшицевость g даёт $\|g \circ u - g \circ f\|_{L^p(K_1)} \leq \text{Lip}(g)\varepsilon'$, и вместе с (27)–(28) получаем

$$\|F - g \circ f\|_{L^p(K)} \leq (1 + \text{Lip}(g))|n|\varepsilon' = \varepsilon.$$

Осталось применить эквивариантную УА для семейства $\mathcal{A}$ к эквивариантному f : существует $\varphi \in \mathcal{A}$, $\|f - \varphi\|_{L^p(K)} \leq \varepsilon/\text{Lip}(g)$, и тогда $\|F - g \circ \varphi\|_{L^p(K)} \leq \varepsilon$. $\square$

Шаг 2: динамическая интерпретация ResNet и аппроксимация потоков остаточными блоками. Ключевая идея: композицию остатков $(\text{id} + f_m) \circ \dots \circ (\text{id} + f_1)$ удобно понимать как (грубую) дискретизацию потока ОДУ, а значит удобно ввести непрерывно-временной «идеальный» класс аппроксиматоров.

Пусть $f: X \rightarrow X$ липшицево. Для $T \in \mathbb{R}$ определим *поток* $\phi(f, T): X \rightarrow X$ как

$$\phi(f, T)(x) = z(T), \quad \dot{z}(t) = f(z(t)), \quad z(0) = x.$$

Стандартные результаты теории ОДУ дают, что $\phi(f, T)$ липшицево (и даже билипшицево, с обратным $\phi(-f, T)$). Определим

$$\text{eqCODE}_{r,\ell} := \{\phi(f_m, t_m) \circ \dots \circ \phi(f_1, t_1) : f_i \in \mathcal{F}_{r,\ell}, t_i \in \mathbb{R}, m \geq 1\}, \quad (29)$$

$$\text{CODE}_{r,\ell} := \{g \circ \Phi : \Phi \in \text{eqCODE}_{r,\ell}\}. \quad (30)$$

Предложение 9.2. Пусть $f: X \rightarrow X$ липшицево с константой L и $K \subset X$ — компакт. Тогда для любого $T \in \mathbb{R}$ и любого $\varepsilon > 0$ существует $N \in \mathbb{N}$ такое, что

$$\sup_{x \in K} \left\| \phi(f, T)(x) - \left(\text{id} + \frac{T}{N} f \right)^N(x) \right\| \leq \varepsilon,$$

где $\circ N$ — N -кратная композиция. В частности, если $f \in \mathcal{F}_{r,\ell}$, то поток $\phi(f, T)$ равномерно на K аппроксимируется элементами $\text{eqresCNN}_{r,\ell}$.

Доказательство утверждения. Это стандартная оценка сходимости явной схемы Эйлера для ОДУ на конечном горизонте времени. Пусть $h := T/N$ (для $T < 0$ рассуждение то же, так как можно заменить $f \mapsto -f$ и $T \mapsto -T$). Рассмотрим истинную траекторию $z(t)$ и дискретную x_k :

$$x_{k+1} = x_k + hf(x_k), \quad x_0 = x, \quad t_k := kh.$$

По формуле Тейлора с интегральным остатком для ОДУ получаем локальную ошибку порядка h^2 :

$$z(t_{k+1}) = z(t_k) + hf(z(t_k)) + \int_{t_k}^{t_{k+1}} (f(z(s)) - f(z(t_k))) ds.$$

Обозначим $e_k := z(t_k) - x_k$. Тогда

$$e_{k+1} = e_k + h(f(z(t_k)) - f(x_k)) + r_k, \quad r_k := \int_{t_k}^{t_{k+1}} (f(z(s)) - f(z(t_k))) ds.$$

Липшицевость даёт $\|f(z(t_k)) - f(x_k)\| \leq L\|e_k\|$. Далее, так как z липшицева по времени на $[0, T]$ (оценка через $\sup \|f\|$ на компактной трубке вокруг траекторий), получаем $\|r_k\| \leq Ch^2$ для некоторой константы C (зависящей от K, f, T). Тогда

$$\|e_{k+1}\| \leq (1 + Lh)\|e_k\| + Ch^2.$$

Итерацией и дискретным неравенством Гронуолла:

$$\|e_N\| \leq Ch^2 \sum_{j=0}^{N-1} (1 + Lh)^j = Ch^2 \frac{(1 + Lh)^N - 1}{(1 + Lh) - 1} \leq \frac{C}{L} h (e^{LT} - 1).$$

Правая часть $\rightarrow 0$ при $h \rightarrow 0$, то есть при $N \rightarrow \infty$. Причём все оценки можно сделать равномерными по $x \in K$ (за счёт компактности K и непрерывности f). Отсюда следует требуемое равномерное приближение потока композицией $(\text{id} + hf)$.

Если $f \in \mathcal{F}_{r,\ell}$, то отображение $x \mapsto x + hf(x)$ — это ровно один остаточный блок $(\text{id} + f_h)$ с $f_h := hf \in \mathcal{F}_{r,\ell}$, а значит N -кратная композиция лежит в $\text{eqresCNN}_{r,\ell}$. $\square$

Дальнейший решающий факт заключается в том, что при минимальных параметрах $(r, \ell) = (1, 2)$ динамический класс уже универсален:

Теорема 9.7. *Динамическое гипотезное пространство $\text{eqCODE}_{1,2}$ обладает сдвиг-эквивариантной УА, а значит $\text{CODE}_{1,2}$ обладает сдвиг-инвариантной УА.*

Её доказательство опирается на «перестановку области» (domain rearrangement) через композиции потоков с маленьким ядром и на схему «coordinate zooming + point matching».

Шаг 3: завершение доказательства пункта (1) теоремы.

(а) *Остаточный случай.* По Теореме 9.7 класс $\text{eqCODE}_{1,2}$ эквивариантно-универсален. По предложению 9.2 каждый поток $\phi(f, t)$ аппроксимируется композициями остаточных блоков, то есть $\text{eqresCNN}_{1,2}$ наследует сдвиг-эквивариантную УА (аппроксимация каждой $\phi(f_i, t_i)$ и устойчивость относительно композиции на компактах). Далее по предложению 9.1 получаем сдвиг-инвариантную УА для $\text{resCNN}_{1,2}$. Для общих $r \geq 1, \ell \geq 2$ имеем включение $\text{resCNN}_{1,2} \subset \text{resCNN}_{r,\ell}$, значит УА сохраняется.

(б) *Неостаточный случай.* Любой остаток $x \mapsto x + f(x)$ можно реализовать неостаточной композицией, если разрешить больше каналов, например $r = 3$ (используется тождество $\text{ReLU}(x) + (-1)\text{ReLU}(-x) = x$). Это даёт УА для $\text{eqCNN}_{3,2}$.

Важный дальнейший шаг — «доводка» до $r = 2$:

Лемма 9.4 (Локальная симуляция остаточных сетей неостаточными при $r = 2$). *Для любого $G \in \text{eqresCNN}_{1,2}$ и компакта $K \subset X$ существует $H \in \text{eqCNN}_{2,2}$, такое что $H(x) = G(x)$ для всех $x \in K$.*

Из неё следует: раз $\text{eqresCNN}_{1,2}$ эквивариантно-универсально, то и $\text{eqCNN}_{2,2}$ эквивариантно-универсально, а затем по предложению 9.1 $\text{CNN}_{2,2}$ становится инвариантно-универсальным. Включение $\text{CNN}_{2,2} \subset \text{CNN}_{r,\ell}$ для $r \geq 2, \ell \geq 2$ завершает доказательство теоремы.

Доказательство Леммы 9.4. Пусть

$$G = f_M \circ \dots \circ f_1, \quad f_i(x) = x + v^i \sigma(w^i * x + b^i \mathbf{1}),$$

где $\sigma = \text{ReLU}$ и $\text{supp}(w^i) \leq 2$. Положим $\gamma_i := f_i \circ \dots \circ f_1$ и $\gamma_0 := \text{id}$. Каждое γ_i липшицево, а K компактен, поэтому найдётся $R > 0$ такое, что $\|\gamma_i(x)\|_\infty \leq R$ для всех $x \in K$ и $i = 0, \dots, M$.

Определим последовательность неостаточных слоёв (каждый является элементом $\mathcal{F}_{2,2}$):

$$u_0(x) := \sigma(x + R\mathbf{1}), \quad (31)$$

$$u_i(x) := \sigma(x) + v^i \sigma\left(w^i * x + (b^i - (\sum_k [w^i]_k)R)\mathbf{1}\right), \quad i = 1, \dots, M. \quad (32)$$

Рассмотрим композиции $\eta_s := u_s \circ \dots \circ u_0$. Тогда $\eta_s \in \text{eqCNN}_{2,2}$.

Покажем по индукции, что

$$\eta_i(x) = \gamma_i(x) + R\mathbf{1} \quad \forall x \in K, \quad i = 0, \dots, M. \quad (33)$$

База $i = 0$ следует из (31), так как $x + R\mathbf{1} \geq 0$ на K и σ на неотрицательных аргументах тождественна. Шаг: пусть (33) верно для i . Тогда для $x \in K$

$$\eta_{i+1}(x) = u_{i+1}(\eta_i(x)) = \sigma(\gamma_i(x) + R\mathbf{1}) + v^{i+1} \sigma\left(w^{i+1} * (\gamma_i(x) + R\mathbf{1}) + (b^{i+1} - (\sum_k [w^{i+1}]_k)R)\mathbf{1}\right).$$

Так как $\gamma_i(x) + R\mathbf{1} \geq 0$, имеем $\sigma(\gamma_i(x) + R\mathbf{1}) = \gamma_i(x) + R\mathbf{1}$. Кроме того, $w^{i+1} * (R\mathbf{1}) = (\sum_k [w^{i+1}]_k)R\mathbf{1}$. Следовательно,

$$\eta_{i+1}(x) = \gamma_i(x) + R\mathbf{1} + v^{i+1} \sigma(w^{i+1} * \gamma_i(x) + b^{i+1}\mathbf{1}) = \gamma_{i+1}(x) + R\mathbf{1}.$$

Индукция завершена.

Наконец, положим $u_{M+1}(x) := \sigma(x) - \sigma(R\mathbf{1})$ и определим

$$H(x) := u_{M+1}(\eta_M(x)).$$

Тогда для $x \in K$ из (33) получаем $H(x) = \sigma(\gamma_M(x) + R\mathbf{1}) - \sigma(R\mathbf{1}) = \gamma_M(x) = G(x)$, так как $\gamma_M(x) + R\mathbf{1} \geq 0$. Построение даёт $H \in \text{eqCNN}_{2,2}$ и требуемое равенство на K . $\square$

Доказательство пункта (2): оптимальность размера ядра. Пусть $\min_s \ell_s = 1$ и, не теряя общности, $\ell_1 = 1$. Тогда легко видеть, что любые сети из $\text{CNN}_{r,\ell} + \mathbb{R}$, $\text{resCNN}_{r,\ell} + \mathbb{R}$ (и даже $\text{CODE}_{r,\ell} + \mathbb{R}$) лежат в вспомогательном классе $\mathcal{H} + \mathbb{R}$, где $\mathcal{H}$ состоит из функций вида

$$H(x) = g(\varphi(x)), \quad [\varphi(x)]_I = \psi(x_I) \quad \text{для некоторой } \psi : X_1 \rightarrow X_1,$$

то есть каждая «строка» x_I (фиксируем первый индекс I) обрабатывается одинаково и независимо, а затем результаты агрегируются глобальным пулингом.

Покажем, что $\mathcal{H} + \mathbb{R}$ не обладает УА. Положим $K = [0, 1]^n$. Определим функцию

$$F(x) := \prod_{i_1 > i_2} \left(\psi([x]_{i_1:}) - \psi([x]_{i_2:}) \right), \quad \psi(y) := \prod_{i'} [y]_{i'}.$$

Заметим: F сдвиг-инвариантна (все строки участвуют симметрично, а перемножение по парам инвариантно к циклической перестановке строк).

Рассмотрим подмножества:

$$K_1 := \{x \in K : x_1 \succ x_2 \succ \dots \succ x_{n_1}\}, \quad K_2 := \{x \in K : x_2 \succ x_1 \succ x_3 \succ \dots \succ x_{n_1}\},$$

где $z_1 \succ z_2$ означает $\min_i [z_1]_i \geq \max_i [z_2]_i$. Определим преобразование τ , меняющее местами первую и вторую строки:

$$[\tau(x)]_2 = [x]_1, \quad [\tau(x)]_1 = [x]_2, \quad [\tau(x)]_i = [x]_i \quad (i \neq 1, 2).$$

Тогда $\tau(K_1) = K_2$, а τ сохраняет меру. По определению $\mathcal{H}$ имеем $(H \circ \tau)(x) = H(x)$ для $x \in K_1$. С другой стороны, из построения F следует $F \circ \tau = -F$ (перестановка двух строк меняет знак произведения по парам). Следовательно,

$$2\|F\|_{L^p(K_1)} = \|F - (F \circ \tau)\|_{L^p(K_1)} \leq \|H - (H \circ \tau)\|_{L^p(K_1)} + \|F - H\|_{L^p(K)} + \|F \circ \tau - H \circ \tau\|_{L^p(K)}.$$

Первое слагаемое равно нулю, а последние два равны (так как τ сохраняет меру), поэтому

$$2\|F\|_{L^p(K_1)} \leq 2\|F - H\|_{L^p(K)} \Rightarrow \|F - H\|_{L^p(K)} \geq \|F\|_{L^p(K_1)} =: \varepsilon_0 > 0.$$

Значит F нельзя произвольно точно приблизить элементами $\mathcal{H} + \mathbb{R}$, УА отсутствует. Так как рассматриваемые сети содержатся в $\mathcal{H} + \mathbb{R}$, они тоже не обладают УА.

Доказательство пункта (3): почему одного канала недостаточно (неостаточный случай). Рассмотрим $G \in \text{CNN}_{1,\infty} + \mathbb{R}$. Тогда G — непрерывная кусочно-линейная функция на $X \cong \mathbb{R}^{|n|}$, и прямой расчёт даёт:

Наблюдение. Существует вектор $g \in X$, такой что для почти всех x (по мере Лебега) градиент $\nabla G(x)$ равен либо 0, либо g .

Из наблюдения следует: для фиксированного направления $\xi \in \partial B(0, 1)$ функция одной переменной

$$\gamma(t) := G(t\xi)$$

почти всюду имеет производную $\gamma'(t) \in \{0, \xi \cdot g\}$. На полусфере $\{\xi : \xi \cdot g < 0\}$ получаем, что $\gamma'(t) \leq 0$ почти всюду, то есть $\gamma(t)$ не возрастает.

Теперь берём целевую функцию $F(x) = \|x\|$ и компакт $B(0, 1)$. По замене переменных в полярных координатах (в $\mathbb{R}^{|n|}$):

$$\int_{x \in B(0,1)} |F(x) - G(x)|^p dx = \int_{\xi \in \partial B(0,1)} \int_0^1 |F(t\xi) - G(t\xi)|^p t^{|n|-1} dt dS(\xi). \quad (34)$$

На полусфере $\{\xi : \xi \cdot g < 0\}$ имеем $f(t) := F(t\xi) = t$ (строго возрастает), а $g(t) := G(t\xi)$ (не возрастает). Снизу оценим вклад каждого такого луча через следующую лемму.

Лемма 9.5. *Для возрастающей $f: [a, b] \rightarrow \mathbb{R}$ верно*

$$\inf_{g \searrow [a,b]} \int_a^b |f - g|^p = \inf_{c \in \mathbb{R}} \int_a^b |f - c|^p.$$

Доказательство леммы. □

Неравенство “ $\leq$ ” очевидно. Для “ $\geq$ ” возьмём произвольную невозрастающую g . Положим $\tilde{g}(t) := g(t_0)$, где t_0 — точка пересечения $f(t_0) = g(t_0)$, если она существует, иначе $\tilde{g}(t) := \{g(b) \text{ при } f(a) < g(a), g(a) \text{ при } f(a) > g(a)\}$. Тогда для всех t легко проверить $|f(t) - g(t)| \geq |f(t) - \tilde{g}(t)|$ (геометрически: невозрастающая кривая лежит по одну сторону от возрастающей), откуда и следует требуемое.

Вернёмся к оценке. Для $\xi \cdot g < 0$ применяем Лемму 9.5 на отрезке $[1/2, 1]$ и получаем:

$$\int_0^1 |t - G(t\xi)|^p t^{|n|-1} dt \geq \int_{1/2}^1 |t - G(t\xi)|^p dt \cdot \left(\frac{1}{2}\right)^{|n|-1} \geq \left(\frac{1}{2}\right)^{|n|-1} \inf_{a \in [1/2, 1]} \int_{1/2}^1 |t - a|^p dt.$$

Последний инфимум вычисляется явно:

$$\inf_{a \in [1/2, 1]} \int_{1/2}^1 |t - a|^p dt = \inf_{a \in [1/2, 1]} \frac{(1-a)^{p+1} + (a-1/2)^{p+1}}{p+1} = \frac{2 \cdot (1/4)^{p+1}}{p+1}$$

(достигается при $a=3/4$)

Обозначая

$$C_p := 2^{-|n|+1} \cdot \frac{2 \cdot (1/4)^{p+1}}{p+1} > 0,$$

получаем, что для всех ξ с $\xi \cdot g < 0$ верно $\int_0^1 |t - G(t\xi)|^p t^{|n|-1} dt \geq C_p$. Интегрируя по полусфере в (34), получаем нижнюю оценку на L^p -ошибку:

$$\int_{B(0,1)} |F(x) - G(x)|^p dx \geq C_p \cdot \frac{\alpha}{2},$$

где α — мера Лебега поверхности $\partial B(0,1)$. Следовательно, $F(x) = \|x\|$ нельзя приблизить сколь угодно точно функциями из $\text{CNN}_{1,\infty} + \mathbb{R}$ на $B(0,1)$, и УА отсутствует. $\square$

9.2 Глубокие распределённые свёрточные сети

В стандартном классе глубоких CNN (DCNN) по Чжоу [31] вектор смещения *структурирован*. Это ключевое ограничение, которое впоследствии будет ослаблено.

Определение (Структурированный вектор смещения в $\mathcal{H}_J^{\text{CNN}}$ [31]). Пусть $2 \leq s \leq d$ и $d_j = d + js$. Для слоёв $j = 1, \dots, J-1$ вектор смещения $b^{(j)} \in \mathbb{R}^{d_j}$ ограничен шаблоном “свободные границы – разделяемая внутренность” (*boundary-free / interior-shared*):

$$b^{(j)} = \left(b_1^{(j)}, \dots, b_s^{(j)}, \underbrace{b_{s+1}^{(j)}, \dots, b_{s+1}^{(j)}}_{d_j - 2s \text{ (общая часть)}}, b_{d_j-s+1}^{(j)}, \dots, b_{d_j}^{(j)} \right)^T.$$

Интерпретация: За исключением эффектов, возникающих из-за дополнения границ (*padding*), порог активации ReLU является *разделяемым* (*shared*) для всех пространственных позиций внутри слоя. Один и тот же скаляр $b_{s+1}^{(j)}$ используется в качестве смещения для множества нейронов. Такая структура резко ограничивает число свободных параметров смещения до $(s+1)$ на слой, но и ограничивает выразительную способность сети.

Следующим логическим шагом в работе Чжоу [34] является ослабление этих ограничений на смещение.

Ключевая мысль: В слое со свёрточными весами (имеющими структуру матрицы Тёплица/ленточной матрицы) сеть высоко структурирована. Основной “рычаг”, который позволяет нарушить жёсткую структуру трансляционной симметрии и создать множество различных порогов активации (“узлов” — *knots*) в различных пространственных позициях, — это *шаблон смещений*.

Таким образом, переход от DCNN к DDCNN заключается в замене *структурированного вектора* смещений на *распределённую матрицу* смещений, где каждый вход связи может иметь свой собственный порог, зависящий от позиции.

В формулировке DDCNN по Чжоу [34] “смещение” на уровне j становится не вектором, а *ленточной матрицей* (*band matrix*), что соответствует *позиционно-зависимым порогам*.

Определение (Смещение как ленточная матрица в DDCNN [34]). На уровне j смещение задаётся матрицей

$$b^{(j-1)} = \left(b_{k,i}^{(j-1)} \right) \in \mathbb{R}^{d_{j-1} \times d_j},$$

где $b_{k,i}^{(j-1)} = 0$ вне локального окна $\max\{1, i-s\} \leq k \leq \min\{d_{j-1}, i\}$.

Каждая выходная координата i использует свой собственный локальный столбец смещений $(b^{(j-1)})_{\cdot, i}$:

$$\phi_i^{(j)}(x) = \sum_{k=\max\{1, i-s\}}^{\min\{d_{j-1}, i\}} w_{i-k}^{(j)} \sigma \left(\phi_k^{(j-1)}(x) - b_{k,i}^{(j-1)} \right), \quad 1 \leq i \leq d_j.$$

Связь с DCNN как частным случаем. Если каждая строка матрицы $b^{(j-1)}$ постоянна вдоль своей ненулевой полосы, т.е. $b_{k,i}^{(j-1)} = b_k^{(j-1)}$ не зависит от i , то все столбцы $(b^{(j-1)})_{\cdot, i}$ совпадают на активных индексах. Это немедленно даёт обычное правило обновления DCNN с единым вектором смещений $b^{(j-1)} \in \mathbb{R}^{d_{j-1}}$. Таким образом, DCNN — это специальный случай DDCNN, а отказ от ограничения на постоянство строк даёт распределённые (позиционно-зависимые) пороги при сохранении того же самого разделения свёрточных весов.

Определение (Пространство гипотез DDCNN [34]). Фиксируем входную размерность $d \in \mathbb{N}$ и длину фильтра $s + 1$, где $2 \leq s \leq d$. Ширины слоёв определяются как $d_0 = d$, $d_j = d + js$ для $j = 1, \dots, J$. Глубокая распределённая CNN (DDCNN) строится из следующих компонентов:

- **Разделяемые локальные маски (фильтры):** $w^{(j)} = (w_0^{(j)}, \dots, w_s^{(j)}) \in \mathbb{R}^{s+1}$ (одна и та же маска повторно используется на всех пространственных позициях).
- **Распределённые (позиционно-/ребро-зависимые) смещения:** $b^{(j-1)} = (b_{k,i}^{(j-1)}) \in \mathbb{R}^{d_{j-1} \times d_j}$ для $j = 2, \dots, J$ (и финальный вектор смещений $b^{(J)} \in \mathbb{R}^{d_J}$).
- **Функция активации ReLU:** $\sigma(t) = t_+ = \max\{t, 0\}$.

Скрытые признаки $\{\phi_i^{(j)}(x)\}$ генерируются локальной рекурсией:

$$\begin{aligned} \phi_i^{(1)}(x) &= \sum_{k=1}^d w_{i-k}^{(1)} x_k, \\ \phi_i^{(j)}(x) &= \sum_{k=\max\{1, i-s\}}^{\min\{d_{j-1}, i\}} w_{i-k}^{(j)} \sigma \left(\phi_k^{(j-1)}(x) - b_{k,i}^{(j-1)} \right), \end{aligned}$$

для $j = 2, \dots, J$ и $i = 1, \dots, d_j$ (где $w_\ell^{(j)} = 0$ вне множества $\{0, \dots, s\}$). Выходной слой является линейной комбинацией сдвинутых ReLU:

$$f(x) = \sum_{k=1}^{d_J} c_k \sigma \left(\phi_k^{(J)}(x) - b_k^{(J)} \right), \quad c \in \mathbb{R}^{d_J}.$$

Полученное пространство гипотез обозначается $\mathcal{H}_J^{\mathbf{w}, \mathbf{b}}$.

Теорема 9.8 (Универсальность DDCNN, теорема 1 [34]). Для любого компакта $\Omega \subset \mathbb{R}^d$ и любой функции $f \in C(\Omega)$,

$$\forall \varepsilon > 0 \exists J \in \mathbb{N} \exists (\mathbf{w}, \mathbf{b}) \exists g \in \mathcal{H}_J^{\mathbf{w}, \mathbf{b}} \quad \text{такие, что} \quad \|f - g\|_{C(\Omega)} < \varepsilon.$$

Эквивалентно, объединение пространств гипотез DDCNN плотно в $C(\Omega)$ при $J \rightarrow \infty$.

Интерпретация (что важно запомнить):

- **Отсутствие промежуточного полносвязного перемешивания:** только локальные свёртки + ReLU, затем финальный линейный выходной слой (“readout”).
- **“Главный регулятор” — глубина:** ширины слоёв ограничены ($d_j = d + js$ растёт только линейно).
- **Откуда берётся универсальность?** Из композиции локальных свёрток плюс возможность размещать множество независимых порогов ReLU через распределённые смещения.

Стандартная стратегия доказательства теорем об универсальной аппроксимации включает два шага:

1. Используя классическую **теорему Стоуна-Вейерштрасса**, приблизить целевую непрерывную функцию $f \in C(\Omega)$ многочленом P :

$$\sup_{x \in \Omega} |f(x) - P(x)| \leq \varepsilon/2.$$

2. Показать, что DDCNN могут равномерно приблизить P на Ω с точностью $\varepsilon/2$.

Таким образом, техническим ядром доказательства становится вопрос: **“Может ли DDCNN аппроксимировать многомерные полиномы?”** Положительный ответ на этот вопрос, основанный на конструировании кусочно-линейных сплайнов с использованием распределённых смещений, и завершает доказательство теоремы 9.8.

Для доказательства теоремы 9.8 необходимо показать, как DDCNN может аппроксимировать произвольный многомерный полином. Это достигается в три основных этапа, опирающихся на следующие ключевые леммы из статьи [34].

Лемма 9.6 (Разложение полинома на одномерные [34]). Пусть $d, \Gamma \in \mathbb{N}$. Существует множество векторов $\{\xi_k\}_{k=1}^{n_\Gamma} \subset \mathbb{R}^d$ с $\|\xi_k\|_2 = 1$, где $n_\Gamma = \binom{d-1+\Gamma}{\Gamma}$, такое что любой полином $P_\Gamma \in \mathcal{P}_\Gamma(\mathbb{R}^d)$ степени не выше Γ можно представить в виде

$$P_\Gamma(x) = \sum_{k=1}^{n_\Gamma} p_{k,\Gamma}(\xi_k \cdot x), \quad x \in \mathbb{R}^d,$$

где каждое $p_{k,\Gamma} \in \mathcal{P}_\Gamma(\mathbb{R})$ является одномерным полиномом.

Лемма 9.7 (Аппроксимация сплайнами [34]). Пусть $t = \{t_1 < t_2 < \dots < t_{N-1} < t_N\}$ — последовательность узлов. Определим линейный оператор L_t на $C[t_2, t_{N-1}]$:

$$L_t(f)(u) = \sum_{j=2}^{N-1} f(t_j) \delta_j(u), \quad u \in [t_2, t_{N-1}],$$

где

$$\delta_j(u) = \frac{1}{t_j - t_{j-1}} \sigma(u - t_{j-1}) - \frac{t_{j+1} - t_{j-1}}{(t_{j+1} - t_j)(t_j - t_{j-1})} \sigma(u - t_j) + \frac{1}{t_{j+1} - t_j} \sigma(u - t_{j+1}).$$

Тогда для любой $f \in C[t_2, t_{N-1}]$ справедлива оценка

$$\|L_t(f) - f\|_{C[t_2, t_{N-1}]} \leq 2\omega(f, \Delta_t),$$

где $\Delta_t = \max_{j=3, \dots, N-1} \{t_j - t_{j-1}\}$, а $\omega(f, \mu)$ — модуль непрерывности функции f .

Лемма 9.8 (Факторизация фильтров [34]). Пусть $s \geq 2$ и $W : \mathbb{Z} \rightarrow \mathbb{R}$ — маска фильтра с носителем на $\{0, 1, \dots, S_W\}$, причём $W_0 > 0$ и $W_{S_W} \neq 0$, где $S_W \geq d \geq s$. Тогда существует целое число $I \in [\frac{S_W}{s}, \frac{S_W}{s-1} + 2)$ и последовательность масок фильтров $\{w^{(j)}\}_{j=1}^I$ с носителем на $\{0, 1, \dots, s\}$, где $w_0^{(1)} = W_0 > 0$ и $w_0^{(j)} = 1$ для $j = 2, \dots, I$, таких что выполняется свёрточная факторизация:

$$W = w^{(I)} * w^{(I-1)} * \dots * w^{(2)} * w^{(1)}.$$

Доказательство. Пусть $\epsilon > 0$. Тогда существует полином $P_\Gamma \in \mathcal{P}_\Gamma(\mathbb{R}^d)$ с некоторым $\Gamma \in \mathbb{N}$ такой, что

$$\|f - P_\Gamma\|_{C(\Omega)} \leq \frac{\epsilon}{2}.$$

По лемме 9.6 (разложение полинома на одномерные) существует множество векторов $\{\xi_k\}_{k=1}^{n_\Gamma} \subset \mathbb{R}^d$ такое, что $\|\xi_k\|_2 = 1$ для каждого k и полином $P_\Gamma \in \mathcal{P}_\Gamma(\mathbb{R}^d)$ может быть выражен в виде

$$P_\Gamma(x) = \sum_{k=1}^{n_\Gamma} p_{k,\Gamma}(\xi_k \cdot x), \quad x \in \mathbb{R}^d,$$

где $\{p_{k,\Gamma}\}_{k=1}^{n_\Gamma} \subset \mathcal{P}_\Gamma(\mathbb{R})$ являются одномерными полиномами.

Заметим, что $|\xi_k \cdot x| \leq \|\xi_k\|_2 \|x\|_2 \leq \|x\|_2$ для каждого $k \in \{1, \dots, n_\Gamma\}$. Следовательно, для $x \in \Omega$ имеем $|\xi_k \cdot x| \leq B_2^{(0)}$, где

$$B_2^{(0)} := \max_{x \in \Omega} \|x\|_2 < \infty.$$

Таким образом, мы рассматриваем аппроксимацию одномерных функций $\{p_{k,\Gamma}\}$ на отрезке $[-B_2^{(0)}, B_2^{(0)}]$. Для $4 \leq N \in \mathbb{N}$ возьмем последовательность узлов $t = \{t_1 < t_2 < \dots < t_{N-1} < t_N\}$ как

$$t_j = -B_2^{(0)} + (j-2) \frac{2B_2^{(0)}}{N-3}, \quad j = 1, 2, \dots, N-1, N,$$

что влечет $[t_2, t_{N-1}] = [-B_2^{(0)}, B_2^{(0)}]$ и $\Delta_t = \frac{2B_2^{(0)}}{N-3}$.

По лемме 9.7 (аппроксимация сплайнами) существует линейный оператор L_t такой, что

$$\|L_t(p_{k,\Gamma}) - p_{k,\Gamma}\|_{C[-B_2^{(0)}, B_2^{(0)}]} \leq 2\omega\left(p_{k,\Gamma}, \frac{2B_2^{(0)}}{N-3}\right),$$

где $\omega(f, \mu)$ — модуль непрерывности функции f .

Поскольку $\lim_{\mu \rightarrow 0+} \omega(g, \mu) = 0$ для любой $g \in C[-B_2^{(0)}, B_2^{(0)}]$, мы знаем, что существует некоторое $\mu_\epsilon > 0$ такое, что $\omega(p_{k,\Gamma}, \mu) \leq \frac{\epsilon}{4n_\Gamma}$ для любого $0 < \mu \leq \mu_\epsilon$ и $k = 1, \dots, n_\Gamma$. Возьмем некоторое $N \in \mathbb{N}$ такое, что $\frac{2B_2^{(0)}}{N-3} \leq \mu_\epsilon$ и $N \geq 4$. Тогда мы имеем

$$\left\| \sum_{k=1}^{n_\Gamma} L_t(p_{k,\Gamma})(\xi_k \cdot x) - P_\Gamma \right\|_{C(\Omega)} \leq \sum_{k=1}^{n_\Gamma} \|L_t(p_{k,\Gamma})(u) - p_{k,\Gamma}(u)\|_{C[-B_2^{(0)}, B_2^{(0)}]} \leq \frac{\epsilon}{2}.$$

Теперь обратимся к построению маски фильтра W . Выразим каждый вектор ξ_k через его компоненты

$$\xi_k = ((\xi_k)_\ell)_{\ell=1}^d \in \mathbb{R}^d, \quad k = 1, \dots, n_\Gamma.$$

Определим маску фильтра $W : \mathbb{Z} \rightarrow \mathbb{R}$ с носителем на $\{0, 1, \dots, dn_\Gamma + 1\}$, положив $W_0 = W_{dn_\Gamma+1} = 1$ и

$$W_{(k-1)d+\ell} = (\xi_k)_{d+1-\ell}, \quad \ell = 1, \dots, d, \quad k = 1, \dots, n_\Gamma.$$

Затем мы применяем лемму 9.8 (факторизация фильтров) к маске фильтра $W : \mathbb{Z} \rightarrow \mathbb{R}$ с $S_W = dn_\Gamma + 1$. Существует целое число $I \in [\frac{dn_\Gamma+1}{s}, \frac{dn_\Gamma+1}{s-1} + 2)$ и последовательность масок фильтров $\{w^{(j)}\}_{j=1}^I$ с носителем на $\{0, 1, \dots, s\}$, имеющая $w_0^{(1)} = W_0 = 1$ и $w_0^{(j)} = 1$ для $j = 2, \dots, I$, таких что выполняется свёрточная факторизация:

$$W = w^{(I)} * w^{(I-1)} * \dots * w^{(2)} * w^{(1)}.$$

Комбинируя это с построением инициализирующих слоёв DDCNN (раздел 3 статьи), мы получаем, что после I слоёв компонента с индексом $kd + 1$ гомогенизированного представления равна

$$\hat{\phi}_{kd+1}^{(I)}(x) = \xi_k \cdot x, \quad k = 1, \dots, n_\Gamma.$$

Используя построение глубоких слоёв DDCNN (раздел 4 статьи) с дополнительными $N - 1$ группами по I слоёв (всего $J = NI$ слоёв) и специальным выбором масок $\{w^{(j)}\}_{j=I+1}^{NI}$ и матриц смещений, мы получаем, что в последнем слое $\Phi^{(J)}(x)$ содержатся функции вида

$$\sigma\left(\hat{\phi}_{d+\ell}^{(I)}(x) - t_i\right), \quad \ell = 1, \dots, Js, \quad i = 1, \dots, N.$$

В частности, взяв $\ell = (k - 1)d + 1$ для $k = 1, \dots, n_\Gamma$, мы получаем, что

$$\sigma(\xi_k \cdot x - t_i) \in \text{span}\left\{\Phi_i^{(J)}(x)\right\}_{i=d+1}^{d+Js} \subseteq \mathcal{H}_J^{\mathbf{w}, \mathbf{b}}.$$

Но определение линейного оператора L_t (лемма 9.7) говорит нам, что

$$L_t(p_{k,\Gamma})(\xi_k \cdot x) \in \text{span}\{\sigma(\xi_k \cdot x - t_i), i = 1, \dots, N\}$$

для каждого $k \in \{1, \dots, n_\Gamma\}$. Следовательно,

$$\sum_{k=1}^{n_\Gamma} L_t(p_{k,\Gamma})(\xi_k \cdot x) \in \text{span}\{\sigma(\xi_k \cdot x - t_i), k = 1, \dots, n_\Gamma, i = 1, \dots, N\} \subseteq \mathcal{H}_J^{\mathbf{w}, \mathbf{b}}.$$

Таким образом, взяв $f^* = \sum_{k=1}^{n_\Gamma} L_t(p_{k,\Gamma})(\xi_k \cdot x) \in \mathcal{H}_J^{\mathbf{w}, \mathbf{b}}$, мы получаем

$$\|f - f^*\|_{C(\Omega)} \leq \|f - P_\Gamma\|_{C(\Omega)} + \|P_\Gamma - f^*\|_{C(\Omega)} \leq \frac{\epsilon}{2} + \frac{\epsilon}{2} = \epsilon.$$

Это доказывает, что для любого $\epsilon > 0$ существует глубина $J = NI$ и параметры $(\mathbf{w}, \mathbf{b})$ такие, что $\mathcal{H}_J^{\mathbf{w}, \mathbf{b}}$ содержит функцию f^* , аппроксимирующую f с точностью ϵ , что и утверждает теорема 9.8. $\square$

Ключевые моменты доказательства:

1. Аппроксимация непрерывной функции полиномом (теорема Стоуна–Вейерштрасса).
2. Разложение многомерного полинома на сумму одномерных полиномов от скалярных произведений $\xi_k \cdot x$ (лемма 9.6).

3. Аппроксимация одномерных полиномов кусочно-линейными сплайнами $L_t(p_{k,\Gamma})$, построенными из сдвигов ReLU $\sigma(u - t_i)$ (лемма 9.7).
4. Кодирование направлений ξ_k в маску фильтра W и её факторизация на короткие фильтры $w^{(j)}$ длины $s + 1$ (лемма 9.8).
5. Использование инициализирующих слоёв DDCNN для генерации линейных функций $\xi_k \cdot x$.
6. Использование глубоких слоёв DDCNN с распределёнными смещениями для независимого размещения порогов t_i и генерации функций $\sigma(\xi_k \cdot x - t_i)$.
7. Линейная комбинация этих функций даёт сплайн $L_t(p_{k,\Gamma})(\xi_k \cdot x)$, который принадлежит $\mathcal{H}_J^{\mathbf{w},\mathbf{b}}$.

Далее проясним, какая интуитивная идея, стоит за переходом от стандартных DCNN к распределённым DDCNN. Мы рассмотрим, как механизм распределённых (позиционно-зависимых) смещений позволяет преодолеть фундаментальные ограничения классической свёртки и создавать сложные функции аппроксимации.

Чистая свёрточная операция (без смещений) обладает свойством *разделения весов* (*weight sharing*): один и тот же локальный линейный функционал применяется в каждой позиции. Это создаёт сильные структурные ограничения. В стандартном DCNN с разделяемыми смещениями (*shared bias*) ситуация несколько улучшается, но остаётся фундаментальная проблема:

- **Разделяемые смещения:** $b_{k,i}^{(j-1)} \equiv \beta_k^{(j-1)}$ (нет зависимости от целевой позиции i)
- **Следствие:** функция активации $\sigma\left(\phi_k^{(j-1)}(x) - b_{k,i}^{(j-1)}\right)$ использует один и тот же порог везде, где повторно используется $\phi_k^{(j-1)}$.
- **Проблема:** точки излома (*breakpoints*) и паттерны активации глобально выровнены по позициям (с точностью до сдвигов), что ограничивает то, насколько мелко мы можем “размещать узлы” при фиксированных локальных масках.

Ключевой вопрос: можем ли мы выбирать различные положения “узлов” ReLU (порогов) в разных позициях i ? В DDCNN ослабляется ограничение на разделение смещений:

- **Распределённые смещения:** $b_{k,i}^{(j-1)}$ свободны (в пределах локальной полосы $i - s \leq k \leq i$)
- **Следствие:** каждое соединение, ведущее в позицию i , может иметь свой собственный порог:

$$\phi_i^{(j)}(x) = \sum_{k=\max\{1, i-s\}}^{\min\{d_{j-1}, i\}} w_{i-k}^{(j)} \sigma\left(\phi_k^{(j-1)}(x) - b_{k,i}^{(j-1)}\right).$$

Что это даёт: мы можем активировать/подавлять один и тот же разделяемый признак $\phi_k^{(j-1)}$ по-разному в разных пространственных позициях i . Это именно то, что нужно для построения множества локализованных паттернов “узлов” и (с помощью глубины) сборки богатого базиса кусочно-линейных функций.

Интерпретация (1D случай): Рассмотрим $b_{k,i}^{(j-1)}$ как *расписание порогов, зависящее от позиции*. Даже если маска $w^{(j)}$ разделяемая, сеть может решать, где (в какой позиции i) ReLU “включается”. Глубина затем собирает эти локально управляемые отклики в произвольную непрерывную целевую функцию.

Замечание. DDCNN = разделяемые локальные фильтры $w^{(j)}$ **какой признак** + распределённые пороги $b^{(j)}$ **где он активируется**.

Интерпретация:

- **Разделяемые фильтры ($w^{(j)}$):** определяют, *какие локальные признаки* извлекаются (например, границы, текстуры).
- **Распределённые смещения ($b^{(j)}$):** определяют, *в каких пространственных позициях* эти признаки становятся релевантными (активируются).
- **Глубина:** позволяет комбинировать эти локально-управляемые активации для создания всё более сложных и глобальных зависимостей.

ReLU-сети естественным образом подходят для *кусочно-линейных* конструкций. Это используется в доказательстве универсальности Чжоу. **Ключевым примитивом** является представление/аппроксимация функций вида

$$x \mapsto (x - t)_+, \quad \text{где } (x)_+ := \max\{x, 0\}.$$

Из этих элементарных “строительных блоков” можно конструировать:

- **Тент-функции / шляпки** (*tent functions / hat functions*)
- **Линейные сплайны** (*linear splines*)
- **В-сплайноподобные базисы** (через линейные комбинации и композиции)
- **Аппроксимации полиномов** с использованием сплайн-базисов

Замечание. В конструкции Чжоу *свёрточная структура* эффективно представляет сдвинутые копии, в то время как *распределённые смещения* задают узлы (*knots*).

Замечание:

Как одномерная свёрточная архитектура может выражать многомерные зависимости? В доказательствах аппроксимации CNN используются две распространённые математические техники:

- **Кодирование индексами:** рассматривать входной вектор $x \in \mathbb{R}^d$ как “последовательность”; свёртка агрегирует локальные группы, а глубина увеличивает область взаимодействия (рост рецептивного поля).
- **Композиционные строительные блоки:** полиномы могут быть выражены через композиции сложений и умножений, которые могут быть аппроксимированы кусочно-линейными сетями.

Вывод: глубина J создаёт постепенно более глобальные взаимодействия, в то время как фильтры остаются маленькими.

9.3 Распределённые свёрточные сети и операторное обучение

Теперь установим мост между теорией универсальной аппроксимации глубоких свёрточных сетей и практической задачей обучения операторов. Мы рассмотрим, когда свёрточная архитектура является подходящим индуктивным смещением для операторного обучения, и сравним её с альтернативными подходами.

С точки зрения обучения операторов мы изучаем **оператор** (отображение между функциональными пространствами):

$$G: X \rightarrow Y, \quad X = C(D; \mathbb{R}^{d_{\text{in}}}) \text{ или } L^2(D; \mathbb{R}^{d_{\text{in}}}), \quad Y = C(U; \mathbb{R}^{d_{\text{out}}}) \text{ или } L^2(U; \mathbb{R}^{d_{\text{out}}}),$$

по парам $\{(u^{(n)}, G(u^{(n)}))\}_{n=1}^N$.

В DeepONet (лекции 4–6) гипотеза представлялась как $N = R \circ A \circ E$:

- **Энкодер / сенсоры** $E: X \rightarrow \mathbb{R}^m$ (или $\mathbb{R}^{md_{\text{in}}}$):

$$E(u) = (u(x_1), \dots, u(x_m)) \quad (\text{точечные сенсоры})$$

или

$$E(u) = (\text{Patch}_r(u; y_1), \dots) \quad (\text{локальные патчи}).$$

- **Конечномерный аппроксиматор** $A: \mathbb{R}^m \rightarrow \mathbb{R}^p$ (“ветвистая сеть”):

$$A(E(u)) = \alpha \in \mathbb{R}^p.$$

- **Реконструктор** $R: \mathbb{R}^p \rightarrow Y$ (“стволовая сеть / базис”):

$$(R(\alpha))(y) = \sum_{k=1}^p \alpha_k \tau_k(y),$$

где τ_k — выученные/параметрические базисные функции (часто через стволовую сеть).

Встаёт вопрос, когда E и/или A должны быть **свёрточными**, а не полносвязными? Рассмотрим оператор сдвига: $(R_\gamma u)(x) = u(x - \gamma)$. Оператор G называется *эквивариантным относительно сдвига*, если

$$G(R_\gamma u) = R_\gamma G(u).$$

Если целевой оператор приближённо соблюдает такие симметрии и является локальным, то *разделение весов свёртки* может быть правильным индуктивным смещением.

Свёрточные / локальные архитектуры, как правило, помогают, когда оператор $G: X \rightarrow Y$ (приближённо) соответствует следующим структурным свойствам:

1. **Эквивариантность относительно сдвига (поля $\rightarrow$ поля):**

$$G(R_\gamma u) \approx R_\gamma G(u) \quad \text{для сдвигов } (R_\gamma u)(x) = u(x - \gamma).$$

Типично для однородных операторов решения УЧП на периодической области / больших внутренних областях.

2. **Инвариантность относительно сдвига (поля $\rightarrow$ скаляры/статистики):** существует функционал $\Phi : X \rightarrow \mathbb{R}$ с $\Phi(R_\gamma u) = \Phi(u)$ (например, глобальные сводки, энергии, метки классов после глобального пулинга).
3. **Локальная зависимость (конечное рецептивное поле):** существует $r > 0$ такое, что, грубо говоря,

$$u|_{B_r(y)} = v|_{B_r(y)} \implies (G(u))(y) \approx (G(v))(y),$$

то есть выход в позиции y зависит в основном от входа вблизи y .

4. **Стационарность / разделение весов по пространству:** одно и то же “локальное правило” применяется во многих позициях (один и тот же ядр везде).
5. **Мультимасштабная структура:** релевантные паттерны проявляются от мелкого к крупному масштабу; субдискретизация/пулинг строит иерархии.

Примерами G могут выступать операторы УЧП с постоянными коэффициентами на сетках; преобразование изображений (шумоподавление, сегментация); локальное пространственно-временное прогнозирование; замыкания турбулентности с локальными шаблонами.

Свёртка может быть ограничением, когда нарушается одно (или более) из следующих условий:

1. **Отсутствие естественной группы сдвигов:** нерегулярные области (графы / многообразия / облака точек) или сильно варьирующаяся плотность дискретизации.
2. **Сильная нестационарность / неоднородность:** коэффициенты или статистики меняются с позицией (например, УЧП с переменными коэффициентами), поэтому глобальное разделение весов является неверной спецификацией без позиционных признаков/эмбедингов.
3. **Глобальная (дальнодействующая) связь доминирует:** интегральные операторы с широкими ядрами, зависимости типа внимания (*attention*), или эллиптические УЧП, где эффекты функции Грина индуцируют нелокальность.
4. **Граничные эффекты существенны:** симметрия сдвигов нарушается вблизи границ; выбор дополнения (*padding*) имеет значение; оператор зависит от граничных условий.
5. **Разреженные сенсоры, а не плотные сетки:** если доступно лишь несколько измерений, глобальный базис (DeepONet/FMLP) может быть более эффективным по данным.

Альтернативы / дополнения: DeepONet/FMLP с выученными глобальными базами; фурье/спектральные операторные модели (в стиле FNO); внимание/трансформеры для дальнодействующей связи; графовые нейронные операторы для нерегулярных областей.

Сравним концепты DeepONet и свёрточных операторных моделей **Вывод:** выбирайте класс гипотез в соответствии с симметриями оператора. Можно также *совмещать* их: использовать CNN внутри E или A , сохраняя при этом стиль DeepONet для R . Более подробно:

Аспект	DeepONet / FMLP	Свёрточная операторная модель
Обработка входа	Сенсоры, сэмплы $E(u) = (u(x_i))_{i=1}^m$	Сетка, патчи + свёрточный экстрактор признаков
Механизм смешивания	Глобальное смешивание в ветвистой сети $A: \mathbb{R}^m \rightarrow \mathbb{R}^p$	Локальное смешивание через ядра (разделение весов), глубина строит большое рецептивное поле
Обработка выхода	Ствол/базис $R(\alpha)(y) = \sum_{k=1}^p \alpha_k \tau_k(y)$	Свёрточный декодер, апсемплинг, покоординатная голова (часто эквивариантная)
Встроенное смещение	Глобальный низкоразмерный базис; отсутствие эквивариантности сдвигов, если не сконструирована явно	Локальность + (приближённая) эквивариантность сдвигов + разделение параметров
Лучше всего, когда	Гладкая глобальная структура; разреженные сенсоры; обучение, не зависящее от геометрии	Локальные, стационарные, мультимасштабные поля; плотные сетки; шаблоны УЧП, операторы типа изображений
Основной риск	Неверная спецификация базиса; может игнорировать локальную физику без индуктивной структуры	Пропуск глобальных взаимодействий, граничных эффектов, нестационарности без дополнительных механизмов

Таблица 1: Концептуальное сравнение DeepONet/FMLP и свёрточных операторных моделей

• **Энкодер E (как вы представляете входную функцию):**

- Сенсоры: $E(u) = (u(x_i))_{i=1}^m$ (классический DeepONet),
- Патчи / локальные окна: $E(u) = (\text{Patch}_r(u; y_i))_{i=1}^m$ (удобно для CNN),
- CNN-энкодер на сетке для получения поля признаков (эквивариантное представление).

• **Аппроксиматор A (конечное отображение):**

- MLP (глобальное смешивание) vs CNN/ResNet (локальное смешивание + глубина),
- опционально: добавить дальнodelствующее смешивание (фурье-слой / внимание), если физика нелокальна.

• **Реконструктор R (как вы производите выход):**

- Глобальный базис (ствол): $R(\alpha)(y) = \sum_{k=1}^p \alpha_k \pi_k(y)$,
- Свёрточный декодер: стиль U-Net апсемплинг / покоординатная голова (локальные выходы).

Замечание (Правило проектирования). Обучение операторов не обязывает использовать полносвязные компоненты: выбирайте $E/A/R$ в соответствии с симметриями оператора (эквивариантность/инвариантность) и локальностью. Гибридные модели позволяют

сохранить глобальную выразительность, одновременно навязывая локальную структуру там, где это важно.

9.4 Основы RKHS: ядра как скалярные произведения (минимальный инструментарий)

В данном разделе вводится математический аппарат воспроизводящих гильбертовых пространств (RKHS) — ключевой теоретический инструмент, позволяющий связать ядерные методы с анализом свойств свёрточных нейронных сетей. Мы определим положительно определённые ядра, сформулируем фундаментальную теорему Мура-Аронсайна и объясним свойство воспроизведения — основу для анализа устойчивости и обобщения.

Определение (Положительно определённое ядро). Функция $K: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ называется *положительно определённой*, если для любого конечного набора точек $\{x_1, \dots, x_n\} \subset \mathcal{X}$ и любых коэффициентов $c = (c_1, \dots, c_n) \in \mathbb{R}^n$ выполняется неравенство:

$$\sum_{i,j=1}^n c_i c_j K(x_i, x_j) \geq 0.$$

Эквивалентно, матрица Грама $\mathbf{K} := [K(x_i, x_j)]_{i,j=1}^n$ является положительно полуопределённой: $\mathbf{K} \succeq 0$.

Интуиция: Положительная определённость ядра гарантирует, что его можно интерпретировать как *скалярное произведение* в некотором (возможно, бесконечномерном) гильбертовом пространстве, даже если это произведение вычисляется в исходном пространстве $\mathcal{X}$ неявно.

Теорема 9.9 (Мура-Аронсайна). Для любого положительно определённого ядра K на множестве $\mathcal{X}$ существует единственное гильбертово пространство функций $\mathcal{H}_K \subset \mathbb{R}^{\mathcal{X}}$, называемое воспроизводящим гильбертовым пространством (RKHS), такое что:

1. Для любого $x \in \mathcal{X}$ функция $K_x := K(x, \cdot)$ принадлежит $\mathcal{H}_K$.
2. Для любой функции $f \in \mathcal{H}_K$ и любой точки $x \in \mathcal{X}$ выполняется свойство воспроизведения (reproducing property):

$$f(x) = \langle f, K_x \rangle_{\mathcal{H}_K}.$$

3. Линейная оболочка функций $\{K_x : x \in \mathcal{X}\}$ плотна в $\mathcal{H}_K$.

Пространство $\mathcal{H}_K$ часто называют пространством признаков, а отображение $\Phi: \mathcal{X} \rightarrow \mathcal{H}_K$, заданное как $\Phi(x) = K_x$, — отображением в признаковое пространство (feature map). При этом ядро выражается через скалярное произведение: $K(x, x') = \langle \Phi(x), \Phi(x') \rangle_{\mathcal{H}_K}$.

Эта теорема является краеугольным камнем ядерных методов, поскольку гарантирует, что любое положительно определённое ядро корректно задаёт гильбертово пространство функций с удобным свойством воспроизведения.

Свойство воспроизведения $f(x) = \langle f, K_x \rangle_{\mathcal{H}_K}$ имеет два фундаментальных следствия:

- **Непрерывность функционала вычисления:** Для любого $x \in \mathcal{X}$ функционал вычисления $\delta_x : f \mapsto f(x)$ является линейным и *непрерывным* на $\mathcal{H}_K$, так как $|\delta_x(f)| = |f(x)| \leq \|f\|_{\mathcal{H}_K} \|K_x\|_{\mathcal{H}_K}$.

- **Ядерная машина (Kernel Machine):** Любая функция из $\mathcal{H}_K$ может быть представлена как линейный функционал в признаковом пространстве: $f(x) = \langle w, \Phi(x) \rangle_{\mathcal{H}_K}$ для некоторого $w \in \mathcal{H}_K$. Это позволяет строить *линейные модели в $\mathcal{H}_K$* , которые соответствуют сложным нелинейным решающим правилам в исходном пространстве $\mathcal{X}$.

Аппарат RKHS предоставляет единую основу для решения задач обучения и анализа моделей.

1. **Норма как мера сложности (регуляризация).** Стандартная задача обучения в RKHS формулируется как минимизация функционала риска с регуляризацией:

$$\min_{f \in \mathcal{H}_K} \frac{1}{n} \sum_{i=1}^n \ell(y_i, f(x_i)) + \lambda \|f\|_{\mathcal{H}_K}^2,$$

где $\|f\|_{\mathcal{H}_K}$ служит естественной мерой сложности (*smoothness*) функции. **Теорема представления** гарантирует, что решение такой задачи лежит в конечномерной линейной оболочке ядер, центрированных на данных: $f(\cdot) = \sum_{i=1}^n \alpha_i K(x_i, \cdot)$ [35].

2. **Устойчивость “проходит через” признаковое отображение.** Используя неравенство Коши-Буняковского и свойство воспроизведения, можно получить оценку устойчивости предсказаний:

$$|f(x) - f(x')| = |\langle f, \Phi(x) - \Phi(x') \rangle_{\mathcal{H}_K}| \leq \|f\|_{\mathcal{H}_K} \|\Phi(x) - \Phi(x')\|_{\mathcal{H}_K}.$$

Таким образом, если само *признаковое отображение* Φ устойчиво (например, к малым деформациям или сдвигам) и норма $\|f\|_{\mathcal{H}_K}$ контролируется, то и предсказания модели будут устойчивыми.

Мост к конструкции Бьетти–Майраль [35]: Если спроектировать ядро K (и, соответственно, признаковое отображение Φ) так, чтобы оно кодировало свёрточную структуру и желаемые симметрии, то анализ инвариантности, устойчивости и обобщающей способности соответствующей модели можно проводить, используя геометрию RKHS.

9.5 Подход Бьетти–Майраль: ядерное представление свёрточных архитектур

Дальше излагается ключевая идея работы Бьетти и Майраля [35]: представление глубокой свёрточной сети (CNN) как многоуровневого признакового отображения в воспроизводящее гильбертово пространство (RKHS). Этот формализм позволяет строго анализировать такие свойства CNN, как инвариантность, устойчивость и сложность, используя аппарат теории ядер.

Бьетти и Майраль предлагают строить представление Φ_n рекуррентно, имитируя слои CNN, что порождает соответствующее ядро глубины n [35].

Определение (Многоуровневое признаковое отображение и ядро). Пусть $x_0 := x$ — входной сигнал. Для каждого уровня $k = 1, \dots, n$ определяем:

$$x_k := A_k M_k P_k x_{k-1},$$

где

- P_k — оператор *извлечения локальных патчей* (аналог свёрточного фильтра).
- M_k — *нелинейное отображение / нормализация* на уровне патча, индуцированное некоторым *ядром скалярного произведения* (dot-product kernel) в пространстве признаков $\mathcal{H}_k$.
- A_k — *линейный оператор усреднения (пулинга)* (например, локальное усреднение или субдискретизация).

Глубинное признаковое отображение определяется как $\Phi_n(x) := x_n$. Соответствующее *глубинное ядро* задаётся скалярным произведением в финальном пространстве признаков:

$$K_n(x, x') := \langle \Phi_n(x), \Phi_n(x') \rangle_{\mathcal{H}_n} = \langle x_n, x'_n \rangle_{\mathcal{H}_n}.$$

Это ядро порождает RKHS $\mathcal{H}_{K_n}$.

Интуитивно каждый шаг $P_k \mapsto M_k \mapsto A_k$ соответствует слою CNN: линейная свёртка (P_k), нелинейная функция активации (M_k), операция пулинга (A_k). Однако в ядерной постановке нелинейность M_k трактуется как отображение в (возможно, бесконечномерное) RKHS, связанное с ядром на патчах.

В теоретической конструкции Бьетти-Майралья [35] пространство признаков для каждого патча является RKHS (возможно, бесконечномерным). Конечноканальная свёрточная сеть (CNN) или свёрточная ядерная сеть (CKN) рассматривается как *приближение или проекция* этого бесконечномерного признакового отображения на конечное число направлений.

Это делает *геометрию представления явной и доступной для анализа*: свойства всего представления Φ_n выводятся из свойств элементарных операторов P_k, M_k, A_k и геометрии RKHS.

Важный результат [35] заключается в том, что построенное RKHS $\mathcal{H}_{K_n}$ содержит в себе функции, реализуемые многими классическими CNN.

Определение (CNN как функция в постановке Бьетти-Майралья). Рассмотрим сигнал $z_0 = x \in L^2(\mathbb{R}^d, \mathbb{R}^{p_0})$. Многоуровневое представление строится как:

$$z_k = A_k \tilde{z}_k, \quad \tilde{z}_k(u) = \varphi_k(P_k z_{k-1}(u)), \quad k = 1, \dots, n,$$

где

- P_k извлекает локальный патч вокруг позиции u ,
- φ_k — *нелинейность на патче*, индуцированная ядром скалярного произведения,
- A_k — линейный оператор пулинга/усреднения.

Предиктор определяется линейным выходным слоем: $f_\sigma(x) = \langle w_{n+1}, z_n \rangle$.

Ключевое предположение: Нелинейность φ_k может быть записана в *однородной форме*. Для патча z :

$$\varphi_k(z) = \|z\| \sigma \left(\frac{\langle g, z \rangle}{\|z\|} \right),$$

где σ — *гладкая положительно однородная функция активации* (например, сглаженный вариант ReLU), удовлетворяющая условию $\sigma(\alpha t) = \alpha \sigma(t)$ для $\alpha \geq 0$.

Теорема 9.10 (Вложение CNN в RKHS [35]). *При выполнении условий согласованности между разложением ядра скалярного произведения и функцией σ , CNN-предиктор f_σ принадлежит RKHS $\mathcal{H}_{K_n}$, порождённый глубинным ядром K_n .*

Вывод: Это означает, что для широкого класса CNN с гладкими однородными активациями можно применять весь аналитический аппарат RKHS (оценки устойчивости, теоремы об обобщении, основанные на норме) для их анализа.

Ядерная точка зрения Бьетти–Майраль позволяет получить *априорные, не зависящие от данных* гарантии для представления [35]:

1. **Гарантии инвариантности и устойчивости к деформациям.** Для диффеоморфизмов L_τ (деформаций, включая сдвиги) доказываются оценки в стиле Мала:

$$\|\Phi_n(L_\tau x) - \Phi_n(x)\| \leq (C_1 \|\nabla \tau\|_\infty + C_2 \|\tau\|_\infty) \|x\|.$$

Сдвигам соответствует $\nabla \tau = 0$, что приводит к инвариантности, контролируемой членом $C_2 \|\tau\|_\infty$.

2. **Сохранение информации.** Формулируются условия, при которых *субдискретизация* (downsampling) в операторах A_k не приводит к потере информации сигнала (инъективность представления по модулю группы инвариантности).
3. **Связь сложности, устойчивости и обобщения.** Если итоговый предиктор линейен в RKHS ($f(x) = \langle w, \Phi_n(x) \rangle_{\mathcal{H}_{K_n}}$), то, используя свойство воспроизведения и неравенство Коши–Буняковского:

$$|f(x) - f(x')| \leq \|f\|_{\mathcal{H}_{K_n}} \|\Phi_n(x) - \Phi_n(x')\|_{\mathcal{H}_{K_n}}.$$

Таким образом, *устойчивость предсказаний наследует устойчивость представления*, а норма $\|f\|_{\mathcal{H}_{K_n}}$ служит одновременно мерой сложности модели (регуляризатором) и контролем чувствительности.

9.6 Инвариантность и устойчивость в ядерном представлении

Следующим делом нам необходимо подробно разобраться в механизмах, с помощью которых свёрточные представления, смоделированные в рамках подхода Бьетти–Майраль, обеспечивают инвариантность к действию групп (например, сдвигов) и устойчивость к малым деформациям сигнала. Ключевую роль в этих механизмах играют операции *пулинга* (усреднения).

Пусть группа G действует на пространстве сигналов $\mathcal{X}$ с помощью операторов T_g .

Определение (Групповой пулинг (усреднение по орбите)). Для компактной группы G с вероятностной мерой Хаара μ определим оператор *группового пулинга* $A_G : \mathcal{H} \rightarrow \mathcal{H}$:

$$A_G(u) := \int_G \rho(g) u \, d\mu(g).$$

Оператор A_G является *линейным* и *в точности инвариантным*:

$$A_G(\rho(h)u) = A_G(u) \quad \forall h \in G, \forall u \in \mathcal{H}.$$

Ключевое следствие: Если признаковое отображение Φ является *эквивариантным*, то композиция $x \mapsto A_G(\Phi(x))$ будет *инвариантной* функцией. Таким образом, в рамках ядерного подхода [35] *инвариантность возникает как результат применения линейного оператора усреднения A_G к эквивариантному представлению*.

Пример (Глобальный пулинг для сдвигов). Рассмотрим сигнал на решётке $z: \mathbb{Z}^\nu \rightarrow \mathbb{R}^m$. Сдвиг на τ задаётся оператором $(R_\tau z)(\gamma) = z(\gamma - \tau)$. Простейший *глобальный пулинг* — это суммирование или усреднение по всему домену Ω :

$$A_{\text{global}}(z) := \sum_{\gamma \in \Omega} z(\gamma) \quad \text{или} \quad \frac{1}{|\Omega|} \sum_{\gamma \in \Omega} z(\gamma).$$

Если представление z является *сдвиго-эквивариантным*, то $A_{\text{global}}(z)$ будет *сдвиго-инвариантным* на выбранном домене Ω .

В реальных CNN пулинг является *локальным* (усреднение или максимум по окну $B \subset \mathbb{Z}^\nu$) и часто сопровождается *прореживанием (stride) s* :

$$(\text{Pool } z)(\gamma) := \text{pool}\{z(\gamma + \beta) : \beta \in B\}, \quad (\text{Down}_s z)(\gamma) := z(s\gamma).$$

Предложение 9.3 (Влияние пулинга и прореживания на эквивариантность). *Чистые свёртки сохраняют эквивариантность относительно сдвигов на исходной решётке. После операции прореживания с шагом s эквивариантность сохраняется, но относительно более coarse решётки: точными симметриями остаются только сдвиги, кратные s (подгруппа $s\mathbb{Z}^\nu$).*

Интуиция: Локальный пулинг даёт *приближённую (локальную) инвариантность*: малые сдвиги входа (меньшие, чем масштаб окна пулинга) приводят к малым изменениям в признаках, так как усреднение сглаживает высокочастотные компоненты. Точная инвариантность обычно требует *глобального агрегирования* (суммирования по всей пространственной области или орбите группы).

Для анализа устойчивости в работе [35] вводится модель малой деформации сигнала.

Определение (Оператор деформации). Пусть $x: \mathbb{R}^d \rightarrow \mathbb{R}^p$ — сигнал (изображение), а $\tau: \mathbb{R}^d \rightarrow \mathbb{R}^d$ — *поле малых смещений* (деформация). *Деформированный сигнал* определяется как:

$$(L_\tau x)(u) := x(u - \tau(u)) = x \circ (\text{Id} - \tau)(u).$$

Мерой “величины” деформации служит норма:

$$\|\tau\|_{\text{size}} := \|\tau\|_\infty + \|\nabla \tau\|_\infty,$$

где $\|\tau\|_\infty = \sup_u \|\tau(u)\|$, а $\|\nabla \tau\|_\infty = \sup_u \|\nabla \tau(u)\|_{\text{op}}$. Сдвиги являются частным случаем при $\tau(u) \equiv a$.

В рамках многоуровневой конструкции представления Φ_n (см. Раздел 9.5) целью является получение оценки, связывающей изменение представления с величиной деформации.

Определение (Липшицевость относительно деформаций). Для глубинного представления Φ_n и оператора деформации L_τ желательно получить оценку вида:

$$\|\Phi_n(x) - \Phi_n(L_\tau x)\|_{L^2(\mathbb{R}^d; \mathcal{H}_n)} \leq C \|\tau\|_{\text{size}} \|x\|_{L^2(\mathbb{R}^d)},$$

где константа C может зависеть от параметров сети (глубины n , ядер пулинга h_k), но не от конкретных x и τ .

Интерпретация: Малая деформация τ (малая как по величине смещения $\|\tau\|_\infty$, так и по его градиенту $\|\nabla\tau\|_\infty$) приводит к малому изменению глубинного представления. Это свойство *устойчивости* критически важно для надёжности модели на слегка искажённых данных (например, слегка повернутых или деформированных изображениях).

Роль операторов A_k : В конструкции Бьетти–Майраль [35] операторы A_k (усреднения/пулинга) являются *линейными* и, как правило, *неэкспансивными* (сжимающими). Это свойство позволяет провести анализ, показывая, что сжатие информации на каждом уровне через усреднение подавляет чувствительность к высокочастотным искажениям, таким как мелкомасштабные деформации.

9.7 Связь спектральной нормы и регуляризации

Данный раздел завершает связь между ядерным представлением свёрточных сетей и практическими методами их обучения. Мы покажем, как норма в RKHS, возникающая в конструкции Бьетти–Майраль [35], естественным образом приводит к *регуляризации спектральных норм весовых матриц* — широко используемой эвристике в глубоком обучении для обеспечения устойчивости и обобщения.

В рамках ядерного подхода [35] сложность CNN-предиктора естественно измеряется нормой в соответствующем RKHS.

Предложение 9.4 (Ограничение нормы CNN в RKHS [35]). *Пусть CNN-предиктор f_σ , построенный с гладкой однородной функцией активации σ , принадлежит RKHS $\mathcal{H}_{K_n}$ глубинного ядра K_n . Тогда существуют константы C_σ , зависящие от активации и ядра, такие что выполняется оценка вида:*

$$\|f_\sigma\|_{\mathcal{H}_{K_n}}^2 \leq \|w_{n+1}\|_2^2 C_\sigma^2 (\|W_n\|_2^2 C_\sigma^2 (\|W_{n-1}\|_2^2 \cdots C_\sigma^2 (\|W_1\|_F^2) \cdots)), \quad (35)$$

где

- w_{n+1} — веса выходного (линейного) слоя,
- W_k — матрица, кодирующая свёрточные фильтры k -го слоя,
- $\|\cdot\|_2$ — спектральная (операторная) норма,
- $\|\cdot\|_F$ — норма Фробениуса.

Интерпретация:

- Норма предиктора в RKHS ограничена *вложенным произведением спектральных норм весовых матриц* всех слоёв (с коррекцией C_σ на каждом шаге).
- В *линейном случае* ($C_\sigma^2(\lambda^2) = \lambda^2$) оценка (35) упрощается до:

$$\|f_\sigma\|_{\mathcal{H}_{K_n}} \lesssim \|w_{n+1}\|_2 \cdot \|W_n\|_2 \cdot \|W_{n-1}\|_2 \cdots \|W_1\|_F.$$

- Таким образом, контролируя спектральные нормы $\|W_k\|_2$ и норму Фробениуса $\|W_1\|_F$, мы контролируем и норму в RKHS $\|f_\sigma\|_{\mathcal{H}_{K_n}}$, которая является естественной мерой сложности модели в рамках ядерной теории.

Ограничение спектральных норм весовых матриц — распространённая практика в глубоком обучении. Ядерный подход Бьетти–Майраль даёт этому две взаимодополняющие теоретические интерпретации.

(А) Управление устойчивостью через контроль числа Липшица. Для композиции функций $f = F_n \circ \dots \circ F_1(x)$ (например, слоёв CNN с 1-липшицевыми активациями типа ReLU) выполняется:

$$\text{Lip}(f) \leq \prod_{k=1}^n \text{Lip}(F_k) \lesssim \prod_{k=1}^n \|W_k\|_2.$$

Следовательно, ограничение произведения спектральных норм $\prod_{k=1}^n \|W_k\|_2$ напрямую ограничивает константу Липшица всей сети:

$$\|f(x) - f(x')\| \leq \left(\prod_{k=1}^n \|W_k\|_2 \right) \|x - x'\|.$$

Практический смысл: Малые возмущения или деформации входа приводят к ограниченному изменению выхода, что повышает *устойчивость* (*robustness*) модели.

(В) Управление сложностью через норму в RKHS (ядро Бьетти–Майраль). Как показано в оценке (35), нормы $\|W_k\|_2$ (и $\|W_1\|_F$) входят в верхнюю границу для нормы предиктора в RKHS $\mathcal{H}_{K_n}$. В задачах обучения с регуляризацией минимизируется функционал вида:

$$\frac{1}{n} \sum_{i=1}^n \ell(y_i, f(x_i)) + \lambda \|f\|_{\mathcal{H}_{K_n}}^2.$$

Таким образом, ограничение спектральных норм является *естественным прокси* для ограничения RKHS-нормы, которая, в свою очередь, контролирует сложность модели и способствует *обобщению* (*generalization*).

Из всего вышесказанного можно сделать вывод: регуляризация спектральных норм — это не просто эвристика, а метод, имеющий строгое теоретическое обоснование в рамках ядерного подхода к CNN.

- **Способствует устойчивости:** Ограничивает расширение признаков (константу Липшица сети), делая предсказания менее чувствительными к малым возмущениям входных данных.
- **Согласуется с контролем сложности в RKHS:** Является практической реализацией ограничения нормы в гильбертовом пространстве, порождённом свёрточным ядром.
- **Поддерживает обобщающую способность:** Прямо следует из теории обобщения для kernel methods, где норма в RKHS фигурирует в классических оценках типа Радемахера.

Итог: В работе Бьетти–Майраль [35] устанавливается мост между *геометрическими свойствами представления* (инвариантность, устойчивость) и *сложностью модели* (регуляризация). Норма в RKHS становится единой мерой, связывающей эти аспекты: её ограничение одновременно способствует устойчивости представления (через оценку Липшица) и улучшает обобщение (через контроль capacity модели).

9.8 Информационная сохранность и субдискретизация

Теперь рассмотрим критический аспект проектирования многоуровневых представлений: компромисс между достижением инвариантности (через пулинг и субдискретизацию) и сохранением полезной информации из входного сигнала. В рамках подхода Бьетти–Майраль [35] анализируются условия, при которых субдискретизация не приводит к катастрофической потере информации.

В CNN операции пулинга (усреднения) и субдискретизации (downsampling) служат двум основным целям:

1. Увеличить *инвариантность* представления к малым пространственным сдвигам.
2. Уменьшить пространственное разрешение и, следовательно, вычислительную сложность последующих слоёв.

Однако существует фундаментальный *компромисс*:

- **Агрессивный пулинг / сильная субдискретизация:** Обеспечивает высокую степень инвариантности, но может привести к *неинъективности (aliasing)* — различным входным сигналам будет соответствовать одно и то же представление, то есть информация будет безвозвратно потеряна.
- **Слабый пулинг / сохранение разрешения:** Сохраняет детальную пространственную информацию, но обеспечивает меньшую инвариантность и вычислительную эффективность.

Ключевой вопрос, исследуемый в [35]: *Можно ли добиться одновременно устойчивости (инвариантности) к преобразованиям и сохранения информации?*

Напомним общую схему построения представления [35]:

$$x_0 := x, \quad x_k := A_k M_k P_k x_{k-1}, \quad k = 1, \dots, n,$$

где P_k извлекает патчи, M_k — ядерная нелинейность, а A_k — оператор усреднения (пулинг), за которым часто следует *субдискретизация (downsampling)*.

Декомпозиция A_k : Оператор A_k можно представить как композицию $A_k \approx D_k \circ S_k$, где:

- S_k — *локальное усреднение (сглаживание)* с ядром h_k (низкочастотный фильтр, антиалиасинг).
- D_k — собственно *операция субдискретизации* (децимация) с заданным шагом (stride).

Когда субдискретизация приводит к потере информации? Она теряется безвозвратно (происходит *алиасинг*), когда:

1. **Нарушение условия Найквиста:** Высокочастотные компоненты в признаковой карте $M_k P_k x_{k-1}$ имеют частоту выше *половины частоты дискретизации*, задаваемой шагом D_k .
2. **Слишком большой шаг (stride):** Шаг субдискретизации значительно превышает *корреляционную длину* признаков (масштаб, на котором признаки существенно изменяются).

3. **Отсутствие избыточности:** Патчи, извлекаемые оператором P_k , почти не перекрываются, и потерянные при субдискретизации координаты не могут быть восстановлены из соседних.

Субдискретизация не приводит к существенной потере информации (с точностью до предполагаемых инвариантностей), если выполняются следующие условия, вытекающие из анализа в [35]:

1. **Предварительное сглаживание (Антиалиасинг):** Оператор S_k (часть A_k) должен эффективно *ограничивать полосу частот* признаковой карты $M_k P_k x_{k-1}$, делая её *приблизительно ограниченной по спектру (band-limited)* на масштабе, соответствующем шагу дискретизации D_k .
2. **Согласование шага и полосы:** Шаг субдискретизации D_k должен быть *согласован с эффективной шириной полосы* сглаженного сигнала (интуиция Найквиста-Шеннона).
3. **Избыточность через перекрытие патчей:** Оператор P_k должен извлекать патчи с *большим перекрытием*, обеспечивая избыточность в представлении, которая позволяет восстановить информацию, усреднённую на этапе S_k .
4. **Выразительность признакового отображения:** Ядерное отображение M_k (и всё последующее представление) должно быть достаточно выразительным, чтобы *различать различные локальные патчи*, даже после усреднения.

В работе Бьетти–Майраль «сохранение информации» формализуется через свойство *инъективности по модулю группы инвариантности*.

Определение (Инъективность по модулю группы). Пусть G — группа преобразований (например, сдвигов). Представление Φ называется *инъективным по модулю G* , если для любых входных сигналов x, x' выполняется:

$$\Phi(x) = \Phi(x') \quad \text{тогда и только тогда, когда} \quad x' = T_g x \text{ для некоторого } g \in G.$$

Эквивалентно: $\|\Phi(x) - \Phi(x')\|$ мало тогда и только тогда, когда x и x' близки с точностью до действия группы G .

Итог: В успешно спроектированной многоуровневой архитектуре, следующей принципам [35], операция $A_k = D_k \circ S_k$ работает как *координатное преобразование*, которое:

- 1) *Сглаживает* данные для подавления чувствительности к высокочастотным искажениям (деформациям),
- 2) *Дискретизирует* с подходящей частотой, сохраняя низкочастотную (смысловую) информацию,
- 3) В идеале сохраняет свойство *инъективности по модулю группы инвариантности*, то есть разные входы (не эквивалентные относительно G) отображаются в разные представления.

Таким образом, пулинг и субдискретизация в такой модели — не просто механическое уменьшение размерности, а часть стратегии построения *устойчивого, инвариантного, но при этом информативного* представления сигнала.

Список литературы

- [1] G. Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals, and Systems*, 2:303–314, 12 1989.
- [2] K. Hornik. Approximation capabilities of multilayer feedforward networks. *Neural Networks*, 4(2):251–257, January 1991.
- [3] K. Hornik, M. Stinchcombe, and H. White. Universal approximation of an unknown mapping and its derivatives using multilayer feedforward networks. *Neural Networks*, 3(5):551–560, January 1990.
- [4] T. Chen and H. Chen. Universal approximation to nonlinear operators by neural networks with arbitrary activation functions and its application to dynamical systems. *IEEE Transactions on Neural Networks*, 6(4):911–917, 1995.
- [5] T. Chen and H. Chen. Approximations of continuous functionals by neural networks with application to dynamic systems. *IEEE Transactions on Neural Networks*, 4(6):910–918, 1993.
- [6] T. Chen and H. Chen. Approximation capability to functions of several variables, nonlinear functionals and operators by radial basis function neural networks. volume 6, pages 1439–1442, Piscataway, 11 1993. IEEE.
- [7] K. S. Narendra and K. Parthasarathy. Identification and control of dynamical systems using neural networks. *IEEE Transactions on Neural Networks*, 1(1):4–27, 1990.
- [8] H. N. Mhaskar and N. Hahm. Neural Networks for Functional Approximation and System Identification. *Neural Computation*, 9(1):143–159, 1997.
- [9] F. Rossi and B. Conan-Guez. Functional Multi-Layer Perceptron: a Nonlinear Tool for Functional Data Analysis. *Neural networks*, 18:45–60, February 2005.
- [10] M. B. Stinchcombe. Neural network approximation of continuous functionals and continuous functions on compactifications. *Neural Networks*, 12(3):467–477, April 1999.
- [11] J. O. Ramsay and B. W. Silverman. *Functional Data Analysis*. Springer New York, 2005.
- [12] L. Lu, P. Jin, G. Pang, Z. Zhang, and G. E. Karniadakis. Learning nonlinear operators via DeepONet based on the universal approximation theorem of operators. *Nature Machine Intelligence*, 3(3):218–229, March 2021.
- [13] M. Telgarsky. Benefits of depth in neural networks. *arXiv*, 2016.
- [14] B. Hanin. Universal Function Approximation by Deep Neural Nets with Bounded Width and ReLU Activations. *Mathematics*, 7(10):992, October 2019.
- [15] S. Lanthaler, S. Mishra, and G. E. Karniadakis. Error estimates for DeepOnets: A deep learning framework in infinite dimensions. *arXiv*, 2021.
- [16] Q. Li, T. Lin, and Z. Shen. Deep learning via dynamical systems: An approximation perspective. *J. Eur. Math. Soc.*, 25:1671–1709, 2023.
- [17] J. Warga. Relaxed variational problems. *J. Math. Anal. Appl.*, 4:111–128, 1962.

- [18] Y. Brenier and W. Gangbo. L^p approximation of maps by diffeomorphisms. *Calc. Var. Partial Differential Equations*, 16:147–164, 2003.
- [19] R. A. DeVore. Nonlinear approximation. In *Acta Numerica 1998*, volume 7, pages 51–150. Cambridge University Press, 1998.
- [20] I. Daubechies. *Ten Lectures on Wavelets*, volume 61 of *CBMS-NSF Regional Conference Series in Applied Mathematics*. SIAM, Philadelphia, PA, 1992.
- [21] S. Mallat. *A Wavelet Tour of Signal Processing*. Academic Press, San Diego, CA, 2nd edition, 1998.
- [22] H. Sussmann. *Nonlinear Controllability and Optimal Control*. CRC Press, 1990.
- [23] K. Balachandran and J. P. Dauer. Controllability of nonlinear systems in Banach spaces: a survey. *J. Optim. Theory Appl.*, 115:7–28, 2002.
- [24] E. N. Chukwu and S. M. Lenhart. Controllability questions for nonlinear systems in abstract spaces. *J. Optim. Theory Appl.*, 68:437–462, 1991.
- [25] M. Fort and Jr. K. The embedding of homeomorphisms in flows. *Proc. Amer. Math. Soc.*, 6:960–967, 1955.
- [26] W. R. Utz. The embedding of homeomorphisms in continuous flows. *Topology Proc.*, 6:159–177, 1981.
- [27] X. Zhang. Embedding diffeomorphisms in flows in banach spaces. *Ergodic Theory Dynam. Systems*, 29(4):1349–1367, 2009.
- [28] W. E, J. Han, and Q. Li. A mean-field optimal control formulation of deep learning. *Research in the Mathematical Sciences*, 6(1):10, December 2018.
- [29] Q. Li, L. Chen, C. Tai, and W. E. Maximum principle based algorithms for deep learning. *J. Mach. Learn. Res.*, 18(1):165, 2017.
- [30] D. Yarotsky. Universal approximations of invariant maps by neural networks. *arXiv*, April 2018.
- [31] Ding-Xuan Zhou. Universality of Deep Convolutional Neural Networks. *arXiv*, July 2018.
- [32] R. DeVore and G. Lorentz. *Constructive Approximation*. Springer, Berlin, 1993.
- [33] Q. Li, T. Lin, and Z. Shen. On the universal approximation property of deep fully convolutional neural networks. *arXiv*, May 2023.
- [34] D. X. Zhou. Deep distributed convolutional neural networks: Universality. *arXiv*, 2018.
- [35] A. Bietti and J. Mairal. Group Invariance, Stability to Deformations, and Complexity of Deep Convolutional Representations. *arXiv*, 2018.